

UNIVERSIDADE FEDERAL DA BAHIA

PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO

PAULO ROBERTO ARAÚJO DA SILVA

Tese de Doutorado

FUSÃO DE INFORMAÇÃO E APRENDIZADO DE MÁQUINA PARA CALIBRAÇÃO DA ENERGIA TRANSVERSAL DE ELÉTRONS EM CALORÍMETROS SEGMENTADOS

Salvador

Novembro, 2026

PAULO ROBERTO ARAÚJO DA SILVA

FUSÃO DE INFORMAÇÃO E APRENDIZADO DE MÁQUINA PARA CALIBRAÇÃO DA ENERGIA TRANSVERSAL DE ELÉTRONS EM CALORÍMETROS SEGMENTADOS

Tese de Doutorado

TESE DE DOUTORADO SUBMETIDA AO CORPO DOCENTE DO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO DA UNIVERSIDADE FEDERAL DA BAHIA (PPGEEC / UFBA) COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE DOUTOR EM ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO.

Orientador: Prof. D.Sc. Eduardo Furtado Simas Filho - UFBA

Salvador

Novembro, 2026

Paulo Roberto Araújo da Silva

Fusão de Informação e Aprendizado de Máquina para Calibração da Energia Transversal de Elétrons em Calorímetros Segmentados

TESE DE DOUTORADO SUBMETIDA AO CORPO DOCENTE DO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO DA UNIVERSIDADE FEDERAL DA BAHIA (PPGEEC / UFBA) COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE DOUTOR EM ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO.

Prof. D.Sc. Eduardo Furtado de Simas Filho
UFBA
Orientador

Prof. D.Sc. Antônio Carlos Lopes Fernandes Júnior
UFBA

Prof. D.Sc. Denis Oliveira Damazio
Brookhaven National Laboratory, EUA

Prof. D.Sc. Lucas Cruz da Silva
CIMATEC

Prof. D.Sc. Gustavo Barbosa Libotte
UERJ

Salvador

Novembro, 2026

Dedico este trabalho à minha família.

Agradecimentos

Agradeço à minha família pelo apoio constante, ao Professor Eduardo Simas pela orientação dedicada e aos colegas e professores da UFBA pelo aprendizado e incentivo ao longo da caminhada.

Aprendizado de máquina é a ciência (e arte) de programar computadores para que eles possam aprender a partir dos dados. (GÉRON, 2019)

Resumo

Esta tese propõe e avalia uma metodologia de **fusão de informação e aprendizado de máquina** para a calibração evento a evento da estimativa rápida da energia transversal de elétrons em calorímetros segmentados, denominada *Standard FastCalo* no *benchmark* adotado. A abordagem explora a informação espacial dos chuveiros eletromagnéticos codificada em 100 anéis calorimétricos e estima um fator multiplicativo aplicado à energia reconstruída rapidamente. A avaliação utiliza aproximadamente 3×10^5 eventos simulados no *Lorenzetti Showers Framework*, em uma configuração calorimétrica inspirada no experimento ATLAS do *Large Hadron Collider*. A investigação é desenvolvida em três etapas progressivas. A primeira compara regressões convencionais e modelos baseados em árvores com a representação completa e representações compactas obtidas por correlação, informação mútua, PCA e ICA. A segunda amplia a modelagem com *Random Forests*, aprendizado residual e modelos empilhados. A terceira avalia redes neurais profundas e propõe uma arquitetura relacional–tabular baseada em rede neural em grafos, concebida para combinar relações locais, organização regional dos anéis e informação tabular. Nas três etapas, os dados são divididos em 70% para desenvolvimento e 30% para teste independente. A Etapa I preserva o protocolo documentado no estudo original; nas Etapas II e III, a seleção de hiperparâmetros em desenvolvimento utiliza validação cruzada aninhada 5×5, com os *folds* internos destinados à seleção e os externos à avaliação interna do procedimento. Os resultados sustentam, no domínio do *benchmark*, a hipótese de que a distribuição estruturada dos depósitos de energia contém informação capaz de melhorar a estimativa rápida. Na Etapa III, a arquitetura relacional–tabular com os 100 anéis apresentou os menores valores de RMSE e d_0 e a melhor resolução relativa entre as configurações avaliadas nessa etapa; em relação ao *Standard FastCalo* da própria etapa, reduziu o RMSE em 65,25%, o IQR em 42,82% e melhorou a resolução relativa de energia em 51,46%. Representações compactas com cinco ou dez entradas também preservaram reduções de RMSE superiores a 50% em diferentes etapas. As principais contribuições são a formulação integrada da calibração baseada em informação calorimétrica estruturada, a caracterização sistemática do compromisso entre compactação e desempenho, a avaliação de aprendizado residual e combinação de modelos, a extensão para fusão neural e a proposição da arquitetura relacional–tabular para a representação em anéis. Os resultados estabelecem uma fronteira desempenho–complexidade e uma base metodológica para validações futuras em condições mais próximas do experimento real.

Palavras-chave: calibração calorimétrica; aprendizado de máquina; física de altas energias; fusão de informação; calorímetros segmentados.

Abstract

This thesis proposes and evaluates an **information fusion and machine learning** methodology for event-by-event calibration of the fast transverse-energy estimate of electrons in segmented calorimeters, referred to as *Standard FastCalo* in the adopted *benchmark*. The approach exploits the spatial information of electromagnetic showers encoded in 100 calorimeter rings and estimates a multiplicative factor applied to the rapidly reconstructed energy. The evaluation uses approximately 3×10^5 simulated events from the *Lorenzetti Showers Framework* in a calorimeter configuration inspired by the ATLAS experiment at the *Large Hadron Collider*. The investigation is developed in three progressive stages. The first compares conventional regression methods and tree-based models using the full representation and compact representations obtained through correlation, mutual information, PCA, and ICA. The second extends the modeling to *Random Forests*, residual learning, and stacked models. The third evaluates deep neural networks and proposes a relational–tabular graph-neural-network architecture designed to combine local relationships, regional organization of the rings, and tabular information. In all three stages, the data are divided into 70% for development and 30% for independent testing. Stage I preserves the protocol documented in the original study; in Stages II and III, hyperparameter selection within the development partition uses 5×5 nested cross-validation, with the inner folds devoted to selection and the outer folds to internal evaluation of the procedure. Within the *benchmark* domain, the results support the hypothesis that the structured distribution of energy deposits contains information capable of improving the fast energy estimate. In Stage III, the relational–tabular architecture using all 100 rings achieved the lowest RMSE and d_0 and the best relative energy resolution among the configurations evaluated in that stage; relative to the Stage III *Standard FastCalo* baseline, it reduced RMSE by 65.25%, IQR by 42.82%, and improved relative energy resolution by 51.46%. Compact representations with five or ten inputs also retained RMSE reductions above 50% across different stages. The main contributions are the integrated formulation of calibration based on structured calorimeter information, the systematic characterization of the compactness–performance trade-off, the evaluation of residual learning and model combination, the extension to neural information fusion, and the proposal of the relational–tabular architecture for the ring representation. The results establish a performance–complexity frontier and a methodological basis for future validation under conditions closer to the real experiment.

Keywords: calorimeter calibration; machine learning; high-energy physics; information fusion; segmented calorimeters.

Lista de ilustrações

Figura 1 – Modelo Padrão da Física de Partículas. Fonte: (ARBUZOV, 2017). 44
Figura 2 – Representação gráfica da instalação subterrânea do LHC no CERN e de alguns experimentos localizados em pontos de colisão. Fonte: (EVANS; BRYANT, 2008). 45
Figura 3 – Representação gráfica do detector ATLAS e de seus principais subsistemas. Fonte: (ATLAS Collaboration, 2008). 46
Figura 4 – Sistema de coordenadas empregado no experimento ATLAS. Fonte: (SIMAS FILHO, 2010). 47
Figura 5 – Representação esquemática do desenvolvimento e da detecção de diferentes tipos de partículas nos subsistemas do detector. Fonte: (PEQUENAO; SCHAFFNER, 2013). 48
Figura 6 – Representação gráfica da composição do sistema de calorimetria do ATLAS. Fonte: (ATLAS Collaboration, 2008). 48
Figura 7 – Representação das camadas do calorímetro eletromagnético e da geometria em acordeão. Fonte: (GABALDóN; on behalf of the ATLAS LAr Collaboration, 2009). 49
Figura 8 – Representação gráfica de um módulo do TileCal. Fonte: (ATLAS Collaboration, 2018). 50
Figura 9 – Representação gráfica simplificada do fluxo do sistema TDAQ do ATLAS na Run 3. Fonte: (ATLAS Collaboration, 2024b). 55
Figura 10 – Representação simplificada da sequência de processamento do HLT para candidatos a elétrons, destacando as etapas rápida e de precisão. A implementação evoluiu entre as Runs 2 e 3. Fontes: (ATLAS Collaboration, 2020; ORELLANA; ATLAS Collaboration, 2021). 56
Figura 11 – Representação gráfica do conceito de reconstrução em anéis. As células calorimétricas são agregadas em anéis em diferentes camadas, preservando informação espacial do chuveiro em uma representação ordenada. Fonte: (PINTO; ATLAS Collaboration, 2016). 57
Figura 12 – Eficiência de *triggers* de elétrons utilizando o algoritmo Ringer e a seleção calorimétrica baseada em cortes, avaliada em função de E_T, η e *pile-up*. A comparação ilustra o uso histórico da representação Ringer para identificação online de elétrons no ATLAS e não corresponde ao problema de regressão de energia investigado nesta tese. Fonte: (ATLAS Collaboration, 2020). 59
Figura 13 – Representações conceituais de uma unidade neural e de uma rede multicamadas. Fonte: adaptado de (HAYKIN, 2009). 105
Figura 14 – Representação esquemática da arquitetura GNN relacional–tabular proposta para a calibração evento a evento da energia transversa. 111

Figura 15 – Fluxo metodológico unificado da calibração calorimétrica. Os blocos seguem a ordem operacional do processo experimental e sintetizam a função principal, as entradas e as saídas de cada etapa. As referências de seção indicam onde cada componente é formalizado. 129
Figura 16 – Vista transversal do calorímetro de amostragem utilizado nas simulações com o *Lorenzetti Showers Framework*. A amostra de elétrons utilizada nesta tese foi restrita a $|\eta| \leq 1{,}46$, alcançando, no limite superior, a vizinhança da transição pelo lado do barril da geometria inspirada no ATLAS. 130
Figura 17 – Distribuição do parâmetro médio de pile-up ($\langle\mu\rangle$) no conjunto de dados simulado com o Lorenzetti utilizado neste trabalho. A distribuição contém 10.010 entradas do perfil de pile-up, com média ($\langle\mu\rangle = 38{,}94$) e desvio padrão (9,999), indicando que o benchmark de calibração inclui um nível substancial de atividade adicional de colisões. Fonte: (SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026). 132
Figura 18 – Fluxo da validação cruzada aninhada utilizada para seleção de hiperparâmetros nas Etapas II e III. Para cada *fold* externo, a busca interna realiza uma triagem inicial das configurações candidatas, forma uma *shortlist*, avalia as configurações retidas nos cinco *folds* internos e seleciona uma configuração de hiperparâmetros. O modelo correspondente é reajustado no conjunto de treinamento externo e avaliado no respectivo conjunto de validação externa. Ao final dos cinco *folds* externos, a configuração final é definida pela moda das cinco configurações selecionadas, sendo então utilizada para o treinamento definitivo em $\mathcal{D}_{70}$ e para a avaliação independente em $\mathcal{D}_{30}$. 138
Figura 19 – Caracterização da resposta rápida no *benchmark* da Etapa I: (a) distribuições de E_{true} e E_{fast} no intervalo estudado; (b) relação evento a evento entre as duas grandezas. Observa-se dispersão da resposta e uma alteração mais pronunciada na região de aproximadamente 250 GeV, compondo o cenário de calibração avaliado pelos modelos. Adaptado de (SILVA et al., 2026b). 154
Figura 20 – Mapa de relevância das variáveis ou componentes empregado na Etapa I para CORR, MUTI, PCA e ICA. As fronteiras entre regiões calorimétricas têm interpretação física somente para CORR e MUTI, que atuam sobre os anéis originais. Componentes PCA e ICA são combinações transformadas e não possuem correspondência um a um com as posições dos anéis. Adaptado de (SILVA et al., 2026b). 155
Figura 21 – Distribuições do erro de calibração e boxplots para combinações representativas de regressão e redução de dimensionalidade na Etapa I: (a) correlação; (b) informação mútua; (c) PCA; (d) ICA. O ponto indicado nos gráficos originais representa o RMSE, enquanto a largura da caixa corresponde ao IQR. Adaptado de (SILVA et al., 2026b). 157
Figura 22 – IQR do fator de calibração nas regiões de (a) pseudorapidez e (b) energia transversa utilizadas na Etapa I. A referência relativa do *Standard FastCalo* é fixada em unidade nos painéis normalizados. Adaptado de (SILVA et al., 2026b). 159

Figura 23 – MAE e RMSE do fator estimado α_{calib} em relação a α_{true} nas regiões de (a) $|\eta|$ e (b) E_T. Adaptado de (SILVA et al., 2026b). 159
Figura 24 – Compromissos entre qualidade de calibração, dimensionalidade e tempo de predição medidos na Etapa I. O índice D_0 deve ser interpretado apenas como critério de ordenação normalizado dentro do conjunto comparado, e não como grandeza física ou requisito universal de implantação. Adaptado de (SILVA et al., 2026b). 161
Figura 25 – Gráficos Q–Q representativos para os resíduos da referência e da configuração `BDT no-Bin: PCA-10`. Os desvios nas caudas justificam o uso complementar de inferência não paramétrica e *bootstrap*. Adaptado de (SILVA et al., 2026b). 162
Figura 26 – Distribuições do erro de calibração $E_{\text{true}} - E_{\text{calib}}$ e boxplots correspondentes para as representações (a) CORR, (b) MUTI, (c) PCA e (d) ICA na Etapa II. Nos boxplots, a largura da caixa representa o IQR e o marcador preto indica o RMSE. Adaptado de (SILVA et al., 2026a). 167
Figura 27 – Comparação das configurações mais bem classificadas segundo d_0 e D_0. Os painéis superiores apresentam os rankings e os painéis inferiores as distribuições do erro das configurações correspondentes. Adaptado de (SILVA et al., 2026a). 169
Figura 28 – IQR do fator de calibração para as configurações selecionadas, avaliado *a posteriori* em regiões de (a) $|\eta|$ e (b) E_T. Os modelos foram treinados globalmente; os bins são utilizados apenas como diagnóstico de estabilidade. Adaptado de (SILVA et al., 2026a). 170
Figura 29 – MAE e RMSE do fator estimado α_{calib} em relação a α_{true} nas regiões de (a) $|\eta|$ e (b) E_T. Adaptado de (SILVA et al., 2026a). 171
Figura 30 – Distribuições de α_{calib} para as configurações selecionadas nas regiões de (a) $|\eta|$ e (b) E_T. A largura das caixas representa o IQR e as linhas verticais tracejadas indicam as fronteiras dos bins. Adaptado de (SILVA et al., 2026a). 171
Figura 31 – Resolução relativa de energia σ_E/E em função de E_{true} para *Standard FastCalo* e para as quatro configurações selecionadas na Etapa II. Adaptado de (SILVA et al., 2026a). 172
Figura 32 – Curvas de aceitação da Etapa II para (a) o RFBDT com 100 anéis e (b) o BDT com ICA-5, ambas comparadas ao Standard FastCalo. As curvas apresentam a taxa de aceitação em função de $\Delta\lambda$ segundo a convenção definida na Seção 5.11. Adaptado de (SILVA et al., 2026a). 173
Figura 33 – energia transversa calibrada em função de E_{true} para duas configurações representativas da Etapa II, comparadas ao Standard FastCalo. A linha diagonal tracejada representa a resposta ideal $E_{\text{calib}} = E_{\text{true}}$. Adaptado de (SILVA et al., 2026a). 174
Figura 34 – Gráficos Q–Q representativos para os resíduos do *Standard FastCalo* e de duas configurações da Etapa II. Os desvios nas caudas justificam o uso complementar de inferência não paramétrica e *bootstrap*. Adaptado de (SILVA et al., 2026a). 175

Figura 35 – Distribuições do erro $E_{\text{true}} - E_{\text{calib}}$ e boxplots correspondentes para as representações (a) CORR, (b) MUTI, (c) PCA e (d) ICA na Etapa III. Os gráficos preservam as referências não neurais avaliadas no mesmo *benchmark*, permitindo contextualizar o desempenho das DNNs. Nos boxplots, a caixa representa o IQR e o marcador preto indica o RMSE. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 179
Figura 36 – Comparação das configurações da Etapa III segundo d_0 e D_0: (a) dez melhores configurações por d_0; (b) dez melhores por D_0; (c) distribuições de erro associadas ao ranking por d_0; (d) distribuições associadas ao ranking por D_0. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 181
Figura 37 – Síntese dos ganhos relativos das configurações representativas da Etapa III em RMSE, IQR, resolução relativa de energia e deslocamento associado à resposta a limiar. Valores maiores representam maior melhoria em relação ao Standard FastCalo. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 183
Figura 38 – Compromisso entre qualidade da calibração e custo de predição para configurações representativas da Etapa III. O eixo vertical apresenta d_0, o eixo horizontal apresenta o tempo de predição amortizado em CPU e o tamanho dos marcadores representa a dimensionalidade externa F. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 183
Figura 39 – IQR do fator de calibração nas regiões de (a) $|\eta|$ e (b) E_T para as configurações selecionadas da Etapa III. Os painéis relativos utilizam *Standard FastCalo* como referência unitária. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 184
Figura 40 – MAE e RMSE do fator previsto α_{calib} em relação a α_{true} nos bins de (a) $|\eta|$ e (b) E_T. A referência de erro nulo representa $\alpha_{\text{calib}} = \alpha_{\text{true}}$. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 185
Figura 41 – Distribuição de α_{calib} para as configurações selecionadas nos bins de (a) $|\eta|$ e (b) E_T. A largura das caixas representa o IQR. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 185
Figura 42 – Resolução relativa de energia σ_E/E em função de E_{true} para *Standard FastCalo* e as quatro configurações neurais selecionadas na Etapa III. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 186
Figura 43 – Curvas de aceitação para (a) GNN com os 100 anéis e (b) DNN com ICA-10, ambas comparadas ao Standard FastCalo. As linhas e marcadores indicam pontos de operação representativos utilizados para quantificar a aceitação em função de $\Delta\lambda$. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). . 187
Figura 44 – energia transversa calibrada em função de E_{true} para duas configurações representativas da Etapa III, comparadas ao Standard FastCalo. A linha diagonal tracejada representa a resposta ideal $E_{\text{calib}} = E_{\text{true}}$. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 188

Figura 45 – Gráficos Q–Q representativos para os resíduos do Standard FastCalo, da GNN completa e da DNN CORR-10. Os desvios nas caudas sustentam o uso complementar de inferência não paramétrica e *bootstrap*. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026). 188

Lista de tabelas

Tabela 1 – Região de cobertura em η, granularidade das células e camadas do sistema calorimétrico do ATLAS. Fonte: (ATLAS Collaboration, 2008). 51
Tabela 2 – Quantidade de anéis por camada na representação Ringer de 100 componentes. Fontes: (ATLAS Collaboration, 2020; PINTO; ATLAS Collaboration, 2016). 58
Tabela 3 – Síntese das famílias de regressão utilizadas na tese e dos principais vieses indutivos relevantes para o problema de calibração. 125
Tabela 4 – Segmentação, cobertura em $|\eta|$ e granularidade das células da configuração calorimétrica utilizada no *benchmark* Lorenzetti. 130
Tabela 5 – Evolução do desenho experimental ao longo da tese. 135
Tabela 6 – Representações avaliadas na Etapa I. Para CORR e MUTI, os índices referem-se aos anéis originais. Para PCA e ICA, indicam componentes transformados. 155
Tabela 7 – Desempenho global das configurações de maior destaque da Etapa I no conjunto de teste independente. As porcentagens correspondem à redução relativa ao *Standard FastCalo* da mesma etapa. Excluindo o *Standard FastCalo* os valores estão ordenados Δd_0 de forma decrescente. 158
Tabela 8 – Configurações compactas destacadas pelo compromisso de engenharia na Etapa I. T é o tempo de predição medido no ambiente computacional do estudo e não a latência de ponta a ponta de um sistema de *trigger*. 160
Tabela 9 – Inferência pareada para o deslocamento do resíduo na Etapa I. Os intervalos são unilaterais de 95%. "Rejeita" significa rejeição de H_0 no nível de significância adotado. 163
Tabela 10 – Comparação da variância dos resíduos na Etapa I. A razão é $R_{\sigma^2} = \sigma^2_{\text{calib}}/\sigma^2_{\text{fast}}$; valores inferiores a 1 indicam menor variância após calibração. 163
Tabela 11 – Representações avaliadas na Etapa II. Para CORR e MUTI, m corresponde ao número de anéis originais retidos; para PCA e ICA, corresponde ao número de componentes transformados. 166
Tabela 12 – Desempenho das quatro configurações representativas da Etapa II. As porcentagens são reduções relativas ao *Standard FastCalo* da mesma etapa. T é o tempo médio amortizado de predição por evento reportado na publicação. . . 170
Tabela 13 – Resolução relativa de energia das configurações selecionadas na Etapa II. As porcentagens correspondem à melhoria relativa ao *Standard FastCalo* no mesmo conjunto de teste. 172
Tabela 14 – Resposta a limiar das configurações selecionadas na Etapa II. $\Delta\lambda_{90}$ representa o valor necessário para atingir 90% de aceitação na convenção definida na Seção 5.11. 173
Tabela 15 – Inferência pareada para o deslocamento do resíduo na Etapa II. Os intervalos para μ_d são unilaterais de 95%. 175
Tabela 16 – Comparação da variância dos resíduos na Etapa II. Valores de $R_{\sigma^2} < 1$ indicam menor variância após calibração. 175

Tabela 17 – Desempenho das quatro configurações neurais representativas da Etapa III. F é a dimensionalidade externa de entrada; T é o tempo amortizado de predição medido no *benchmark* CPU. 180
Tabela 18 – Resumo da resolução relativa de energia para as configurações selecionadas da Etapa III. 186
Tabela 19 – Resposta a limiar das configurações selecionadas da Etapa III. $\Delta\lambda_{90}$ representa o valor necessário para atingir 90% de aceitação na convenção definida na Seção 5.11. 187
Tabela 20 – Inferência pareada para o deslocamento do resíduo na Etapa III. Os intervalos para μ_d são unilaterais de 95%. 189
Tabela 21 – Comparação da variância dos resíduos na Etapa III. Valores de $R_{\sigma^2} < 1$ indicam menor variância após calibração. 189
Tabela 22 – Evolução das configurações representativas de melhor desempenho em cada etapa. As porcentagens correspondem a reduções relativas ao *Standard FastCalo* da própria etapa. A Etapa I utiliza o protocolo descrito no Capítulo 5; por isso, os valores devem ser comparados entre etapas principalmente por suas reduções relativas, e não como uma ablação controlada de arquitetura. 193
Tabela 23 – Configurações compactas representativas ao longo da tese. As porcentagens são reduções relativas ao *Standard FastCalo* da própria etapa. 194
Tabela 24 – Verificação dos objetivos específicos da tese. 198
Tabela 25 – Alcance das principais conclusões da tese. 201
Tabela 26 – Mapeamento entre famílias de modelos e implementações computacionais utilizadas. 211
Tabela 27 – Espaços consolidados de hiperparâmetros para os regressores da Etapa I. . . 212
Tabela 28 – Espaços consolidados de busca para as principais famílias da Etapa II. 213
Tabela 29 – Valores selecionados nas configurações finais arquivadas para modelos representativos da Etapa II. Os demais parâmetros permanecem nos valores fixos da Tabela 28. 213
Tabela 30 – Espaço de busca e hiperparâmetros selecionados para as DNNs representativas da Etapa III. 214
Tabela 31 – Espaço final de refinamento e configuração selecionada para GNN no-Bin: Rings[1:100] na Etapa III. 214

Lista de abreviaturas e siglas

AdamW	Variante do otimizador Adam com *weight decay* desacoplado.
ALICE	*A Large Ion Collider Experiment*.
ATLAS	*A Toroidal LHC ApparatuS*.
BCa	*Bias-Corrected and Accelerated*; intervalo de confiança bootstrap corrigido por viés e aceleração.
BDT	*Boosted Decision Tree*.
BDTRF	Modelo híbrido de correção residual com BDT no primeiro estágio e Random Forest no segundo.
CERN	Organização Europeia para a Pesquisa Nuclear (*European Organization for Nuclear Research*).
CMS	*Compact Muon Solenoid*.
CNN	*Convolutional Neural Network*; rede neural convolucional.
CORR	Seleção de características baseada na correlação de Pearson.
CPU	*Central Processing Unit*.
CV	*Cross-Validation*; validação cruzada.
DDR4	*Double Data Rate 4*; geração de memória DDR utilizada na plataforma computacional.
DNN	*Deep Neural Network*; rede neural profunda.
DTree	*Decision Tree*; árvore de decisão.
EAR	*Event Acceptance Rate*; taxa de aceitação de eventos.
eFEX	*electron Feature Extractor*; processador FEX do primeiro nível orientado à formação de objetos eletromagnéticos e taus.
EM	Região ou calorimetria eletromagnética.
EM1–EM3	Primeira, segunda e terceira camadas/amostragens do calorímetro eletromagnético.
EMB	*Electromagnetic Barrel*; calorímetro eletromagnético de barril do ATLAS.
EMEC	*Electromagnetic Endcap Calorimeter*; calorímetro eletromagnético de tampa do ATLAS.

FCal *Forward Calorimeter*; calorímetro frontal do ATLAS.

FEX *Feature Extractor*; família de processadores de extração de características do primeiro nível de trigger.

FLOPs *Floating-Point Operations*; operações de ponto flutuante.

FPGA *Field-Programmable Gate Array*; dispositivo lógico programável utilizado em processamento de baixa latência.

FSR *Final-State Radiation*; radiação no estado final.

GA *Genetic Algorithm*; algoritmo genético.

GAT *Graph Attention Network*; rede neural em grafos baseada em atenção.

GCN *Graph Convolutional Network*; rede convolucional em grafos.

GEANT4 *Geometry and Tracking*; conjunto de ferramentas para simulação do transporte e das interações de partículas na matéria.

GELU *Gaussian Error Linear Unit*.

gFEX *global Feature Extractor*; processador FEX do primeiro nível orientado a objetos e grandezas globais.

GNN *Graph Neural Network*; rede neural em grafos.

GPU *Graphics Processing Unit*.

GSC *Global Sequential Calibration*.

HAD Região hadrônica da representação calorimétrica.

HAD1–HAD3 Primeira, segunda e terceira camadas/amostragens hadrônicas utilizadas na representação Ringer.

HEC *Hadronic Endcap Calorimeter*; calorímetro hadrônico de tampa do ATLAS.

HepMC Interface/formato para representação e intercâmbio de registros de eventos Monte Carlo.

HLT *High-Level Trigger*; nível de seleção online baseado em software.

IC95% Intervalo de confiança de 95%.

ICA *Independent Component Analysis*; Análise de Componentes Independentes.

IEEE *Institute of Electrical and Electronics Engineers*.

IQR *Interquartile Range*; intervalo interquartil.

jFEX *jet Feature Extractor*; processador FEX do primeiro nível orientado à reconstrução de jatos.

KDE	*Kernel Density Estimation*; estimação não paramétrica de densidade por núcleos.
L1	*Level-1 Trigger*; primeiro nível do sistema de trigger.
L1Calo	Sistema de calorimetria do primeiro nível de trigger.
LAr	*Liquid Argon*; argônio líquido.
LCW	*Local Cell Weighting*.
LHC	*Large Hadron Collider*.
LHCb	*Large Hadron Collider beauty*.
LHCf	*Large Hadron Collider forward*.
MAE	*Mean Absolute Error*; erro absoluto médio.
MI	*Mutual Information*; informação mútua.
ML	*Machine Learning*; Aprendizado de Máquina.
MLP	*Multilayer Perceptron*; perceptron multicamadas.
MLR	*Multiple Linear Regression*; regressão linear multivariada.
MoEDAL	*Monopole and Exotics Detector at the LHC*.
MP	Modelo Padrão da Física de Partículas.
MSE	*Mean Squared Error*; erro quadrático médio.
MUTI	Configuração de seleção de características baseada em informação mútua, conforme a nomenclatura experimental adotada na tese.
OOB	*Out-of-Bag*; predição ou amostra fora do bootstrap de uma árvore/ensemble.
OOF	*Out-of-Fold*; predição produzida fora do fold utilizado no ajuste correspondente.
PCA	*Principal Component Analysis*; Análise de Componentes Principais.
PM	Pitman–Morgan; teste pareado empregado para comparação de variâncias correlacionadas.
PPGEEC	Programa de Pós-Graduação em Engenharia Elétrica e de Computação.
PReg	*Polynomial Regression*; regressão polinomial.
PS	*Presampler*; pré-amostrador do calorímetro eletromagnético.
Q–Q	*Quantile–Quantile*; gráfico quantil–quantil.
ReLU	*Rectified Linear Unit*; unidade linear retificada.

RF	*Random Forest*.
RFBDT	Modelo híbrido de correção residual com Random Forest no primeiro estágio e BDT no segundo.
RFBDTS	Modelo empilhado (*stacked model*) que combina Random Forest e BDT com meta-regressor Ridge.
RFOR	Nomenclatura utilizada nos gráficos publicados da Etapa II para *Random Forest*.
RMSE	*Root Mean Squared Error*; raiz do erro quadrático médio.
RQ	*Research Question*; questão de pesquisa.
SSD	*Solid-State Drive*.
SVD	*Singular Value Decomposition*; decomposição em valores singulares.
TDAQ	*Trigger and Data Acquisition*; sistema de trigger e aquisição de dados.
TileCal	*Tile Calorimeter*; calorímetro hadrônico de telhas cintiladoras do ATLAS.
TNS	*Transactions on Nuclear Science*.
TOTEM	*TOTal Elastic and diffractive cross section Measurement*.
UFBA	Universidade Federal da Bahia.

Lista de símbolos

x, y, z	Coordenadas cartesianas no sistema de referência do detector.
ϕ	Ângulo azimutal no plano transversal ao feixe.
θ	Ângulo polar medido em relação ao eixo z.
η	Pseudorapidez, definida por $\eta = -\ln[\tan(\theta/2)]$.
E	Energia de uma partícula ou objeto, quando utilizada sem qualificador específico.
E_T	Energia transversal, $E_T = E \sin\theta = E/\cosh\eta$.
X_0	Comprimento de radiação, escala característica do desenvolvimento de chuveiros eletromagnéticos.
μ	Número médio esperado de interações próton–próton por cruzamento de feixes; parâmetro de *pile-up*.
$\langle\mu\rangle$	Valor médio do parâmetro de *pile-up* no perfil ou conjunto considerado.
$\mathbf{S}_k$	Vetor de amostras digitalizadas do sinal da célula calorimétrica k.
A_k	Amplitude do pulso associado à célula calorimétrica k.
$\widehat{A}_k$	Estimativa reconstruída da amplitude do pulso da célula k.
$\mathbf{f}$	Forma temporal nominal do pulso amostrado.
$\mathbf{n}_k$	Vetor de contribuições de ruído associado à célula k.
$\mathbf{w}$	Vetor de pesos do Filtro Ótimo no Capítulo 2; na formulação de FastICA, vetor de separação unitário, conforme o contexto.
$\mathbf{N}$	Matriz de covariância do ruído no modelo esquemático do Filtro Ótimo.
C_k	Fator de conversão e calibração aplicado à amplitude reconstruída da célula k.
$E_{\mathrm{cell},k}$	Energia reconstruída da célula calorimétrica k.
E_{raw}	Energia bruta do objeto calorimétrico, obtida pela soma das energias das células associadas.
$E_{\mathrm{T,fast}}$	Notação explícita para a estimativa rápida de energia transversal utilizada como referência *Standard FastCalo*; equivalente a E_{fast} na notação simplificada adotada nos capítulos experimentais.

$E_{\mathrm{T,true}}$	Notação explícita para a energia transversal de verdade da partícula gerada; equivalente a E_{true} na notação simplificada adotada nos capítulos experimentais.
$E_{\mathrm{T,calib}}$	Notação explícita para a energia transversal após a aplicação da correção proposta; equivalente a E_{calib} na notação simplificada adotada nos capítulos experimentais.
η_{cluster}	Pseudorapidez associada ao objeto calorimétrico reconstruído.
$E_{r,j}$	Energia transversal agregada no j-ésimo anel calorimétrico.
$\widetilde{E}_{r,j}$	Valor do j-ésimo anel na convenção normalizada adotada na formulação matemática.
$\widetilde{\mathbf{E}}_r$	Representação completa de 100 anéis na convenção normalizada adotada na formulação.
$\mathbf{x}^{(i)}$	Vetor de características apresentado ao regressor para o evento i.
F	Dimensionalidade externa da representação fornecida ao regressor.
N	Número de eventos em uma amostra ou matriz de dados, conforme o contexto.
m	Número de características ou componentes retidos em uma representação compacta; na Seção 5.11, o mesmo símbolo é usado localmente como índice do método, $m \in \{\mathrm{calib}, \mathrm{fast}\}$.
$g_{\mathrm{ML}}(\cdot)$	Operador de representação: identidade, seleção de características ou extração de componentes.
$\mathcal{T}_g$	Procedimento de treinamento ou ajuste que define $g_{\mathrm{ML}}(\cdot)$ a partir dos dados permitidos de desenvolvimento.
$f_{\mathrm{ML}}(\cdot)$	Função de regressão treinada para estimar o fator de calibração.
E_{true}	Notação simplificada para a energia transversal de verdade da partícula gerada, disponível apenas em Monte Carlo.
E_{fast}	Notação simplificada para a estimativa rápida de energia transversal utilizada como referência *Standard FastCalo* no *benchmark*.
E_{calib}	Notação simplificada para a energia transversal após aplicação da correção de calibração proposta.
α_{true}	Fator ideal de calibração, $\alpha_{\mathrm{true}} = E_{\mathrm{true}}/E_{\mathrm{fast}}$.
α_{calib}	Fator de calibração previsto pelo modelo, $\alpha_{\mathrm{calib}} = f_{\mathrm{ML}}(\mathbf{x})$.
$\mathcal{L}$	Função de perda genérica utilizada na formulação do treinamento supervisionado.

N_{train} Número de eventos na amostra de treinamento considerada em uma etapa de ajuste.

$\mathcal{D}_{70}$ Partição de desenvolvimento, correspondente a 70% do conjunto principal.

$\mathcal{D}_{30}$ Partição independente de teste, correspondente a 30% do conjunto principal.

N_{dev} Número de eventos na partição de desenvolvimento.

N_{test} Número de eventos na partição independente de teste.

Ξ Espaço discreto de configurações candidatas de hiperparâmetros considerado na busca interna da validação cruzada aninhada.

N_{Ξ} Número de configurações candidatas contidas em Ξ.

$\boldsymbol{\xi}$ Configuração completa candidata de hiperparâmetros pertencente a Ξ.

$\mathcal{D}_{\text{tr},k}$ Conjunto de treinamento do k-ésimo *fold* externo da validação cruzada aninhada.

$\mathcal{D}_{\text{va},k}$ Conjunto de validação do k-ésimo *fold* externo da validação cruzada aninhada.

$\mathcal{D}_{\text{tr,in},k,j}$ Conjunto de treinamento do j-ésimo *fold* interno associado ao k-ésimo *fold* externo.

$\mathcal{D}_{\text{va,in},k,j}$ Conjunto de validação do j-ésimo *fold* interno associado ao k-ésimo *fold* externo.

$\widetilde{q}(\boldsymbol{\xi}; \mathcal{A})$ Valor da métrica q normalizado por min–max entre as configurações do conjunto $\mathcal{A}$ durante a seleção de hiperparâmetros.

$S_{\text{pilot},k}(\boldsymbol{\xi})$ Escore utilizado no primeiro *split* interno para ranquear as configurações candidatas e formar a *shortlist* do k-ésimo *fold* externo.

N_{short} Número de configurações retidas na *shortlist* após a triagem piloto.

$\Xi_{\text{short},k}$ Subconjunto de Ξ retido pela triagem piloto no k-ésimo *fold* externo e submetido à avaliação completa nos cinco *folds* internos.

$\overline{\text{RMSE}}_{\text{inner},k}(\boldsymbol{\xi})$ Média dos cinco valores de RMSE obtidos para a configuração $\boldsymbol{\xi}$ nos *folds* internos do k-ésimo *fold* externo.

$\overline{\text{IQR}}_{\text{inner},k}(\boldsymbol{\xi})$ Média dos cinco valores de IQR obtidos para a configuração $\boldsymbol{\xi}$ nos *folds* internos do k-ésimo *fold* externo.

$S_{\text{inner},k}(\boldsymbol{\xi})$ Escore interno baseado nas versões normalizadas de $\overline{\text{RMSE}}_{\text{inner},k}$ e $\overline{\text{IQR}}_{\text{inner},k}$, maximizado para selecionar hiperparâmetros.

$\boldsymbol{\xi}_{\text{sel},k}$ Configuração completa de hiperparâmetros selecionada no laço interno associado ao k-ésimo *fold* externo.

$R[f;\mathcal{D}]$	Medida genérica de desempenho de um modelo já ajustado f quando avaliado no conjunto $\mathcal{D}$.
$f_{\mathrm{ML},k}(\cdot)$	Regressor reajustado em todo $\mathcal{D}_{\mathrm{tr},k}$ com a configuração $\boldsymbol{\xi}_{\mathrm{sel},k}$.
$\widehat{R}_{\mathrm{outer},k}$	Desempenho de $f_{\mathrm{ML},k}$ em $\mathcal{D}_{\mathrm{va},k}$; utilizado para avaliar o procedimento de seleção e não para escolher hiperparâmetros.
$\boldsymbol{\xi}_{\mathrm{final}}$	Configuração final de hiperparâmetros definida pela moda das cinco configurações completas $\boldsymbol{\xi}_{\mathrm{sel},k}$.
$f_{\mathrm{ML}}^{\mathrm{final}}(\cdot)$	Regressor final reajustado em toda a partição $\mathcal{D}_{70}$ com $\boldsymbol{\xi}_{\mathrm{final}}$ e utilizado na avaliação independente em $\mathcal{D}_{30}$.
ρ_j	Coeficiente de correlação de Pearson entre o j-ésimo atributo e a variável-alvo.
EVR_k	Proporção de variância explicada pelo k-ésimo componente principal.
$s_{\mathrm{PCA},k}$	Escore de relevância da k-ésima componente PCA para a tarefa de calibração, definido pelo módulo de sua correlação de Pearson com E_{true}.
π_{PCA}	Permutação que ordena as componentes PCA em ordem decrescente do escore $s_{\mathrm{PCA},k}$.
$\mathcal{S}_{\mathrm{PCA}}^{(m)}$	Conjunto dos índices das m componentes PCA retidas após a ordenação por relevância em relação a E_{true}.
$\mathrm{EVR}_{\mathrm{sel}}^{(m)}$	Fração da variância total associada ao subconjunto de m componentes PCA selecionado segundo o critério de relevância supervisionada.
$I(X;Y)$	Informação mútua entre as variáveis aleatórias X e Y.
$D_{\mathrm{KL}}(P\|Q)$	Divergência de Kullback–Leibler entre as distribuições P e Q.
J_{GA}	Função objetivo utilizada pelo algoritmo genético para construir a segmentação em $(\|\eta\|, E_{\mathrm{true}})$ na Etapa I; a notação E_T é preservada nas figuras do artigo por rastreabilidade.
N_b	Número de eventos no bin b durante a otimização da segmentação.
$Q_p(X)$	Quantil de ordem p da variável aleatória X.
$\varepsilon_{\mathrm{calib}}$	Resíduo da energia calibrada, $\varepsilon_{\mathrm{calib}} = E_{\mathrm{true}} - E_{\mathrm{calib}}$.
$\varepsilon_{\mathrm{fast}}$	Resíduo da referência, $\varepsilon_{\mathrm{fast}} = E_{\mathrm{true}} - E_{\mathrm{fast}}$.
d_0	Métrica auxiliar conjunta no plano RMSE–IQR, $d_0 = \sqrt{\mathrm{RMSE}^2 + \mathrm{IQR}^2}$; não deve ser confundida com o parâmetro de impacto transverso usualmente denotado por d_0 no ATLAS.
r	Resposta relativa de energia, $r = E_{\mathrm{calib}}/E_{\mathrm{true}}$.

δ	Resíduo relativo de energia, $\delta = (E_{\text{calib}} - E_{\text{true}})/E_{\text{true}} = r - 1$.
$\mathcal{B}_\ell$	Conjunto de eventos pertencentes ao ℓ-ésimo intervalo de E_{true} utilizado na avaliação da resolução.
σ_r	Desvio-padrão da distribuição da resposta relativa r.
σ_δ	Desvio-padrão da distribuição do resíduo relativo δ.
σ_E/E	Resolução relativa de energia, estimada empiricamente em intervalos de E_{true} pela dispersão de r.
σ_{eq}	Largura gaussiana equivalente estimada por $\sigma_{\text{eq}} \approx \text{IQR}(r)/1{,}349$.
$E_m^{(i)}$	Estimativa de energia do método m para o evento i na análise de aceitação, com $m \in \{\text{calib}, \text{fast}\}$.
$\Delta\lambda$	Tolerância positiva aplicada ao módulo do resíduo na análise de aceitação e, equivalentemente, semi-largura da janela energética simétrica centrada em E_{true}, de modo que $\lvert\varepsilon_m^{(i)}\rvert < \Delta\lambda$ equivale a $E_{\text{true}}^{(i)} - \Delta\lambda < E_m^{(i)} < E_{\text{true}}^{(i)} + \Delta\lambda$.
$\sigma_{\varepsilon_{\text{calib}}}$	Desvio-padrão da distribuição dos resíduos da energia calibrada.
$\sigma_{\varepsilon_{\text{fast}}}$	Desvio-padrão da distribuição dos resíduos da referência Standard FastCalo.
$\Delta\lambda_{\text{max}}$	Limite superior da varredura de $\Delta\lambda$, definido por $\Delta\lambda_{\text{max}} = 6\max(\sigma_{\varepsilon_{\text{calib}}}, \sigma_{\varepsilon_{\text{fast}}})$.
$\Delta\lambda_s$	s-ésimo ponto da grade de 1000 valores igualmente espaçados entre zero e $\Delta\lambda_{\text{max}}$.
$I(\cdot)$	Função indicadora, igual a 1 quando a condição especificada é satisfeita e a 0 caso contrário.
$\text{EAR}_m(\Delta\lambda_s)$	Taxa de aceitação de eventos do método m no ponto $\Delta\lambda_s$, calculada como a fração dos eventos que satisfazem $\lvert\varepsilon_m^{(i)}\rvert < \Delta\lambda_s$.
q	Na análise de aceitação, nível utilizado para definir um ponto resumido da curva; nas expressões da GNN, índice local de macro-região $q \in \{\text{PS}, \text{EM}, \text{HAD}\}$, conforme o contexto.
$\Delta\lambda_{q,m}$	Primeiro valor da varredura para o qual $\text{EAR}_m(\Delta\lambda_s) \geq q$; para $q = 0{,}90$, define-se $\Delta\lambda_{90,m}$.
T	Tempo médio amortizado de predição por evento do modelo treinado.
$T_{\text{wall,batch}}$	Tempo de relógio medido para processar um lote de eventos durante a inferência.
N_{batch}	Número de eventos processados no lote utilizado para calcular o tempo amortizado de predição.

$z^{(N)}$	Valor normalizado por min–max de uma grandeza z dentro de um conjunto fixo de configurações.
D_0	Índice composto normalizado que combina IQR, RMSE, dimensionalidade externa F e tempo de predição T.
d	Diferença pareada entre os resíduos, $d = \varepsilon_{\text{calib}} - \varepsilon_{\text{fast}}$.
μ_d	Média da diferença pareada dos resíduos, $\mu_d = \mathbb{E}[d]$.
R_{σ^2}	Razão entre as variâncias dos resíduos calibrado e de referência, $R_{\sigma^2} = \sigma^2_{\text{calib}}/\sigma^2_{\text{fast}}$.
H_0	Hipótese nula de um teste estatístico.
H_1	Hipótese alternativa de um teste estatístico.
$\mathcal{G} = (\mathcal{V}, \mathcal{E})$	Grafo composto pelo conjunto de nós $\mathcal{V}$ e pelo conjunto de arestas $\mathcal{E}$.
$\mathcal{G}_q^{(i)}$	Grafo regional do evento i para $q \in \{\text{PS}, \text{EM}, \text{HAD}\}$, contendo $\mathcal{V}_q$, $\mathcal{E}_q$ e a matriz de características nodais $\mathbf{Z}_q^{(i)}$.
$\mathcal{V}_q$	Conjunto de nós da região calorimétrica q.
$\mathcal{E}_q$	Conjunto de arestas bidirecionais entre anéis consecutivos da região q.
n_q	Número de nós/anéis na região q.
$\mathbf{Z}_q^{(i)}$	Matriz das características dos nós da região q para o evento i.
$\mathbf{z}_v^{(i)}$	Vetor de sete características associado ao nó v do evento i.
$\widetilde{E}_{r,v,\text{std}}^{(i)}$	Versão padronizada por *z-score* do valor do anel associado ao nó v.
$p_{v,\text{local}}$	Posição ordinal normalizada do nó dentro de sua macro-região.
$p_{v,\text{global}}$	Posição ordinal normalizada do nó na sequência completa dos 100 anéis.
$\mathbf{e}_{v,q}$	Codificação *one-hot* da macro-região do nó.
$\mathbf{h}_{v,\ell}^{(i)}$	Representação latente do nó v na camada ℓ da GNN para o evento i.
$\mathbf{m}_{v,\ell}^{(i)}$	Informação agregada dos vizinhos do nó v na camada ℓ.
$\mathbf{g}_q^{(i)}$	*Embedding* regional obtido pela concatenação de *mean pooling* e *max pooling*.
$\mathbf{g}^{(i)}$	*Embedding* gráfico do evento, obtido pela concatenação dos vetores de PS, EM e HAD.
$S_q^{(i)}$	Soma dos valores dos anéis na região q para o evento i.
$S_{\text{tot}}^{(i)}$	Soma das contribuições de PS, EM e HAD no evento i.
$\text{Frac}_q^{(i)}$	Fração regional, $\text{Frac}_q^{(i)} = S_q^{(i)}/S_{\text{tot}}^{(i)}$.

$R^{(i)}_{\mathrm{HAD/EM}}$	Razão $S^{(i)}_{\mathrm{HAD}}/S^{(i)}_{\mathrm{EM}}$.
$R^{(i)}_{\mathrm{PS/EM}}$	Razão $S^{(i)}_{\mathrm{PS}}/S^{(i)}_{\mathrm{EM}}$.
$S^{(i)}_{\mathrm{EM1}}, S^{(i)}_{\mathrm{EM2}}, S^{(i)}_{\mathrm{EM3}}$	Somas dos anéis correspondentes às amostragens EM1, EM2 e EM3.
$R^{(i)}_{\mathrm{EM}k/\mathrm{EM}}$	Razão entre a soma da amostragem EMk e a soma total da região EM, para $k \in \{1, 2, 3\}$.
$p_{q,j}$	Coordenada ordinal normalizada do j-ésimo anel dentro da região q.
$w^{(i)}_{q,j}$	Peso min–max empregado nos momentos posicionais do j-ésimo anel da região q.
$\overline{p}^{(i)}_{q}$	Média posicional ponderada dos anéis da região q.
$\sigma^{(i)}_{p,q}$	Desvio-padrão posicional ponderado dos anéis da região q.
$\mathbf{d}^{(i)}$	Vetor dos 20 descritores determinísticos derivados dos anéis.
$\mathbf{x}^{(i)}_{\mathrm{tab}}$	Entrada tabular de 120 componentes formada pela representação completa e pelos 20 descritores.
$\mathbf{t}^{(i)}$	Representação latente de 256 componentes produzida pelo ramo tabular.
$\mathbf{r}^{(i)}_{\mathrm{tab}}$	Representação de 128 componentes utilizada na saída tabular não linear.
s_{g}	Escalar treinável aplicado ao *embedding* gráfico antes da fusão.
$\widetilde{\mathbf{g}}^{(i)}$	*Embedding* gráfico escalado por s_{g}.
$\mathbf{u}^{(i)}$	Vetor de 1024 componentes fornecido ao estágio de fusão relacional–tabular.
$\alpha^{(i)}_{\mathrm{lin}}$	Contribuição escalar do caminho linear interno da GNN.
$\alpha^{(i)}_{\mathrm{tab}}$	Contribuição escalar do ramo tabular não linear.
$\alpha^{(i)}_{\mathrm{fus}}$	Contribuição escalar do estágio de fusão relacional–tabular.
$e^{(i)}$	Resíduo no domínio do fator de calibração durante o treinamento da GNN, $e^{(i)} = \alpha^{(i)}_{\mathrm{true}} - \alpha^{(i)}_{\mathrm{calib}}$.
λ_{MSE}	Peso da componente MSE na função objetivo combinada da GNN.
β	Parâmetro de transição da perda *Smooth L1*.
$\mathcal{L}_{\mathrm{MSE}}$	Componente de erro quadrático médio da função objetivo da GNN.
$\mathcal{L}_{\mathrm{SL1}}$	Componente *Smooth L1* da função objetivo da GNN.
$\boldsymbol{\theta}$	Conjunto dos parâmetros treináveis da arquitetura GNN; em contexto detector, θ sem negrito continua denotando o ângulo polar.
$\boldsymbol{\theta}^{\star}$	Conjunto de parâmetros da GNN retido ao término do treinamento.

$\mathcal{B}_t$	Mini-lote utilizado na iteração de treinamento t.
ν	Taxa de aprendizado; na seção de *gradient boosting*, o mesmo símbolo representa o fator de *shrinkage*, conforme o contexto.
λ_{wd}	Coeficiente de *weight decay* do AdamW.

Sumário

1 INTRODUÇÃO . . . 33
1.1 Contextualização . . . 33
1.2 Motivação e lacuna científica . . . 34
1.3 Problema científico e escopo da tese . . . 36
1.4 Hipótese de pesquisa . . . 37
1.5 Questões de pesquisa . . . 38
1.6 Objetivos . . . 38
1.6.1 Objetivo geral . . . 38
1.6.2 Objetivos específicos . . . 38
1.7 Contribuições científicas . . . 39
1.8 Publicações associadas à tese . . . 41
1.9 Organização da tese . . . 41

2 CALORIMETRIA E RECONSTRUÇÃO RÁPIDA DE ENERGIA EM FÍSICA DE ALTAS ENERGIAS . . . 43
2.1 Contexto físico da medição de elétrons . . . 43
2.2 O LHC e o experimento ATLAS . . . 44
2.2.1 *Large Hadron Collider* . . . 44
2.2.2 Visão geral do detector ATLAS . . . 45
2.2.3 Sistema de coordenadas . . . 46
2.3 Calorimetria no ATLAS . . . 47
2.3.1 Princípio de medição calorimétrica . . . 47
2.3.2 Calorímetro eletromagnético de argônio líquido . . . 47
2.3.3 Calorimetria hadrônica . . . 50
2.4 Da amostra digital à energia reconstruída . . . 51
2.4.1 Células calorimétricas como unidades de medição . . . 51
2.4.2 De células a clusters e energia transversa . . . 52
2.5 Ruído, *pile-up*, vazamento e dependências da resposta . . . 53
2.6 Seleção online e reconstrução rápida de elétrons . . . 54
2.6.1 Função do sistema de *trigger* . . . 54
2.6.2 Primeiro nível de *trigger* na Run 3 . . . 54
2.6.3 HLT de elétrons: etapas rápida e de precisão . . . 55
2.6.4 Limiar de energia, eficiência e taxa . . . 57
2.7 Representação Ringer . . . 57
2.7.1 Construção dos anéis . . . 57
2.7.2 Ringer na identificação online de elétrons . . . 58
2.8 Simulação Monte Carlo e relação com o ambiente experimental . . . 59
2.9 Conclusão do capítulo . . . 60

3 FORMULAÇÃO DA CALIBRAÇÃO E REPRESENTAÇÃO DA INFORMAÇÃO CALORIMÉTRICA . . . 62
3.1 Calibração como problema de estimação supervisionada . . . 62
3.1.1 Regressão do fator de calibração e regressão direta da energia . . . 66
3.2 Representação da informação e redução de dimensionalidade . . . 68
3.3 Seleção de características . . . 69
3.3.1 Correlação de Pearson . . . 69
3.3.2 Informação mútua . . . 71
3.4 Extração de características . . . 75
3.4.1 Análise de Componentes Principais . . . 75
3.4.2 Análise de Componentes Independentes . . . 79
3.5 Conclusão do capítulo . . . 83

4 MODELOS DE REGRESSÃO E FUSÃO DE INFORMAÇÃO PARA CALIBRAÇÃO CALORIMÉTRICA . . . 85
4.1 Modelos de regressão convencionais e baseados em árvores . . . 85
4.1.1 Regressão linear multivariada . . . 85
4.1.2 Regressão polinomial . . . 88
4.1.3 Árvores de decisão . . . 91
4.1.4 *Gradient Boosted Decision Trees* (BDT) . . . 93
4.1.5 *Random Forest* . . . 96
4.2 Aprendizado residual e ensembles híbridos . . . 98
4.2.1 Correção residual sequencial . . . 98
4.2.2 *Stacked models* . . . 101
4.3 Redes neurais profundas para regressão . . . 103
4.3.1 Do neurônio ao perceptron multicamadas . . . 104
4.3.2 Capacidade, regularização e treinamento . . . 106
4.4 Redes neurais em grafos e viés indutivo relacional . . . 109
4.4.1 Representação em grafos . . . 111
4.4.2 Propagação de mensagens e GraphSAGE . . . 113
4.4.3 Ramo tabular e descritores derivados dos anéis . . . 115
4.4.4 Fusão relacional–tabular e treinamento . . . 118
4.5 Fusão de informação na cadeia de calibração . . . 122
4.6 Complexidade, generalização e custo computacional . . . 123
4.7 Robustez a ruído, *pile-up* e efeitos instrumentais . . . 124
4.8 Síntese das famílias de modelos . . . 124
4.9 Conclusão do capítulo . . . 125

5 METODOLOGIA EXPERIMENTAL UNIFICADA . . . 127
5.1 Princípios do desenho experimental . . . 127
5.2 Ambiente Monte Carlo e domínio experimental . . . 128
5.2.1 *Benchmark* Lorenzetti . . . 128
5.2.2 Amostra de elétrons e cobertura cinemática . . . 131

5.2.3 Ruído eletrônico e *pile-up* . . . 131
5.2.4 Perturbação não linear controlada . . . 132
5.3 Interface calorimétrica utilizada no *benchmark* . . . 132
5.4 Aplicação da formulação de calibração . . . 133
5.5 Representações de entrada . . . 133
5.5.1 Ajuste da representação e prevenção de vazamento . . . 134
5.6 Evolução dos protocolos experimentais . . . 135
5.6.1 Etapa I: modelos convencionais e segmentação . . . 135
5.6.2 Etapas II e III: treinamento global e avaliação regional . . . 137
5.7 Particionamento, validação cruzada e seleção de modelos . . . 137
5.7.1 Partição independente de teste . . . 137
5.7.2 Validação cruzada aninhada . . . 138
5.8 Métricas de erro global . . . 142
5.8.1 RMSE . . . 142
5.8.2 Quartis e IQR . . . 143
5.8.3 Métrica conjunta d_0 . . . 143
5.9 Avaliação Regional em Segmentos de $|\eta|$ e $E_{\mathbf{T}}$ do fator de calibração . . . 143
5.10 Resolução de energia . . . 144
5.11 Resposta próxima a limiares de seleção . . . 145
5.12 Avaliação computacional . . . 146
5.12.1 Métrica composta D_0 . . . 147
5.13 Validação estatística . . . 148
5.13.1 Deslocamento do resíduo . . . 148
5.13.2 Comparação de variâncias . . . 148
5.14 Reprodutibilidade e implementação . . . 149
5.15 Limitações e níveis de validade . . . 150
5.16 Relação entre o protocolo e as questões de pesquisa . . . 151
5.17 Conclusão do capítulo . . . 151

6 CALIBRAÇÃO COM MODELOS CONVENCIONAIS E REDUÇÃO DE DIMENSIONALIDADE . . . 153
6.1 Escopo da Etapa I . . . 153
6.2 Resposta de referência do Standard FastCalo . . . 153
6.3 Informação dos anéis e representações compactas . . . 154
6.4 Desempenho global da calibração . . . 156
6.5 Treinamento global e treinamento segmentado . . . 158
6.6 Análise Regional do Fator de Calibração em Segmentos de $|\eta|$ e $E_{\mathbf{T}}$ . . . 159
6.7 Compromisso entre erro, dimensionalidade e custo de predição . . . 160
6.8 Resposta a limiar e aceitação de eventos . . . 162
6.9 Validação estatística . . . 162
6.10 Escopo dos resultados da Etapa I . . . 164
6.11 Conclusão do capítulo . . . 164

7 CALIBRAÇÃO COM ENSEMBLES E APRENDIZADO RESIDUAL 165
7.1 Escopo da Etapa II . . . 165
7.2 Representações com cardinalidade controlada . . . 166
7.3 Desempenho global da calibração . . . 166
7.4 Aprendizado residual e efeito da ordem dos *ensembles* . . . 168
7.5 Compromisso entre erro, dimensionalidade e custo de predição . . . 168
7.6 Estabilidade regional do fator de calibração . . . 170
7.7 Resolução relativa de energia . . . 172
7.8 Resposta a limiar e aceitação de eventos . . . 173
7.9 Linearidade e consistência evento a evento . . . 174
7.10 Validação estatística . . . 175
7.11 Escopo dos resultados da Etapa II . . . 176
7.12 Conclusão do capítulo . . . 176

8 CALIBRAÇÃO NEURAL E FUSÃO DE INFORMAÇÃO 178
8.1 Escopo da Etapa III . . . 178
8.2 Fusão neural em representações completas e compactas . . . 178
8.3 Desempenho global e comparação entre DNN e GNN . . . 180
8.4 Compromisso entre desempenho, dimensionalidade e custo . . . 182
8.5 Estabilidade regional do fator de calibração . . . 184
8.6 Resolução relativa de energia . . . 184
8.7 Resposta a limiar e aceitação de eventos . . . 186
8.8 Linearidade e consistência evento a evento . . . 187
8.9 Validação estatística . . . 188
8.10 Implicação para reconstrução de massa invariante . . . 189
8.11 Escopo dos resultados da Etapa III . . . 190
8.12 Conclusão do capítulo . . . 190

9 SÍNTESE, DISCUSSÃO E CONCLUSÕES 192
9.1 Visão integrada da investigação . . . 192
9.2 Evolução dos resultados ao longo das três etapas . . . 193
9.2.1 Configurações representativas de maior desempenho por etapa . . . 193
9.2.2 Representações compactas . . . 194
9.2.3 Capacidade do modelo e estrutura residual . . . 194
9.3 Fronteira desempenho–complexidade . . . 195
9.4 Respostas às questões de pesquisa . . . 195
9.4.1 RQ1 — Informação e compactação . . . 195
9.4.2 RQ2 — Regressores convencionais . . . 195
9.4.3 RQ3 — Aprendizado híbrido . . . 196
9.4.4 RQ4 — Fusão neural . . . 196
9.4.5 RQ5 — Estrutura relacional . . . 196
9.4.6 RQ6 — Compromissos de engenharia . . . 196
9.5 Avaliação da hipótese central . . . 197

9.6 Objetivos alcançados e contribuições consolidadas . . . 197
9.7 Implicações para calorimetria rápida e seleção por limiar . . . 198
9.7.1 O que a calibração corrige . . . 198
9.7.2 Resolução e comportamento próximo a limiares . . . 198
9.7.3 Propagação para observáveis físicos . . . 199
9.8 Síntese da evidência estatística . . . 199
9.9 Domínio de validade e limitações . . . 199
9.9.1 Monte Carlo versus dados experimentais . . . 199
9.9.2 *Pile-up* . . . 200
9.9.3 Cobertura geométrica e fidelidade do detector . . . 200
9.9.4 Latência e implantação . . . 200
9.10 Alcance das conclusões . . . 200
9.11 Perspectivas e trabalhos futuros . . . 201
9.11.1 Validação de domínio e fidelidade . . . 201
9.11.2 Validação ressonante e dados experimentais . . . 201
9.11.3 Validação operacional . . . 202
9.11.4 Validação arquitetural e novas fontes de informação . . . 202
9.12 Conclusão geral . . . 202

REFERÊNCIAS . . . 204

A REPRODUTIBILIDADE . . . 210
A.1 Escopo e princípio de rastreabilidade . . . 210
A.2 Ambiente computacional e implementações . . . 210
A.3 Conjunto de dados e separação desenvolvimento–teste . . . 211
A.4 Protocolo experimental e determinismo . . . 212
A.5 Hiperparâmetros e configurações arquivadas . . . 212
A.5.1 Etapa I — modelos convencionais e BDT . . . 212
A.5.2 Etapa II — árvores, aprendizado residual e *stacking* . . . 213
A.5.3 Etapa III — DNN e GNN . . . 213
A.5.3.1 DNN . . . 213
A.5.3.2 GNN . . . 214

B QUESTÕES CIENTÍFICAS E METODOLÓGICAS RECORRENTES . . . 216
B.1 Escopo do apêndice . . . 216
B.2 Problema científico, contribuição e originalidade . . . 216
B.3 Física, calorimetria e cadeia de reconstrução . . . 217
B.4 Lorenzetti, ATLAS e validade do benchmark . . . 218
B.5 Representação Ringer e redução de dimensionalidade . . . 220
B.6 Formulação da calibração . . . 222
B.7 Particionamento, nested CV e prevenção de vazamento . . . 223
B.8 Modelos convencionais, árvores e aprendizado híbrido . . . 224
B.9 DNN e arquitetura GNN relacional–tabular . . . 226
B.10 Detalhamento da arquitetura GNN relacional–tabular . . . 227

B.11 Métricas, estatística e interpretação dos resultados 229
B.12 Binning, segmentação e dependência regional 232
B.13 Trigger, resposta a limiar e fundo 233
B.14 Pile-up, ruído e robustez 234
B.15 Custo computacional, latência e implantação 235
B.16 Reprodutibilidade 236
B.17 Validade externa, dados reais e observáveis físicos 237
B.18 Questões de síntese da pesquisa 238

C DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL GENERATIVA 239
C.1 ChatGPT (OpenAI) 239

1 Introdução

1.1 Contextualização

Experimentos de física de altas energias baseados em colisores dependem da reconstrução precisa e eficiente das propriedades das partículas produzidas nas colisões. No *Large Hadron Collider* (LHC), o experimento ATLAS utiliza um sistema de detecção de propósito geral no qual os calorímetros desempenham papel central na reconstrução de elétrons e fótons, objetos relevantes em análises de processos eletrofracos e do bóson de Higgs (ATLAS Collaboration, 2008; ATLAS Collaboration, 2021). Esta tese concentra-se especificamente na calibração da energia transversa de elétrons, grandeza que influencia tanto decisões de seleção online quanto observáveis físicos construídos posteriormente, incluindo massas invariantes de sistemas que contêm elétrons (GRIFFITHS, 2008).

A medição calorimétrica é produzida a partir da resposta de um sistema detector altamente segmentado. A energia depositada pelas partículas é amostrada em numerosas células, cujos sinais são submetidos a etapas de leitura e reconstrução antes da formação dos objetos calorimétricos. A estimativa resultante é afetada por flutuações do desenvolvimento da cascata de partículas que atravessam o material (chuveiro de partículas), ruído eletrônico, *pile-up*, não linearidades, material anterior ao calorímetro, vazamentos e dependências geométricas da resposta do detector (FABJAN; GIANOTTI, 2003; ATLAS Collaboration, 2024a). A calibração de energia constitui, portanto, parte da cadeia de medição necessária para controlar desvios de escala e dispersões da resposta reconstruída.

O problema adquire uma dimensão adicional quando a reconstrução é utilizada em sistemas de seleção online (*trigger*). Nesses sistemas, qualidade da estimativa e custo de processamento devem ser tratados conjuntamente sob elevada taxa de eventos. Erros na estimativa da energia podem deslocar candidatos através de limiares de seleção de eventos, enquanto o aumento da complexidade do algoritmo pode elevar o custo computacional por evento. Além disso, eficiência para elétrons e taxa de aceitação de eventos não relevantes são grandezas distintas: melhorar a resolução de energia do sinal não implica, por si só, redução da taxa global do *trigger* (ATLAS Collaboration, 2024b; ORELLANA; ATLAS Collaboration, 2021).

Sob a perspectiva da Engenharia Elétrica e de Computação, esse problema pode ser interpretado como a calibração orientada por dados de um sistema de medição distribuído e de alta dimensionalidade. As células calorimétricas fornecem observações locais do chuveiro de partículas, e essas observações precisam ser agregadas, representadas e processadas para produzir uma estimativa de energia. Essa interpretação conecta instrumentação eletrônica, processamento digital de sinais, representação de dados, estimação estatística, fusão de informação, inteligência artificial, aprendizado de máquina e processamento computacional de alta taxa, constituindo o eixo de engenharia investigado nesta tese (FABJAN; GIANOTTI, 2003; MENG et al., 2020).

Métodos de Aprendizado de Máquina (*Machine Learning*, ML) têm sido empregados

em diferentes tarefas de reconstrução e análise na física de altas energias, especialmente em problemas nos quais relações não lineares ou representações de alta dimensionalidade dificultam o uso de parametrizações simples (ALBERTSSON et al., 2018; BALDI; SADOWSKI; WHITESON, 2014). No contexto de calibração, esses métodos permitem aprender funções de correção a partir de observáveis do detector e de uma quantidade de referência. Entretanto, o desempenho de uma solução não depende somente do algoritmo de regressão: depende também da informação apresentada ao modelo, da forma como essa informação é representada, do protocolo empregado para estimá-lo e do custo computacional associado à inferência.

Uma representação particularmente relevante para esse propósito é produzida pelo algoritmo Ringer. Em uma região de interesse do calorímetro, depósitos de energia transversa das células são agregados em anéis organizados em torno do núcleo do chuveiro, formando um perfil ordenado que preserva informação espacial e reduz a dimensionalidade em relação à leitura original no nível de células (PINTO; ATLAS Collaboration, 2016; ORELLANA; ATLAS Collaboration, 2021). O Ringer constitui, portanto, uma primeira etapa de redução estruturada orientada por conhecimento do detector e do desenvolvimento do chuveiro, e não apenas uma compressão estatística dos dados. Nesta tese, essa representação estabelece a formulação entre a medição calorimétrica segmentada e os modelos de calibração.

A pesquisa organiza essa cadeia como um processo de fusão de informação em múltiplos estágios. Medições no nível de células são agregadas em descritores baseados em anéis; a representação resultante pode ser preservada integralmente ou transformada por seleção ou extração de características; finalmente, modelos de regressão utilizam essa informação para estimar um fator de correção específico para cada evento. Essa leitura é compatível com o princípio geral de fusão de informação, no qual medições, características ou representações complementares são combinadas para produzir uma estimativa de interesse (CASTANEDO, 2013; MENG et al., 2020).

A avaliação experimental utiliza o *Lorenzetti Showers Framework* como ambiente aberto e reprodutível de referência (ARAÚJO et al., 2023; PINTO et al., 2022). A configuração empregada é inspirada em características de segmentação da calorimetria eletromagnética do ATLAS e fornece acesso aos observáveis necessários à construção da representação em anéis. O Lorenzetti, entretanto, não corresponde à cadeia oficial de simulação e reconstrução do ATLAS. Essa distinção é mantida ao longo de toda a tese e delimita o alcance das conclusões quantitativas.

1.2 Motivação e lacuna científica

A motivação desta tese não decorre da inexistência de procedimentos consolidados de calibração em experimentos de física de altas energias. A calibração de elétrons e fótons no ATLAS utiliza uma cadeia sofisticada de reconstrução e correções derivadas de simulação e de dados experimentais (ATLAS Collaboration, 2024a). O problema investigado aqui é diferente e mais restrito: determinar se a informação espacial do chuveiro eletromagnético, disponível em uma representação baseada em anéis, pode ser utilizada para corrigir evento a evento uma estimativa de energia transversa produzida por algoritmos rápidos de reconstrução calorimétrica.

Essa distinção é importante. A proposta não pretende substituir a cadeia completa de reconstrução e calibração de elétrons do ATLAS. No ambiente experimental considerado nesta tese, a estimação online (rápida) da energia já existe antes da aplicação da solução de ML proposta, então, a tarefa consiste em estimar um fator multiplicativo adicional a partir da estrutura do chuveiro. A questão científica, portanto, não é se uma calibração convencional "funciona" ou "não funciona", mas se informação calorimétrica que não está explicitamente representada em uma única estimativa escalar pode ser explorada para reduzir erros residuais da reconstrução rápida.

A representação Ringer torna essa questão testável. Um valor escalar de energia resume o resultado de várias etapas da reconstrução, enquanto o perfil dos anéis preserva a distribuição relativa da deposição em diferentes regiões do calorímetro. Flutuações do chuveiro, dependências geométricas, ruído e atividade adicional podem modificar esse perfil de formas que não são descritas por um único número. Surge, assim, um problema de engenharia com dimensões acopladas: *quanto* da informação deve ser preservado, *como* representá-la, *qual* capacidade de regressão é necessária para explorá-la e *qual* custo adicional essa solução introduz.

Um estudo precedente baseado em informação calorimétrica organizada em anéis demonstrou a viabilidade do uso de árvores de decisão com reforço por gradiente (*Gradient Boosted Decision Trees* - BDT) para estimação de energia em um detector altamente segmentado (SIMAS FILHO et al., 2025). A primeira etapa desta tese ampliou essa investigação pela comparação de regressão linear multivariada, regressão polinomial, árvores de decisão simples e BDTs, associados a seleção de características por correlação e informação mútua e a extração de atributos por análise de componentes principais (*Principal Component Analysis* - PCA) e independentes (*Independent Component Analysis* - ICA) (SILVA et al., 2026b). Essa etapa estabeleceu que a informação dos anéis pode ser utilizada para calibração e mostrou que representações de baixa dimensão podem preservar parcela relevante do ganho.

A segunda etapa investigou se mecanismos complementares de aprendizagem poderiam explorar estrutura residual deixada por regressores individuais. Foram avaliados *Random Forests*, BDTs, correção residual e modelos empilhados (*stacked models*), juntamente com um protocolo de avaliação ampliado para resolução relativa de energia, estabilidade regional, comportamento próximo a limiares de seleção de eventos e custo de predição (SILVA et al., 2026a). Os resultados mostraram que um modelo híbrido pode produzir ganho adicional, mas também que esse ganho é pequeno quando comparado a uma BDT completa já fortemente ajustada ao problema. Em paralelo, a representação completa apresentou vantagem quando o objetivo era maximizar a qualidade absoluta, enquanto representações compactas mantiveram soluções competitivas com menor dimensionalidade.

A terceira etapa ampliou o problema para fusão neural de informação. Redes neurais profundas (*Deep Neural Networks* - DNN) foram aplicadas às representações completa e compactas, enquanto uma arquitetura de redes neurais em grafos relacional–tabular (*Graph Neural Network* - GNN) introduziu relações locais e organização regional entre os anéis (SILVA; SIMAS FILHO, 2026). Essa abordagem é motivada pelo fato de que o perfil Ringer possui estrutura associada às regiões calorimétricas, e não constitui apenas um conjunto arbitrário de atributos (BATTAGLIA

et al., 2018; SHLOMI; BATTAGLIA; VLIMANT, 2020). A comparação final, contudo, deve ser interpretada no nível da arquitetura completa: a GNN avaliada também contém ramo tabular, descritores derivados e mecanismos de fusão, de modo que seu desempenho não isola causalmente o efeito da topologia do grafo.

A lacuna científica abordada pela tese está, portanto, na avaliação integrada da relação entre informação calorimétrica, representação, capacidade do regressor, qualidade da calibração e custo computacional. A originalidade não é atribuída à criação de novos algoritmos genéricos de ML. Ela decorre da construção e da avaliação progressiva de uma metodologia comum de calibração baseada em anéis, capaz de comparar modelos convencionais, híbridos e neurais sem alterar a definição física da tarefa, e de caracterizar os compromissos de engenharia resultantes dessas escolhas.

1.3 Problema científico e escopo da tese

Considere, para o evento i, a estimativa rápida de energia transversa $E_{\text{fast}}^{(i)}$ e o vetor normalizado de energias dos anéis, denotado por $\widetilde{\mathbf{E}}_r^{(i)}$. Nesta tese, por convenção, E_{fast}, E_{true} e E_{calib} denotam grandezas de energia transversa, em conformidade com a notação consolidada nos estudos que constituem a base experimental do trabalho.

No *benchmark* adotado, E_{fast} é a estimativa de energia transversa obtida pela cadeia rápida de reconstrução calorimétrica utilizada como referência e denominada Standard FastCalo. A calibração investigada é aplicada sobre essa estimativa por meio de um fator multiplicativo; não se propõe a substituir a formação das células, a reconstrução do objeto calorimétrico ou a cadeia oficial de calibração de elétrons do experimento ATLAS.

A cadeia de estimação adotada nesta tese é organizada em dois mapeamentos conceitualmente distintos. O operador de representação $g_{\text{ML}}(\cdot)$ transforma os anéis normalizados em um vetor $\mathbf{x}^{(i)} = g_{\text{ML}}\left(\widetilde{\mathbf{E}}_r^{(i)}\right)$, que pode preservar a representação completa ou corresponder a uma representação compacta. A função treinada $f_{\text{ML}}(\cdot)$, obtida a partir do treinamento de modelos de ML específicos, recebe esse vetor e estima o fator multiplicativo $\alpha_{\text{calib}}^{(i)} = f_{\text{ML}}\left(\mathbf{x}^{(i)}\right)$, utilizado para obter $E_{\text{calib}}^{(i)} = \alpha_{\text{calib}}^{(i)} E_{\text{fast}}^{(i)}$.

No ambiente supervisionado de simulação, a referência para o treinamento é $\alpha_{\text{true}}^{(i)} = E_{\text{true}}^{(i)}/E_{\text{fast}}^{(i)}$, em que $E_{\text{true}}^{(i)}$ é a energia transversa da partícula gerada disponível no nível de verdade de Monte Carlo. Essa grandeza não existe como observável evento a evento em dados experimentais reais e não é utilizada como entrada durante a inferência. Transformações dependentes do alvo são ajustadas exclusivamente com os dados permitidos para desenvolvimento e posteriormente aplicadas sem acesso ao valor verdadeiro do novo evento.

A formulação matemática completa do problema, incluindo a distinção entre regressão do fator de calibração e regressão direta da energia, é estabelecida no Capítulo 3. O Capítulo 5 especifica posteriormente como essa formulação é operacionalizada e como os protocolos experimentais evoluem entre as três etapas da pesquisa.

Com base nessas definições, o problema científico central é formulado:

Como explorar a informação espacial do chuveiro eletromagnético, codificada por representações calorimétricas baseadas em anéis, para estimar fatores de correção evento a evento da energia transversa rápida de elétrons e caracterizar os compromissos entre qualidade da calibração, dimensionalidade da representação, capacidade do regressor e custo computacional?

O escopo experimental é deliberadamente controlado. A investigação utiliza aproximadamente 3×10^5 eventos de elétrons individuais produzidos por simulação de Monte Carlo com o Lorenzetti, em uma configuração calorimétrica inspirada no ATLAS e restrita à região de barril considerada no *benchmark*, com ruído eletrônico e *pile-up* incluídos (ARAÚJO et al., 2023; SILVA et al., 2026b; SILVA et al., 2026a). A presença de *pile-up* na amostra não equivale a uma demonstração de invariância frente a diferentes valores de μ, pois não foi realizada uma varredura controlada dessa variável.

As conclusões quantitativas dizem respeito ao desempenho relativo dos métodos nesse ambiente simulado. A tese não demonstra, por si só, transferência para dados experimentais reais, generalização para outras regiões ou outros detectores, robustez a regimes de *pile-up* não avaliados, redução da taxa de fundo de um menu de *trigger* ou atendimento à latência de ponta a ponta de uma cadeia operacional. Os tempos computacionais são tratados como *benchmarks* de predição dos modelos nas plataformas utilizadas, e não como demonstração de prontidão para implantação.

1.4 Hipótese de pesquisa

A hipótese central desta tese é que a distribuição estruturada dos depósitos de energia transversa de um chuveiro eletromagnético, quando codificada por uma representação baseada em anéis, contém informação utilizável para estimar correções evento a evento da energia transversa rápida. Consequentemente, é possível construir modelos supervisionados que, no domínio experimental considerado, produzam fatores de calibração capazes de reduzir o erro de reconstrução e a dispersão da resposta em relação ao Standard FastCalo.

A hipótese não pressupõe que uma família específica de regressão, uma representação particular ou uma arquitetura relacional seja universalmente superior. Admite-se, em vez disso, que diferentes combinações entre quantidade de informação preservada e capacidade do modelo produzam compromissos distintos entre precisão, compactação e custo computacional. A tese testa essa proposição por meio de uma sequência de estudos que preserva a mesma formulação geral de calibração e amplia progressivamente as representações e famílias de regressores.

O suporte empírico à hipótese é avaliado em dados não utilizados no ajuste final dos modelos e não depende de um único indicador. São considerados de forma complementar erro global, dispersão, resolução relativa de energia, estabilidade em diferentes regiões do detector e inferência estatística pareada. O comportamento próximo a limiares de seleção de eventos é tratado como análise complementar, pois sua interpretação operacional exige especificação inequívoca do procedimento de varredura e do ponto de operação, além da avaliação conjunta da eficiência de sinal e da taxa de fundo. Dessa forma, a conclusão sobre a hipótese decorre da

convergência de evidências de medição e de desempenho fora da amostra dentro do *benchmark*, e não apenas do valor da função de custo utilizada no treinamento.

1.5 Questões de pesquisa

A investigação é orientada pelas seguintes questões de pesquisa:

- **RQ1 — Informação e compactação:** em que medida a representação baseada em anéis fornece informação útil para a calibração evento a evento e quanto do desempenho pode ser preservado quando essa representação é reduzida por seleção ou extração de características?
- **RQ2 — Regressores convencionais:** como modelos lineares, polinomiais e baseados em árvores exploram as representações completa e compactas no problema de estimação do fator de calibração?
- **RQ3 — Aprendizado híbrido:** em que medida modelos baseados em correção residual e *stacked models* conseguem modelar estrutura remanescente dos regressores individuais e produzir ganho adicional de calibração?
- **RQ4 — Fusão neural:** como DNNs exploram a informação contida na representação completa e nas representações compactas, e como seu desempenho se compara ao das famílias de regressão anteriormente avaliadas?
- **RQ5 — Estrutura relacional:** como a arquitetura relacional–tabular completa se compara a uma DNN tabular sobre a mesma representação de 100 anéis, e que conclusões podem ser estabelecidas sem atribuir causalmente eventual diferença de desempenho à topologia do grafo isoladamente?
- **RQ6 — Compromissos de engenharia:** quais compromissos emergem entre erro de calibração, dispersão, resolução, estabilidade regional, dimensionalidade da entrada e custo de inferência nas diferentes configurações avaliadas?

1.6 Objetivos

1.6.1 Objetivo geral

Desenvolver e avaliar uma metodologia de calibração evento a evento da energia transversa rápida de elétrons em um calorímetro segmentado, utilizando representações do chuveiro eletromagnético baseadas em anéis e diferentes estratégias de seleção, extração e fusão de informação associadas a modelos de regressão convencionais, híbridos e neurais, de modo a caracterizar a qualidade da reconstrução e os compromissos entre desempenho, dimensionalidade e custo computacional no ambiente de referência considerado.

1.6.2 Objetivos específicos

Os objetivos específicos são:

1. **Formalização do problema:** definir a calibração da energia transversa rápida como um problema supervisionado de estimação de um fator multiplicativo de correção evento a evento, distinguindo explicitamente a referência Standard FastCalo, a verdade de Monte Carlo e a energia calibrada;

2. **Representação da informação:** caracterizar a representação calorimétrica de 100 anéis e investigar sua redução por seleção baseada em correlação e informação mútua e por extração baseada em PCA e ICA;

3. **Etapa I — regressores convencionais:** avaliar regressões lineares, polinomiais e modelos baseados em árvores sobre representações completas e compactas, incluindo a comparação entre treinamento global e segmentado no protocolo da primeira etapa;

4. **Etapa II — ensembles e aprendizado residual:** investigar *Random Forests*, correção residual e *stacked models*, quantificando o ganho incremental em relação aos melhores regressores individuais;

5. **Etapa III — fusão neural e relacional:** avaliar DNNs sobre representações completas e compactas e propor e avaliar uma arquitetura GNN relacional–tabular específica para a organização regional e local da representação calorimétrica em anéis;

6. **Avaliação da medição:** comparar as configurações por métricas complementares de erro, dispersão, resolução relativa de energia e estabilidade em regiões do detector, utilizando a análise próxima a limiares de seleção de eventos como diagnóstico complementar;

7. **Avaliação estatística e computacional:** preservar o pareamento entre eventos na inferência estatística, quantificar tamanho de efeito e estabilidade das diferenças observadas e caracterizar dimensionalidade e custo de predição sem confundir *benchmark* computacional com latência operacional; e

8. **Validade externa:** delimitar o domínio das conclusões, distinguindo resultados demonstrados em Monte Carlo de hipóteses sobre dados experimentais, diferentes regimes de *pile-up*, outras regiões do detector, taxa de fundo e implantação em uma cadeia real de *trigger*.

1.7 Contribuições científicas

A originalidade desta tese não é atribuída à proposição de novos algoritmos genéricos de ML. Regressões lineares e polinomiais, árvores de decisão, BDTs, *Random Forests*, DNNs e GNNs são técnicas estabelecidas. As contribuições decorrem da formulação e da avaliação progressiva de uma metodologia de calibração rápida baseada em informação calorimétrica estruturada, da comparação de diferentes níveis de representação sob uma mesma formulação de estimação e da caracterização dos compromissos de engenharia resultantes.

Essa distinção não exclui originalidade no nível arquitetural. Em particular, a Etapa III propõe uma arquitetura GNN relacional–tabular concebida especificamente para a representação Ringer e para a organização regional do sistema calorimétrico considerado. A contribuição não consiste em propor um novo operador genérico de GNN, mas em combinar, de forma orientada

pela estrutura do detector (*detector-informed*), grafos regionais, propagação local de mensagens, operações de agregação (*pooling*), descritores derivados, processamento tabular, conexões de atalho e fusão final para a estimação do fator de calibração.

Assim, as principais contribuições científicas são:

1. **Consolidação de uma formulação comum de calibração baseada em anéis.** A tese organiza a sequência medição segmentada–representação Ringer–transformação por $g_{\mathrm{ML}}(\cdot)$–regressão por $f_{\mathrm{ML}}(\cdot)$–correção multiplicativa de E_{fast}. Essa formulação permite alterar representação e regressor sem alterar a definição física da tarefa e torna rastreável a evolução das três etapas experimentais.

2. **Caracterização sistemática da informação e da compactação.** A Etapa I demonstrou que a representação em anéis pode reduzir substancialmente o erro da energia rápida e que uma BDT com PCA alcançou redução de 58,44% no RMSE usando somente dez componentes (SILVA et al., 2026b). A análise conjunta das etapas mostrou que configurações com cinco ou dez entradas permanecem competitivas, embora a representação completa seja favorecida quando se busca desempenho absoluto máximo.

3. **Quantificação do valor incremental do aprendizado residual.** A Etapa II mostrou que uma *Random Forest* com resíduos tratados por uma BDT nos 100 anéis atingiu redução de 60,61% no RMSE e melhora de 44,96% na resolução relativa (SILVA et al., 2026a). Entretanto, a BDT completa já atingia redução de 60,17% no RMSE e IQR ligeiramente menor. Assim, os resultados são compatíveis com a existência de estrutura residual explorável pela arquitetura avaliada, mas mostram que o retorno da complexidade adicional é incremental e dependente da métrica.

4. **Extensão para fusão neural em representações completas e compactas.** A Etapa III mostrou que DNNs podem explorar eficazmente os dois regimes de representação. A DNN completa apresentou redução de 63,72% no RMSE, enquanto a DNN com ICA preservou redução de 55,76% utilizando dez componentes. Esses resultados ampliam a investigação de capacidade de regressão sem modificar a formulação geral de calibração.

5. **Proposição e avaliação de uma arquitetura GNN relacional–tabular específica para a calibração calorimétrica.** A Etapa III propõe e implementa uma arquitetura original no nível de sua composição para explorar a estrutura da representação Ringer. Os 100 anéis são organizados segundo regiões calorimétricas, relações locais são processadas por uma ramificação em grafo e a informação global é preservada por uma ramificação tabular com descritores derivados, sendo ambas combinadas na estimação final do fator de calibração. A configuração GNN relacional–tabular aos 100 anéis apresentou o menor RMSE da Etapa III. A originalidade da arquitetura, contudo, não é utilizada como evidência de que a topologia do grafo isoladamente cause o ganho observado nem de que GNNs sejam universalmente superiores às DNNs.

6. **Ampliação da avaliação para um problema de engenharia multidimensional.** A tese integra RMSE, IQR, métricas compostas, resolução relativa, estabilidade regional,

inferência estatística pareada, dimensionalidade e custo de predição, separando métricas físicas, estatísticas e computacionais. A síntese final mostra que não existe uma configuração dominante para todos os critérios: modelos completos e expressivos favorecem máxima precisão, enquanto representações compactas preservam parcela substancial do ganho com menor dimensionalidade.

1.8 Publicações associadas à tese

A pesquisa foi desenvolvida de forma incremental. Trabalhos apresentados em congressos contribuíram para a exploração inicial do problema de calibração e para o uso de informação calorimétrica estruturada em modelos baseados em árvores (SIMAS FILHO et al., 2021; ALVES, A. S. O.; SILVA, P. R. A.; SIMAS FILHO, E. F. et al., 2023; ALVES, A. S. O.; SILVA, P. R. A.; SIMAS FILHO, E. F. et al., 2024). A partir dessa base, os resultados centrais da tese foram organizados em três estudos de periódico correspondentes a etapas sucessivas da investigação.

1. **Machine Learning for Energy Calibration in High Energy Physics Experiments Using the Lorenzetti Showers Framework.** Publicado em 2026 na *IEEE Transactions on Nuclear Science*. O trabalho estabelece a primeira avaliação sistemática desta tese envolvendo seleção e extração de características e diferentes modelos de regressão para estimação do fator de calibração (SILVA et al., 2026b).

2. **Hybrid tree-based machine learning for calorimetric energy calibration using the Lorenzetti Showers framework.** Publicado em 2026 na revista *Measurement*. O estudo estende a metodologia para *Random Forests*, aprendizado residual e *stacked models* e amplia o protocolo de avaliação física, estatística e computacional (SILVA et al., 2026a).

3. **Multi-Stage Neural Information Fusion for Fast Energy Calibration in Segmented Particle-Detector Calorimeters.** Manuscrito submetido à revista *Information Fusion*. O estudo constitui a etapa metodologicamente mais abrangente da pesquisa e estende a cadeia de calibração para DNNs e para uma arquitetura GNN relacional–tabular, além de consolidar a interpretação da tarefa como fusão de informação em múltiplos estágios (SILVA; SIMAS FILHO, 2026).

A evolução do desenho experimental ocorre principalmente nas representações avaliadas, nas famílias de regressores, no abandono do treinamento segmentado após a Etapa I e na ampliação das métricas físicas, estatísticas e computacionais.

1.9 Organização da tese

Além deste capítulo introdutório, a tese está organizada da seguinte forma:

- **Capítulo 2 — Calorimetria e Reconstrução Rápida de Energia em Física de Altas Energias:** apresenta os fundamentos físicos e instrumentais necessários à compreensão do problema, incluindo o LHC e o ATLAS como contexto de referência, sistema de coordenadas,

calorimetria segmentada, formação de sinais e células, reconstrução de objetos calorimétricos, ruído, *pile-up*, seleção online e representação Ringer.

- **Capítulo 3 — Formulação da Calibração e Representação da Informação Calorimétrica:** estabelece a formulação matemática comum do problema de calibração, separando o operador de representação $g_{\mathrm{ML}}(\cdot)$ da função de regressão $f_{\mathrm{ML}}(\cdot)$, e apresenta as estratégias de representação completa, seleção de características por CORR e MUTI e extração de características por PCA e ICA.

- **Capítulo 4 — Modelos de Regressão e Fusão de Informação para Calibração Calorimétrica:** apresenta as famílias utilizadas para implementar $f_{\mathrm{ML}}(\cdot)$, incluindo regressões convencionais, árvores e ensembles, aprendizado residual, modelos empilhados (*stacked models*), DNNs e a arquitetura GNN relacional–tabular, além da interpretação da cadeia sob a perspectiva de fusão de informação e dos compromissos de complexidade, generalização e custo computacional.

- **Capítulo 5 — Metodologia Experimental Unificada:** operacionaliza a formulação estabelecida nos capítulos anteriores, descreve o ambiente Lorenzetti e o conjunto de dados, especifica as representações efetivamente avaliadas, estabelece os procedimentos de treinamento, validação e prevenção de vazamento de informação e explicita as diferenças de protocolo entre as três etapas experimentais.

- **Capítulo 6 — Calibração com Modelos Convencionais e Redução de Dimensionalidade:** apresenta a Etapa I, publicada na *IEEE Transactions on Nuclear Science*, e estabelece a viabilidade da calibração baseada em anéis e da compactação da representação.

- **Capítulo 7 — Calibração com Ensembles e Aprendizado Residual:** apresenta a Etapa II, publicada na revista *Measurement*, quantifica o ganho incremental dos modelos híbridos e amplia a avaliação para resolução relativa, estabilidade regional, estatística pareada e custo de predição.

- **Capítulo 8 — Calibração Neural e Fusão de Informação:** apresenta a Etapa III, com DNNs completas e compactas e a arquitetura GNN relacional–tabular, comparando desempenho global, resolução, estabilidade regional, representações compactas e custo de predição, além da comparação entre as arquiteturas DNN e GNN.

- **Capítulo 9 — Síntese, Discussão e Conclusões:** integra quantitativamente as três etapas, responde às seis questões de pesquisa, avalia a hipótese central e os objetivos, consolida as contribuições, delimita o alcance das conclusões e organiza as perspectivas de validação em dados reais, diferentes condições de *pile-up*, validação ressonante e implantação.

2 Calorimetria e Reconstrução Rápida de Energia em Física de Altas Energias

Este capítulo apresenta os fundamentos físicos, instrumentais e computacionais necessários para compreender o problema de calibração investigado nesta tese. O objetivo não é realizar uma revisão exaustiva da Física de Partículas, mas estabelecer a cadeia causal que conecta a produção de elétrons em colisões de altas energias à formação de sinais em células calorimétricas, à reconstrução de objetos eletromagnéticos e à seleção online. Essa organização é particularmente importante no contexto desta tese, pois a representação em anéis utilizada pelos modelos de calibração não constitui uma medição independente: ela é construída a partir de sinais de células previamente reconstruídos e organizados segundo a segmentação longitudinal e transversal do calorímetro.

A discussão adota o experimento ATLAS como cenário experimental de referência e distingue, ao longo do texto, três níveis conceituais que não devem ser confundidos: o detector e a cadeia de reconstrução do ATLAS; a representação Ringer empregada na seleção online de elétrons; e o ambiente Lorenzetti utilizado posteriormente como *benchmark* aberto para os estudos de calibração desta tese. As grandezas calorimétricas básicas, a convenção para as energias transversais e a representação Ringer são introduzidas neste capítulo. A formulação matemática da calibração, incluindo o fator multiplicativo e os operadores de representação e regressão, é estabelecida no Capítulo 3. O Capítulo 5 detalha o uso dessas grandezas no *benchmark* Lorenzetti, o conjunto de dados e o protocolo experimental.

2.1 Contexto físico da medição de elétrons

O Modelo Padrão (MP) descreve as interações eletromagnética, fraca e forte entre as partículas elementares conhecidas, organizadas em férmions e bósons de calibre, juntamente com o setor de Higgs (GRIFFITHS, 2008; PERKINS, 2009; ARBUZOV, 2017). A gravitação não faz parte do Modelo Padrão. A Figura 1 apresenta uma representação resumida do conteúdo de partículas da teoria.

Entre os léptons carregados, o elétron é especialmente relevante para esta tese porque produz chuveiros predominantemente eletromagnéticos e tem sua energia medida principalmente no calorímetro eletromagnético. Elétrons aparecem em estados finais de processos envolvendo os bósons W, Z e Higgs e também em buscas por ressonâncias ou processos além do Modelo Padrão (ATLAS Collaboration, 2012; ATLAS Collaboration, 2019b; GRAY, 2021). A descoberta do bóson de Higgs pelos experimentos ATLAS e CMS ilustra a importância da reconstrução precisa de objetos eletromagnéticos em análises de altas energias (ATLAS Collaboration, 2012; CMS Collaboration, 2012).

Além disso, como a massa da ressonância $Z \to e^+e^-$, $m_Z = 91{,}1879 \pm 0{,}0020$ GeV, é

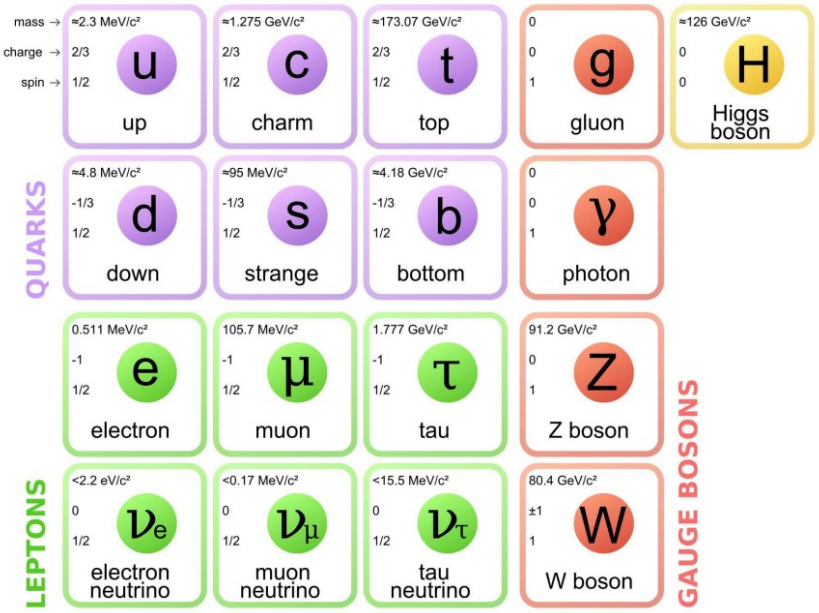


Figura 1 – Modelo Padrão da Física de Partículas. Fonte: (ARBUZOV, 2017).

conhecida com elevada precisão, a distribuição da massa invariante reconstruída do par e^+e^- fornece uma referência experimental para estudos de escala e resolução de energia de elétrons (PERKINS, 2009; TAKAHASHI et al., 2026). Esse canal, $Z \to e^+e^-$, é empregado em procedimentos de calibração e validação do ATLAS, inclusive em medições de eficiência baseadas em *tag-and-probe* [1] (ATLAS Collaboration, 2020; ATLAS Collaboration, 2024a). Consequentemente, a qualidade da calibração de energia influencia não apenas a escala de uma variável isolada, mas também observáveis físicos compostos, como massas invariantes.

A existência de canais como $Z \to e^+e^-$ não implica que um conjunto de treinamento de calibração deva ser restrito a essa topologia. Como será discutido no Capítulo 5, a utilização de elétrons individuais em uma ampla região cinemática permite estudar a função de calibração sob condições controladas, enquanto amostras ressonantes constituem uma etapa distinta de validação física. Essa separação é importante para não confundir cobertura do espaço de treinamento com validação em processos físicos específicos.

2.2 O LHC e o experimento ATLAS

2.2.1 *Large Hadron Collider*

O *Large Hadron Collider* (LHC), instalado no CERN, é um acelerador e colisor de partículas com aproximadamente 27 km de circunferência (EVANS; BRYANT, 2008; BRÜNING; BURKHARDT; MYERS, 2012). É o LHC que acelera e conduz os feixes em sentidos opostos e os faz colidir em pontos de interação específicos. O projeto foi concebido para colisões próton–próton com energia de centro de massa de até 14 TeV; durante a Run 3, o LHC operou com energia de

[1] O método *tag-and-probe* utiliza tipicamente um decaimento ressonante, como $Z \to e^+e^-$, no qual um dos elétrons (*tag*) é selecionado com requisitos rigorosos para identificar o evento, enquanto o segundo (*probe*) é utilizado para medir, com reduzido viés de seleção, a eficiência de reconstrução, identificação ou *trigger* sob estudo.

centro de massa de 13,6 TeV (BRÜNING; BURKHARDT; MYERS, 2012; ATLAS Collaboration, 2024b). O espaçamento nominal de 25 ns entre pacotes corresponde a uma frequência máxima de cruzamento de feixes de 40 MHz.

A Figura 2 apresenta esquematicamente a instalação subterrânea e alguns dos experimentos localizados nos pontos de colisão.

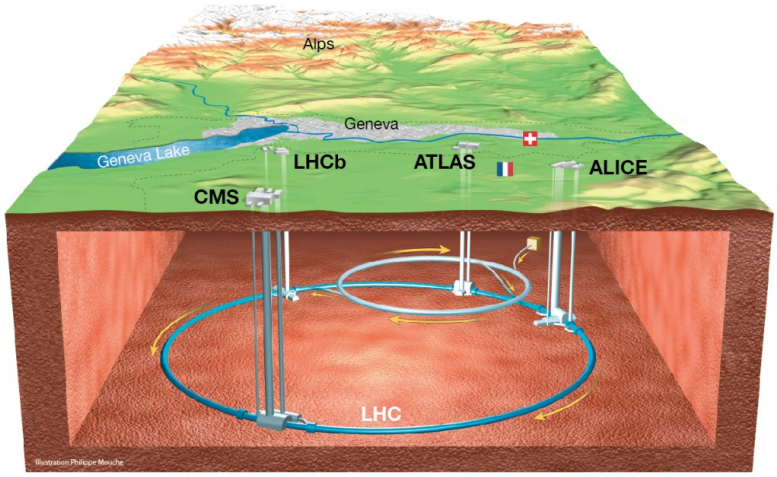


Figura 2 – Representação gráfica da instalação subterrânea do LHC no CERN e de alguns experimentos localizados em pontos de colisão. Fonte: (EVANS; BRYANT, 2008).

Os detectores instalados no LHC foram desenvolvidos para objetivos complementares. ATLAS e CMS são detectores de propósito geral; ALICE é especializado no estudo de matéria fortemente interagente em colisões de íons pesados; LHCb investiga, entre outros temas, física de hádrons contendo quarks pesados; e experimentos como TOTEM, LHCf e MoEDAL exploram regimes cinemáticos ou assinaturas mais específicas (ALICE Collaboration, 2008; LHCb Collaboration, 2008; TOTEM Collaboration, 2008; TIBERIO; on behalf of the LHCf Collaboration, 2023; MITSOU; on behalf of the MoEDAL Collaboration, 2017). Para esta tese, o ATLAS é utilizado como referência por sua calorimetria finamente segmentada, sua cadeia de seleção online de elétrons e o uso consolidado de representações Ringer.

2.2.2 Visão geral do detector ATLAS

O ATLAS (*A Toroidal LHC ApparatuS*) é um detector de propósito geral organizado aproximadamente em camadas concêntricas em torno do ponto de interação (ATLAS Collaboration, 2008). A Figura 3 apresenta seus principais subsistemas.

Do ponto de vista funcional, o detector pode ser dividido em três grandes sistemas de medição. O detector interno mede posições de partículas carregadas em sucessivas camadas e permite a reconstrução de trajetórias (*tracks*) e momentos em presença do campo do solenóide. Os vértices de interação não são medidos por um sensor de vértice independente: eles são inferidos a partir da compatibilidade espacial de conjuntos de trajetórias reconstruídas. Os calorímetros eletromagnético e hadrônico medem a energia depositada por chuveiros de partículas. Externamente, o espectrômetro de múons mede trajetórias de múons em um sistema magnético toroidal (ATLAS Collaboration, 2008).

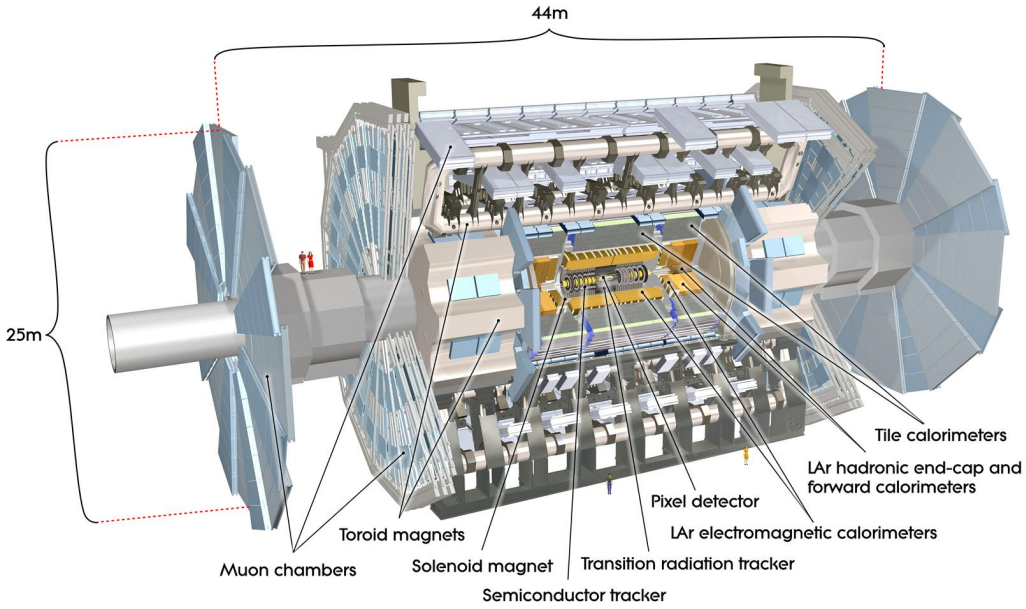


Figura 3 – Representação gráfica do detector ATLAS e de seus principais subsistemas. Fonte: (ATLAS Collaboration, 2008).

Essa distinção é relevante para a reconstrução de elétrons. Um candidato a elétron combina informação calorimétrica associada ao chuveiro eletromagnético com informação de uma trajetória carregada no detector interno. Na etapa rápida do HLT, entretanto, parte da seleção pode ser realizada inicialmente apenas com informação calorimétrica, reduzindo o número de candidatos que necessitam de etapas de rastreamento computacionalmente mais custosas (ATLAS Collaboration, 2020; ORELLANA; ATLAS Collaboration, 2021).

2.2.3 Sistema de coordenadas

Antes de detalhar a calorimetria, é conveniente definir o sistema de coordenadas utilizado no ATLAS. A origem é tomada no ponto nominal de interação; o eixo z é aproximadamente coincidente com a direção dos feixes, o eixo x aponta do ponto de interação para o centro do anel do LHC e o eixo y aponta verticalmente para cima. No plano transversal ao feixe utiliza-se o ângulo azimutal ϕ. O ângulo polar θ é medido a partir do eixo z (ATLAS Collaboration, 2008; SIMAS FILHO, 2010).

A pseudorapidez é definida por

$$\eta = -\ln\left[\tan\left(\frac{\theta}{2}\right)\right]. \tag{2.1}$$

Essa variável é particularmente útil em colisores hadrônicos porque diferenças de pseudorapidez são aproximadamente invariantes sob transformações de Lorentz longitudinais para partículas ultrarrelativísticas (PERKINS, 2009). A energia transversa de um objeto com energia E e direção polar θ pode ser escrita como

$$E_T = E \sin\theta = \frac{E}{\cosh\eta}. \tag{2.2}$$

A Figura 4 ilustra o sistema de coordenadas empregado ao longo desta tese.

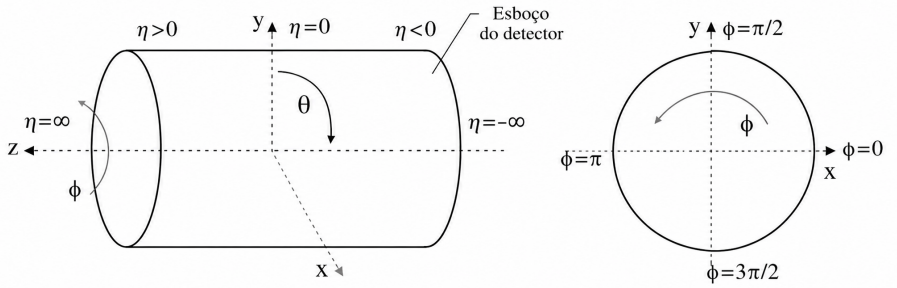


Figura 4 – Sistema de coordenadas empregado no experimento ATLAS. Fonte: (SIMAS FILHO, 2010).

2.3 Calorimetria no ATLAS

2.3.1 Princípio de medição calorimétrica

Um calorímetro não mede diretamente "a energia de uma partícula" como uma entidade independente. A partícula incidente interage com o material do detector e inicia uma cascata de partículas secundárias, também chamada de chuveiro de partículas. Parte da energia dessa cascata é convertida em sinais mensuráveis no meio ativo. A energia da partícula incidente é então estimada a partir da resposta conjunta das células instrumentadas (WIGMANS, 2018). A Figura 5 ilustra qualitativamente a resposta de diferentes subsistemas do detector a diferentes tipos de partículas.

Para elétrons e fótons, o desenvolvimento do chuveiro é dominado por bremsstrahlung [2] e produção de pares, levando a uma cascata eletromagnética cuja extensão longitudinal é naturalmente descrita em comprimentos de radiação X_0. Para hádrons, processos nucleares produzem chuveiros de natureza distinta, caracterizados em termos do comprimento de interação nuclear. A separação entre calorímetros eletromagnético e hadrônico explora essas diferenças físicas e tecnológicas (WIGMANS, 2018; ATLAS Collaboration, 2008).

A Figura 6 apresenta a organização geral do sistema calorimétrico do ATLAS.

2.3.2 Calorímetro eletromagnético de argônio líquido

O calorímetro eletromagnético do ATLAS é um calorímetro de amostragem que utiliza chumbo como absorvedor e argônio líquido (LAr) como meio ativo (ATLAS Collaboration, 2008; ATLAS Collaboration, 2011). Ele é dividido em uma região de barril (EMB) e duas regiões de tampa (EMEC). A cobertura do barril eletromagnético estende-se até aproximadamente $|\eta| = 1{,}475$, enquanto as tampas cobrem aproximadamente $1{,}375 < |\eta| < 3{,}2$, com regiões

[2] *Bremsstrahlung*, ou radiação de frenagem, é a emissão de fótons por uma partícula carregada ao sofrer aceleração ou deflexão no campo eletromagnético da matéria. Para elétrons de alta energia, constitui um dos principais mecanismos de desenvolvimento do chuveiro eletromagnético (WIGMANS, 2018).

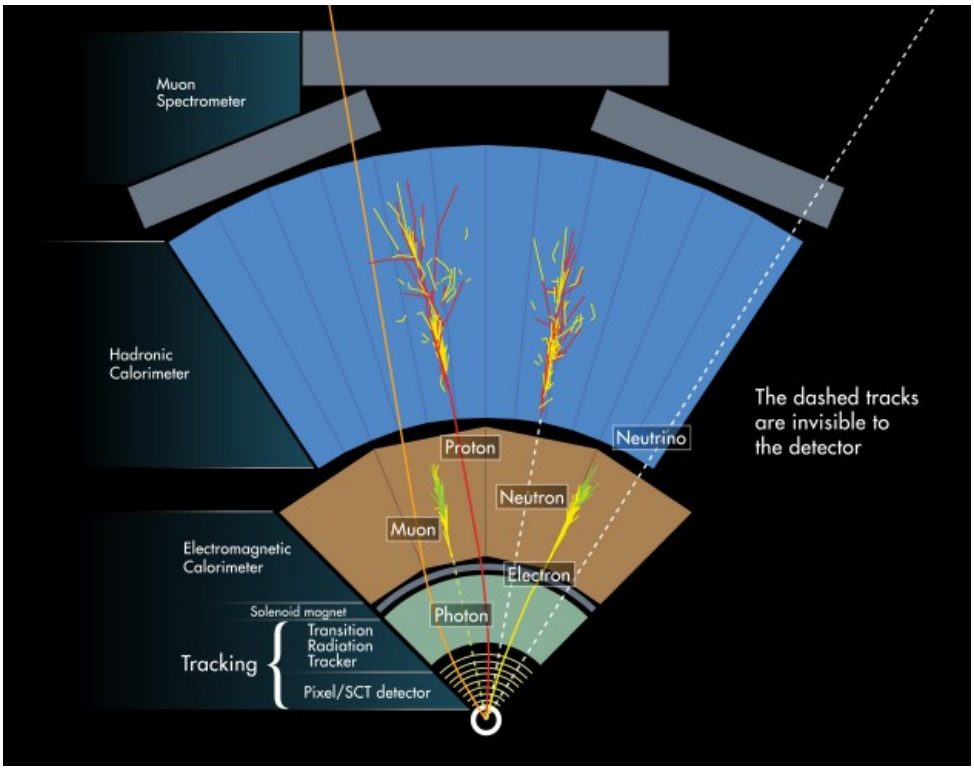


Figura 5 – Representação esquemática do desenvolvimento e da detecção de diferentes tipos de partículas nos subsistemas do detector. Fonte: (PEQUENAO; SCHAFFNER, 2013).

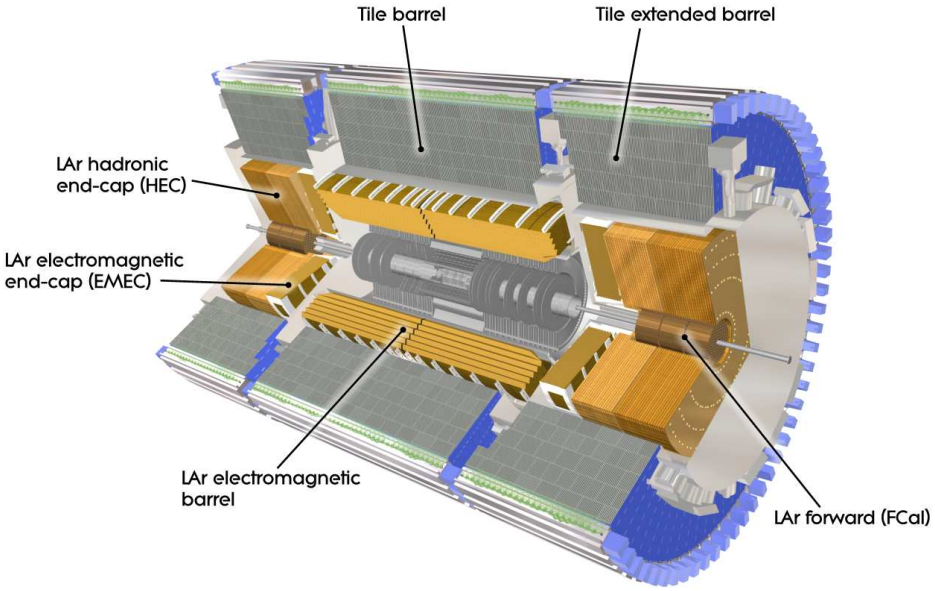


Figura 6 – Representação gráfica da composição do sistema de calorimetria do ATLAS. Fonte: (ATLAS Collaboration, 2008).

de transição entre subsistemas. Um pré-amostrador (*presampler*, PS) é utilizado em parte da aceitação para estimar e corrigir energia perdida em material anterior ao calorímetro (ATLAS Collaboration, 2008; ATLAS Collaboration, 2011).

A geometria em acordeão dos absorvedores e eletrodos fornece continuidade em ϕ e permite uma segmentação transversal e longitudinal fina. A Figura 7 mostra esquematicamente as camadas do calorímetro eletromagnético e sua geometria.

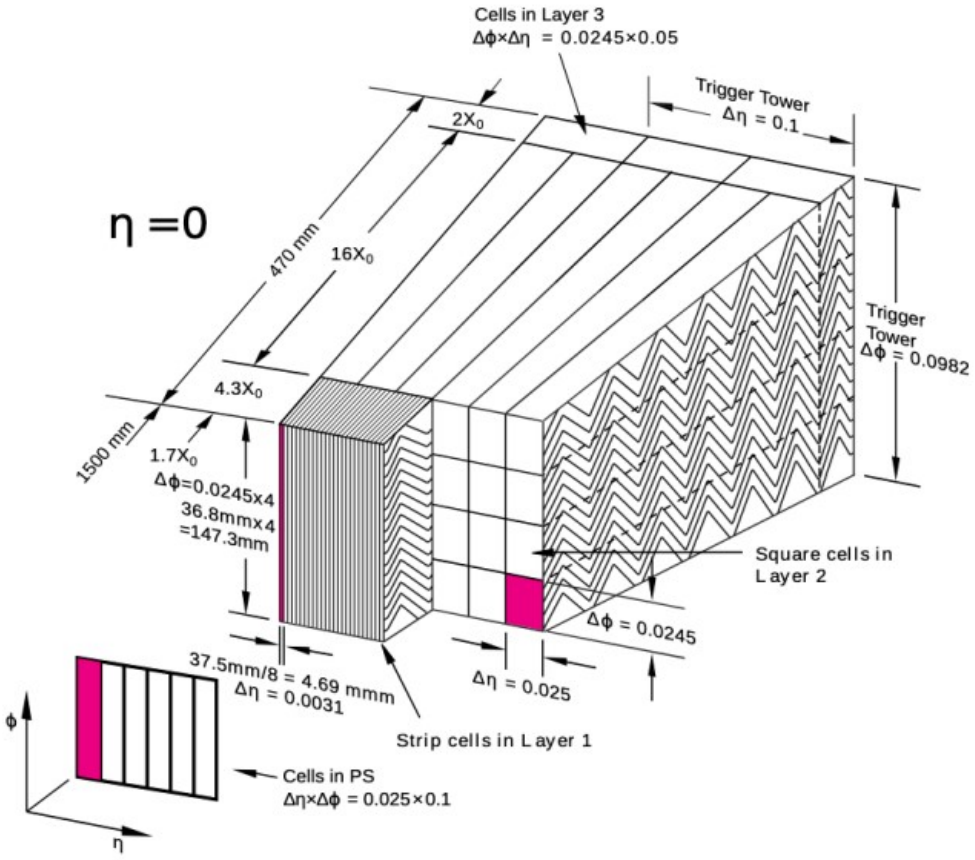


Figura 7 – Representação das camadas do calorímetro eletromagnético e da geometria em acordeão. Fonte: (GABALDóN; on behalf of the ATLAS LAr Collaboration, 2009).

Além do pré-amostrador, o calorímetro eletromagnético possui três amostragens longitudinais. A primeira camada é finamente segmentada em η e fornece informação detalhada sobre o desenvolvimento lateral inicial do chuveiro; a segunda concentra a maior fração da energia depositada por elétrons e fótons; e a terceira amostra a parte final do chuveiro, contribuindo para a caracterização de sua profundidade e de possíveis perdas longitudinais (ATLAS Collaboration, 2008; ATLAS Collaboration, 2011). Essa organização em camadas é essencial para a representação Ringer discutida na Seção 2.7, porque os anéis são construídos separadamente sobre diferentes amostragens calorimétricas.

Quando o chuveiro atravessa os espaços preenchidos com LAr, as partículas carregadas ionizam o meio. O movimento das cargas de ionização sob o campo elétrico produz pulsos de corrente, posteriormente conformados, amplificados e digitalizados. Dessa forma, a unidade elementar de informação para a reconstrução não é o cluster, mas o sinal de uma célula calorimétrica.

Clusters e representações em anéis são construídos somente após a reconstrução dessas células.

2.3.3 Calorimetria hadrônica

Na região central, a calorimetria hadrônica é realizada predominantemente pelo TileCal, um calorímetro de amostragem formado por absorvedores de aço e telhas de cintilador plástico (ATLAS Collaboration, 2010; ATLAS Collaboration, 2018). A luz produzida no cintilador é conduzida por fibras deslocadoras de comprimento de onda a fotomultiplicadoras, que convertem o sinal óptico em sinal elétrico. A Figura 8 apresenta um módulo típico.

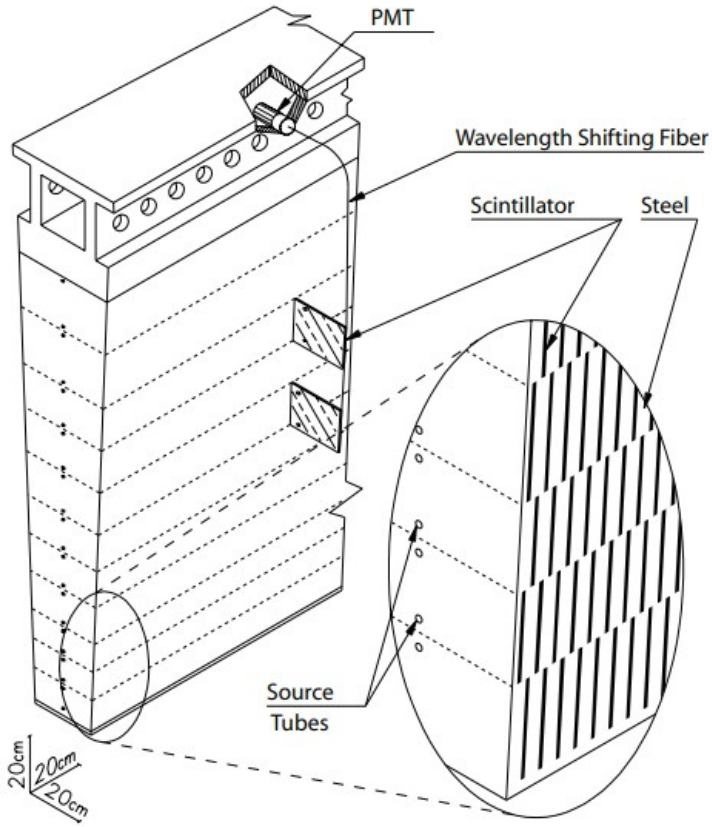


Figura 8 – Representação gráfica de um módulo do TileCal. Fonte: (ATLAS Collaboration, 2018).

Nas regiões de maior pseudorapidez, o calorímetro hadrônico de tampa (HEC) utiliza placas de cobre como absorvedor e LAr como meio ativo. O calorímetro frontal (FCal) também utiliza LAr, com um primeiro módulo predominantemente eletromagnético baseado em cobre e módulos hadrônicos de alta densidade baseados em tungstênio (ATLAS Collaboration, 2008). Essa distinção de materiais é importante porque a resposta, a granularidade, o ruído e o desenvolvimento longitudinal dos chuveiros dependem da tecnologia e da região do detector.

A Tabela 1 resume a segmentação e a granularidade de diferentes regiões calorimétricas utilizadas como referência neste capítulo.

A segmentação não é uniforme em todo o detector. Consequentemente, uma mesma distância em índices de células não representa necessariamente a mesma área em (η, ϕ) em todas as camadas. Essa característica deve ser considerada ao interpretar representações compactas do

Tabela 1 – Região de cobertura em η, granularidade das células e camadas do sistema calorimétrico do ATLAS. Fonte: (ATLAS Collaboration, 2008).

Camada	Amostrador		Cobertura	Granularidade ($\Delta\eta \times \Delta\phi$)
Pré-amostrador	Barril	PSB	$0,00 < \|\eta\| < 1.58$	0,025×0,1
	Tampa	PSE	$1,50 < \|\eta\| < 1,80$	0,025×0,1
Calorímetro Eletromagnético				
Camada 1	Barril	EMB1	$0,00 < \|\eta\| < 1.55$	0,003×0,1
	Tampa	EMEC1	$1,37 < \|\eta\| < 1.80$	0,003×0,1
			$1,80 < \|\eta\| < 2,00$	0,025×0,1
			$2,00 < \|\eta\| < 2,37$	0,006×0,1
			$2,37 < \|\eta\| < 3,20$	0,1×0,1
Camada 2	Barril	EMB2	$0,00 < \|\eta\| < 1,50$	0,025×0,025
	Tampa	EMEC2	$1,35 < \|\eta\| < 2,50$	0,025×0,025
			$2,50 < \|\eta\| < 3,20$	0,1×0,1
Camada 3	Barril	EMB3	$0,00 < \|\eta\| < 1.58$	0,05×0,1
	Tampa	EMEC3	$1,35 < \|\eta\| < 2,50$	0,05×0,025
			$2,50 < \|\eta\| < 3,20$	0,1×0,1
Calorímetro Hadrônico				
Camada 1	Barril	TileCal1	$0,00 < \|\eta\| < 1,09$	0,1×0,1
	Barril Extendido	TileExt1	$0,94 < \|\eta\| < 1,77$	0,1×0,1
	Tampa	HEC1	$1,50 < \|\eta\| < 2,50$	0,1×0,1
			$2,50 < \|\eta\| < 3,20$	0,2×0,2
Camada 2	Barril	TileCal2	$0,00 < \|\eta\| < 1,09$	0,1×0,1
	Barril Extendido	TileExt2	$0,85 < \|\eta\| < 1,41$	0,1×0,1
	Tampa	HEC2	$1,50 < \|\eta\| < 2,50$	0,1×0,1
			$2,50 < \|\eta\| < 3,20$	0,2×0,2
Camada 3	Barril	TileCal3	$0,85 < \|\eta\| < 0,72$	0,2×0,1
	Barril Extendido	TileExt3	$0,85 < \|\eta\| < 1,41$	0,2×0,1
	Tampa	HEC3	$1,50 < \|\eta\| < 2,50$	0,1×0,1
			$2,50 < \|\eta\| < 3,20$	0,2×0,2

chuveiro e constitui uma das razões pelas quais o Ringer utiliza uma construção específica por camada.

2.4 Da amostra digital à energia reconstruída

2.4.1 Células calorimétricas como unidades de medição

A reconstrução de energia começa no nível de células. Para uma célula k, o circuito de leitura produz um pulso conformado que é amostrado digitalmente em instantes discretos. Em uma representação linear simplificada, o vetor de amostras pode ser escrito como

$$\mathbf{S}_k = A_k\mathbf{f} + \mathbf{n}_k, \tag{2.3}$$

em que A_k é a amplitude do pulso, $\mathbf{f}$ representa a forma temporal nominal do sinal amostrado e $\mathbf{n}_k$ representa as contribuições de ruído. A forma de pulso e a matriz de covariância do ruído são propriedades da cadeia de leitura e das condições de operação (ATLAS Collaboration, 2011).

Uma estimativa linear de mínima variância para a amplitude pode ser expressa como

$$\widehat{A}_k = \mathbf{w}^T \mathbf{S}_k, \tag{2.4}$$

com a restrição de ganho unitário $\mathbf{w}^T\mathbf{f} = 1$. Se $\mathbf{N}$ representa a matriz de covariância do ruído, os pesos do filtro ótimo, na forma idealizada de uma única restrição, são

$$\mathbf{w} = \frac{\mathbf{N}^{-1}\mathbf{f}}{\mathbf{f}^T\mathbf{N}^{-1}\mathbf{f}}. \tag{2.5}$$

A expressão acima representa deliberadamente uma forma idealizada com restrição de ganho unitário. Implementações completas de Filtro Ótimo em sistemas calorimétricos podem incorporar restrições adicionais associadas, por exemplo, à derivada temporal da forma de pulso, reduzindo a sensibilidade a deslocamentos de fase, e ao tratamento do nível de pedestal (ATLAS Collaboration, 2011; ATLAS Collaboration, 2010). Esses detalhes dependem da eletrônica e do procedimento de reconstrução do subsistema e não constituem parâmetros ajustados pelos modelos de calibração desta tese.

A conversão da amplitude reconstruída para energia requer constantes de calibração da cadeia eletrônica e da célula. Assim, de forma esquemática, a energia da célula k pode ser expressa como

$$E_{\mathrm{cell},k} = C_k \widehat{A}_k, \tag{2.6}$$

em que C_k representa os fatores de conversão e calibração pertinentes. As Eqs. 2.3–2.6 são utilizadas neste capítulo para explicitar o fluxo de processamento do sinal, portanto, elas não pretendem substituir a implementação completa da reconstrução de células do ATLAS, que inclui detalhes adicionais de pedestal, ganho, temporização, condições e calibrações (ATLAS Collaboration, 2011; ATLAS Collaboration, 2008).

Além do ruído próprio de cada canal, acoplamentos eletrônicos ou capacitivos podem produzir *cross-talk* entre canais vizinhos. Esse efeito é relevante porque altera correlações espaciais no nível de células antes da formação de clusters ou anéis. No calorímetro de argônio líquido do ATLAS, medidas do sistema de leitura mostram contribuição de *cross-talk* entre canais vizinhos, associada tanto à eletrônica quanto a acoplamentos capacitivos na própria estrutura calorimétrica (ATLAS Collaboration, 2011; ABREU et al., 2010). No ambiente Lorenzetti, esse tipo de efeito pode ser modelado explicitamente (ARAÚJO et al., 2023).

2.4.2 De células a clusters e energia transversa

Após a reconstrução das células, algoritmos de agrupamento combinam depósitos espacialmente relacionados em objetos calorimétricos. Em uma representação genérica, a energia bruta de um *cluster* $\mathcal{C}$ pode ser escrita como

$$E_{\mathrm{raw}} = \sum_{k \in \mathcal{C}} E_{\mathrm{cell},k}. \tag{2.7}$$

A escolha das células que pertencem a $\mathcal{C}$ depende do algoritmo e da etapa de reconstrução. Portanto, a Eq. 2.7 define a operação de agregação, mas não implica uma janela geométrica única ou fixa para todas as versões do *trigger*.

A energia transversa associada à célula k é obtida a partir de sua energia e pseudorapidez η_k,

$$E_{\mathrm{T},k} = \frac{E_{\mathrm{cell},k}}{\cosh \eta_k}. \tag{2.8}$$

No *benchmark* adotado nesta tese, a estimativa rápida de energia transversa associada ao objeto calorimétrico reconstruído $\mathcal{C}$, denominada *Standard FastCalo*, é calculada por

$$E_{\mathrm{T,fast}} = \frac{E_{\mathrm{raw}}}{\cosh \eta_{\mathrm{cluster}}}, \tag{2.9}$$

em que E_{raw} e η_{cluster} são grandezas reconstruídas. Consequentemente, $E_{\mathrm{T,fast}}$ também é uma grandeza reconstruída e não deve ser confundida com a energia transversa de verdade da partícula gerada em simulação, $E_{\mathrm{T,true}}$ (SILVA et al., 2026b; SILVA et al., 2026a).

Ao longo desta tese, adota-se a notação simplificada E_{true}, E_{fast} e E_{calib}, correspondentes, respectivamente, a $E_{\mathrm{T,true}}$, $E_{\mathrm{T,fast}}$ e $E_{\mathrm{T,calib}}$. O subscrito T é omitido nessas três grandezas para manter compatibilidade com a notação consolidada nos estudos associados (SILVA et al., 2026b; SILVA et al., 2026a). Nessa convenção, E_{calib} denota a energia transversa após a aplicação da correção proposta, cuja definição matemática é estabelecida no Capítulo 3.

A distinção entre essas grandezas é essencial. E_{true} pertence ao nível de verdade da simulação e não é reconstruída a partir de E_{raw} ou de η_{cluster}. Por sua vez, E_{fast} é uma grandeza reconstruída fornecida pela cadeia rápida utilizada como referência no domínio considerado e não deve ser interpretada como uma descrição completa da cadeia oficial de reconstrução e calibração de elétrons do ATLAS (ATLAS Collaboration, 2024a). Os detalhes do *benchmark* Lorenzetti, do conjunto de dados e do protocolo de avaliação são apresentados no Capítulo 5.

2.5 Ruído, *pile-up*, vazamento e dependências da resposta

A energia reconstruída em uma célula ou *cluster* é afetada por mais de uma fonte de flutuação. O ruído eletrônico decorre da cadeia de leitura e pode ser correlacionado temporalmente ou entre canais. O desenvolvimento estocástico do chuveiro produz flutuações físicas mesmo para partículas com a mesma energia incidente. A segmentação e a quantidade finita de material instrumentado podem ainda fazer com que parte da energia não seja incluída no conjunto de células utilizado na reconstrução (WIGMANS, 2018; ATLAS Collaboration, 2011).

Nesta tese, o termo "vazamento" é utilizado para descrever energia associada ao chuveiro que não é contabilizada no volume ou no conjunto de células considerado para a medida. Pode-se distinguir, conceitualmente, vazamento longitudinal, quando a cascata se estende além da profundidade considerada, e vazamento lateral, quando depósitos se encontram fora da região transversal utilizada na reconstrução. Regiões de transição, material inativo e perdas antes do calorímetro também podem contribuir para diferenças entre a energia incidente e a energia reconstruída (ATLAS Collaboration, 2024a).

O *pile-up* corresponde à atividade adicional produzida por interações próton–próton distintas da interação de interesse. Duas contribuições devem ser distinguidas. O *in-time pile-up* decorre de múltiplas interações no mesmo cruzamento de feixes. O *out-of-time pile-up* decorre da

resposta temporal do detector e da eletrônica a interações ocorridas em cruzamentos vizinhos. Essa segunda contribuição é particularmente relevante quando a forma de pulso se estende por mais de um intervalo de 25 ns, de modo que uma amostra digital pode conter componentes de diferentes cruzamentos (ATLAS Collaboration, 2011; ATLAS Collaboration, 2024b).

O parâmetro μ descreve o número médio esperado de interações por cruzamento sob determinadas condições de luminosidade. Ele não deve ser confundido com o número de vértices primários reconstruídos em um evento: as duas grandezas são correlacionadas, mas pertencem a níveis distintos de descrição e estão sujeitas a eficiências e efeitos de reconstrução. Em calorimetria, o *pile-up* pode deslocar o nível de energia das células, alterar a forma espacial do chuveiro reconstruído e modificar variáveis derivadas, incluindo os anéis (ORELLANA; ATLAS Collaboration, 2021; ATLAS Collaboration, 2024b).

Esses efeitos justificam avaliar uma calibração não apenas por uma métrica global agregada, mas também em função de energia, pseudorapidez e condições de operação. Entretanto, a presença de *pile-up* em um conjunto de dados não é equivalente à demonstração de robustez frente a diferentes regimes de μ. Uma afirmação de invariância requer uma varredura controlada ou, no mínimo, uma avaliação estratificada das condições relevantes. Essa distinção será retomada na análise das limitações experimentais.

2.6 Seleção online e reconstrução rápida de elétrons

2.6.1 Função do sistema de *trigger*

O sistema de *trigger* não deve ser entendido apenas como um mecanismo de "processamento rápido". Sua função é realizar seleção online sob restrições de taxa, latência e recursos, preservando elevada eficiência para assinaturas de interesse ao mesmo tempo em que reduz a taxa de fundo a níveis compatíveis com leitura, processamento e armazenamento (ATLAS Collaboration, 2024b). Assim, duas propriedades distintas precisam ser consideradas: a eficiência de seleção para o sinal e a taxa de eventos aceitos. Melhorar uma estimativa de energia pode reduzir migrações através de um limiar, mas não implica automaticamente redução da taxa de fundo.

Na Run 3, a arquitetura do ATLAS mantém dois níveis principais: um primeiro nível implementado em hardware dedicado (L1) e o *High-Level Trigger* (HLT), implementado em software (ATLAS Collaboration, 2024b). A taxa de cruzamentos pode atingir 40 MHz; o L1 reduz essa taxa para a ordem de 10^5 eventos por segundo, e o HLT realiza a seleção final para a ordem de 10^3 eventos por segundo, com valores operacionais dependentes do menu e das condições de tomada de dados.

A Figura 9 apresenta uma visão simplificada do fluxo TDAQ da Run 3.

2.6.2 Primeiro nível de *trigger* na Run 3

O L1 utiliza informação de latência reduzida proveniente principalmente dos calorímetros e do sistema de múons. Para a calorimetria, a Run 3 introduziu uma cadeia com granularidade

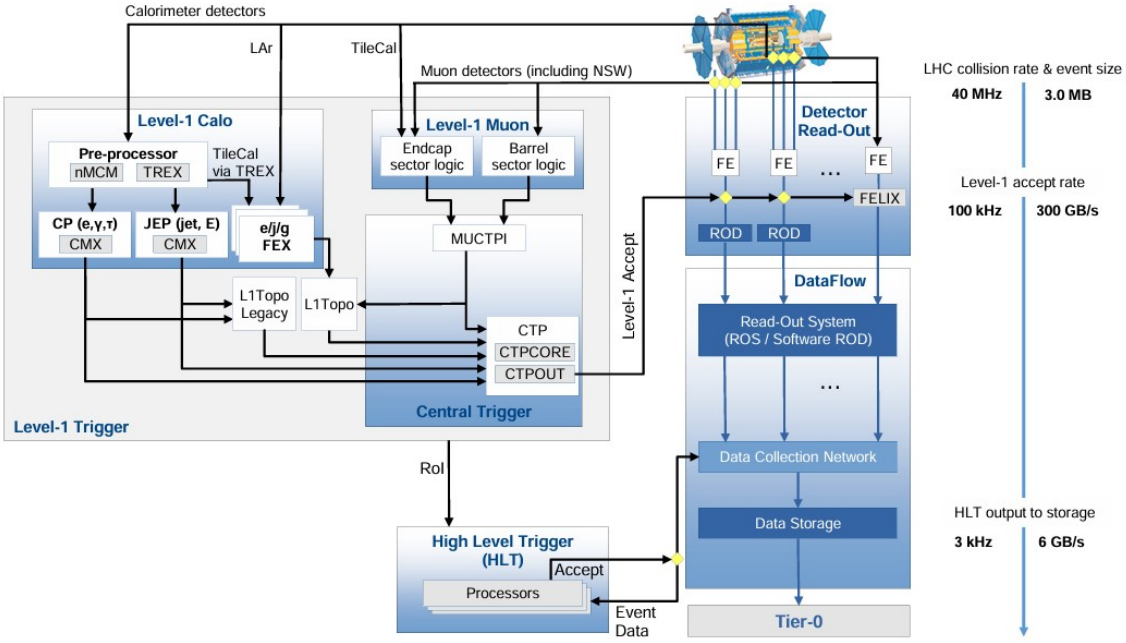


Figura 9 – Representação gráfica simplificada do fluxo do sistema TDAQ do ATLAS na Run 3. Fonte: (ATLAS Collaboration, 2024b).

aumentada no LAr e processadores FPGA denominados *Feature EXtractors* (FEX). O eFEX é orientado à formação de objetos eletromagnéticos e taus; jFEX e gFEX tratam, respectivamente, objetos de jatos em diferentes escalas e grandezas globais (ATLAS Collaboration, 2024b). Essa arquitetura é mais representativa da Run 3 do que uma descrição baseada exclusivamente nas *trigger towers* e na janela deslizante utilizada em gerações anteriores do L1Calo.

Os objetos formados pelo L1 definem sementes para a reconstrução posterior. Em particular, candidatos eletromagnéticos selecionados no L1 determinam regiões do detector que podem ser processadas com algoritmos de maior complexidade no HLT. A utilização de maior granularidade no L1 melhora a capacidade de discriminar objetos eletromagnéticos de depósitos hadrônicos e de lidar com condições de *pile-up* (ATLAS Collaboration, 2024b).

2.6.3 HLT de elétrons: etapas rápida e de precisão

O HLT é executado em uma fazenda (*farm*) de processamento e emprega algoritmos de software progressivamente mais detalhados. Para elétrons, a sequência pode ser entendida em duas classes de processamento: uma etapa rápida, destinada a rejeitar cedo uma grande fração do fundo com custo reduzido, e uma etapa de precisão, que utiliza algoritmos mais próximos da reconstrução offline (ATLAS Collaboration, 2020; ORELLANA; ATLAS Collaboration, 2021; ATLAS Collaboration, 2024b).

Na etapa rápida, a reconstrução calorimétrica é restrita à região de interesse e fornece observáveis empregados na seleção inicial. A representação Ringer, detalhada na Seção 2.7, é utilizada como parte dessa cadeia para identificação calorimétrica de candidatos a elétrons. Candidatos que sobrevivem à seleção podem prosseguir para reconstrução rápida de trajetórias e formação de objetos eletrônicos. Na etapa de precisão, a reconstrução calorimétrica e de trajetórias

utiliza algoritmos mais completos, e a construção de *superclusters* permite recuperar depósitos associados, por exemplo, à radiação de bremsstrahlung do elétron (ATLAS Collaboration, 2020; ORELLANA; ATLAS Collaboration, 2021; ATLAS Collaboration, 2024b).

A Figura 10 é mantida como uma representação simplificada da cadeia de elétrons que motivou a separação entre etapas rápida e de precisão. Ela não deve ser interpretada como um diagrama completo de todos os componentes do TDAQ da Run 3; para essa finalidade, a Figura 9 é a referência arquitetural mais atual deste capítulo.

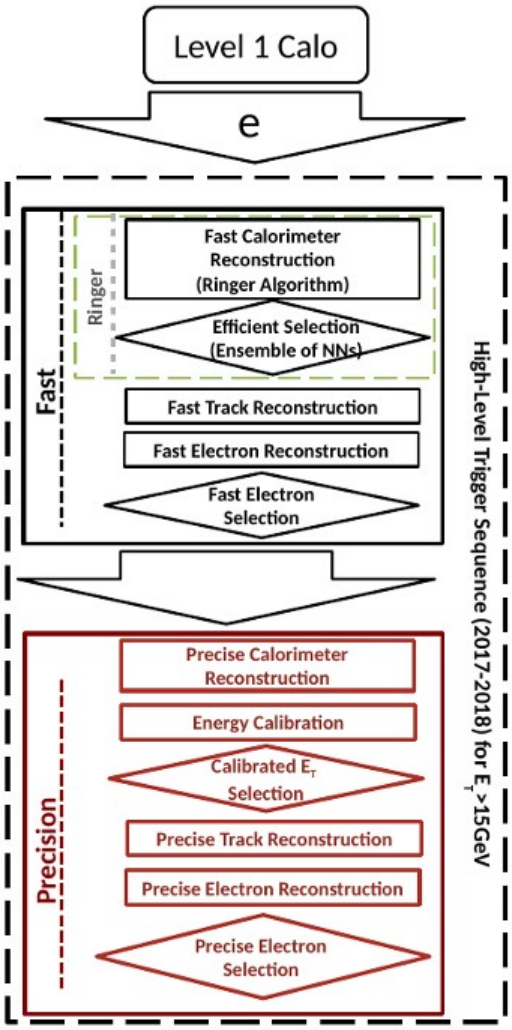


Figura 10 – Representação simplificada da sequência de processamento do HLT para candidatos a elétrons, destacando as etapas rápida e de precisão. A implementação evoluiu entre as Runs 2 e 3. Fontes: (ATLAS Collaboration, 2020; ORELLANA; ATLAS Collaboration, 2021).

A distinção entre as duas etapas, rápida e precisa, corrige uma ambiguidade importante para o escopo desta tese: os *superclusters* pertencem à reconstrução de precisão, enquanto o problema investigado aqui está associado à estimação calorimétrica rápida e à informação em anéis disponível antes das etapas mais custosas computacionalmente. A proposta de calibração não pretende substituir toda a cadeia de calibração do ATLAS; ela investiga uma correção adicional sobre uma estimativa rápida no ambiente de referência definido no Capítulo 5.

2.6.4 Limiar de energia, eficiência e taxa

Um *trigger* de elétrons normalmente impõe requisitos de energia transversa e identificação. Se a energia reconstruída apresenta viés ou dispersão, candidatos próximos ao limiar podem migrar entre as regiões de aceitação e rejeição. Uma calibração que reduza a dispersão pode tornar mais estreita a transição da curva de eficiência em torno do limiar. Entretanto, a escolha operacional do limiar depende simultaneamente da eficiência para elétrons e da taxa produzida por fundos, em especial jatos que mimetizam assinaturas eletromagnéticas (ATLAS Collaboration, 2020; ATLAS Collaboration, 2024b).

Essa observação delimita a interpretação dos estudos desta tese. Um conjunto composto apenas por elétrons permite avaliar erro de energia, resolução e comportamento de aceitação do sinal em torno de um limiar. Ele não permite, isoladamente, determinar a taxa de fundo ou concluir que uma calibração reduzirá a taxa global de *trigger*. Para esse segundo objetivo seriam necessárias amostras de fundo e uma análise conjunta de calibração, identificação e menu de *trigger*. Essa distinção será preservada nos capítulos de resultados.

2.7 Representação Ringer

2.7.1 Construção dos anéis

A representação Ringer foi desenvolvida para codificar a distribuição espacial de energia em uma região de interesse usando um número reduzido de variáveis calorimétricas (SEIXAS et al., 1996; PINTO; ATLAS Collaboration, 2016; ATLAS Collaboration, 2020). Em cada camada, a construção parte de uma célula central de referência e agrega células em anéis concêntricos ou aproximadamente concêntricos, respeitando a granularidade retangular da camada. O valor de cada anel corresponde à soma da energia transversa das células que o compõem. A Figura 11 ilustra o conceito.

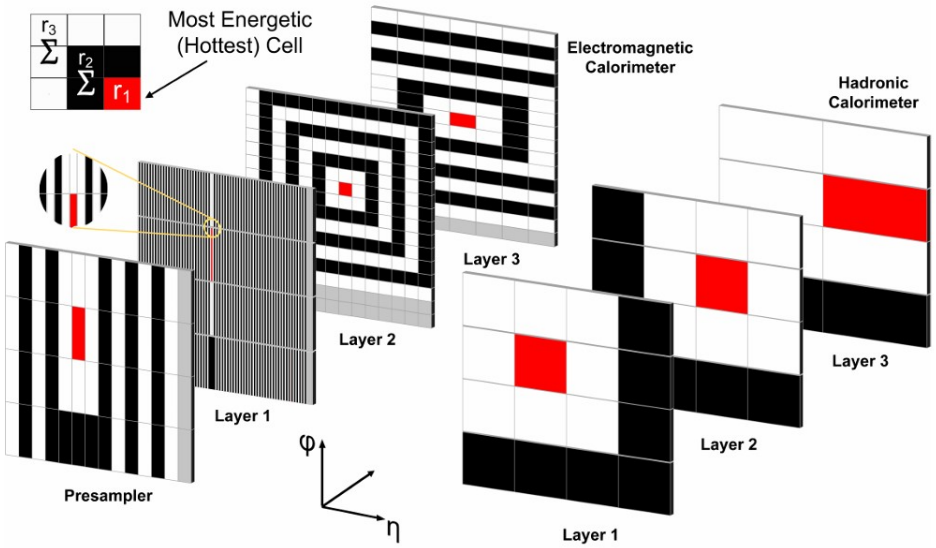


Figura 11 – Representação gráfica do conceito de reconstrução em anéis. As células calorimétricas são agregadas em anéis em diferentes camadas, preservando informação espacial do chuveiro em uma representação ordenada. Fonte: (PINTO; ATLAS Collaboration, 2016).

Na configuração de 100 anéis empregada historicamente para a seleção de elétrons, a distribuição entre camadas é mostrada na Tabela 2 (ATLAS Collaboration, 2020; PINTO; ATLAS Collaboration, 2016).

Tabela 2 – Quantidade de anéis por camada na representação Ringer de 100 componentes. Fontes: (ATLAS Collaboration, 2020; PINTO; ATLAS Collaboration, 2016).

Camada	PS	EM1	EM2	EM3	HAD1	HAD2	HAD3
Nº de anéis	8	64	8	8	4	4	4

Com a concatenação nessa ordem, os índices podem ser interpretados como

$$\begin{gathered}\text{PS}: \ 1\text{–}8, \qquad \text{EM1}: \ 9\text{–}72, \qquad \text{EM2}: \ 73\text{–}80, \\ \text{EM3}: \ 81\text{–}88, \quad \text{HAD1}: \ 89\text{–}92, \quad \text{HAD2}: \ 93\text{–}96, \quad \text{HAD3}: \ 97\text{–}100.\end{gathered} \tag{2.10}$$

Essa explicitação é útil para a interpretação física das análises de relevância de atributos. Por exemplo, nessa convenção o *Ringer* 74 pertence à segunda camada eletromagnética (EM2), camada na qual uma fração substancial da energia de um chuveiro eletromagnético é tipicamente depositada.

Se $\mathcal{R}_j$ representa o conjunto de células que compõe o j-ésimo anel, a partir da Eq. 2.8, a energia transversa total desse conjunto é o somatório das energias transversais das células $k \in \mathcal{R}_j$. Então, para o i-ésimo evento, tem-se

$$E_{r,j}^{(i)} = \sum_{k \in \mathcal{R}_j} E_{\mathrm{T},k}^{(i)}. \tag{2.11}$$

A normalização empregada na representação Ringer pode ser escrita como

$$\widetilde{E}_{r,j}^{(i)} = \frac{E_{r,j}^{(i)}}{\sum_{\ell=1}^{100} E_{r,\ell}^{(i)}}, \qquad j = 1, \ldots, 100, \tag{2.12}$$

e conduz ao vetor dos 100 anéis normalizados,

$$\widetilde{\mathbf{E}}_r^{(i)} = \left[\widetilde{E}_{r,1}^{(i)}, \ldots, \widetilde{E}_{r,100}^{(i)}\right]^T. \tag{2.13}$$

O vetor $\widetilde{\mathbf{E}}_r^{(i)}$ constitui, portanto, um descritor predominantemente associado à forma do chuveiro. A normalização reduz a dependência direta da magnitude absoluta da energia, mas não torna a representação imune a *pile-up*, sobreposição de chuveiros, ruído ou *cross-talk*, pois esses efeitos podem redistribuir energia entre os anéis.

2.7.2 Ringer na identificação online de elétrons

No ATLAS, a representação Ringer foi empregada em redes neurais para identificação online de elétrons. Durante a Run 2, conjuntos de MLPs foram treinados em regiões de (E_T, η) para discriminar elétrons de fundo hadrônico a partir do vetor normalizado de anéis (ATLAS Collaboration, 2020). Para a Run 3, o Ringer foi incorporado à sequência rápida de elétrons de

forma mais ampla, com atualizações de treinamento e integração ao novo ambiente de *trigger* (ORELLANA; ATLAS Collaboration, 2021; ATLAS Collaboration, 2024b).

A Figura 12 ilustra o desempenho da seleção baseada em Ringer em relação a abordagens baseadas em cortes (ATLAS Collaboration, 2020). O objetivo da figura neste capítulo é mostrar o papel histórico do Ringer como ferramenta de identificação, e não quantificar o desempenho da calibração proposta nesta tese.

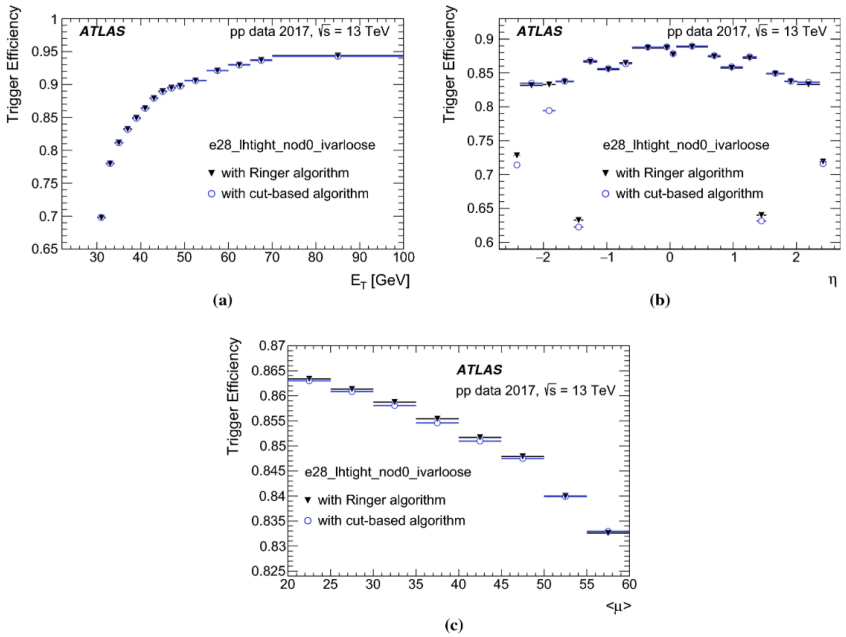


Figura 12 – Eficiência de *triggers* de elétrons utilizando o algoritmo Ringer e a seleção calorimétrica baseada em cortes, avaliada em função de E_T, η e *pile-up*. A comparação ilustra o uso histórico da representação Ringer para identificação online de elétrons no ATLAS e não corresponde ao problema de regressão de energia investigado nesta tese. Fonte: (ATLAS Collaboration, 2020).

É fundamental distinguir "identificação" de "calibração". No uso histórico do Ringer, a saída da rede é um discriminante destinado a separar elétrons de jatos. Nesta tese, os anéis são utilizados como observáveis de entrada para um problema de regressão: estimar um fator multiplicativo de correção da energia. O fato de a mesma representação ser informativa para classificação não implica, por si só, que as mesmas variáveis, regiões de E_T ou arquiteturas sejam ótimas para calibração. Essa distinção justifica avaliar explicitamente seleção de atributos, extração de componentes e diferentes famílias de regressores nos capítulos seguintes.

2.8 Simulação Monte Carlo e relação com o ambiente experimental

Simulações Monte Carlo são indispensáveis em física de altas energias porque permitem gerar amostras nas quais o estado gerado da partícula e a resposta do detector são simultaneamente conhecidos. A cadeia típica envolve geração do evento, transporte das partículas através do detector, simulação da deposição de energia, digitização da resposta eletrônica e reconstrução dos observáveis (METROPOLIS; ULAM, 1949; ATLAS Collaboration, 2010; ARAÚJO et al., 2023).

Na infraestrutura oficial do ATLAS, geradores como *Pythia8* [3] podem produzir eventos

[3] *Pythia8* é um gerador Monte Carlo de eventos de colisões de altas energias, utilizado para modelar processos

que são representados em formatos de intercâmbio como HepMC [4]; o transporte e as interações com o detector são simulados com GEANT4 [5]; e as etapas de digitização e reconstrução são integradas ao ambiente de software da colaboração (SJÖSTRAND; MRENNA; SKANDS, 2008; DOBBS; HANSEN, 2001; AGOSTINELLI; ALLISON et al., 2003; ATLAS Collaboration, 2010). Esse ambiente possui a fidelidade e a integração necessárias às análises oficiais, mas não foi a camada de simulação utilizada para produzir o conjunto principal de dados dos estudos desta tese.

O *Lorenzetti Showers Framework* foi desenvolvido como um ambiente aberto e configurável para estudos de reconstrução e seleção baseados em calorimetria (ARAÚJO et al., 2023). Ele integra geração de eventos, transporte em geometria calorimétrica segmentada, digitização, modelagem da resposta eletrônica e reconstrução de observáveis de baixo nível, disponibilizando sinais de células e representações Ringer adequados à investigação conjunta do detector, do processamento de sinais e dos algoritmos de estimação. Nos estudos desta tese, o *framework* foi configurado tomando como referência características de geometria, materiais e segmentação do sistema calorimétrico do ATLAS (ARAÚJO et al., 2023; SILVA et al., 2026b). Estudos anteriores empregando essa configuração reportaram comparações entre a resposta simulada e referências experimentais para observáveis como perfis de deposição de energia, desenvolvimento longitudinal e transversal dos chuveiros, resposta por camada e resolução de energia (SIMAS FILHO et al., 2025; SILVA et al., 2026b). A geometria e os parâmetros de segmentação e granularidade efetivamente utilizados no *benchmark* são apresentados no Capítulo 5.

O Lorenzetti, contudo, não substitui a simulação oficial do ATLAS e não deve ser tratado como evidência de que um método está validado para uso operacional no experimento. Nesta tese, ele constitui um *benchmark* detector-inspirado, aberto e reprodutível, escolhido para comparar métodos sob uma mesma interface de dados. A configuração efetivamente empregada, o número de eventos, a incorporação de ruído e *pile-up*, a região cinemática e a definição do *Standard FastCalo* são apresentados no Capítulo 5. Essa separação evita confundir fundamentos do detector real com hipóteses específicas do ambiente de simulação.

2.9 Conclusão do capítulo

Este capítulo estabeleceu a cadeia física e instrumental necessária para a formulação da calibração investigada nesta tese. Elétrons produzidos nas colisões do LHC desenvolvem chuveiros eletromagnéticos no calorímetro; a energia depositada é convertida em sinais elétricos e reconstruída no nível de células; células são agrupadas em objetos calorimétricos; e a energia transversa desses objetos é utilizada em decisões de seleção online. A precisão dessa cadeia é afetada por ruído, *pile-up*, vazamentos, segmentação e dependências da resposta.

No ATLAS, o sistema de *trigger* reduz a taxa de eventos em duas etapas principais. A Run 3 introduziu maior granularidade e processadores FEX no primeiro nível, enquanto o HLT

duros, chuveiros partônicos, hadronização e decaimentos (SJÖSTRAND; MRENNA; SKANDS, 2008).

[4] HepMC é um formato e uma interface para armazenamento e intercâmbio do registro de eventos Monte Carlo entre geradores e etapas posteriores de simulação (DOBBS; HANSEN, 2001).

[5] *GEANT4* é um conjunto de ferramentas para simular o transporte e as interações de partículas através da matéria e de geometrias de detectores (AGOSTINELLI; ALLISON et al., 2003).

utiliza uma sequência de reconstrução rápida e de precisão. Para elétrons, o Ringer fornece uma representação compacta e ordenada da deposição calorimétrica e foi originalmente empregado para identificação online. A mesma representação fornece, nesta tese, a formulação física entre a medição segmentada e os modelos de regressão destinados à calibração.

Do ponto de vista de Engenharia Elétrica e de Computação, o problema pode ser entendido como uma cadeia de medição e inferência: sinais amostrados são convertidos em energias de células, informações espacialmente distribuídas são agregadas em uma representação estruturada e algoritmos de estimação utilizam essa informação sob restrições de generalização e custo computacional. Com essa base física e instrumental estabelecida, o Capítulo 3 formaliza o problema de calibração e examina como a informação Ringer é preservada, selecionada ou transformada; o Capítulo 4 apresenta as famílias de regressão e os mecanismos de fusão utilizados para estimar a correção; e o Capítulo 5 operacionaliza esses elementos no desenho experimental da tese.

3 Formulação da Calibração e Representação da Informação Calorimétrica

Este capítulo estabelece a formulação matemática comum da calibração investigada nesta tese e, a partir dela, examina como a informação calorimétrica é representada antes da etapa de regressão. A formulação separa explicitamente dois componentes da cadeia de estimação: $g_{\mathrm{ML}}(\cdot)$, responsável por preservar, selecionar ou extrair características da representação Ringer, e $f_{\mathrm{ML}}(\cdot)$, responsável por estimar o fator multiplicativo de calibração. Essa decomposição permite estudar representação e regressor como componentes distintos sem modificar a definição física da quantidade que se pretende corrigir.

O ponto de partida é a representação Ringer introduzida no Capítulo 2, que agrega a informação de células calorimétricas em 100 descritores ordenados segundo a estrutura do sistema considerado (PINTO; ATLAS Collaboration, 2016). Após a formulação do problema supervisionado, a atenção deste capítulo recai sobre $g_{\mathrm{ML}}(\cdot)$. São discutidas a representação completa e as estratégias de seleção e extração utilizadas na pesquisa, enfatizando suas hipóteses, a natureza das variáveis produzidas, a eventual dependência do alvo durante o ajuste e as consequências para dimensionalidade e interpretabilidade (SILVA et al., 2026b; SILVA et al., 2026a).

A formulação é apresentada antes das técnicas de representação porque define o papel de E_{true}, E_{fast}, α_{true}, α_{calib}, $g_{\mathrm{ML}}(\cdot)$ e $f_{\mathrm{ML}}(\cdot)$ em toda a tese e estabelece a fronteira entre informação disponível durante o desenvolvimento e informação permitida na inferência. Uma vez definida a representação $\mathbf{x}^{(i)} = g_{\mathrm{ML}}\left(\widetilde{\mathbf{E}}_r^{(i)}\right)$, o Capítulo 4 apresenta os modelos utilizados para implementar $f_{\mathrm{ML}}(\cdot)$. O Capítulo 5 especifica posteriormente como os dois componentes são ajustados e avaliados nas três etapas experimentais.

3.1 Calibração como problema de estimação supervisionada

A calibração calorimétrica investigada nesta tese pode ser interpretada, do ponto de vista de Engenharia Elétrica e de Computação, como um problema de estimação no qual uma medida já disponível é corrigida a partir de informação adicional contida na estrutura espacial do sinal. No caso considerado, a grandeza inicialmente disponível é a estimativa rápida da energia transversa, E_{fast}, enquanto a informação complementar é fornecida principalmente pela distribuição dos depósitos calorimétricos organizada na representação Ringer discutida na Seção 2.7. Essa representação agrega a informação de células calorimétricas em um vetor estruturado de anéis, preservando características radiais e longitudinais do chuveiro eletromagnético (PINTO; ATLAS Collaboration, 2016).

Conforme a convenção adotada ao longo desta tese, E_{true}, E_{fast} e E_{calib} denotam energias transversais. Para o i-ésimo evento, define-se a energia calibrada por uma correção multiplicativa

da estimativa rápida,

$$E_{\text{calib}}^{(i)} = \alpha_{\text{calib}}^{(i)} E_{\text{fast}}^{(i)}, \tag{3.1}$$

em que $\alpha_{\text{calib}}^{(i)}$ é o fator de calibração estimado para aquele evento. No limite ideal,

$$E_{\text{calib}}^{(i)} = E_{\text{true}}^{(i)}, \tag{3.2}$$

de modo que o fator de correção correspondente seria

$$\alpha_{\text{true}}^{(i)} = \frac{E_{\text{true}}^{(i)}}{E_{\text{fast}}^{(i)}}, \qquad E_{\text{fast}}^{(i)} \neq 0. \tag{3.3}$$

A grandeza $\alpha_{\text{true}}^{(i)}$ constitui, portanto, o alvo ideal de calibração para o i-ésimo evento. Ela é conhecida durante o desenvolvimento dos modelos porque E_{true} está disponível no nível de verdade da simulação Monte Carlo. Em dados experimentais reais, entretanto, E_{true} não é observável evento a evento. O problema de aprendizado não consiste, assim, em calcular a razão da Eq. 3.3 durante a operação do detector, mas em aprender, a partir de eventos simulados, uma função capaz de estimar essa correção utilizando somente grandezas reconstruídas disponíveis no evento.

Essa distinção é central para a interpretação do aprendizado supervisionado empregado nesta tese. A simulação Monte Carlo fornece observáveis reconstruídos e uma referência conhecida, tornando possível aprender estatisticamente a relação entre a estrutura do chuveiro e a correção necessária. Isso não implica que grandezas de verdade da simulação Monte Carlo, como E_{true} ou α_{true}, estejam disponíveis em uma aplicação experimental futura; elas desempenham exclusivamente o papel de informação supervisora, ou alvo, durante o desenvolvimento e a avaliação dos modelos.

A cadeia de estimação é organizada em dois mapeamentos conceitualmente distintos. Seja

$$\widetilde{\mathbf{E}}_r^{(i)} = \left[\widetilde{E}_{r,1}^{(i)}, \widetilde{E}_{r,2}^{(i)}, \ldots, \widetilde{E}_{r,100}^{(i)}\right]^T \in \mathbb{R}^{100} \tag{3.4}$$

a representação normalizada dos 100 anéis para o evento i. O primeiro mapeamento, relacionado à redução de dimensionalidade,

$$g_{\text{ML}} : \mathbb{R}^{100} \longrightarrow \mathbb{R}^F, \tag{3.5}$$

define a representação apresentada ao regressor,

$$\mathbf{x}^{(i)} = g_{\text{ML}}\left(\widetilde{\mathbf{E}}_r^{(i)}\right), \qquad \mathbf{x}^{(i)} \in \mathbb{R}^F. \tag{3.6}$$

Quando se deseja que $\mathbf{x}^{(i)}$ corresponda à representação integral dos 100 anéis ($F = 100$), faz-se $g_{\text{ML}}(\cdot)$ corresponder a uma transformação identidade. Para representações compactas, $g_{\text{ML}}(\cdot)$ representa o procedimento de seleção ou extração de características utilizado para construir um espaço com $F < 100$. Os diferentes casos são formalizados na Seção 3.2.

O segundo mapeamento é o regressor propriamente dito,

$$f_{\text{ML}} : \mathbb{R}^F \longrightarrow \mathbb{R}, \tag{3.7}$$

que produz, evento a evento,

$$\alpha_{\text{calib}}^{(i)} = f_{\text{ML}}\left(\mathbf{x}^{(i)}\right). \tag{3.8}$$

Combinando as Eqs. 3.1, 3.6 e 3.8, a cadeia completa de calibração pode ser expressa por

$$E_{\text{calib}}^{(i)} = E_{\text{fast}}^{(i)} f_{\text{ML}} \left[g_{\text{ML}} \left(\widetilde{\mathbf{E}}_r^{(i)} \right) \right]. \tag{3.9}$$

A Eq. 3.9 resume a formulação central empregada ao longo da tese. A informação calorimétrica é inicialmente estruturada nos anéis; $g_{\text{ML}}(\cdot)$ determina a representação efetivamente entregue ao modelo; $f_{\text{ML}}(\cdot)$ realiza a fusão dessa informação para estimar o fator multiplicativo; e esse fator corrige E_{fast}. Dessa forma, diferentes técnicas de redução de dimensionalidade e diferentes famílias de regressão podem ser comparadas sem modificar a definição física da quantidade estimada. Para formalizar o treinamento, considere

$$\mathcal{D}_{\text{train}} = \left\{ \left(\mathbf{x}^{(i)}, \alpha_{\text{true}}^{(i)} \right) \right\}_{i=1}^{N_{\text{train}}}, \tag{3.10}$$

em que N_{train} é o número de eventos disponibilizados ao procedimento de ajuste e $\mathbf{x}^{(i)} \in \mathbb{R}^F$ é a representação correspondente ao evento i. Durante o desenvolvimento do modelo, pode-se escrever explicitamente o regressor como

$$f_{\text{ML}} \left(\mathbf{x}; \boldsymbol{\theta} \right), \tag{3.11}$$

em que $\boldsymbol{\theta}$ representa seus parâmetros internos. O treinamento supervisionado pode então ser formulado, de maneira geral, como minimização de risco empírico (HASTIE; TIBSHIRANI; FRIEDMAN, 2009),

$$\boldsymbol{\theta}^{\star} = \arg\min_{\boldsymbol{\theta}} \widehat{R} \left(\boldsymbol{\theta} \right), \tag{3.12}$$

com

$$\widehat{R} \left(\boldsymbol{\theta} \right) = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \mathcal{L} \left[\alpha_{\text{true}}^{(i)}, f_{\text{ML}} \left(\mathbf{x}^{(i)}; \boldsymbol{\theta} \right) \right], \tag{3.13}$$

em que $\mathcal{L}$ é a função de perda associada ao procedimento de treinamento. Essa escrita é propositalmente geral: diferentes famílias de modelos podem utilizar funções de perda, mecanismos de regularização e algoritmos de otimização distintos. A função utilizada para treinamento também não deve ser confundida automaticamente com o conjunto completo de métricas empregadas para avaliação científica do modelo, que inclui, nesta tese, medidas de erro, dispersão, resolução, estabilidade regional e custo computacional.

Após o ajuste, os parâmetros $\boldsymbol{\theta}^{\star}$ são considerados incorporados à função treinada. Por essa razão, adota-se simplesmente a notação $f_{\text{ML}}(\cdot)$ para o modelo final. A mesma convenção é empregada para todas as famílias de regressão avaliadas.

É importante distinguir ainda o conhecimento do alvo no conjunto de treinamento da existência de uma expressão analítica universal para o problema. Em Monte Carlo, $\alpha_{\text{true}}^{(i)}$ é calculável diretamente para cada evento por meio da Eq. 3.3. O que não é conhecido *a priori* é o mapeamento geral entre a informação reconstruída do chuveiro e a correção que deverá ser aplicada a um novo evento. Dependendo da família de regressão, a estimação dos parâmetros pode possuir solução analítica — como em determinadas formulações de regressão linear — ou exigir procedimentos iterativos e numéricos, como ocorre em árvores com reforço, ensembles e redes neurais. O papel do aprendizado é estimar esse mapeamento a partir de uma amostra

finita e avaliar sua capacidade de generalização para eventos não utilizados no ajuste (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Na forma vetorial, para um conjunto de N eventos, sejam

$$\mathbf{E}_{\text{true}} = \left[E_{\text{true}}^{(1)}, \ldots, E_{\text{true}}^{(N)}\right]^T, \tag{3.14}$$

$$\mathbf{E}_{\text{fast}} = \left[E_{\text{fast}}^{(1)}, \ldots, E_{\text{fast}}^{(N)}\right]^T, \tag{3.15}$$

$$\boldsymbol{\alpha}_{\text{true}} = \left[\alpha_{\text{true}}^{(1)}, \ldots, \alpha_{\text{true}}^{(N)}\right]^T \tag{3.16}$$

e

$$\boldsymbol{\alpha}_{\text{calib}} = \left[\alpha_{\text{calib}}^{(1)}, \ldots, \alpha_{\text{calib}}^{(N)}\right]^T. \tag{3.17}$$

A aplicação em lote do regressor pode ser representada por

$$\boldsymbol{\alpha}_{\text{calib}} = f_{\text{ML}}\left(\mathbf{X}\right), \qquad \mathbf{X} \in \mathbb{R}^{N \times F}, \tag{3.18}$$

entendendo-se que f_{ML} é aplicado às linhas de $\mathbf{X}$. A energia calibrada para o conjunto é então

$$\mathbf{E}_{\text{calib}} = \boldsymbol{\alpha}_{\text{calib}} \odot \mathbf{E}_{\text{fast}}, \tag{3.19}$$

em que $\odot$ representa o produto de Hadamard, isto é, o produto elemento a elemento entre vetores de mesma dimensão (HOGBEN, 2013).

Essa escrita vetorial é particularmente útil para treinamento, validação e avaliação em lote. Conceitualmente, entretanto, a calibração permanece evento a evento: para cada novo candidato, $f_{\text{ML}}(\cdot)$ produz um único fator $\alpha_{\text{calib}}^{(i)}$, que é aplicado à respectiva estimativa $E_{\text{fast}}^{(i)}$.

Uma condição fundamental dessa formulação é a separação entre informações disponíveis durante o aprendizado e informações permitidas durante a inferência. E_{true} e, consequentemente, α_{true} são grandezas de verdade da simulação Monte Carlo e não podem integrar o vetor de entrada de um modelo avaliado em validação, teste ou eventual aplicação sobre dados experimentais. Em uma validação aninhada de ponta a ponta, qualquer normalização, ordenação de atributos, seleção de características ou extração de componentes dependente dos dados deve ser reajustada dentro de cada partição de treinamento correspondente. Nas Etapas II e III desta tese, entretanto, $g_{\text{ML}}(\cdot)$ foi definido uma única vez utilizando exclusivamente a partição de desenvolvimento de 70%, denotada por $\mathcal{D}_{70}$, e somente $f_{\text{ML}}(\cdot)$ foi submetido à validação cruzada aninhada; por isso, as estatísticas dos *folds* externos são condicionais à representação fixada, conforme detalhado no Capítulo 5. Em todos os casos, a partição independente de teste de 30%, denotada por $\mathcal{D}_{30}$, permanece fora do ajuste da representação e do regressor.

Em particular, métodos de representação supervisionados podem utilizar E_{true} durante o ajuste de $g_{\text{ML}}(\cdot)$ para determinar quais variáveis devem ser preservadas. Isso não significa que E_{true} constitua argumento de $g_{\text{ML}}(\cdot)$ durante a inferência. Uma vez ajustado com os dados de treinamento, o operador recebe exclusivamente a informação reconstruída do novo evento,

$$\mathbf{x}^{(i)} = g_{\text{ML}}\left(\widetilde{\mathbf{E}}_r^{(i)}\right), \tag{3.20}$$

sem acesso ao respectivo $E_{\text{true}}^{(i)}$. Essa distinção entre "ajuste da transformação" e "aplicação da transformação" é formalizada em maior detalhe na Seção 3.2 e no Capítulo 5.

3.1.1 Regressão do fator de calibração e regressão direta da energia

A escolha de α_{true} como variável-alvo estabelece uma parametrização multiplicativa do problema. Embora essa escolha seja natural para uma tarefa de calibração, ela deve ser distinguida matematicamente de uma regressão direta de E_{true},

$$E_{\text{true}}^{(i)} = \alpha_{\text{true}}^{(i)} E_{\text{fast}}^{(i)}. \tag{3.21}$$

Pela definição de $E_{\text{calib}}^{(i)}$ na Eq. 3.1, define-se o resíduo da energia calibrada como

$$\varepsilon_{\text{calib}}^{(i)} = E_{\text{true}}^{(i)} - E_{\text{calib}}^{(i)}. \tag{3.22}$$

Substituindo as expressões anteriores,

$$\varepsilon_{\text{calib}}^{(i)} = E_{\text{fast}}^{(i)} \left(\alpha_{\text{true}}^{(i)} - \alpha_{\text{calib}}^{(i)} \right). \tag{3.23}$$

Portanto,

$$\left(\varepsilon_{\text{calib}}^{(i)} \right)^2 = \left(E_{\text{fast}}^{(i)} \right)^2 \left(\alpha_{\text{true}}^{(i)} - \alpha_{\text{calib}}^{(i)} \right)^2. \tag{3.24}$$

Essa relação permite estabelecer precisamente a diferença entre otimizar o fator de calibração e otimizar diretamente a energia. Considere primeiro o erro quadrático médio no domínio do fator,

$$\text{MSE}_\alpha = \frac{1}{N} \sum_{i=1}^{N} \left(\alpha_{\text{true}}^{(i)} - \alpha_{\text{calib}}^{(i)} \right)^2. \tag{3.25}$$

No domínio da energia,

$$\text{MSE}_E = \frac{1}{N} \sum_{i=1}^{N} \left(E_{\text{true}}^{(i)} - E_{\text{calib}}^{(i)} \right)^2. \tag{3.26}$$

Utilizando a Eq. 3.23,

$$\text{MSE}_E = \frac{1}{N} \sum_{i=1}^{N} \left(E_{\text{fast}}^{(i)} \right)^2 \left(\alpha_{\text{true}}^{(i)} - \alpha_{\text{calib}}^{(i)} \right)^2. \tag{3.27}$$

A Eq. 3.27 mostra que minimizar um MSE não ponderado no fator de calibração não é, em geral, matematicamente equivalente a minimizar um MSE não ponderado diretamente na energia. Os fatores $\left(E_{\text{fast}}^{(i)} \right)^2$ são positivos, mas variam evento a evento e, portanto, modificam a contribuição relativa das observações para a função objetivo. A positividade dos pesos, isoladamente, não garante igualdade entre os minimizadores das duas funções.

A equivalência ocorre em situações particulares. Por exemplo, se $E_{\text{fast}}^{(i)}$ fosse constante para todos os eventos, MSE_E diferiria de MSE_α apenas por um fator multiplicativo global. Alternativamente, pode-se definir um MSE ponderado no domínio do fator de calibração,

$$\text{MSE}_{\alpha,w} = \frac{1}{N} \sum_{i=1}^{N} w_i \left(\alpha_{\text{true}}^{(i)} - \alpha_{\text{calib}}^{(i)} \right)^2, \tag{3.28}$$

com

$$w_i = \left(E_{\text{fast}}^{(i)} \right)^2, \tag{3.29}$$

caso em que

$$\text{MSE}_{\alpha,w} = \text{MSE}_E. \tag{3.30}$$

Essa distinção possui consequência prática. Uma perda quadrática não ponderada no fator de calibração atribui o mesmo peso explícito aos erros em α_{calib} independentemente da escala de E_{fast}, enquanto uma perda quadrática no domínio da energia atribui peso proporcional a $(E_{\text{fast}})^2$. Assim, eventos de maior energia podem contribuir mais intensamente para a otimização no segundo caso. A escolha da variável-alvo e da função de perda define, portanto, não apenas uma parametrização matemática, mas também a maneira pela qual diferentes regiões do espectro influenciam o ajuste.

A parametrização por fator multiplicativo é mantida nesta tese por razões físicas e de engenharia. Primeiro, ela descreve explicitamente a tarefa como uma correção de uma estimativa rápida já existente, em vez de substituir essa estimativa por uma reconstrução independente. Segundo, α_{calib} é adimensional e possui uma interpretação direta: $\alpha_{\text{calib}} = 1$ corresponde à ausência de correção multiplicativa, valores superiores a um aumentam a energia reconstruída e valores inferiores a um a reduzem. Terceiro, a distribuição de α_{calib} pode ser analisada diretamente em diferentes regiões cinemáticas, fornecendo um diagnóstico adicional da estabilidade da calibração. Por fim, uma vez estimado o fator, sua aplicação à energia rápida requer apenas a operação multiplicativa da Eq. 3.1, mantendo claramente separadas a estimação realizada pelo modelo e a aplicação da correção.

A utilização de uma razão como alvo também introduz uma característica que deve ser reconhecida. Como a Eq. 3.3 contém E_{fast} no denominador, flutuações absolutas em E_{fast} podem produzir variações relativamente maiores no fator quando o denominador assume valores menores. Portanto, métricas calculadas diretamente sobre α_{calib} e métricas calculadas sobre E_{calib} não devem ser interpretadas como medidas intercambiáveis. Essa distinção é particularmente importante nas análises regionais apresentadas nos capítulos de resultados.

Consequentemente, a adoção de α_{true} como alvo nesta tese não implica a afirmação de que regressão do fator de calibração seja universalmente superior à regressão direta de E_{true}. Uma formulação direta,

$$\widehat{E}^{(i)} = h_{\text{ML}}\left(\mathbf{x}^{(i)}\right), \tag{3.31}$$

onde $\widehat{E}^{(i)}$ é a energia estimada diretamente por um modelo $h_{\text{ML}}(\cdot)$, seria matematicamente válida e poderia ser comparada experimentalmente com a parametrização multiplicativa. Essa comparação, entretanto, constitui uma questão experimental distinta e não foi utilizada como hipótese implícita para justificar o método adotado. A escolha feita neste trabalho decorre da interpretação da tarefa como calibração de uma estimativa rápida já disponível e da possibilidade de estudar diretamente o fator de correção evento a evento.

Em síntese, a formulação central utilizada ao longo da tese é a apresentada na Eq. 3.9, com o alvo supervisionado definido pela Eq. 3.3. Essa decomposição estabelece a base comum para todas as etapas experimentais desta tese: $g_{\text{ML}}(\cdot)$ determina quanto e de que forma a informação calorimétrica é preservada, enquanto $f_{\text{ML}}(\cdot)$ determina como essa informação é combinada para estimar a correção. As seções seguintes analisam separadamente esses dois componentes antes da apresentação do protocolo experimental unificado no Capítulo 5.

3.2 Representação da informação e redução de dimensionalidade

A redução de dimensionalidade nesta tese ocorre em dois níveis conceitualmente distintos. O primeiro é físico e orientado por conhecimento especializado: o Ringer agrega sinais de células em descritores radiais associados às camadas calorimétricas, como discutido na Seção 2.7. Esse processamento reduz a dimensionalidade da leitura calorimétrica original preservando informações a respeito da geometria do chuveiro (PINTO; ATLAS Collaboration, 2016). O segundo nível é estatístico ou orientado por dados: a partir do vetor de 100 anéis, os métodos estatísticos propostos constroem representações ainda mais compactas (SILVA et al., 2026b; SILVA et al., 2026a).

Seja

$$\widetilde{\mathbf{E}}_r \in \mathbb{R}^{N\times 100} \tag{3.32}$$

a matriz de energias normalizadas dos anéis para N eventos. O operador de representação introduzido no Capítulo 1 produz

$$\mathbf{X} = g_{\mathrm{ML}}\left(\widetilde{\mathbf{E}}_r\right), \qquad \mathbf{X} \in \mathbb{R}^{N\times F}, \tag{3.33}$$

em que F é a dimensionalidade utilizada pelo regressor. Para a representação completa, $F = 100$, e para representações compactas, $F < 100$.

É útil distinguir "seleção de características" de "extração de características". Na seleção, cada dimensão preservada continua correspondendo a um anel original. Isso mantém uma associação física direta entre a variável e sua posição na representação calorimétrica. Na extração, novas coordenadas são construídas como transformações das variáveis originais; a compactação pode ser maior ou produzir características mais adequadas ao regressor, mas a interpretação deixa de ser atribuível a um único anel (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; JOLLIFFE, 2002; HYVÄRINEN; KARHUNEN; OJA, 2001).

Nos estudos desta tese, determinadas representações compactas utilizam E_{true} para ordenar variáveis ou componentes por relevância. Isso é permitido durante o treinamento supervisionado, mas exige uma separação estrita entre "ajuste da representação" e "aplicação da representação". Esse critério preserva o protocolo dos estudos associados, pois como o alvo do regressor é α_{true}, a ordenação por E_{true} deve ser entendida como uma heurística supervisionada de relevância em relação à escala energética, e não como uma seleção otimizada diretamente para a função de perda de $f_{\mathrm{ML}}(\cdot)$. Nesta tese não foi realizada uma ablação específica entre ordenações por E_{true}, por α_{true} e por critérios condicionais ou multivariados. Essa comparação permanece como possibilidade de refinamento metodológico futuro.

Seja $\mathcal{T}_g$ o procedimento que define g_{ML}. De forma abstrata,

$$g_{\mathrm{ML}} = \mathcal{T}_g\left(\widetilde{\mathbf{E}}_{r,\mathrm{train}}, \mathbf{E}_{\mathrm{true,train}}\right), \tag{3.34}$$

quando o método requer ordenação supervisionada. Uma vez definido,

$$\mathbf{X}_{\mathrm{test}} = g_{\mathrm{ML}}\left(\widetilde{\mathbf{E}}_{r,\mathrm{test}}\right), \tag{3.35}$$

sem qualquer acesso a $E_{\mathrm{true,test}}$. O mesmo princípio vale para validação. A implementação concreta e a relação dessa regra com o protocolo de validação cruzada são detalhadas no Capítulo 5.

A escolha de trabalhar prioritariamente com informações derivadas dos anéis é deliberada. Variáveis adicionais, como E_T, η, número médio de interações μ, propriedades do cluster ou informações de trajetória, poderiam fornecer informação complementar. Entretanto, adicioná-las modificaria a pergunta experimental sobre quanto da correção pode ser inferido a partir da estrutura calorimétrica codificada pelos anéis. Esses acréscimos são, portanto, tratados como possíveis extensões ou ablações, e não incorporados silenciosamente ao espaço de entrada.

3.3 Seleção de características

Nesta tese, a seleção de características preserva atributos da representação Ringer original e altera apenas o subconjunto apresentado ao regressor. As duas estratégias avaliadas são baseadas, respectivamente, na associação linear medida pela correlação de Pearson e na dependência estatística medida pela informação mútua. Como ambas preservam colunas da representação original, os atributos selecionados mantêm correspondência direta com os índices dos anéis (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

3.3.1 Correlação de Pearson

A seleção de características baseada em correlação constitui a abordagem supervisionada mais simples considerada nesta tese para identificar quais componentes da representação Ringer apresentam maior associação linear com a variável de referência. Do ponto de vista estatístico, fornece uma medida univariada de relevância de baixo custo computacional e interpretação direta. Do ponto de vista físico, como a seleção atua sobre os próprios anéis e não sobre combinações transformadas, cada atributo preservado continua associado a uma posição definida na representação calorimétrica.

Para duas variáveis aleatórias X e Y, o coeficiente de correlação linear de Pearson é definido, no nível populacional, por

$$\rho(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sigma_X \sigma_Y}, \tag{3.36}$$

em que $\mathrm{Cov}(X,Y)$ é a covariância entre as variáveis e σ_X e σ_Y são seus respectivos desvios-padrão. O coeficiente assume valores no intervalo $[-1,1]$: valores próximos de $+1$ indicam forte associação linear crescente, valores próximos de -1 indicam forte associação linear decrescente, e valores próximos de zero indicam ausência de associação *linear* relevante, não necessariamente ausência de dependência estatística (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Na amostra finita utilizada para desenvolvimento dos modelos, a associação entre o j-ésimo anel e E_{true} é estimada pelo coeficiente amostral

$$\rho_j = \frac{\sum_{i=1}^{N} \left(\widetilde{E}_{r,j}^{(i)} - \overline{\widetilde{E}}_{r,j}\right)\left(E_{\mathrm{true}}^{(i)} - \overline{E}_{\mathrm{true}}\right)}{\sqrt{\sum_{i=1}^{N} \left(\widetilde{E}_{r,j}^{(i)} - \overline{\widetilde{E}}_{r,j}\right)^2}\sqrt{\sum_{i=1}^{N} \left(E_{\mathrm{true}}^{(i)} - \overline{E}_{\mathrm{true}}\right)^2}}, \tag{3.37}$$

em que

$$\overline{\widetilde{E}}_{r,j} = \frac{1}{N}\sum_{i=1}^{N} \widetilde{E}_{r,j}^{(i)} \tag{3.38}$$

e

$$\overline{E}_{\text{true}} = \frac{1}{N}\sum_{i=1}^{N} E_{\text{true}}^{(i)} \tag{3.39}$$

são as respectivas médias amostrais.

Como tanto associações crescentes quanto decrescentes podem conter informação preditiva, a relevância do anel é caracterizada por $|\rho_j|$. Essa utilização do módulo é importante pois uma variável com $\rho_j \simeq -1$ possui associação linear tão forte com o alvo quanto uma variável com $\rho_j \simeq +1$, diferindo apenas o sentido da relação. Descartá-la por causa do sinal constituiria uma perda injustificada de informação.

Na Etapa I da investigação a seleção por correlação foi realizada por limiares de relevância (SILVA et al., 2026b). Para um limiar τ, define-se o conjunto

$$\mathcal{S}_{\text{CORR}}(\tau) = \{j \in \{1,\ldots,100\} \mid |\rho_j| \geq \tau\}, \tag{3.40}$$

com

$$\tau \in \{0{,}50; 0{,}70; 0{,}80; 0{,}90\}. \tag{3.41}$$

Se

$$F_\tau = |\mathcal{S}_{\text{CORR}}(\tau)| \tag{3.42}$$

é o número de anéis que satisfazem o critério, a representação reduzida correspondente pode ser escrita como

$$\mathbf{X}_{\text{CORR},\tau} = g_{\text{CORR},\tau}\left(\widetilde{\mathbf{E}}_r\right) = \widetilde{\mathbf{E}}_r\,[:, \mathcal{S}_{\text{CORR}}(\tau)] \in \mathbb{R}^{N\times F_\tau}, \tag{3.43}$$

em que $\widetilde{\mathbf{E}}_r \in \mathbb{R}^{N\times 100}$ é a matriz contendo os anéis normalizados dos eventos e a notação $[:, \mathcal{S}]$ indica a retenção das colunas cujos índices pertencem ao conjunto $\mathcal{S}$.

Os valores de τ utilizados nessa primeira etapa não representam parâmetros universais da técnica. Eles constituem pontos de operação definidos experimentalmente para investigar o compromisso entre quantidade de informação preservada, dimensionalidade da entrada e desempenho posterior da calibração. Quanto maior τ, mais restritiva é a seleção e, em geral, menor é F_τ. Essa variação permitiu avaliar se parte significativa da informação relevante para a calibração poderia ser concentrada em poucos anéis.

Nas etapas posteriores da pesquisa, a estratégia foi modificada para permitir uma comparação metodologicamente mais controlada entre os métodos propostos (SILVA et al., 2026a). Em vez de impor um mesmo limiar numérico a escores de natureza estatística diferente, os anéis são ordenados segundo

$$|\rho_{\pi_{\text{CORR}}(1)}| \geq |\rho_{\pi_{\text{CORR}}(2)}| \geq \cdots \geq |\rho_{\pi_{\text{CORR}}(100)}|, \tag{3.44}$$

em que π_{CORR} é uma permutação dos índices dos anéis. Para uma cardinalidade prescrita m, são então mantidos os m anéis mais relevantes,

$$\mathcal{S}_{\text{CORR}}^{(m)} = \{\pi_{\text{CORR}}(1), \ldots, \pi_{\text{CORR}}(m)\}, \tag{3.45}$$

e

$$\mathbf{X}_{\mathrm{CORR},m} = \widetilde{\mathbf{E}}_r \left[:, \mathcal{S}^{(m)}_{\mathrm{CORR}}\right] \in \mathbb{R}^{N\times m}. \tag{3.46}$$

Nas Etapas II e III são considerados

$$m \in \{50, 10, 5, 2\}. \tag{3.47}$$

Essa mudança de protocolo é relevante também para a nomenclatura. Na Etapa I, uma configuração como `CORR-90` designa o uso do limiar $\tau = 0{,}90$. Nas etapas posteriores, uma configuração como `CORR-10` indica a retenção dos dez anéis de maior $|\rho_j|$. Portanto, o número presente no identificador não deve ser interpretado de forma indistinta entre as etapas experimentais.

A seleção por correlação preserva uma propriedade particularmente útil para a interpretação física: como as variáveis escolhidas continuam sendo anéis originais, seus índices podem ser relacionados às camadas calorimétricas definidas na representação Ringer. Consequentemente, concentrações de atributos selecionados em PS, EM1, EM2, EM3 ou nas camadas hadrônicas podem ser examinadas à luz do desenvolvimento longitudinal e transversal do chuveiro eletromagnético (PINTO; ATLAS Collaboration, 2016). Essa interpretação não está disponível de maneira direta para componentes PCA ou ICA, que são combinações das variáveis originais.

No entanto, elevada correlação individual com E_{true} não implica que um atributo seja indispensável em presença dos demais. Anéis espacialmente próximos podem responder a partes relacionadas do mesmo chuveiro e, portanto, apresentar forte correlação entre si. Nesse caso, dois ou mais atributos podem possuir valores elevados de $|\rho_j|$ e ainda assim transportar informação parcialmente redundante.

De forma mais geral, a seleção por Pearson constitui um método de relevância *marginal*: cada atributo é examinado separadamente em relação ao alvo. Ela não otimiza diretamente o desempenho do regressor, não maximiza informação conjunta entre o subconjunto escolhido e E_{true} e não controla explicitamente redundância entre os atributos selecionados. Sua utilidade nesta tese decorre precisamente de sua simplicidade, interpretabilidade e capacidade de fornecer uma referência linear contra a qual métodos capazes de detectar dependências mais gerais possam ser comparados.

Além disso, um valor pequeno de $|\rho_j|$ não permite concluir que o anel seja estatisticamente irrelevante. Relações simétricas ou fortemente não lineares podem possuir correlação de Pearson próxima de zero e ainda assim carregar informação considerável sobre o alvo (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Essa limitação motiva a utilização complementar da informação mútua, discutida a seguir.

3.3.2 Informação mútua

A Informação Mútua (*Mutual Information*, MUTI) fornece uma medida mais geral de dependência estatística do que a correlação linear. Enquanto o coeficiente de Pearson quantifica especificamente associação linear, a informação mútua mede quanto o conhecimento de uma variável reduz a incerteza sobre outra e, portanto, pode detectar dependências não lineares que

produziriam correlação linear pequena ou mesmo nula (COVER; THOMAS, 1991; KRASKOV; STÖGBAUER; GRASSBERGER, 2004).

Para duas variáveis aleatórias contínuas X e Y, com densidade conjunta $p_{XY}(x, y)$ e densidades marginais $p_X(x)$ e $p_Y(y)$, a informação mútua é definida por

$$I(X;Y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} p_{XY}(x,y) \log \left[\frac{p_{XY}(x,y)}{p_X(x) p_Y(y)} \right] dx\, dy. \tag{3.48}$$

Essa expressão pode ser interpretada como a divergência de Kullback–Leibler entre a distribuição conjunta p_{XY} e a distribuição que seria obtida caso as variáveis fossem independentes,

$$I(X;Y) = D_{\mathrm{KL}} \left(p_{XY} \,\|\, p_X p_Y \right). \tag{3.49}$$

Consequentemente,

$$I(X;Y) \geq 0, \tag{3.50}$$

e

$$I(X;Y) = 0 \quad \Longleftrightarrow \quad X \text{ e } Y \text{ são independentes}, \tag{3.51}$$

sob as condições usuais para existência das densidades envolvidas (COVER; THOMAS, 1991). A simetria

$$I(X;Y) = I(Y;X) \tag{3.52}$$

mostra ainda que a grandeza quantifica dependência e não uma relação causal ou direcional.

De forma equivalente, quando as entropias diferenciais envolvidas são bem definidas,

$$I(X;Y) = h(X) + h(Y) - h(X,Y), \tag{3.53}$$

o que explicita a interpretação da MUTI como redução de incerteza proporcionada pela observação conjunta das variáveis. A unidade depende da base do logaritmo utilizada: logaritmo natural fornece informação em *nats*, enquanto $\log_2$ fornece informação em *bits* (COVER; THOMAS, 1991) [1].

No problema desta tese, considera-se

$$X = \widetilde{E}_{r,j}, \qquad Y = E_{\mathrm{true}}, \tag{3.54}$$

de modo que a relevância do j-ésimo anel é caracterizada por

$$I_j = I\left(\widetilde{E}_{r,j}; E_{\mathrm{true}} \right). \tag{3.55}$$

Diferentemente do coeficiente de Pearson, I_j não possui sinal. Dependências crescentes, decrescentes ou não monotônicas podem produzir valores positivos de informação mútua. Essa propriedade é particularmente importante para o problema de calibração, pois a resposta de um anel pode depender da energia e da evolução do chuveiro de maneira não estritamente linear.

[1] A base do logaritmo altera apenas a escala numérica da informação mútua, e não a ordenação entre variáveis quando a mesma convenção é utilizada em todo o conjunto. Por essa razão, limiares numéricos de MUTI somente possuem significado em conjunto com a definição e o estimador empregados.

A Eq. 3.48 envolve densidades de probabilidade desconhecidas, que precisam ser estimadas a partir da amostra finita. Existem diferentes estimadores não paramétricos para esse problema. Uma forma explícita de aproximar a definição contínua consiste em estimar as densidades por *Kernel Density Estimation* (KDE) e realizar numericamente a integração. Outra família importante utiliza distâncias entre vizinhos próximos, evitando a estimação explícita das densidades (KRASKOV; STÖGBAUER; GRASSBERGER, 2004). A definição da MUTI é independente dessa escolha; o valor empírico obtido, entretanto, depende do estimador e de seus parâmetros.

Estimadores baseados em k vizinhos mais próximos oferecem uma alternativa que evita a construção explícita das densidades e da grade de integração. A classe de estimadores proposta por Kraskov, Stögbauer e Grassberger estima as entropias necessárias a partir das distâncias locais entre observações e é amplamente utilizada em problemas envolvendo variáveis contínuas (KRASKOV; STÖGBAUER; GRASSBERGER, 2004). Por essa razão, é conveniente representar genericamente por

$$\widehat{I}_j = \widehat{I}\left(\widetilde{E}_{r,j}; E_{\text{true}}\right) \tag{3.56}$$

o escore empírico produzido pelo estimador de informação mútua adotado, distinguindo a definição teórica I_j da sua estimação a partir de uma amostra finita.

Na Etapa I, a seleção publicada empregou limiares de relevância sobre o escore de informação mútua (SILVA et al., 2026b). Para um limiar τ, define-se

$$\mathcal{S}_{\text{MUTI}}(\tau) = \left\{ j \in \{1, \ldots, 100\} \;\middle|\; \widehat{I}_j \geq \tau \right\}, \tag{3.57}$$

e a representação resultante é

$$\mathbf{X}_{\text{MUTI},\tau} = g_{\text{MUTI},\tau}\left(\widetilde{\mathbf{E}}_r\right) = \widetilde{\mathbf{E}}_r\left[:, \mathcal{S}_{\text{MUTI}}(\tau)\right] \in \mathbb{R}^{N \times F_\tau}. \tag{3.58}$$

A Etapa I utilizou os valores

$$\tau \in \{0{,}50; 0{,}70; 0{,}80; 0{,}90; \}, \tag{3.59}$$

originando as configurações `MUTI-50`, `MUTI-70`, `MUTI-80` e `MUTI-90`. Esses identificadores são preservados por rastreabilidade com o estudo publicado. Entretanto, diferentemente da correlação de Pearson, cuja magnitude possui intervalo intrínseco $[0, 1]$, a informação mútua não possui, em sua definição geral, limite superior unitário. Consequentemente, os valores acima devem ser interpretados como limiares numéricos no escore empregado naquela etapa experimental, e não como "50%", "70%", "80%" ou "90% da informação total" em sentido informacional universal. Essa distinção evita interpretar a nomenclatura histórica como uma porcentagem de informação mútua. O valor numérico da MUTI depende, entre outros fatores, da base do logaritmo, do estimador empregado e, para amostras finitas, de parâmetros do estimador. Portanto, limiares absolutos de MUTI não devem ser transferidos automaticamente entre conjuntos de dados ou implementações diferentes.

Nas etapas posteriores, essa dificuldade é evitada utilizando a informação mútua apenas como critério de ordenação. Seja

$$\widehat{I}_{\pi_{\text{MUTI}}(1)} \geq \widehat{I}_{\pi_{\text{MUTI}}(2)} \geq \cdots \geq \widehat{I}_{\pi_{\text{MUTI}}(100)}, \tag{3.60}$$

a ordenação dos anéis por relevância. Para uma cardinalidade m,

$$\mathcal{S}_{\mathrm{MUTI}}^{(m)} = \{\pi_{\mathrm{MUTI}}(1), \ldots, \pi_{\mathrm{MUTI}}(m)\} \tag{3.61}$$

e

$$\mathbf{X}_{\mathrm{MUTI},m} = \widetilde{\mathbf{E}}_r \left[:, \mathcal{S}_{\mathrm{MUTI}}^{(m)}\right] \in \mathbb{R}^{N \times m}, \tag{3.62}$$

com

$$m \in \{50, 10, 5, 2\}. \tag{3.63}$$

Assim como em CORR, há uma diferença de nomenclatura entre os protocolos experimentais: `MUTI-80`, na Etapa I, refere-se ao limiar histórico $\tau = 0{,}80$, enquanto `MUTI-10`, nas etapas posteriores, designa diretamente uma representação contendo os dez anéis de maior informação mútua.

CORR e MUTI possuem em comum o fato de serem métodos de seleção de características. Nenhuma nova variável é construída, ou seja, são preservadas colunas da representação original. Dessa forma, os índices selecionados mantêm correspondência direta com regiões físicas do calorímetro. Esse aspecto permite interpretar, por exemplo, a recorrência de anéis associados às regiões EM1 e EM2 como resultado da distribuição espacial da informação relevante para o problema de calibração.

Entretanto, ambos os métodos avaliam relevância marginal. Em CORR,

$$s_j = \left|\rho\left(\widetilde{E}_{r,j}, E_{\mathrm{true}}\right)\right|, \tag{3.64}$$

enquanto em MUTI,

$$s_j = \widehat{I}\left(\widetilde{E}_{r,j}; E_{\mathrm{true}}\right). \tag{3.65}$$

Em ambos os casos, o j-ésimo anel é avaliado isoladamente em relação ao alvo. Logo, selecionar individualmente os atributos de maior escore não implica que o conjunto resultante maximize

$$I\left(\mathbf{X}; E_{\mathrm{true}}\right), \tag{3.66}$$

nem garante ausência de redundância interna. Dois anéis altamente dependentes entre si podem apresentar simultaneamente elevada informação mútua com E_{true} e, ainda assim, fornecer informação conjunta adicional limitada.

Portanto, a superioridade conceitual da MUTI sobre Pearson restringe-se à classe de dependências que pode detectar: MUTI é capaz de capturar relações lineares e não lineares, enquanto Pearson caracteriza apenas a componente linear. Isso não implica que uma seleção marginal por MUTI deva necessariamente produzir melhor desempenho de regressão do que uma seleção por CORR. O desempenho final depende da estrutura conjunta das variáveis selecionadas, da redundância entre elas, da capacidade do regressor $f_{\mathrm{ML}}(\cdot)$ e do tamanho da amostra.

Finalmente, a utilização de E_{true} em CORR e MUTI caracteriza essas duas estratégias como procedimentos supervisionados de construção da representação. Isso não significa que E_{true}

seja uma entrada disponível durante inferência. O alvo é empregado apenas na fase de definição dos escores e do conjunto de atributos. Após a seleção,

$$\mathbf{x}^{(i)} = g_{\mathrm{ML}}\left(\widetilde{\mathbf{E}}_r^{(i)}\right) \tag{3.67}$$

é produzido para um novo evento utilizando exclusivamente os anéis correspondentes. No protocolo experimental desta tese, o operador de representação é definido utilizando apenas a partição de desenvolvimento permitida e posteriormente mantido fixo na avaliação sobre dados não utilizados nessa definição, conforme detalhado no Capítulo 5.

A seleção por CORR ou MUTI procura, portanto, concentrar em uma representação de menor dimensionalidade os anéis individualmente mais relacionados à energia verdadeira. Essa compactação pode reduzir armazenamento, movimentação de dados e custo de processamento dos regressores subsequentes, mas a redução da dimensionalidade externa F não deve ser confundida automaticamente com redução proporcional da latência de ponta a ponta do sistema. O custo real depende também da construção da representação, da arquitetura de $f_{\mathrm{ML}}(\cdot)$, da plataforma de execução e das demais etapas da cadeia.

Os métodos discutidos até aqui preservam atributos originais. Uma estratégia distinta consiste em construir novas coordenadas a partir da combinação dos 100 anéis, buscando concentrar a informação em um espaço transformado. Essa segunda classe de redução de dimensionalidade é investigada nas seções seguintes por meio da Análise de Componentes Principais (*Principal Component Analysis*, PCA) e da Análise de Componentes Independentes (*Independent Component Analysis*, ICA).

3.4 Extração de características

Diferentemente da seleção de características, a extração constrói novas coordenadas a partir de combinações das variáveis originais. Nesta tese, PCA e ICA são utilizadas para investigar duas hipóteses distintas de representação compacta: concentração de variância em direções ortogonais e obtenção de componentes com dependência estatística reduzida, respectivamente (JOLLIFFE, 2002; HYVÄRINEN; KARHUNEN; OJA, 2001).

3.4.1 Análise de Componentes Principais

A Análise de Componentes Principais (*Principal Component Analysis*, PCA) é uma transformação linear destinada a representar um conjunto de variáveis correlacionadas em um novo sistema de coordenadas ortogonais, denominado sistema de componentes principais. As novas direções são construídas de modo que a primeira componente possua a maior variância possível entre todas as projeções lineares unitárias, a segunda maximize a variância remanescente sob a restrição de ortogonalidade em relação à primeira, e assim sucessivamente (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GÉRON, 2019; JOLLIFFE, 2002).

Esse princípio fornece à PCA uma interpretação geométrica e estatística precisa. A redução de dimensionalidade não decorre da hipótese de que variância e informação preditiva sejam conceitos equivalentes, mas da possibilidade de que grande parte da variabilidade da

representação original esteja concentrada em um subespaço linear de dimensão menor. Nesse caso, uma projeção sobre um número reduzido de componentes pode preservar parcela substancial da estrutura dos dados e, simultaneamente, diminuir a dimensionalidade fornecida aos regressores.

No contexto desta tese, a PCA parte da matriz de anéis normalizados $\widetilde{\mathbf{E}}_r \in \mathbb{R}^{N\times 100}$ definida na Eq. 3.32. Antes da obtenção das componentes principais, cada atributo é centralizado em torno de sua média amostral. Para o j-ésimo anel,

$$\mu_j = \frac{1}{N}\sum_{i=1}^{N} \widetilde{E}_{r,j}^{(i)}, \qquad j = 1, \ldots, 100, \tag{3.68}$$

e, reunindo as médias em

$$\boldsymbol{\mu} = [\mu_1, \mu_2, \ldots, \mu_{100}]^T, \tag{3.69}$$

a matriz centralizada é

$$\mathbf{X}_c = \widetilde{\mathbf{E}}_r - \mathbf{1}\boldsymbol{\mu}^T, \tag{3.70}$$

em que $\mathbf{1} \in \mathbb{R}^N$ é um vetor de elementos unitários. Equivalentemente,

$$x_{ij} = \widetilde{E}_{r,j}^{(i)} - \mu_j, \qquad i = 1, \ldots, N, \quad j = 1, \ldots, 100. \tag{3.71}$$

A centralização é necessária porque a PCA descreve a dispersão dos dados em torno da média. Sem essa operação, um deslocamento global das variáveis poderia influenciar a decomposição apesar de não representar variabilidade entre eventos.

A partir de $\mathbf{X}_c$, define-se a matriz de covariância amostral

$$\mathbf{C} = \frac{1}{N-1}\mathbf{X}_c^T\mathbf{X}_c \in \mathbb{R}^{100\times 100}, \tag{3.72}$$

cujos elementos fora da diagonal representam covariâncias entre diferentes anéis e cujos elementos diagonais correspondem às respectivas variâncias.

No presente problema existe uma particularidade decorrente da própria normalização Ringer. Como, para cada evento,

$$\sum_{j=1}^{100} \widetilde{E}_{r,j}^{(i)} = 1, \tag{3.73}$$

segue, após a centralização, que

$$\mathbf{X}_c\mathbf{1}_{100} = \mathbf{0}, \tag{3.74}$$

em que $\mathbf{1}_{100}$ é o vetor de 100 elementos unitários. Consequentemente,

$$\mathbf{C}\mathbf{1}_{100} = \mathbf{0}. \tag{3.75}$$

Portanto, a representação normalizada possui pelo menos uma dependência linear exata e a matriz de covariância completa é positiva semidefinida, mas não necessariamente positiva definida. Em aritmética finita, o autovalor correspondente pode aparecer como zero ou numericamente próximo de zero. Essa propriedade será particularmente importante para o branqueamento empregado na ICA.

Como $\mathbf{C}$ é real e simétrica, admite uma base ortonormal de autovetores. O problema de autovalores é

$$\mathbf{C}\mathbf{v}_k = \lambda_k\mathbf{v}_k, \qquad k = 1, \ldots, 100, \tag{3.76}$$

e a decomposição espectral pode ser escrita como

$$\mathbf{C} = \mathbf{V}\boldsymbol{\Lambda}\mathbf{V}^T, \tag{3.77}$$

em que

$$\mathbf{V} = \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_{100} \end{bmatrix} \tag{3.78}$$

é ortogonal e

$$\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \lambda_2, \ldots, \lambda_{100}) \tag{3.79}$$

contém os autovalores não negativos. Na ordenação natural da PCA,

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_{100} \geq 0. \tag{3.80}$$

Cada autovetor $\mathbf{v}_k$ define uma direção principal e o autovalor associado λ_k corresponde à variância da projeção dos dados nessa direção. A transformação completa é, portanto,

$$\mathbf{X}_{\mathrm{PCA}} = \mathbf{X}_c\mathbf{V}. \tag{3.81}$$

A covariância das variáveis transformadas é

$$\frac{1}{N-1}\mathbf{X}_{\mathrm{PCA}}^T\mathbf{X}_{\mathrm{PCA}} = \boldsymbol{\Lambda}, \tag{3.82}$$

mostrando que as componentes principais são não correlacionadas entre si na amostra utilizada para construir a transformação.

A proporção da variância total associada ao k-ésimo componente é

$$\mathrm{EVR}_k = \frac{\lambda_k}{\sum_{j=1}^{100} \lambda_j}, \tag{3.83}$$

em que EVR_k denota a razão de variância explicada (*explained variance ratio*) pela componente k. Para os primeiros m componentes na ordenação natural da PCA, a fração acumulada é

$$\sum_{k=1}^{m} \mathrm{EVR}_k = \frac{\sum_{k=1}^{m} \lambda_k}{\sum_{j=1}^{100} \lambda_j}. \tag{3.84}$$

A Eq. 3.84 descreve a truncação canônica da PCA segundo a ordenação natural dos autovalores. Entretanto, essa não foi a regra utilizada para selecionar as componentes fornecidas aos regressores nos experimentos desta tese. Após o ajuste da transformação PCA, cada componente foi avaliada segundo sua relevância para o alvo de calibração por meio do módulo da correlação de Pearson com E_{true}.

Para a k-ésima componente da transformação completa, define-se

$$s_{\mathrm{PCA},k} = \left|\rho\left(\mathbf{X}_{\mathrm{PCA}}[:,k], \mathbf{E}_{\mathrm{true}}\right)\right|, \qquad k = 1, \ldots, 100, \tag{3.85}$$

em que $\mathbf{X}_{\mathrm{PCA}}[:,k]$ denota a k-ésima coluna da transformação PCA completa. Seja π_{PCA} a permutação dos índices das componentes tal que

$$s_{\mathrm{PCA},\pi_{\mathrm{PCA}}(1)} \geq s_{\mathrm{PCA},\pi_{\mathrm{PCA}}(2)} \geq \cdots \geq s_{\mathrm{PCA},\pi_{\mathrm{PCA}}(100)}. \tag{3.86}$$

Para uma cardinalidade m, o conjunto de componentes retidos é

$$\mathcal{S}_{\mathrm{PCA}}^{(m)} = \{\pi_{\mathrm{PCA}}(1), \ldots, \pi_{\mathrm{PCA}}(m)\}, \tag{3.87}$$

e a representação utilizada pelos regressores é

$$\mathbf{X}_{\mathrm{PCA},m} = \mathbf{X}_{\mathrm{PCA}}\left[:, \mathcal{S}_{\mathrm{PCA}}^{(m)}\right] = g_{\mathrm{PCA}}\left(\widetilde{\mathbf{E}}_r, m\right) \in \mathbb{R}^{N\times m}, \tag{3.88}$$

com $g_{\mathrm{ML}}(\cdot) = g_{\mathrm{PCA}}(\cdot)$ quando a PCA é utilizada.

Esse procedimento de ordenação por relevância em relação a E_{true} foi empregado nas três etapas experimentais. Na Etapa I foram avaliadas as cardinalidades

$$m \in \{100,\ 10,\ 5,\ 2\}, \tag{3.89}$$

enquanto nas Etapas II e III foram consideradas

$$m \in \{50,\ 10,\ 5,\ 2\}. \tag{3.90}$$

Portanto, uma configuração como `PCA-10` representa as dez componentes de maior $s_{\mathrm{PCA},k}$ após a transformação PCA, e não necessariamente as dez primeiras componentes na ordenação natural dos autovalores. A configuração `PCA-100` preserva todas as componentes; nesse caso, a ordenação por relevância apenas permuta as coordenadas e não produz redução de dimensionalidade.

A distinção é importante para interpretar a variância explicada. A Eq. 3.84 fornece a variância acumulada dos primeiros m componentes na ordenação natural por λ_k. Para o subconjunto efetivamente selecionado por relevância supervisionada, a fração de variância correspondente é

$$\mathrm{EVR}_{\mathrm{sel}}^{(m)} = \frac{\displaystyle\sum_{k\in\mathcal{S}_{\mathrm{PCA}}^{(m)}} \lambda_k}{\displaystyle\sum_{j=1}^{100} \lambda_j}. \tag{3.91}$$

Somente quando $\mathcal{S}_{\mathrm{PCA}}^{(m)} = \{1,\ldots,m\}$ essa quantidade coincide com a variância explicada acumulada dos primeiros m componentes na ordenação natural. Assim, a construção da base PCA permanece não supervisionada, mas a seleção das componentes empregada nas configurações reduzidas desta tese é supervisionada por E_{true} (SILVA et al., 2026b; SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026).

A PCA apresenta, assim, duas propriedades de interesse para o problema desta tese. Primeiro, transforma atributos originalmente correlacionados em coordenadas linearmente não correlacionadas, reduzindo problemas de multicolinearidade para modelos sensíveis a essa estrutura. Segundo, pode concentrar grande parte da variabilidade da representação dos anéis

em um número pequeno de componentes. Em contrapartida, cada componente passa a ser uma combinação linear de diferentes anéis,

$$X_{\mathrm{PCA},k}^{(i)} = \sum_{j=1}^{100} v_{jk} \left(\widetilde{E}_{r,j}^{(i)} - \mu_j \right), \tag{3.92}$$

de modo que deixa de existir uma correspondência um a um entre a entrada transformada e uma posição física específica da representação calorimétrica.

Cabe ainda qualificar a afirmação de que a PCA é um procedimento não supervisionado. A construção da base PCA não requer E_{true} e, em princípio, poderia ser estimada a partir de uma amostra não rotulada. Isso não significa, entretanto, que uma transformação PCA treinada sobre dados simulados possa ser simplesmente recalculada sobre dados experimentais e substituída sem consequências. Modificar a base altera as coordenadas apresentadas a $f_{\mathrm{ML}}(\cdot)$ e, portanto, exigiria novo treinamento ou, no mínimo, uma validação específica da cadeia completa. No protocolo experimental desta tese, após a construção da base, as componentes são ordenadas segundo sua correlação absoluta com E_{true}; essa etapa de ordenação é, portanto, supervisionada.

No protocolo experimental desta tese, a transformação e a ordenação dos componentes são definidas *offline* utilizando somente a partição de desenvolvimento. Posteriormente, os parâmetros permanecem fixos. Para um novo evento, não é necessário recalcular autovalores, autovetores ou correlações; é necessário apenas aplicar a centralização e a transformação linear previamente determinadas. Dessa forma, o custo de ajuste da PCA não integra a inferência evento a evento, embora o custo da aplicação de $g_{\mathrm{PCA}}(\cdot)$ não seja matematicamente nulo e deva ser considerado em uma eventual medição de latência de ponta a ponta.

3.4.2 Análise de Componentes Independentes

A Análise de Componentes Independentes (*Independent Component Analysis*, ICA) também constrói uma nova representação por meio de combinações lineares das variáveis observadas, mas utiliza um critério estatístico distinto daquele da PCA. Em vez de buscar direções ortogonais ordenadas por variância, a ICA procura componentes cuja dependência estatística mútua seja tão pequena quanto possível, sob um modelo de mistura linear (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GÉRON, 2019; HYVÄRINEN; KARHUNEN; OJA, 2001; HYVÄRINEN; OJA, 1997).

No modelo clássico de ICA, considera-se um vetor observado $\mathbf{x}$ produzido pela combinação linear de componentes latentes,

$$\mathbf{x} = \mathbf{A}\mathbf{s}, \tag{3.93}$$

em que $\mathbf{s}$ contém componentes estatisticamente independentes e $\mathbf{A}$ é uma matriz de mistura desconhecida. O problema consiste em estimar uma transformação de separação $\mathbf{W}$ tal que

$$\mathbf{s} \approx \mathbf{W}\mathbf{x}. \tag{3.94}$$

A interpretação de "fontes" nessa formulação deve ser feita com cautela no problema calorimétrico. Os anéis não são assumidos como resultado literal da mistura de processos físicos independentes

identificáveis. A ICA é utilizada nesta tese como método de extração de características: suas componentes são direções latentes determinadas estatisticamente a partir da representação dos anéis, e não são interpretadas automaticamente como mecanismos físicos isolados do desenvolvimento do chuveiro.

Independência estatística é uma condição mais forte do que ausência de correlação. Se duas variáveis possuem variância finita e são independentes, então são não correlacionadas; o recíproco, porém, não é verdadeiro em geral. Consequentemente, uma transformação baseada apenas na matriz de covariância, como o branqueamento, não é suficiente para produzir componentes independentes. A ICA necessita explorar propriedades da distribuição que não estão contidas apenas nas estatísticas de segunda ordem (HYVÄRINEN; KARHUNEN; OJA, 2001).

No contexto desta tese, a ICA parte da mesma matriz $\widetilde{\mathbf{E}}_r$, da matriz centralizada $\mathbf{X}_c$ e da covariância amostral $\mathbf{C}$ definidas nas Eqs. 3.32, 3.70 e 3.72, respectivamente. Então, o primeiro estágio usual da ICA é o branqueamento (*whitening*), cujo objetivo é produzir uma representação com covariância identidade no subespaço de variância não nula. Para isso, utiliza-se a decomposição espectral

$$\mathbf{C} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T. \tag{3.95}$$

em que $\mathbf{V} \in \mathbb{R}^{100\times100}$ é a matriz cujas colunas são os autovetores ortonormais de $\mathbf{C}$, $\mathbf{\Lambda} \in \mathbb{R}^{100\times100}$ é a matriz diagonal formada pelos autovalores correspondentes e $\mathbf{V}^T$ denota a transposta de $\mathbf{V}$. Como $\mathbf{C}$ é uma matriz real e simétrica, essa decomposição pode ser realizada com uma base ortonormal de autovetores (STRANG, 2023).

No presente problema, não se deve assumir que todos os autovalores de $\mathbf{C}$ sejam estritamente positivos. Como mostrado na Eq. 3.74, a normalização dos anéis introduz uma dependência linear entre as 100 variáveis. Portanto, a inversão indiscriminada de uma matriz diagonal contendo todos os autovalores não é matematicamente adequada.

Nas expressões de branqueamento, $\mathbf{V}$ e $\mathbf{\Lambda}$ devem ser entendidas como restritas às direções cujos autovalores são numericamente não nulos. Assim,

$$\mathbf{X}_w = \mathbf{X}_c\mathbf{V}\mathbf{\Lambda}^{-1/2}, \tag{3.96}$$

e, no subespaço retido,

$$\frac{1}{N-1}\mathbf{X}_w^T\mathbf{X}_w = \mathbf{I}. \tag{3.97}$$

Para um único vetor centrado, a mesma transformação pode ser escrita como

$$\mathbf{z} = \mathbf{\Lambda}^{-1/2}\mathbf{V}^T\mathbf{x}_c. \tag{3.98}$$

Esse tratamento evita a inversão de direções degeneradas ou de variância numericamente desprezível. Implementações robustas realizam essa operação por decomposição espectral ou SVD, com tolerância numérica apropriada. O branqueamento produz componentes não correlacionadas e com variância unitária, mas não garante independência. A etapa seguinte busca uma rotação adicional do espaço branqueado que maximize um critério associado à não Gaussianidade das projeções. A utilização de não Gaussianidade está relacionada à identificabilidade do modelo clássico de ICA. Sob as hipóteses usuais de mistura linear e independência, combinações de

variáveis independentes tendem a apresentar distribuições mais próximas da Gaussianidade do que as fontes individuais. Assim, procurar projeções maximamente não gaussianas constitui uma estratégia para recuperar componentes estatisticamente independentes (HYVÄRINEN; KARHUNEN; OJA, 2001).[2]

Um algoritmo amplamente utilizado para esse propósito é o FastICA (HYVÄRINEN; OJA, 1997). Para dados branqueados, considere um vetor de separação unitário $\mathbf{w}$. Uma atualização amostral do algoritmo de ponto fixo pode ser escrita como

$$\mathbf{w}^{(\text{new})} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{x}_w^{(i)}\, \mathcal{T}\left(\mathbf{w}^T \mathbf{x}_w^{(i)}\right) - \left[\frac{1}{N}\sum_{i=1}^{N} \mathcal{T}'\left(\mathbf{w}^T \mathbf{x}_w^{(i)}\right)\right] \mathbf{w}, \tag{3.99}$$

em que $\mathbf{x}_w^{(i)}$ é a representação branqueada do i-ésimo evento e $\mathcal{T}(\cdot)$ é uma função não linear associada ao contraste utilizado para medir não Gaussianidade.

Uma escolha comum é

$$\mathcal{T}(u) = \tanh(u), \tag{3.100}$$

com

$$\mathcal{T}'(u) = 1 - \tanh^2(u). \tag{3.101}$$

A tangente hiperbólica é frequentemente utilizada em FastICA por fornecer um contraste suave e relativamente robusto à influência de valores extremos (HYVÄRINEN; KARHUNEN; OJA, 2001).[3]

Após a atualização, o vetor é normalizado,

$$\mathbf{w} \leftarrow \frac{\mathbf{w}^{(\text{new})}}{\left\|\mathbf{w}^{(\text{new})}\right\|}. \tag{3.102}$$

Quando mais de uma componente é estimada, a normalização isolada não é suficiente: as diferentes direções precisam também ser decorrelacionadas entre si durante o procedimento iterativo. Isso pode ser realizado por um esquema de deflação, com ortogonalização de cada nova direção em relação às já obtidas, ou por uma atualização simétrica da matriz de separação (HYVÄRINEN; KARHUNEN; OJA, 2001; HYVÄRINEN; OJA, 1997).

O processo é repetido até que as direções sucessivas apresentem variação inferior à tolerância adotada. Como o sinal de uma componente ICA é indeterminado, um critério de convergência mais apropriado do que a simples distância Euclidiana entre dois vetores é

$$1 - \left|\mathbf{w}^{(k+1)T} \mathbf{w}^{(k)}\right| < \varepsilon, \tag{3.103}$$

em que ε é a tolerância numérica do procedimento.

[2] A utilização de uma função não linear no critério de otimização da ICA não torna a transformação final uma transformação não linear dos anéis. A representação obtida continua sendo uma combinação linear das variáveis observadas. A não linearidade é utilizada para estimar estatísticas além da covariância e, consequentemente, distinguir direções que uma simples descorrelação não permitiria identificar. No modelo clássico de ICA, a identificabilidade também requer hipóteses adicionais, entre elas que não haja mais de uma componente gaussiana independente.

[3] A escolha $\mathcal{T}(u) = \tanh(u)$ está associada à derivada de funções de contraste do tipo $\log\cosh(u)$ empregadas como aproximações de negentropia. Diferentes funções de contraste podem apresentar comportamentos distintos de robustez e eficiência conforme a distribuição das componentes.

Após a convergência, as direções estimadas são reunidas na matriz de separação $\mathbf{W}$. Mantendo a convenção utilizada nesta tese, na qual eventos ocupam as linhas das matrizes, as componentes podem ser escritas diretamente como

$$\mathbf{X}_{\mathrm{ICA}} = \mathbf{X}_w \mathbf{W}^T, \tag{3.104}$$

de modo que cada linha corresponde a um evento e cada coluna a uma componente independente. Essa convenção evita a necessidade de construir as componentes inicialmente na orientação $m \times N$ e realizar uma transposição apenas para adequação ao restante do pipeline.

Existe uma diferença fundamental entre a ordenação das componentes de PCA e ICA. Na PCA, os autovalores fornecem uma ordenação intrínseca à decomposição: componentes com maiores λ_k possuem maior variância explicada. Na ICA, por outro lado, a solução possui indeterminação de permutação e de sinal. Se um conjunto de componentes independentes satisfaz o modelo, sua permutação também satisfaz. Consequentemente, não existe uma noção intrínseca de primeira componente ICA baseada em variância explicada (HYVÄRINEN; KARHUNEN; OJA, 2001).

Por essa razão, para utilizar um número reduzido de componentes no problema de calibração, é necessário introduzir um critério adicional de relevância. Nesta tese, após o ajuste da transformação ICA, as colunas de $\mathbf{X}_{\mathrm{ICA}}$ são ordenadas segundo o módulo de sua correlação de Pearson com E_{true},

$$\left|\rho\left(\mathbf{x}_{\mathrm{ICA}}^{(1)}, \mathbf{E}_{\mathrm{true}}\right)\right| \geq \left|\rho\left(\mathbf{x}_{\mathrm{ICA}}^{(2)}, \mathbf{E}_{\mathrm{true}}\right)\right| \geq \cdots, \tag{3.105}$$

em que $\mathbf{x}_{\mathrm{ICA}}^{(j)}$ representa o vetor contendo a j-ésima componente para os eventos da partição utilizada na definição da representação (nesse caso não representa eventos).

Dessa forma, selecionam-se as m componentes de maior relevância segundo esse critério,

$$\mathbf{X}_{\mathrm{ICA},m} = g_{\mathrm{ICA}}\left(\widetilde{\mathbf{E}}_r, m\right) \in \mathbb{R}^{N \times m}, \tag{3.106}$$

com $g_{\mathrm{ML}}(\cdot) = g_{\mathrm{ICA}}(\cdot)$ quando essa representação é empregada.

Na Etapa I foram avaliadas as cardinalidades

$$m \in \{100,\, 10,\, 5,\, 2\}, \tag{3.107}$$

enquanto as etapas posteriores utilizaram

$$m \in \{50,\, 10,\, 5,\, 2\}. \tag{3.108}$$

Por rastreabilidade com a nomenclatura experimental, a configuração completa é denominada `ICA-100`. Essa designação refere-se ao uso da representação completa como entrada da transformação e não implica a existência de 100 direções independentes e não degeneradas. A dimensionalidade efetiva da ICA é limitada pelo posto numérico do espaço branqueado.

É importante enfatizar que a ordenação supervisionada das componentes ICA não altera a natureza da transformação ICA utilizada para construí-las. O ajuste da ICA propriamente dita é não supervisionado e depende apenas de $\widetilde{\mathbf{E}}_r$. E_{true} é utilizado posteriormente para estabelecer

quais componentes serão priorizadas para a tarefa específica de calibração (SILVA et al., 2026b; SILVA et al., 2026a). Portanto, a representação final reduzida combina uma extração não supervisionada com uma seleção supervisionada das componentes.

Entretanto, isso não significa que a ICA possua custo ou latência nula durante a aplicação: para um novo evento ainda é necessário realizar a centralização e aplicar a transformação linear previamente estimada. Como branqueamento e separação são transformações lineares fixas após o treinamento, suas matrizes podem ser combinadas previamente, reduzindo a aplicação a uma única transformação linear seguida da seleção das componentes necessárias.

A mesma lógica vale para PCA. O cálculo de médias, matrizes de covariância, autovetores, critérios de independência e rankings pertence à fase de ajuste da representação. Na inferência, utilizam-se apenas os parâmetros previamente determinados. Ainda assim, uma eventual avaliação de implantação deve contabilizar o custo da aplicação de $g_{\mathrm{PCA}}(\cdot)$ ou $g_{\mathrm{ICA}}(\cdot)$ juntamente com $f_{\mathrm{ML}}(\cdot)$, em vez de assumir que a redução de latência foi produzida sem custo computacional.

PCA e ICA investigam, portanto, estruturas diferentes da representação calorimétrica. A PCA produz direções ortogonais que diagonalizam a covariância e são naturalmente ordenadas pela variância. A ICA parte de dados tipicamente branqueados e procura uma rotação adicional que reduza dependências estatísticas de ordem superior, sem fornecer uma ordenação intrínseca por variância. Além disso, em ambos os casos as componentes são combinações de múltiplos anéis e perdem a correspondência direta entre uma entrada e uma região física individual do calorímetro.

Nenhuma dessas propriedades garante, isoladamente, superioridade preditiva. Variância elevada não implica máxima relevância para E_{true}, da mesma forma que independência estatística entre componentes não implica que eles constituam a representação ótima para uma determinada família de regressores. Por essa razão, PCA e ICA são avaliadas empiricamente sob a mesma formulação de calibração e comparadas às estratégias de seleção CORR e MUTI e à representação completa dos anéis.

Com a etapa de representação definida, o Capítulo 4 apresenta as famílias de regressão utilizadas para implementar $f_{\mathrm{ML}}(\cdot)$ e estimar o fator de calibração evento a evento.

3.5 Conclusão do capítulo

Este capítulo estabeleceu a formulação comum da calibração evento a evento utilizada ao longo da tese e separou a cadeia de estimação em dois componentes conceitualmente distintos: a construção da representação por $g_{\mathrm{ML}}(\cdot)$ e a estimação do fator de calibração por $f_{\mathrm{ML}}(\cdot)$. Essa decomposição permite modificar a representação ou a família de regressão sem alterar a definição da quantidade calibrada.

No primeiro desses componentes, foram distinguidas seleção e extração de características. CORR e MUTI preservam anéis originais e, portanto, mantêm correspondência direta com posições da representação Ringer, enquanto PCA e ICA constroem componentes transformados e substituem essa correspondência individual por novas coordenadas estatísticas (SILVA et al., 2026b; SILVA et al., 2026a). Também foi explicitada a diferença entre ajuste e aplicação de

$g_{\mathrm{ML}}(\cdot)$: métodos supervisionados de construção ou ordenação da representação podem utilizar E_{true} durante o desenvolvimento, mas essa grandeza não constitui informação disponível para a transformação de um novo evento.

As representações completas e compactas definidas neste capítulo constituem, assim, a interface de entrada dos regressores avaliados na tese. O Capítulo 4 parte dessa interface para apresentar os modelos que implementam $f_{\mathrm{ML}}(\cdot)$, desde regressões convencionais e árvores até ensembles, redes neurais profundas e a arquitetura GNN relacional–tabular. Posteriormente, o Capítulo 5 estabelece como $g_{\mathrm{ML}}(\cdot)$ e $f_{\mathrm{ML}}(\cdot)$ são combinados no protocolo experimental, incluindo as regras de particionamento, ajuste e prevenção de vazamento de informação.

4 Modelos de Regressão e Fusão de Informação para Calibração Calorimétrica

Este capítulo apresenta as famílias de modelos utilizadas para implementar o segundo componente da cadeia de calibração definida no Capítulo 3: a função $f_{\mathrm{ML}}(\cdot)$ que transforma a representação $\mathbf{x}^{(i)} = g_{\mathrm{ML}}\left(\widetilde{\mathbf{E}}_r^{(i)}\right)$ em uma estimativa do fator $\alpha_{\mathrm{calib}}^{(i)}$. A definição do alvo, a relação entre α_{calib} e E_{calib} e a distinção entre regressão do fator de calibração e regressão direta da energia não são redefinidas aqui; elas permanecem estabelecidas pela formulação comum do capítulo anterior.

As famílias consideradas introduzem diferentes vieses indutivos e mecanismos de modelagem. MLR e regressão polinomial fornecem referências funcionais globais; árvores de decisão, BDTs e *Random Forests* introduzem partições adaptativas e mecanismos de ensemble; os modelos híbridos combinam regressores por correção residual ou empilhamento; e as arquiteturas neurais realizam fusão não linear da informação. A progressão culmina na arquitetura GNN relacional–tabular proposta para explorar conjuntamente a organização da representação Ringer e sua informação tabular (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; SILVA et al., 2026b; SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026).

O objetivo deste capítulo é fornecer o formalismo necessário para compreender como cada família produz $f_{\mathrm{ML}}(\cdot)$, quais hipóteses estruturais introduz e quais compromissos de capacidade, generalização e custo computacional devem ser considerados. As configurações experimentais, os espaços de hiperparâmetros e os procedimentos de seleção e avaliação são tratados no Capítulo 5 e no Apêndice de Reprodutibilidade.

4.1 Modelos de regressão convencionais e baseados em árvores

As primeiras etapas desta tese utilizam famílias de regressão com diferentes vieses indutivos e diferentes níveis de capacidade. Essa diversidade é metodologicamente útil: permite verificar se a relação entre a representação calorimétrica e o fator de calibração pode ser descrita por um mapeamento aproximadamente linear, se requer interações polinomiais explícitas ou se é melhor representada por partições adaptativas e ensembles de árvores (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; BISHOP, 2006).

4.1.1 Regressão linear multivariada

A regressão linear multivariada (*Multiple Linear Regression*, MLR) constitui o modelo de menor complexidade funcional entre os regressores considerados nesta tese. Seu objetivo é representar a relação entre o vetor de atributos fornecido por $g_{\mathrm{ML}}(\cdot)$ e o fator de calibração por meio de uma combinação linear global das variáveis de entrada (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; BISHOP, 2006).

Para o i-ésimo evento, seja

$$\mathbf{x}^{(i)} = \left[x_1^{(i)}, x_2^{(i)}, \ldots, x_F^{(i)}\right]^T \in \mathbb{R}^F \tag{4.1}$$

a representação utilizada pelo regressor, em que F é a dimensionalidade da entrada após a aplicação de $g_{\mathrm{ML}}(\cdot)$. Dependendo da configuração experimental, $\mathbf{x}^{(i)}$ pode corresponder aos 100 anéis originais ou a uma representação reduzida por CORR, MUTI, PCA ou ICA.

A MLR modela o fator de calibração como

$$\alpha_{\mathrm{calib}}^{(i)} = f_{\mathrm{MLR}}\left(\mathbf{x}^{(i)}\right) = \beta_0 + \sum_{j=1}^{F} \beta_j x_j^{(i)}, \tag{4.2}$$

em que β_0 é o intercepto e β_j, $j = 1, \ldots, F$, são os coeficientes associados aos atributos.

A Eq. 4.2 estabelece um único hiperplano no espaço de entrada. Portanto, a MLR pode representar relações lineares entre os atributos e o fator de calibração, mas não introduz explicitamente curvaturas, produtos entre variáveis ou mudanças locais de regime. Essa característica constitui simultaneamente sua principal vantagem e sua principal limitação: trata-se de um modelo simples, interpretável e de baixo custo computacional, porém com capacidade funcional restrita (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; BISHOP, 2006).

Para N eventos de treinamento, define-se a matriz de projeto aumentada

$$\mathbf{\Phi} = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \cdots & x_F^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \cdots & x_F^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(N)} & x_2^{(N)} & \cdots & x_F^{(N)} \end{bmatrix} \in \mathbb{R}^{N \times (F+1)}, \tag{4.3}$$

e o vetor de parâmetros

$$\boldsymbol{\beta} = [\beta_0, \beta_1, \ldots, \beta_F]^T \in \mathbb{R}^{F+1}. \tag{4.4}$$

O vetor-alvo de treinamento é

$$\boldsymbol{\alpha}_{\mathrm{true}} = \left[\alpha_{\mathrm{true}}^{(1)}, \alpha_{\mathrm{true}}^{(2)}, \ldots, \alpha_{\mathrm{true}}^{(N)}\right]^T, \tag{4.5}$$

com

$$\alpha_{\mathrm{true}}^{(i)} = \frac{E_{\mathrm{true}}^{(i)}}{E_{\mathrm{fast}}^{(i)}}, \qquad E_{\mathrm{fast}}^{(i)} \neq 0. \tag{4.6}$$

Na forma matricial, as predições da MLR são

$$\boldsymbol{\alpha}_{\mathrm{calib}} = \mathbf{\Phi}\boldsymbol{\beta}. \tag{4.7}$$

O ajuste por mínimos quadrados ordinários consiste em determinar os coeficientes que minimizam a soma dos resíduos quadráticos no domínio do fator de calibração,

$$\boldsymbol{\beta}^{\star} = \arg\min_{\boldsymbol{\beta}} \|\boldsymbol{\alpha}_{\mathrm{true}} - \mathbf{\Phi}\boldsymbol{\beta}\|_2^2 . \tag{4.8}$$

Equivalentemente,

$$\boldsymbol{\beta}^{\star} = \arg\min_{\boldsymbol{\beta}} \frac{1}{N} \sum_{i=1}^{N} \left[\alpha_{\mathrm{true}}^{(i)} - f_{\mathrm{MLR}}\left(\mathbf{x}^{(i)}\right)\right]^2 . \tag{4.9}$$

Se $\mathbf{\Phi}$ possui posto completo nas colunas, as equações normais fornecem

$$\boldsymbol{\beta}^{\star} = \left(\mathbf{\Phi}^T\mathbf{\Phi}\right)^{-1}\mathbf{\Phi}^T\boldsymbol{\alpha}_{\text{true}}. \tag{4.10}$$

Entretanto, essa expressão pressupõe que $\mathbf{\Phi}^T\mathbf{\Phi}$ seja inversível. Essa condição não deve ser assumida de forma geral neste trabalho, pois a representação calorimétrica pode conter atributos fortemente correlacionados.

Além disso, quando os 100 anéis são fornecidos sob uma normalização evento a evento que imponha

$$\sum_{j=1}^{100} \widetilde{E}_{r,j}^{(i)} = 1, \tag{4.11}$$

surge uma dependência linear estrutural. Nessa condição, quando os 100 anéis são utilizados simultaneamente com um intercepto, a coluna de unidades pode ser escrita como combinação linear das colunas dos anéis, tornando a matriz de projeto não plenamente identificável nessa parametrização. Por essa razão, uma forma matematicamente mais geral da solução é expressa pela pseudoinversa de Moore–Penrose,

$$\boldsymbol{\beta}_{\text{LS}} = \mathbf{\Phi}^{+}\boldsymbol{\alpha}_{\text{true}}, \tag{4.12}$$

que fornece uma solução de mínimos quadrados mesmo quando a matriz de projeto possui deficiência de posto (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Quando existem múltiplas soluções que produzem o mesmo erro residual mínimo, a pseudoinversa seleciona a solução de norma Euclidiana mínima. Na prática, a solução não requer a formação explícita da inversa de $\mathbf{\Phi}^T\mathbf{\Phi}$. Métodos numéricos baseados em decomposições QR, SVD ou algoritmos de mínimos quadrados equivalentes são preferíveis, especialmente na presença de colinearidade, por apresentarem melhor estabilidade numérica (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; BISHOP, 2006).

Uma vez estimados os coeficientes, a inferência para um novo evento é realizada por

$$\alpha_{\text{calib}}^{(i)} = \beta_0^{\star} + \sum_{j=1}^{F} \beta_j^{\star} x_j^{(i)}. \tag{4.13}$$

A energia transversa calibrada é então obtida pela relação geral da Eq. 3.1, $E_{\text{calib}}^{(i)} = \alpha_{\text{calib}}^{(i)} E_{\text{fast}}^{(i)}$.

É importante recordar a distinção estabelecida na Seção 3.1.1: como a MLR é ajustada utilizando α_{true} como alvo, a função de custo acima corresponde ao erro quadrático no domínio do fator de calibração. Isso não é, em geral, matematicamente equivalente a minimizar diretamente um MSE não ponderado em E_{calib}.

Sob o ponto de vista computacional, a inferência da MLR envolve essencialmente F multiplicações ponderadas e a acumulação de seus resultados, além do intercepto. Essa baixa complexidade torna o modelo uma referência importante para estudar o compromisso entre desempenho e custo de predição. O tempo de aplicação de $g_{\text{ML}}(\cdot)$, entretanto, constitui uma etapa separada e deve ser considerado em uma eventual caracterização de latência de ponta a ponta.

A função linear também possui interpretação metodológica importante nesta tese. Se uma MLR apresentasse desempenho próximo ao de modelos de maior capacidade para uma mesma representação, isso indicaria que parcela substancial da estrutura relevante para estimação de α_{true} poderia ser explicada por um mapeamento linear global. Em contrapartida, uma vantagem consistente de modelos não lineares constitui evidência de que relações de interação, curvatura ou dependências locais presentes na representação requerem maior capacidade funcional.

A MLR é, portanto, utilizada não apenas como um *baseline* computacional, mas como um teste experimental da hipótese de linearidade aproximada entre a informação calorimétrica disponibilizada ao regressor e o fator de calibração.

4.1.2 Regressão polinomial

A regressão polinomial (*Polynomial Regression*, PReg) amplia a capacidade da regressão linear por meio de uma transformação explícita das variáveis de entrada. Em vez de ajustar apenas termos lineares em $\mathbf{x}$, são acrescentados produtos, potências e interações entre os atributos até um grau máximo predefinido (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GÉRON, 2019).

Para um evento com

$$\mathbf{x}^{(i)} = \left[x_1^{(i)}, \ldots, x_F^{(i)}\right]^T, \tag{4.14}$$

um modelo polinomial de grau máximo p pode ser escrito como

$$\begin{aligned} \alpha_{\text{calib}}^{(i)} = \beta_0 &+ \sum_{j=1}^{F} \beta_j x_j^{(i)} \\ &+ \sum_{j=1}^{F} \sum_{k=j}^{F} \beta_{jk} x_j^{(i)} x_k^{(i)} + \cdots \\ &+ \sum_{j_1 \leq \cdots \leq j_p} \beta_{j_1 \cdots j_p} \prod_{\ell=1}^{p} x_{j_\ell}^{(i)}. \end{aligned} \tag{4.15}$$

Essa expressão inclui tanto potências individuais, como $(x_j^{(i)})^2$, quanto interações entre atributos diferentes, como $x_j^{(i)} x_k^{(i)}$. Dessa forma, a PReg é capaz de representar curvaturas e interações que não podem ser descritas diretamente pela MLR.

Apesar de a função ser não linear em relação às variáveis de entrada, o modelo continua sendo linear em relação aos parâmetros $\boldsymbol{\beta}$. Essa distinção é fundamental: a PReg não constitui um modelo não linear nos parâmetros, mas uma regressão linear aplicada a um espaço de características expandido.

Definindo por

$$\boldsymbol{\phi}_p(\mathbf{x}) \tag{4.16}$$

o vetor contendo todos os monômios de $\mathbf{x}$ com grau total menor ou igual a p, incluindo o termo constante, o modelo pode ser escrito de forma compacta como

$$f_{\text{PReg}}(\mathbf{x}) = \boldsymbol{\beta}^T \boldsymbol{\phi}_p(\mathbf{x}). \tag{4.17}$$

Para F variáveis de entrada, o número de monômios de grau exatamente q com repetição é

$$\binom{F+q-1}{q}. \tag{4.18}$$

Consequentemente, o número total de termos até o grau p, incluindo o intercepto, é

$$D(F,p) = \sum_{q=0}^{p} \binom{F+q-1}{q} = \binom{F+p}{p}. \tag{4.19}$$

Esse resultado explicita o crescimento combinatório do espaço expandido. Por exemplo, para $F = 100$ e grau $p = 2$,

$$D(100,2) = \binom{102}{2} = 5151. \tag{4.20}$$

Assim, uma representação contendo originalmente 100 atributos passa a produzir 5151 termos polinomiais quando todos os monômios até segundo grau são incluídos. Para graus maiores, o crescimento torna-se ainda mais pronunciado. Essa característica possui implicações diretas sobre memória, custo de treinamento, condicionamento numérico e custo de inferência.

Para N eventos, a matriz de projeto polinomial pode ser escrita como

$$\boldsymbol{\Phi}_p = \begin{bmatrix} \boldsymbol{\phi}_p\left(\mathbf{x}^{(1)}\right)^T \\ \boldsymbol{\phi}_p\left(\mathbf{x}^{(2)}\right)^T \\ \vdots \\ \boldsymbol{\phi}_p\left(\mathbf{x}^{(N)}\right)^T \end{bmatrix} \in \mathbb{R}^{N \times D(F,p)}. \tag{4.21}$$

A estimação dos coeficientes permanece um problema de mínimos quadrados,

$$\boldsymbol{\beta}^{\star}_{\mathrm{PReg}} = \arg\min_{\boldsymbol{\beta}} \|\boldsymbol{\alpha}_{\mathrm{true}} - \boldsymbol{\Phi}_p \boldsymbol{\beta}\|_2^2, \tag{4.22}$$

ou, equivalentemente,

$$\boldsymbol{\beta}^{\star}_{\mathrm{PReg}} = \arg\min_{\boldsymbol{\beta}} \frac{1}{N} \sum_{i=1}^{N} \left[\alpha^{(i)}_{\mathrm{true}} - \boldsymbol{\beta}^T \boldsymbol{\phi}_p\left(\mathbf{x}^{(i)}\right)\right]^2. \tag{4.23}$$

Quando a matriz possui posto adequado, as equações normais conduziriam formalmente a

$$\boldsymbol{\beta}^{\star}_{\mathrm{PReg}} = \left(\boldsymbol{\Phi}_p^T \boldsymbol{\Phi}_p\right)^{-1} \boldsymbol{\Phi}_p^T \boldsymbol{\alpha}_{\mathrm{true}}. \tag{4.24}$$

Entretanto, pelas mesmas razões discutidas para MLR — e de forma ainda mais relevante após a expansão polinomial — não é apropriado pressupor que $\boldsymbol{\Phi}_p^T \boldsymbol{\Phi}_p$ seja não singular. Assim, a solução geral pode ser escrita como

$$\boldsymbol{\beta}^{\star}_{\mathrm{PReg}} = \boldsymbol{\Phi}_p^{+} \boldsymbol{\alpha}_{\mathrm{true}}. \tag{4.25}$$

A expansão polinomial pode introduzir forte dependência entre colunas mesmo quando as variáveis originais não são perfeitamente colineares. Por exemplo, termos como x_j, x_j^2, $x_j x_k$

e combinações de diferentes atributos podem apresentar elevada correlação em determinadas regiões do espaço amostral. Como consequência, o problema pode tornar-se numericamente mal condicionado.[1]

Outro efeito do aumento de dimensionalidade é a maior capacidade de ajuste. Para uma amostra de treinamento finita, adicionar termos polinomiais nunca reduz o espaço funcional disponível ao modelo. Consequentemente, o erro de treinamento pode diminuir ou permanecer igual. Isso, contudo, não implica melhor generalização. Graus elevados podem fazer com que o modelo ajuste flutuações específicas da amostra de desenvolvimento em vez da estrutura persistente do problema, caracterizando sobreajuste (*overfitting*) (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GÉRON, 2019).

Esse compromisso entre viés e variância constitui uma razão importante para limitar a complexidade da expansão. Na configuração consolidada da Etapa I desta tese, a PReg utiliza

$$p = 2, \tag{4.26}$$

isto é, uma expansão quadrática. Portanto, o modelo efetivamente avaliado contém termos lineares, quadráticos e interações de segunda ordem, mas não polinômios cúbicos ou de grau superior.

Para $p = 2$, a Eq. 4.15 reduz-se a

$$\alpha_{\text{calib}}^{(i)} = \beta_0 + \sum_{j=1}^{F} \beta_j x_j^{(i)} + \sum_{j=1}^{F} \sum_{k=j}^{F} \beta_{jk} x_j^{(i)} x_k^{(i)}. \tag{4.27}$$

A energia calibrada permanece definida pela mesma relação geral da Eq. 3.1, $E_{\text{calib}}^{(i)} = \alpha_{\text{calib}}^{(i)} E_{\text{fast}}^{(i)}$.

Também neste caso, a função de treinamento está definida sobre α_{true}. Portanto, como demonstrado na Seção 3.1.1, minimizar o erro quadrático não ponderado no fator de calibração não deve ser interpretado como uma minimização automaticamente equivalente do MSE não ponderado no domínio da energia.

Do ponto de vista metodológico, a PReg ocupa uma posição intermediária entre MLR e modelos adaptativos não lineares. Comparada à MLR, ela permite testar explicitamente se termos de segunda ordem e interações entre atributos acrescentam capacidade preditiva. Entretanto, a forma funcional dessas interações é estabelecida *a priori*: todas as combinações polinomiais admitidas pela expansão são construídas antes do ajuste. Árvores e redes neurais, discutidas nas seções seguintes, possuem mecanismos diferentes para adaptar a estrutura da função aos dados.

Há também uma diferença importante em custo computacional. Enquanto a inferência da MLR cresce aproximadamente com o número de entradas F, a PReg exige primeiro construir $\boldsymbol{\phi}_p(\mathbf{x})$ e depois avaliar a combinação linear no espaço expandido, cujo tamanho é $D(F, p)$.

[1] Multicolinearidade refere-se à presença de relações lineares exatas ou aproximadas entre colunas da matriz de projeto. Em regressão, esse fenômeno pode tornar os coeficientes individuais sensíveis a pequenas perturbações nos dados e aumentar sua variância, dificultando a interpretação paramétrica. A deficiência de posto constitui o caso limite de colinearidade exata. Transformações de representação e métodos de regularização, como Ridge ou Lasso, são alternativas possíveis para mitigar esses efeitos, embora regularização não tenha sido introduzida como componente do modelo PReg consolidado da Etapa I desta tese (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; BISHOP, 2006).

Portanto, mesmo com um regressor linear nos coeficientes, a expansão polinomial pode tornar-se computacionalmente onerosa em representações de alta dimensão.

Esse comportamento reforça a importância das representações compactas investigadas nesta tese. Para um grau polinomial fixo, reduzir F produz uma redução mais do que linear do número de termos. Por exemplo, para $p = 2$,

$$D(F, 2) = \frac{(F + 1)(F + 2)}{2}. \tag{4.28}$$

Assim, a redução da representação antes da PReg não atua apenas sobre a quantidade de variáveis originais, mas também sobre o tamanho da própria expansão polinomial. Essa propriedade estabelece uma conexão direta entre a etapa de redução de dimensionalidade $g_{\mathrm{ML}}(\cdot)$ e a complexidade do regressor $f_{\mathrm{PReg}}(\cdot)$.

A PReg é, portanto, empregada nesta tese como um segundo nível de referência: mais flexível que a MLR por incorporar curvaturas e interações explícitas, mas ainda baseada em uma transformação funcional global previamente especificada. Seu desempenho permite avaliar se a introdução de não linearidades polinomiais simples é suficiente para explorar a informação calorimétrica ou se o problema requer modelos com maior capacidade adaptativa.

4.1.3 Árvores de decisão

As árvores de decisão utilizadas para regressão (*Decision Trees*, DTree) constituem modelos não paramétricos que aproximam a relação entre as variáveis de entrada e o alvo por meio de uma partição recursiva do espaço de atributos. Em vez de assumir uma forma funcional global, como ocorre na MLR e na PReg, uma árvore subdivide o espaço $\mathbb{R}^F$ em regiões disjuntas e associa uma predição local a cada uma delas (QUINLAN, 1986; HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GÉRON, 2019).

Uma árvore de regressão produz uma partição

$$\mathbb{R}^F = \bigcup_{m=1}^{M} \mathcal{R}_m, \qquad \mathcal{R}_m \cap \mathcal{R}_\ell = \varnothing \quad \text{para } m \neq \ell, \tag{4.29}$$

em que $\mathcal{R}_m$ representa a região associada à m-ésima folha terminal. A função aprendida possui então a forma

$$f_{\mathrm{DTree}}(\mathbf{x}) = \sum_{m=1}^{M} c_m \mathbb{I}(\mathbf{x} \in \mathcal{R}_m), \tag{4.30}$$

em que $\mathbb{I}(\cdot)$ é a função indicadora e c_m é a resposta atribuída à região $\mathcal{R}_m$.

Na construção convencional baseada em divisões univariadas, cada nó interno aplica uma condição do tipo

$$x_j \leq t \tag{4.31}$$

ou

$$x_j > t, \tag{4.32}$$

em que j identifica um atributo e t é o limiar de divisão. Como consequência, cada folha corresponde à interseção de sucessivas restrições sobre as coordenadas de entrada e, geometrica-

mente, define uma região hiper-retangular alinhada aos eixos do espaço de atributos (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Considere um nó associado a uma região $\mathcal{R}$. Para regressão com erro quadrático, a melhor predição constante nessa região é a média dos alvos dos eventos nela contidos,

$$\overline{\alpha}_{\mathcal{R}} = \frac{1}{N_{\mathcal{R}}} \sum_{i:\mathbf{x}^{(i)} \in \mathcal{R}} \alpha_{\text{true}}^{(i)}, \tag{4.33}$$

em que $N_{\mathcal{R}}$ é o número de eventos da região.

A impureza quadrática do nó pode ser escrita como

$$Q\left(\mathcal{R}\right) = \frac{1}{N_{\mathcal{R}}} \sum_{i:\mathbf{x}^{(i)} \in \mathcal{R}} \left(\alpha_{\text{true}}^{(i)} - \overline{\alpha}_{\mathcal{R}}\right)^2. \tag{4.34}$$

Para um candidato a divisão (j, t), a região corrente é particionada em

$$\mathcal{R}_L(j,t) = \{\mathbf{x} \in \mathcal{R} \mid x_j \leq t\} \tag{4.35}$$

e

$$\mathcal{R}_R(j,t) = \{\mathbf{x} \in \mathcal{R} \mid x_j > t\}. \tag{4.36}$$

A qualidade da divisão pode ser caracterizada pela redução da impureza,

$$\begin{aligned} \Delta Q(j,t) = Q(\mathcal{R}) - \Bigg[& \frac{N_{\mathcal{R}_L}}{N_{\mathcal{R}}} Q\left(\mathcal{R}_L\right) \\ & + \frac{N_{\mathcal{R}_R}}{N_{\mathcal{R}}} Q\left(\mathcal{R}_R\right) \Bigg]. \end{aligned} \tag{4.37}$$

Seleciona-se então o par

$$(j^\star, t^\star) = \arg\max_{j,t} \Delta Q(j,t). \tag{4.38}$$

De forma equivalente, essa escolha minimiza a soma dos erros quadráticos das duas regiões resultantes. O procedimento é aplicado recursivamente aos nós descendentes, produzindo progressivamente uma partição adaptada à distribuição dos dados.

Uma vez encerrado o crescimento da árvore, o valor armazenado na folha $\mathcal{R}_m$ é

$$c_m = \frac{1}{N_{\mathcal{R}_m}} \sum_{i:\mathbf{x}^{(i)} \in \mathcal{R}_m} \alpha_{\text{true}}^{(i)}. \tag{4.39}$$

Portanto, para um novo evento,

$$\alpha_{\text{calib}}^{(i)} = f_{\text{DTree}}\left(\mathbf{x}^{(i)}\right) = c_m, \qquad \mathbf{x}^{(i)} \in \mathcal{R}_m. \tag{4.40}$$

A energia transversa calibrada é finalmente obtida pela relação geral da Eq. 3.1, $E_{\text{calib}}^{(i)} = \alpha_{\text{calib}}^{(i)} E_{\text{fast}}^{(i)}$.

Assim como discutido para MLR e PReg, o critério quadrático utilizado para ajustar α_{calib} atua no domínio do fator de calibração. Sua minimização não deve ser interpretada como

matematicamente equivalente, em geral, à minimização de um MSE não ponderado diretamente sobre E_{calib}.

A forma da Eq. 4.30 mostra uma propriedade fundamental das árvores de regressão: sua resposta é constante dentro de cada folha e pode apresentar descontinuidades nas fronteiras entre regiões. Essa estrutura permite modelar relações não lineares, interações entre atributos e mudanças locais de regime sem especificar previamente potências, produtos ou outras funções de base. Ao mesmo tempo, o procedimento de crescimento é guloso (*greedy*). A melhor divisão é escolhida localmente em cada nó e não resulta, em geral, da otimização conjunta de todas as fronteiras da árvore. Consequentemente, pequenas perturbações na amostra podem modificar divisões próximas da raiz e produzir estruturas consideravelmente diferentes. Essa instabilidade está relacionada à elevada variância característica de árvores individuais (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

A complexidade precisa, portanto, ser controlada. Parâmetros como profundidade máxima, número mínimo de eventos necessário para dividir um nó, número mínimo de eventos em uma folha, quantidade de atributos examinada em cada divisão e ganho mínimo exigido para realizar um *split* limitam o crescimento da árvore. Procedimentos de poda podem ainda remover subdivisões cujo ganho não compense o aumento de complexidade. As configurações concretamente utilizadas nesta tese são tratadas no protocolo experimental e no Apêndice de Reprodutibilidade, evitando misturar a definição do método com escolhas específicas de hiperparâmetros (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GÉRON, 2019).

Outro aspecto importante no contexto desta tese é a interação entre a árvore e a representação $g_{\text{ML}}(\cdot)$. Como as divisões convencionais são alinhadas aos eixos, árvores não são invariantes a rotações gerais do espaço de atributos. Assim, utilizar os anéis originais, componentes PCA ou componentes ICA pode alterar significativamente a facilidade com que determinada relação é representada por sucessivas divisões, mesmo quando a dimensionalidade das entradas é a mesma. A redução de dimensionalidade não atua, portanto, apenas sobre custo: ela também modifica a geometria do problema apresentado ao regressor (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Por não exigir uma forma funcional global e por capturar automaticamente interações entre atributos, a DTree fornece um primeiro nível de modelagem adaptativa além de MLR e PReg. Sua limitação de variância, entretanto, motiva a utilização de ensembles de árvores. As duas estratégias consideradas nesta tese — BDT e *Random Forest* — reduzem limitações da árvore individual por mecanismos distintos.

4.1.4 *Gradient Boosted Decision Trees* (BDT)

O *gradient boosting* transforma um conjunto de árvores de regressão em um modelo aditivo construído sequencialmente. A ideia central é que cada novo estimador seja treinado para melhorar a função acumulada até a etapa anterior. Em sua formulação geral, essa melhoria é orientada pelo gradiente negativo de uma função de perda, permitindo interpretar o procedimento como uma forma de descida do gradiente no espaço de funções (FRIEDMAN, 2001; HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Para uma função de perda genérica $\mathcal{L}(y, F(\mathbf{x}))$, o procedimento inicia com uma função constante

$$F_0(\mathbf{x}) = \arg\min_c \sum_{i=1}^{N} \mathcal{L}\left(\alpha_{\text{true}}^{(i)}, c\right). \tag{4.41}$$

Para a perda quadrática escrita na forma

$$\mathcal{L}(y, F) = \frac{1}{2}(y - F)^2, \tag{4.42}$$

a solução inicial é simplesmente

$$F_0(\mathbf{x}) = \overline{\alpha}_{\text{true}} = \frac{1}{N}\sum_{i=1}^{N} \alpha_{\text{true}}^{(i)}. \tag{4.43}$$

Na iteração m, calcula-se para cada evento o pseudo-resíduo

$$r_m^{(i)} = -\left.\frac{\partial \mathcal{L}\left(\alpha_{\text{true}}^{(i)}, F(\mathbf{x}^{(i)})\right)}{\partial F(\mathbf{x}^{(i)})}\right|_{F=F_{m-1}}. \tag{4.44}$$

Sob a convenção da Eq. 4.42, tem-se

$$r_m^{(i)} = \alpha_{\text{true}}^{(i)} - F_{m-1}\left(\mathbf{x}^{(i)}\right), \tag{4.45}$$

isto é, o gradiente negativo coincide exatamente com o resíduo no domínio do fator de calibração. O fator $1/2$ introduzido na Eq. 4.42 elimina o fator constante 2 que apareceria na derivada do erro quadrático escrito sem essa convenção.

Uma árvore $h_m(\mathbf{x})$ é então ajustada para aproximar os pseudo-resíduos,

$$h_m = \arg\min_{h\in\mathcal{H}} \sum_{i=1}^{N} \left[r_m^{(i)} - h\left(\mathbf{x}^{(i)}\right)\right]^2, \tag{4.46}$$

em que $\mathcal{H}$ representa a família de árvores permitida pela parametrização do modelo.

Uma forma geral de determinar a magnitude da contribuição da nova árvore é utilizar uma busca unidimensional,

$$\gamma_m = \arg\min_{\gamma} \sum_{i=1}^{N} \mathcal{L}\left[\alpha_{\text{true}}^{(i)}, F_{m-1}\left(\mathbf{x}^{(i)}\right) + \gamma h_m\left(\mathbf{x}^{(i)}\right)\right]. \tag{4.47}$$

O modelo é então atualizado segundo

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu\gamma_m h_m(\mathbf{x}), \tag{4.48}$$

em que

$$0 < \nu \leq 1 \tag{4.49}$$

é a taxa de aprendizado (*learning rate* ou *shrinkage*).

Após M etapas,

$$F_M(\mathbf{x}) = F_0(\mathbf{x}) + \sum_{m=1}^{M} \nu\gamma_m h_m(\mathbf{x}), \tag{4.50}$$

e a predição para o evento i é

$$\alpha_{\text{calib}}^{(i)} = f_{\text{BDT}}\left(\mathbf{x}^{(i)}\right) = F_M\left(\mathbf{x}^{(i)}\right). \tag{4.51}$$

Consequentemente,

$$E_{\text{calib}}^{(i)} = F_M\left(\mathbf{x}^{(i)}\right) E_{\text{fast}}^{(i)}. \tag{4.52}$$

A formulação em termos de gradientes é mais geral do que a descrição de que cada árvore simplesmente "corrige os resíduos". Para a perda quadrática, ambas as interpretações coincidem. Para outras funções de perda diferenciáveis, entretanto, a árvore é ajustada aos pseudo-resíduos definidos pelo gradiente negativo, que não precisam coincidir com a diferença simples entre alvo e predição (FRIEDMAN, 2001).

O BDT também difere fundamentalmente da construção de uma única árvore grande. A complexidade do modelo é distribuída entre múltiplas árvores adicionadas progressivamente, e a contribuição de cada novo estimador é controlada por ν. Uma taxa de aprendizado menor normalmente exige um número maior de árvores, estabelecendo um compromisso entre tamanho do passo, número de iterações e capacidade de generalização (FRIEDMAN, 2001; HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

A regularização ocorre em diferentes níveis. A profundidade máxima, o número máximo de folhas e o número mínimo de eventos nas folhas controlam a complexidade de cada árvore. A taxa de aprendizado reduz a magnitude das atualizações. Subamostragem de eventos ou de atributos pode introduzir aleatoriedade adicional. Penalizações sobre a complexidade das folhas e critérios mínimos de ganho podem ainda impedir subdivisões com benefício marginal. O número total de iterações deve igualmente ser controlado, pois adicionar árvores indefinidamente pode aumentar a capacidade de ajuste sobre flutuações específicas da amostra (FRIEDMAN, 2001; HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Nos experimentos consolidados desta tese, o BDT é implementado com LightGBM (KE et al., 2017). Essa escolha fornece uma implementação eficiente de *gradient boosting* sobre árvores e é mantida de forma comum entre as etapas que utilizam essa família, evitando transformar o estudo em uma comparação entre diferentes bibliotecas de boosting. O LightGBM utiliza discretização dos valores dos atributos em histogramas para avaliar candidatos a divisão de forma computacionalmente eficiente e adota crescimento orientado pela folha que produz a maior redução da função objetivo. Essa estratégia pode construir árvores expressivas com custo reduzido, mas também torna importante o controle do número de folhas, profundidade e tamanho mínimo das folhas para evitar crescimento excessivamente especializado (KE et al., 2017).

Parâmetros como número de árvores, taxa de aprendizado, número de folhas, profundidade, quantidade mínima de eventos por folha, frações de eventos e atributos utilizadas no ajuste e termos de regularização pertencem ao protocolo experimental e são documentados no Capítulo 5 e no Apêndice de Reprodutibilidade. Essa separação permite apresentar aqui a formulação geral sem atribuir ao algoritmo valores específicos que pertencem a determinada etapa da investigação.

No contexto da calibração calorimétrica, o BDT possui uma propriedade metodologicamente relevante: as árvores sucessivas podem concentrar capacidade em regiões nas quais o modelo

acumulado ainda apresenta erro. Isso permite aproximar relações não lineares e mudanças locais de comportamento sem definir previamente uma expansão funcional global. Tal característica é particularmente pertinente no benchmark utilizado nesta tese, que contém uma perturbação não linear e não suave na resposta rápida. Ainda assim, o bom desempenho sobre essa estrutura controlada não deve ser interpretado como demonstração de que uma descontinuidade equivalente esteja presente na resposta experimental real.

A estrutura aditiva também explica por que BDT e DTree representam hipóteses diferentes. A DTree tenta construir toda a aproximação em uma única partição hierárquica, enquanto o BDT combina várias partições que refinam progressivamente a resposta. Esse mecanismo tende a reduzir o viés de uma árvore individual, embora sua eficácia dependa de regularização adequada e da seleção do número de iterações.

Por fim, o uso de uma implementação computacionalmente otimizada não permite, isoladamente, afirmar compatibilidade com a latência de uma cadeia real de *trigger*. Os tempos medidos nesta tese caracterizam a predição do modelo treinado no ambiente de benchmark. Uma conclusão de implantação exige incluir também construção das características, movimentação de memória, concorrência, plataforma de execução e latência de pior caso. O BDT é, portanto, avaliado como candidato de elevada capacidade para dados tabulares, e não declarado *a priori* uma solução operacional para o HLT.

4.1.5 *Random Forest*

A *Random Forest* (RF) é um método de ensemble baseado na combinação de múltiplas árvores de decisão construídas com mecanismos de aleatorização destinados a reduzir a correlação entre os estimadores individuais. Para regressão, a resposta final é obtida pela média das predições das árvores (BREIMAN, 2001; HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Enquanto uma árvore individual pode apresentar elevada variância, a média de diferentes árvores tende a produzir uma função mais estável, desde que os erros dos estimadores não sejam perfeitamente correlacionados. Essa é a ideia fundamental da RF: preservar a capacidade não linear das árvores e reduzir parte de sua instabilidade por meio de agregação.

Para cada árvore $b = 1, \ldots, B$, constrói-se uma amostra *bootstrap* por sorteio com reposição de eventos pertencentes a $\mathcal{D}_{\text{train}}$ (Eq. 3.10).

A árvore

$$T_b(\mathbf{x}) \tag{4.53}$$

é então ajustada sobre essa realização amostral.

Na formulação clássica de *Random Forest*, uma segunda fonte de aleatoriedade é introduzida durante o crescimento da árvore: em cada nó, apenas um subconjunto das F características é considerado como candidato às divisões (BREIMAN, 2001). Esse mecanismo reduz a tendência de que um pequeno grupo de atributos muito dominantes produza árvores excessivamente semelhantes.

A predição agregada para regressão é

$$f_{\mathrm{RF}}(\mathbf{x}) = \frac{1}{B}\sum_{b=1}^{B} T_b(\mathbf{x}). \tag{4.54}$$

No problema desta tese,

$$\alpha_{\mathrm{calib}}^{(i)} = f_{\mathrm{RF}}\left(\mathbf{x}^{(i)}\right), \tag{4.55}$$

e

$$E_{\mathrm{calib}}^{(i)} = f_{\mathrm{RF}}\left(\mathbf{x}^{(i)}\right) E_{\mathrm{fast}}^{(i)}. \tag{4.56}$$

O mecanismo de redução de variância pode ser compreendido observando-se que aumentar apenas o número de árvores não é suficiente se todas elas produzirem praticamente os mesmos erros. A eficiência da média depende simultaneamente da variância das árvores individuais e da correlação entre elas. O *bootstrap* e, na formulação clássica, a seleção aleatória de atributos procuram justamente introduzir diversidade entre os estimadores (BREIMAN, 2001; HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Esse comportamento distingue RF de BDT. No BDT, a construção é sequencial: a árvore da iteração m depende do modelo formado nas iterações anteriores e é treinada para melhorar sua função objetivo. Em RF, as árvores não são treinadas para corrigir umas às outras. Cada árvore é construída a partir de uma realização aleatorizada dos dados e as respostas são combinadas somente ao final pela média.

A construção por *bootstrap* da Random Forest permite obter, para cada evento da amostra de desenvolvimento, predições produzidas apenas pelas árvores em cujas amostras de treinamento aquele evento não esteve presente. Essas predições são denominadas *out-of-bag* (OOB) e são utilizadas posteriormente no RFBDTS para construir entradas do meta-regressor sem reutilizar, para cada evento, uma predição gerada por árvores que o tenham usado diretamente no ajuste (BREIMAN, 2001; SILVA et al., 2026a).

As predições OOB são um mecanismo interno da amostra de desenvolvimento e não substituem o teste independente. A avaliação científica final continua sendo realizada na partição $\mathcal{D}_{30}$, mantida fora de todo o desenvolvimento, conforme o Capítulo 5.

Assim como em DTree, a complexidade de cada árvore da RF precisa ser controlada por parâmetros como profundidade máxima, número mínimo de eventos para divisão, número mínimo de eventos por folha e regras de poda. Adicionalmente, o número de árvores, a fração de eventos utilizada em cada amostra *bootstrap* e a quantidade de atributos disponibilizada a cada divisão controlam a diversidade e o custo do ensemble.

É importante distinguir a formulação clássica do método das configurações concretamente avaliadas. A seleção aleatória de um subconjunto de características em cada divisão é um dos mecanismos clássicos de *Random Forest*, mas a quantidade efetivamente disponibilizada constitui um hiperparâmetro e pode variar até o uso de todos os F atributos. Assim, o grau de diversificação produzido pela aleatoriedade de características depende da configuração experimental e não deve ser pressuposto apenas a partir do nome do algoritmo.

Do ponto de vista computacional, uma RF com B árvores requer a avaliação de múltiplos caminhos de decisão para produzir uma única predição. Embora as árvores possam ser construídas e avaliadas de maneira altamente paralelizável, aumentar B também aumenta armazenamento e quantidade de operações de inferência. Portanto, a redução de variância obtida pela agregação deve ser analisada juntamente com o custo adicional do ensemble.

No contexto desta tese, a RF não é introduzida apenas como mais um regressor de referência. Sua estratégia estatística é deliberadamente complementar àquela do BDT. Enquanto o BDT procura melhorar sequencialmente o modelo acumulado, a RF procura reduzir a variância por diversificação e média. Essa diferença motiva a investigação, na etapa seguinte, de modelos que combinam as duas famílias por aprendizado residual e por modelos empilhados (*stacked models*) (SILVA et al., 2026a).

A comparação entre DTree, BDT e RF estabelece, portanto, três regimes distintos de modelagem baseada em árvores: uma única partição adaptativa, um ensemble aditivo sequencial e um ensemble diversificado por reamostragem e agregação. Os modelos híbridos apresentados na seção seguinte investigam se os erros remanescentes dessas estratégias possuem estrutura complementar que possa ser explorada por uma segunda etapa de aprendizado.

4.2 Aprendizado residual e ensembles híbridos

A motivação para os modelos híbridos não é assumir que a combinação de dois regressores seja necessariamente superior aos modelos individuais. Um segundo estágio somente pode fornecer ganho de generalização se a informação que recebe permitir explicar parte do erro que permanece após o primeiro estágio. Caso contrário, o aumento de capacidade pode apenas ajustar flutuações específicas da amostra e elevar o custo computacional sem produzir benefício fora dos dados utilizados no desenvolvimento.

A Etapa II desta tese introduz três combinações híbridas: BDTRF, RFBDT e RFBDTS (SILVA et al., 2026a). As duas primeiras implementam correção residual sequencial, enquanto a terceira utiliza modelos empilhados (*stacked models*). Essas arquiteturas não são apresentadas como novas classes gerais de Aprendizado de Máquina, mas a sua contribuição experimental está em sua aplicação e avaliação controlada dentro da cadeia de calibração baseada em anéis.

4.2.1 Correção residual sequencial

Considere inicialmente um regressor primário $f_1(\cdot)$ treinado para estimar o fator de calibração a partir da representação $\mathbf{x}^{(i)}$. Para o i-ésimo evento, sua predição é

$$\alpha_1^{(i)} = f_1\left(\mathbf{x}^{(i)}\right), \tag{4.57}$$

e o erro remanescente no domínio do fator pode ser definido por

$$r_1^{(i)} = \alpha_{\text{true}}^{(i)} - \alpha_1^{(i)}. \tag{4.58}$$

O objetivo do segundo estágio é aprender um mapeamento

$$f_2 : \mathbb{R}^F \longrightarrow \mathbb{R} \tag{4.59}$$

capaz de estimar a parcela previsível desse resíduo. Formalmente,

$$f_2^\star = \arg\min_{f_2} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}\left[r_1^{(i)}, f_2\left(\mathbf{x}^{(i)}\right)\right]. \tag{4.60}$$

Para perda quadrática,

$$f_2^\star = \arg\min_{f_2} \frac{1}{N} \sum_{i=1}^{N} \left[r_1^{(i)} - f_2\left(\mathbf{x}^{(i)}\right)\right]^2. \tag{4.61}$$

A predição híbrida passa então a ser

$$\alpha_{\text{calib}}^{(i)} = f_1\left(\mathbf{x}^{(i)}\right) + f_2\left(\mathbf{x}^{(i)}\right), \tag{4.62}$$

e o resíduo final pode ser escrito como

$$\begin{aligned} r_{\text{hyb}}^{(i)} &= \alpha_{\text{true}}^{(i)} - \alpha_{\text{calib}}^{(i)} \\ &= r_1^{(i)} - f_2\left(\mathbf{x}^{(i)}\right). \end{aligned} \tag{4.63}$$

Essa expressão torna explícito que o segundo estágio não procura reconstruir novamente todo o fator de calibração. Seu alvo é a parcela ainda não explicada pelo primeiro regressor.

Sob perda quadrática, para um primeiro modelo fixado e admitindo uma classe funcional suficientemente rica para $f_2(\cdot)$, o minimizador populacional é a esperança condicional do resíduo dado o vetor de entrada (HASTIE; TIBSHIRANI; FRIEDMAN, 2009),

$$f_2^\star(\mathbf{x}) = \mathbb{E}\left[r_1 \mid \mathbf{x}\right]. \tag{4.64}$$

Assim, se

$$\mathbb{E}\left[r_1 \mid \mathbf{x}\right] = 0, \tag{4.65}$$

não existe, sob essa função de perda, estrutura condicional adicional que possa ser explorada por um segundo modelo baseado nas mesmas entradas. Em amostras finitas, naturalmente, o regressor residual também está sujeito a erro de estimação, viés e variância.

Essa interpretação fornece uma maneira mais rigorosa de compreender a finalidade dos modelos híbridos. Um ganho de generalização após a inclusão de $f_2(\cdot)$ constitui evidência de que o primeiro modelo deixou uma componente previsível no resíduo. A ausência de ganho, por outro lado, pode indicar que o resíduo remanescente é predominantemente não estruturado em relação às entradas disponíveis ou que o segundo modelo não possui capacidade ou dados suficientes para explorá-lo.

Há, entretanto, uma questão metodológica essencial. Os resíduos utilizados para ajustar o segundo estágio não devem ser calculados a partir de predições do primeiro modelo sobre os mesmos eventos utilizados em seu próprio ajuste, pois isso pode produzir resíduos artificialmente otimistas. Nesta tese, os alvos residuais são construídos a partir de predições internas fora da amostra do primeiro estágio. Se $\widetilde{\alpha}_1^{(i)}$ denota uma predição para o evento i produzida por um estimador que não utilizou esse evento em seu ajuste, então

$$\widetilde{r}_1^{(i)} = \alpha_{\text{true}}^{(i)} - \widetilde{\alpha}_1^{(i)}. \tag{4.66}$$

O segundo estágio é ajustado para estimar $\widetilde{r}_1$ a partir de $\mathbf{x}$. Essa construção aproxima a condição encontrada na inferência sobre eventos novos e reduz o risco de vazamento de informação entre os dois estágios.

Após a geração desses resíduos e o treinamento de $f_2(\cdot)$, o regressor primário é reajustado utilizando todos os dados permitidos daquela etapa de desenvolvimento (SILVA et al., 2026a). Durante a inferência, ambos os modelos permanecem fixos e são avaliados sobre a mesma entrada para cada evento,

$$\alpha_{\text{calib}}^{(i)} = f_1\left(\mathbf{x}^{(i)}\right) + f_2\left(\mathbf{x}^{(i)}\right). \tag{4.67}$$

Essa construção não deve ser confundida com o próprio *gradient boosting*. Embora ambos produzam modelos aditivos e utilizem informação associada ao erro remanescente, o BDT discutido na Seção 4.1.4 realiza uma sequência de atualizações dentro de uma mesma família de árvores e de uma função objetivo de boosting. Os modelos híbridos desta seção utilizam apenas dois estágios explicitamente distintos, pertencentes a famílias diferentes, e o segundo estágio é ajustado sobre resíduos fora da amostra produzidos pelo primeiro.

Nas expressões seguintes, os resíduos representam a decomposição funcional das arquiteturas. Durante o ajuste do segundo estágio, os respectivos alvos são construídos a partir das predições fora da amostra definidas na Eq. 4.66.

Na arquitetura BDTRF, o primeiro estágio é um BDT,

$$\alpha_{\text{BDT}}^{(i)} = f_{\text{BDT},\alpha}\left(\mathbf{x}^{(i)}\right), \tag{4.68}$$

e o resíduo utilizado como alvo do segundo estágio é

$$r_{\text{BDT}}^{(i)} = \alpha_{\text{true}}^{(i)} - \alpha_{\text{BDT}}^{(i)}. \tag{4.69}$$

Uma Random Forest é treinada para estimar essa correção,

$$\widehat{r}_{\text{BDT}}^{(i)} = f_{\text{RF},r}\left(\mathbf{x}^{(i)}\right), \tag{4.70}$$

produzindo

$$\alpha_{\text{calib}}^{(i)} = f_{\text{BDT},\alpha}\left(\mathbf{x}^{(i)}\right) + f_{\text{RF},r}\left(\mathbf{x}^{(i)}\right). \tag{4.71}$$

A hipótese experimental associada ao BDTRF é que uma Random Forest, cujo mecanismo de agregação tende a reduzir a variância de árvores individuais, possa representar parte da estrutura residual deixada pelo BDT (SILVA et al., 2026a).

Na arquitetura RFBDT, a ordem é invertida. A estimativa inicial é fornecida pela Random Forest,

$$\alpha_{\text{RF}}^{(i)} = f_{\text{RF},\alpha}\left(\mathbf{x}^{(i)}\right), \tag{4.72}$$

com resíduo

$$r_{\text{RF}}^{(i)} = \alpha_{\text{true}}^{(i)} - \alpha_{\text{RF}}^{(i)}. \tag{4.73}$$

O BDT é então ajustado para representar a componente previsível desse resíduo,

$$\widehat{r}_{\text{RF}}^{(i)} = f_{\text{BDT},r}\left(\mathbf{x}^{(i)}\right), \tag{4.74}$$

de modo que

$$\alpha_{\text{calib}}^{(i)} = f_{\text{RF},\alpha}\left(\mathbf{x}^{(i)}\right) + f_{\text{BDT},r}\left(\mathbf{x}^{(i)}\right). \tag{4.75}$$

A inversão da ordem não constitui uma alteração meramente nominal. Em geral,

$$f_{\text{BDT},\alpha} + f_{\text{RF},r} \neq f_{\text{RF},\alpha} + f_{\text{BDT},r}, \tag{4.76}$$

porque os dois primeiros estágios produzem aproximações diferentes de α_{true} e, consequentemente, geram distribuições residuais distintas. Além disso, BDT e RF possuem mecanismos de regularização, variância e capacidade de aproximação diferentes. Portanto, a operação de correção residual é assimétrica.

O ganho obtido por um segundo estágio também deve ser confrontado com seu custo. A inferência exige a avaliação de dois regressores,

$$f_{\text{hyb}}(\mathbf{x}) = f_1(\mathbf{x}) + f_2(\mathbf{x}), \tag{4.77}$$

de modo que qualquer redução incremental de erro deve ser analisada juntamente com o aumento de tempo de predição, memória, complexidade de validação e manutenção do modelo. Essa relação desempenho–complexidade é examinada quantitativamente no Capítulo 7.

4.2.2 *Stacked models*

Os *stacked models*, ou modelos empilhados, constituem uma estratégia de *ensemble* na qual as predições produzidas por diferentes modelos-base são tratadas como novas variáveis de entrada para um meta-modelo (WOLPERT, 1992; TING; WITTEN, 1997; HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Em vez de impor uma média fixa entre os regressores, o segundo nível aprende como combinar suas respostas a partir dos dados.

Na arquitetura RFBDTS avaliada nesta tese, os dois modelos-base são uma Random Forest e um BDT. Para o evento i, suas previsões são

$$\alpha_{\text{RF}}^{(i)} = f_{\text{RF}}\left(\mathbf{x}^{(i)}\right) \tag{4.78}$$

e

$$\alpha_{\text{BDT}}^{(i)} = f_{\text{BDT}}\left(\mathbf{x}^{(i)}\right). \tag{4.79}$$

Essas duas respostas formam a representação utilizada pelo meta-regressor,

$$\mathbf{z}_{\text{stack}}^{(i)} = \begin{bmatrix} \alpha_{\text{RF}}^{(i)} \\ \alpha_{\text{BDT}}^{(i)} \end{bmatrix}. \tag{4.80}$$

No RFBDTS, o meta-modelo é uma regressão Ridge. Assim,

$$\alpha_{\text{calib}}^{(i)} = w_0 + w_1\alpha_{\text{RF}}^{(i)} + w_2\alpha_{\text{BDT}}^{(i)}, \tag{4.81}$$

ou, substituindo explicitamente os modelos-base,

$$\alpha_{\text{calib}}^{(i)} = w_0 + w_1 f_{\text{RF}}\left(\mathbf{x}^{(i)}\right) + w_2 f_{\text{BDT}}\left(\mathbf{x}^{(i)}\right). \tag{4.82}$$

Os parâmetros do meta-modelo podem ser obtidos pela minimização da função

$$(w_0^\star, \mathbf{w}^\star) = \arg\min_{w_0,\mathbf{w}} \left\{ \sum_{i=1}^{N} \left[\alpha_{\text{true}}^{(i)} - w_0 - \mathbf{w}^T \mathbf{z}_{\text{stack}}^{(i)}\right]^2 + \lambda \left\|\mathbf{w}\right\|_2^2 \right\}, \tag{4.83}$$

em que

$$\mathbf{w} = [w_1, w_2]^T \tag{4.84}$$

e $\lambda \geq 0$ controla a intensidade da regularização L_2 (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

A penalização reduz a sensibilidade do meta-modelo a coeficientes de grande magnitude, propriedade especialmente relevante porque RF e BDT são ajustados para o mesmo alvo e suas predições podem ser fortemente correlacionadas. Sem regularização, elevada colinearidade entre essas duas entradas poderia tornar a ponderação estimada mais sensível às particularidades da amostra.

A Eq. 4.81 não deve ser interpretada como uma média convexa obrigatória. Na formulação Ridge utilizada, não é imposto, em geral, que

$$w_1 + w_2 = 1 \tag{4.85}$$

nem que

$$w_1, w_2 \geq 0. \tag{4.86}$$

O meta-regressor aprende uma combinação afim regularizada das predições dos modelos-base. Dessa forma, sua função é mais geral do que uma média aritmética simples.

Por outro lado, como o meta-modelo do RFBDTS é linear e utiliza coeficientes globais, é importante não lhe atribuir uma capacidade que ele não possui. O Ridge não aprende explicitamente pesos diferentes para cada região do espaço de entrada. Ele aprende uma combinação global das respostas da RF e do BDT. Uma combinação dependente diretamente de $\mathbf{x}$ exigiria, por exemplo, um meta-modelo não linear ou um mecanismo de ponderação condicionado às características, o que não corresponde à arquitetura avaliada nesta tese.

Assim como na correção residual, o segundo nível deve ser treinado sem reutilizar predições *in-sample* dos modelos-base. No RFBDTS, a Random Forest fornece predições *out-of-bag* (OOB) e o BDT fornece predições *out-of-fold* (OOF), de modo que, para cada evento utilizado na construção das entradas do Ridge, a predição correspondente é produzida sem utilizar diretamente esse evento no ajuste do respectivo modelo-base (SILVA et al., 2026a). Essas duas predições constituem as entradas do meta-regressor e preservam a lógica da Eq. 4.81 sem introduzir informação do teste independente.

Após o ajuste do Ridge, a Random Forest e o BDT são reajustados utilizando os dados de desenvolvimento permitidos e permanecem fixos na inferência final. O uso de OOB e OOF pertence exclusivamente à construção interna do RFBDTS e é distinto da validação cruzada aninhada empregada para seleção de hiperparâmetros. Em nenhuma dessas operações a partição independente $\mathcal{D}_{30}$ é utilizada para formar resíduos, entradas do meta-regressor, pesos ou hiperparâmetros.

A diferença conceitual entre correção residual e *stacking* pode ser resumida pela informação apresentada ao segundo estágio. Em BDTRF e RFBDT,

$$f_2 : \mathbf{x} \longmapsto r_1, \tag{4.87}$$

isto é, o segundo modelo recebe novamente a representação calorimétrica e aprende diretamente o erro remanescente do primeiro. No RFBDTS,

$$f_{\text{meta}} : (f_{\text{RF}}(\mathbf{x}), f_{\text{BDT}}(\mathbf{x})) \longmapsto \alpha_{\text{calib}}, \tag{4.88}$$

de modo que o segundo nível recebe as previsões dos dois modelos-base e aprende uma regra regularizada de combinação.

Os três modelos híbridos respondem, portanto, a perguntas diferentes. BDTRF testa se uma RF consegue explicar estrutura residual deixada por um BDT; RFBDT testa se um BDT consegue refinar a resposta inicialmente estabilizada por uma RF; e RFBDTS testa se as duas previsões contêm informação complementar que possa ser explorada por uma combinação linear regularizada (SILVA et al., 2026a; WOLPERT, 1992; TING; WITTEN, 1997).

Assim como nos demais métodos desta tese, maior capacidade estrutural não implica automaticamente melhor calibração. Cada arquitetura híbrida introduz custo adicional de treinamento, inferência e validação. Sua utilidade deve ser determinada empiricamente pelo ganho obtido em erro, dispersão e resolução, confrontado com dimensionalidade e tempo de predição. Essa análise é realizada na Etapa II apresentada no Capítulo 7.

4.3 Redes neurais profundas para regressão

As redes neurais artificiais constituem uma família de modelos parametrizados baseada na composição de transformações lineares e funções de ativação não lineares. Historicamente, sua formulação evoluiu a partir dos primeiros modelos matemáticos de unidades neurais, como o modelo de McCulloch–Pitts, passando pelo desenvolvimento do perceptron e pela consolidação do treinamento de redes multicamadas por retropropagação do erro (MCCULLOCH; PITTS, 1943; HAYKIN, 2009; RUMELHART; HINTON; WILLIAMS, 1986). O desenvolvimento posterior de arquiteturas profundas, algoritmos de otimização e recursos computacionais ampliou significativamente a aplicação desses modelos a problemas de classificação, regressão e representação de dados (LECUN; BENGIO; HINTON, 2015; GOODFELLOW; BENGIO; COURVILLE, 2016).

No contexto de uma rede *feed-forward*, a informação é propagada da camada de entrada em direção à saída sem conexões recorrentes. Cada camada realiza uma transformação afim seguida, nas camadas ocultas, por uma função de ativação não linear. A composição dessas transformações permite construir funções com capacidade significativamente maior do que aquela disponível em modelos lineares ou em expansões polinomiais de ordem previamente fixada (BISHOP, 2006; HAYKIN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016).

Na Física de Altas Energias, modelos neurais são utilizados em diferentes problemas de classificação, reconstrução, identificação de objetos e regressão, incluindo aplicações sobre representações de alta dimensionalidade produzidas por detectores de partículas (ALBERTSSON

et al., 2018; KOMISKE; METODIEV; THALER, 2019). Sua utilização, entretanto, não implica automaticamente robustez a ruído, *pile-up* ou efeitos instrumentais. Essas propriedades dependem da distribuição utilizada no treinamento, da arquitetura, da regularização e da validação realizada sobre condições representativas do domínio de aplicação (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

Nesta tese, as redes neurais profundas (*Deep Neural Networks*, DNNs) são empregadas na Etapa III para investigar se uma função de regressão com maior capacidade não linear consegue explorar a informação contida tanto na representação completa dos 100 anéis quanto em representações compactas produzidas pelos métodos discutidos anteriormente. A DNN considerada corresponde a um perceptron multicamadas profundo (*Multilayer Perceptron*, MLP), totalmente conectado, e implementa o mesmo problema de calibração multiplicativa utilizado pelas demais famílias de regressores.

4.3.1 Do neurônio ao perceptron multicamadas

A unidade elementar de uma rede neural densa realiza uma combinação linear das entradas, acrescida de um termo de viés, seguida por uma função de ativação. Para manter a convenção adotada neste capítulo, o índice do evento é representado por sobrescrito (i), enquanto o índice da camada é representado por subscrito.

Para o evento i, a representação de entrada da rede é

$$\mathbf{h}_0^{(i)} = \mathbf{x}^{(i)} \in \mathbb{R}^F, \tag{4.89}$$

de modo que $h_0 = F$, em que F representa a dimensionalidade externa da entrada fornecida por $g_{\mathrm{ML}}(\cdot)$.

Para uma DNN com L camadas ocultas, a transformação afim da camada $\ell = 1, \ldots, L$ é

$$\mathbf{a}_\ell^{(i)} = \mathbf{W}_\ell \mathbf{h}_{\ell-1}^{(i)} + \mathbf{b}_\ell, \tag{4.90}$$

com

$$\mathbf{W}_\ell \in \mathbb{R}^{h_\ell \times h_{\ell-1}}, \qquad \mathbf{b}_\ell \in \mathbb{R}^{h_\ell}, \tag{4.91}$$

em que $\mathbf{W}_\ell$ e $\mathbf{b}_\ell$ são, respectivamente, a matriz de pesos e o vetor de vieses treináveis da camada ℓ.

A representação produzida pela camada é

$$\mathbf{h}_\ell^{(i)} = \varphi_\ell\left(\mathbf{a}_\ell^{(i)}\right), \qquad \ell = 1, \ldots, L, \tag{4.92}$$

em que $\varphi_\ell(\cdot)$ denota a função de ativação aplicada elemento a elemento.

A representação $\mathbf{x}^{(i)}$ pode corresponder diretamente à representação completa dos 100 anéis, $F = 100$, ou a um conjunto compacto de atributos ou componentes obtido por CORR, MUTI, PCA ou ICA.

É importante preservar a distinção estabelecida nas seções anteriores: embora E_{true} possa participar da definição supervisionada de determinadas representações durante a fase de

desenvolvimento, ele não integra o vetor $\mathbf{x}^{(i)}$ utilizado pela rede durante validação, teste ou inferência. Uma vez determinado $g_{\mathrm{ML}}(\cdot)$,

$$\mathbf{x}^{(i)} = g_{\mathrm{ML}}\left(\widetilde{\mathbf{E}}_r^{(i)}\right) \tag{4.93}$$

é calculado exclusivamente a partir das informações disponíveis para o novo evento.

A composição sucessiva das camadas permite que representações intermediárias sejam construídas a partir das saídas das camadas anteriores, produzindo uma hierarquia de transformações aprendidas diretamente dos dados (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

Como o problema considerado é uma regressão escalar, a camada final possui uma única saída e utiliza transformação linear,

$$\alpha_{\mathrm{calib}}^{(i)} = \mathbf{W}_{L+1}\mathbf{h}_L^{(i)} + b_{L+1}, \tag{4.94}$$

com

$$\mathbf{W}_{L+1} \in \mathbb{R}^{1\times h_L}, \qquad b_{L+1} \in \mathbb{R}. \tag{4.95}$$

Consequentemente,

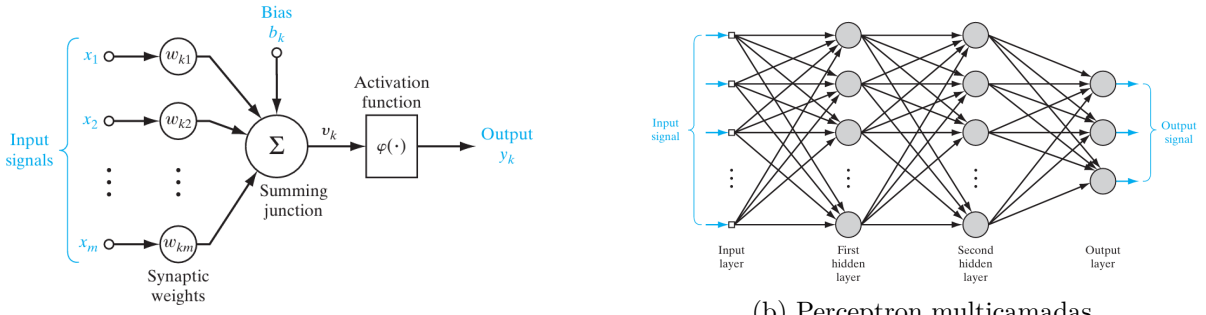
$$\alpha_{\mathrm{calib}}^{(i)} = f_{\mathrm{DNN}}\left(\mathbf{x}^{(i)}\right), \tag{4.96}$$

e a energia transversa calibrada permanece definida pela relação geral da Eq. 3.1,

$$E_{\mathrm{calib}}^{(i)} = \alpha_{\mathrm{calib}}^{(i)} E_{\mathrm{fast}}^{(i)}. \tag{4.97}$$

A DNN atua, portanto, como mecanismo de fusão não linear da informação disponível em $\mathbf{x}^{(i)}$. No caso da representação completa, essa fusão ocorre diretamente sobre os 100 anéis. Para representações compactas, a DNN combina os atributos ou componentes previamente selecionados ou extraídos por $g_{\mathrm{ML}}(\cdot)$.

A Figura 13 apresenta esquematicamente uma unidade neural e uma rede multicamadas.



(a) Neurônio/perceptron.

(b) Perceptron multicamadas.

Figura 13 – Representações conceituais de uma unidade neural e de uma rede multicamadas. Fonte: adaptado de (HAYKIN, 2009).

Uma função de ativação utilizada nas DNNs avaliadas nesta tese é a unidade linear retificada,

$$\mathrm{ReLU}(u) = \max(0, u). \tag{4.98}$$

Sua derivada é

$$\mathrm{ReLU}'(u) = \begin{cases} 0, & u < 0, \\ 1, & u > 0, \end{cases} \tag{4.99}$$

enquanto em $u = 0$ a derivada clássica não é definida e implementações numéricas adotam uma convenção apropriada para o gradiente (GOODFELLOW; BENGIO; COURVILLE, 2016).

Embora a ReLU seja linear separadamente nos domínios $u < 0$ e $u > 0$, a mudança de regime introduz a não linearidade necessária para que a composição de múltiplas camadas não se reduza a uma única transformação afim. Com ativações puramente lineares em todas as camadas,

$$\mathbf{W}_L \cdots \mathbf{W}_2 \mathbf{W}_1 \mathbf{x} \tag{4.100}$$

continuaria sendo apenas uma transformação linear, independentemente do número de camadas (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

Além da função de ativação, profundidade e largura determinam a quantidade de parâmetros treináveis. Para uma rede totalmente conectada com

$$h_0 = F, \qquad h_{L+1} = 1, \tag{4.101}$$

o número total de parâmetros é

$$P_{\mathrm{DNN}} = \sum_{\ell=1}^{L+1} \left(h_\ell h_{\ell-1} + h_\ell \right). \tag{4.102}$$

Essa expressão torna explícito que a dimensionalidade externa F não constitui, isoladamente, uma medida completa da complexidade da rede. Duas arquiteturas que recebem o mesmo número de entradas podem possuir profundidade, largura, quantidade de parâmetros e custo computacional muito diferentes (GOODFELLOW; BENGIO; COURVILLE, 2016).

4.3.2 Capacidade, regularização e treinamento

O treinamento da DNN consiste em ajustar seus pesos e vieses de modo a minimizar uma função de perda definida sobre os eventos disponíveis para desenvolvimento. Seja

$$\boldsymbol{\theta} = \{\mathbf{W}_\ell, \mathbf{b}_\ell\}_{\ell=1}^{L} \cup \{\mathbf{W}_{L+1}, b_{L+1}\}, \tag{4.103}$$

o conjunto de parâmetros da rede durante o treinamento. O alvo supervisionado continua sendo $\alpha_{\mathrm{true}}^{(i)}$.

Para uma perda quadrática com penalização L_2 sobre as matrizes de pesos, uma formulação geral pode ser escrita como

$$\begin{aligned} \mathcal{L}(\boldsymbol{\theta}) = & \frac{1}{2N} \sum_{i=1}^{N} \left[\alpha_{\mathrm{true}}^{(i)} - f_{\mathrm{DNN}}\left(\mathbf{x}^{(i)}; \boldsymbol{\theta}\right) \right]^2 \\ & + \frac{\lambda}{2} \sum_{\ell=1}^{L+1} \|\mathbf{W}_\ell\|_F^2, \end{aligned} \tag{4.104}$$

em que $\lambda \geq 0$ controla a intensidade da regularização e $\|\cdot\|_F$ representa a norma de Frobenius.[2]

A regularização L_2 não deve ser interpretada como garantia de robustez física. Ela modifica o critério de estimação dos parâmetros e pode contribuir para a generalização, mas não demonstra invariância a ruído eletrônico, *pile-up*, alterações de calibração ou diferenças entre simulação e dados. Esses efeitos requerem validações experimentais específicas (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

Assim como nas regressões anteriores, a função objetivo da Eq. 4.104 atua sobre o fator de calibração. Portanto, sua minimização não é, em geral, matematicamente equivalente à minimização de um MSE não ponderado diretamente sobre E_{calib}, conforme demonstrado na Seção 3.1.1.

Os parâmetros são ajustados por métodos baseados no gradiente da função de perda. A retropropagação do erro (*backpropagation*) aplica a regra da cadeia de forma eficiente à composição de funções que constitui a rede, permitindo calcular os gradientes das camadas a partir da saída em direção à entrada (RUMELHART; HINTON; WILLIAMS, 1986; HAYKIN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016).

Para simplificar a escrita, considere a contribuição quadrática do evento i para a perda, sem o termo de regularização,

$$\mathcal{E}^{(i)} = \frac{1}{2}\left(\alpha_{\text{calib}}^{(i)} - \alpha_{\text{true}}^{(i)}\right)^2. \tag{4.105}$$

Como a camada de saída possui dimensão unitária, define-se o vetor de erro da saída por

$$\boldsymbol{\delta}_{L+1}^{(i)} = \left[\alpha_{\text{calib}}^{(i)} - \alpha_{\text{true}}^{(i)}\right] \in \mathbb{R}^1. \tag{4.106}$$

Para as camadas ocultas, os erros são propagados recursivamente por

$$\boldsymbol{\delta}_{\ell}^{(i)} = \left[\mathbf{W}_{\ell+1}^T \boldsymbol{\delta}_{\ell+1}^{(i)}\right] \odot \varphi_{\ell}'\left(\mathbf{a}_{\ell}^{(i)}\right), \qquad \ell = L, L-1, \ldots, 1. \tag{4.107}$$

em que $\odot$ representa o produto de Hadamard.

Para as camadas ocultas, os gradientes associados às matrizes de pesos são

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_{\ell}} = \frac{1}{N}\sum_{i=1}^{N} \boldsymbol{\delta}_{\ell}^{(i)} \mathbf{h}_{\ell-1}^{(i)T} + \lambda \mathbf{W}_{\ell}, \tag{4.108}$$

enquanto, para os vieses,

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}_{\ell}} = \frac{1}{N}\sum_{i=1}^{N} \boldsymbol{\delta}_{\ell}^{(i)}. \tag{4.109}$$

Os gradientes associados aos parâmetros da camada de saída, $\mathbf{W}_{L+1}$ e b_{L+1}, são obtidos analogamente a partir de $\boldsymbol{\delta}_{L+1}^{(i)}$.

Na prática, esses gradientes são normalmente calculados sobre mini-lotes (*mini-batches*) em vez de toda a amostra simultaneamente. Isso permite combinar estimativas estocásticas do

[2] Para uma matriz $\mathbf{W} \in \mathbb{R}^{m\times n}$, a norma de Frobenius é definida por $\|\mathbf{W}\|_F = \sqrt{\sum_{r=1}^{m}\sum_{s=1}^{n} w_{rs}^2}$. A penalização L_2 desencoraja soluções com pesos de grande magnitude e constitui uma forma clássica de controle de complexidade em modelos parametrizados (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

gradiente com operações matriciais eficientes e constitui uma estratégia padrão de treinamento de redes profundas (GOODFELLOW; BENGIO; COURVILLE, 2016).

Nas DNNs desta tese, a atualização dos parâmetros utiliza o algoritmo Adam (KINGMA; BA, 2015). Na iteração t, o gradiente da função objetivo é $\nabla_{\boldsymbol{\theta}}\mathcal{L}_t$. O Adam mantém estimativas exponencialmente ponderadas do primeiro e do segundo momentos desse gradiente,

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1-\beta_1)\,\nabla_{\boldsymbol{\theta}}\mathcal{L}_t, \tag{4.110}$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1-\beta_2)\,(\nabla_{\boldsymbol{\theta}}\mathcal{L}_t) \odot (\nabla_{\boldsymbol{\theta}}\mathcal{L}_t)\,. \tag{4.111}$$

Como ambas as estimativas são inicializadas tipicamente em zero, introduzem-se as correções de viés

$$\widehat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1-\beta_1^t}, \tag{4.112}$$

e

$$\widehat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1-\beta_2^t}. \tag{4.113}$$

A atualização dos parâmetros é então

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \nu \frac{\widehat{\mathbf{m}}_t}{\sqrt{\widehat{\mathbf{v}}_t} + \epsilon}, \tag{4.114}$$

em que as operações de divisão e raiz quadrada são realizadas elemento a elemento, ν é a taxa de aprendizado e ϵ é uma constante positiva utilizada para estabilidade numérica. Na formulação original do Adam, valores como $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ e $\epsilon = 10^{-8}$ são apresentados como escolhas padrão de referência (KINGMA; BA, 2015).

Essa formulação explicita uma distinção importante entre treinamento e inferência. O Adam, a retropropagação e as múltiplas épocas são utilizados exclusivamente para determinar os parâmetros da rede durante a fase *offline*. Eles não fazem parte da propagação direta executada para cada evento após o modelo estar treinado. Consequentemente, uma convergência mais rápida do otimizador pode reduzir o custo de desenvolvimento e treinamento, mas não reduz diretamente a latência de inferência do modelo.

Após o treinamento, os parâmetros $\boldsymbol{\theta}^\star$ são considerados incorporados a $f_{\mathrm{DNN}}(\cdot)$, de acordo com a convenção adotada para as demais famílias de regressão. A inferência requer apenas a sequência de transformações afins e ativações das Eqs. 4.90–4.94.

Para uma DNN densa, o custo principal da propagação direta está associado às multiplicações matriz–vetor. Desconsiderando constantes e operações elementares de ativação, o número de operações cresce aproximadamente com

$$\sum_{\ell=1}^{L+1} h_\ell h_{\ell-1}, \tag{4.115}$$

mostrando novamente que F representa apenas a dimensionalidade externa e não a complexidade total do modelo (GOODFELLOW; BENGIO; COURVILLE, 2016).

Maior profundidade ou largura aumenta a capacidade parametrizada da rede, mas também amplia o espaço de modelos disponível para ajuste. Em uma amostra finita, isso pode reduzir o erro

de treinamento sem necessariamente melhorar a generalização, produzindo sobreajuste quando estruturas específicas da amostra são aprendidas em detrimento de regularidades persistentes (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

Por essa razão, a seleção da arquitetura deve ser realizada com dados separados daqueles utilizados para a avaliação final. Nesta tese, profundidade, largura e formato das camadas são tratados como hiperparâmetros e selecionados dentro do protocolo de validação cruzada aninhada descrito no Capítulo 5. A partição independente de teste permanece isolada até a avaliação final.

Além da penalização L_2, as DNNs consolidadas da Etapa III utilizam *early stopping*. Nesse procedimento, uma fração dos dados disponíveis ao ajuste é utilizada para acompanhar o desempenho durante o treinamento, e o processo é encerrado quando não ocorre melhoria suficiente durante um número predefinido de épocas. Esse mecanismo limita treinamento desnecessário e pode reduzir sobreajuste, embora não constitua garantia de generalização fora do domínio representado pelos dados (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

É importante distinguir esses mecanismos daqueles que são apenas possibilidades gerais em redes neurais. Técnicas como *dropout* e diferentes formas de normalização interna são amplamente utilizadas em aprendizado profundo (GOODFELLOW; BENGIO; COURVILLE, 2016), mas não devem ser atribuídas automaticamente à DNN desta tese. A arquitetura consolidada emprega os mecanismos explicitamente documentados no protocolo experimental e no Apêndice de Reprodutibilidade.

No estudo realizado, as DNNs são implementadas como MLPs densos com ativação ReLU, regularização L_2, otimização Adam e *early stopping*. Profundidade, largura e forma das camadas são investigadas como parte da seleção do modelo, enquanto as configurações finais e os respectivos espaços de busca são apresentados no Apêndice de Reprodutibilidade. Essa separação mantém a presente seção dedicada à formulação do método e evita confundir princípios gerais com valores específicos de uma realização experimental (SILVA; SIMAS FILHO, 2026; HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016).

A interpretação do custo de inferência da DNN segue a distinção entre tempo de predição do modelo e latência de ponta a ponta estabelecida na Seção 4.6. Os tempos medidos nesta tese caracterizam exclusivamente o benchmark computacional adotado.

4.4 Redes neurais em grafos e viés indutivo relacional

Redes Neurais em Grafos (*Graph Neural Networks*, GNNs) constituem uma família de modelos destinada ao processamento de dados cuja estrutura pode ser descrita explicitamente em termos de entidades e relações entre elas (SCARSELLI et al., 2008; BRONSTEIN et al., 2017; BATTAGLIA et al., 2018). Em contraste com uma rede totalmente conectada convencional, na qual as entradas são tratadas essencialmente como coordenadas de um vetor e as relações entre elas devem ser inferidas a partir dos dados, uma GNN permite incorporar à arquitetura uma estrutura relacional previamente definida.

Essa propriedade pode ser interpretada como um *viés indutivo relacional*: a conectividade do grafo introduz a hipótese de que determinadas relações entre elementos são particularmente

relevantes e, portanto, devem ser processadas explicitamente pelo modelo (BATTAGLIA et al., 2018). Em Física de Altas Energias, abordagens desse tipo têm sido empregadas em problemas nos quais partículas, *hits*, células, objetos reconstruídos ou outros elementos detectoriais possuem relações estruturais conhecidas (SHLOMI; BATTAGLIA; VLIMANT, 2020; QU; GOUSKOS, 2020; QASIM et al., 2019; QASIM et al., 2022).

No problema tratado nesta tese, os 100 anéis não constituem um conjunto arbitrário e desordenado de atributos. A representação Ringer preserva uma organização associada às regiões e amostragens calorimétricas, de modo que a posição do anel na representação também carrega informação sobre a localização da deposição de energia no perfil construído a partir do detector. Uma DNN tabular pode aprender interações globais entre quaisquer componentes desse vetor, mas não recebe explicitamente a hipótese de que elementos próximos na organização da representação devam trocar informação localmente.

Essa distinção é relevante porque a resposta calorimétrica depende, entre outros fatores, do desenvolvimento longitudinal e lateral do chuveiro, da segmentação do detector, de perdas de energia e das diferentes respostas das regiões instrumentadas (FABJAN; GIANOTTI, 2003; ATLAS Collaboration, 2024a). Informação relacional local e informação global sobre o perfil do chuveiro podem, portanto, fornecer descrições complementares do mesmo evento.

A arquitetura desenvolvida na Etapa III desta tese foi concebida especificamente para investigar essa hipótese. Ela não corresponde à aplicação direta de uma GNN genérica sobre características arbitrárias nem a uma arquitetura exclusivamente baseada em grafo. Trata-se de uma arquitetura de "fusão relacional–tabular" que combina grafos regionais, propagação local de mensagens, descritores derivados do perfil dos anéis, processamento tabular e diferentes caminhos de regressão (SILVA; SIMAS FILHO, 2026).

A originalidade da contribuição encontra-se no desenho dessa composição para a interface Ringer e para o sistema calorimétrico considerado. Não se reivindica a proposição de um novo operador matemático de GNN; componentes estabelecidos, particularmente GraphSAGE (HAMILTON; YING; LESKOVEC, 2017), são organizados em uma arquitetura *detector-informed* destinada à estimação do fator de calibração.

O uso de GNNs para reconstrução e calibração calorimétrica não é, por si só, inédito. A colaboração ATLAS, por exemplo, avaliou arquiteturas baseadas em nuvens de pontos, incluindo GNNs, para reconstrução e calibração de píons a partir de informação calorimétrica e de trajetória (ATLAS Collaboration, 2022). A contribuição reivindicada nesta tese é mais específica: a construção relacional–tabular sobre a interface Ringer de 100 anéis, com particionamento regional PS–EM–HAD, relações locais na sequência Ringer e fusão com descritores derivados, aplicada à calibração evento a evento da estimativa rápida de energia transversa de elétrons no *benchmark* considerado.

A Figura 14 sintetiza o fluxo computacional da arquitetura GNN relacional–tabular proposta e avaliada na Etapa III. A mesma representação Ringer de 100 anéis alimenta dois ramos complementares. No ramo gráfico, os anéis são particionados nas regiões PS, EM e HAD, codificados como nós e processados por propagação local de mensagens com GraphSAGE e

pooling regional. No ramo tabular, os 100 anéis são combinados com 20 descritores determinísticos e processados por transformações densas, preservando-se também um caminho linear direto. As representações gráfica e tabular são posteriormente combinadas no estágio de fusão, enquanto as contribuições linear, tabular não linear e relacional–tabular são somadas para produzir o fator de calibração α_{calib}. As subseções seguintes formalizam cada um desses blocos e suas respectivas transformações.

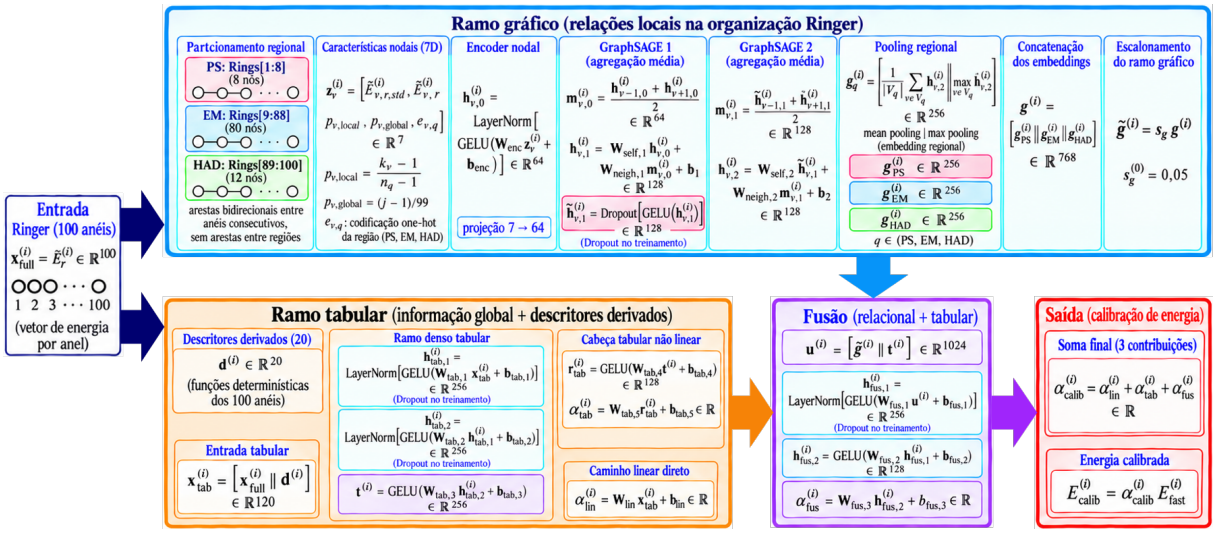


Figura 14 – Representação esquemática da arquitetura GNN relacional–tabular proposta para a calibração evento a evento da energia transversa.

4.4.1 Representação em grafos

Um grafo pode ser representado por

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}), \tag{4.116}$$

em que $\mathcal{V}$ é o conjunto de nós e $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ é o conjunto de arestas. Cada nó $v \in \mathcal{V}$ pode possuir um vetor de n_c características,

$$\mathbf{z}_v \in \mathbb{R}^{n_c}. \tag{4.117}$$

A escolha de $\mathcal{E}$ constitui parte do modelo. Inserir uma aresta entre dois nós equivale a introduzir a hipótese de que sua relação deve ser processada localmente. Consequentemente, a topologia do grafo deve ser definida a partir de conhecimento do problema ou submetida a validação experimental (BATTAGLIA et al., 2018).

Na arquitetura proposta nesta tese, a entrada externa corresponde exclusivamente à representação completa dos 100 anéis para o i-ésimo evento,

$$\mathbf{x}_{\text{full}}^{(i)} = \widetilde{\mathbf{E}}_r^{(i)} \in \mathbb{R}^{100}. \tag{4.118}$$

Essa escolha preserva a correspondência entre cada entrada e uma posição determinada na representação Ringer. Componentes obtidos por representações compactas não preservam uma vizinhança local diretamente associada à representação calorimétrica e, portanto, não foram utilizados aqui como entrada.

A representação completa é particionada em três macro-regiões,

$$\mathbf{x}_{\text{full}}^{(i)} = \left[\mathbf{x}_{\text{PS}}^{(i)}, \mathbf{x}_{\text{EM}}^{(i)}, \mathbf{x}_{\text{HAD}}^{(i)}\right], \tag{4.119}$$

com

$$\mathbf{x}_{\text{PS}}^{(i)} \in \mathbb{R}^8, \qquad \mathbf{x}_{\text{EM}}^{(i)} \in \mathbb{R}^{80}, \qquad \mathbf{x}_{\text{HAD}}^{(i)} \in \mathbb{R}^{12}, \tag{4.120}$$

correspondendo às regiões PS (`Rings[1:8]`), EM (`Rings[9:88]`) e HAD (`Rings[89:100]`).

Então, para cada região $q \in \{\text{PS}, \text{EM}, \text{HAD}\}$, é construído um grafo

$$\mathcal{G}_q^{(i)} = \left(\mathcal{V}_q, \mathcal{E}_q, \mathbf{Z}_q^{(i)}\right), \tag{4.121}$$

em que $\mathbf{Z}_q^{(i)} = [\mathbf{z}_1^{(i)}, \mathbf{z}_2^{(i)}, \ldots, \mathbf{z}_{n_q}^{(i)}]^T \in \mathbb{R}^{n_q \times 7}$ contém, por linhas, as características dos n_q nós da região q para o i-ésimo evento.

Os três grafos possuem topologia fixa entre eventos e somente os valores das características nodais dependem do evento. Na configuração selecionada, relações bidirecionais são introduzidas exclusivamente entre anéis consecutivos dentro de cada região,

$$(v_j, v_{j+1}) \in \mathcal{E}_q \quad \text{e} \quad (v_{j+1}, v_j) \in \mathcal{E}_q. \tag{4.122}$$

Não são inseridas arestas entre regiões distintas. Assim, PS, EM e HAD são processadas inicialmente como três estruturas relacionais independentes. Essa escolha não pressupõe independência física entre as três regiões. Ela representa apenas um viés arquitetural segundo o qual a propagação local é realizada dentro de cada região antes de a informação global ser combinada pelo ramo tabular e pelo estágio de fusão.

As arestas representam vizinhança na organização sequencial da representação Ringer e não uma reconstrução completa da geometria tridimensional das células do calorímetro. Como as macro-regiões EM e HAD reúnem diferentes amostragens calorimétricas, a consecutividade dos índices dentro dessas macro-regiões também pode atravessar fronteiras entre EM1, EM2 e EM3 ou entre HAD1, HAD2 e HAD3. Portanto, uma aresta codifica adjacência na sequência Ringer adotada pelo modelo, e não necessariamente adjacência geométrica direta entre células ou continuidade radial física no detector (PINTO; ATLAS Collaboration, 2016; SILVA; SIMAS FILHO, 2026).

Os blocos iniciais do ramo gráfico na Figura 14 sintetizam essa construção: a representação Ringer é particionada em PS, EM e HAD, são estabelecidas relações locais entre anéis consecutivos dentro de cada região e, em seguida, cada nó recebe o conjunto de características calorimétricas, posicionais e regionais formalizado a seguir.

Dessa forma, para o nó v do evento i, a arquitetura implementada utiliza um descritor de sete dimensões,

$$\mathbf{z}_v^{(i)} = \left[\widetilde{E}_{r,v,\text{std}}^{(i)}, \widetilde{E}_{r,v}^{(i)}, p_{v,\text{local}}, p_{v,\text{global}}, \mathbf{e}_{v,q}\right] \in \mathbb{R}^7, \tag{4.123}$$

em que $\widetilde{E}_{r,v,\text{std}}^{(i)}$ é a versão padronizada (*z-score*) do valor do anel na região, $\widetilde{E}_{r,v}^{(i)}$ é seu valor original, $p_{v,\text{local}} \in [0,1]$ representa a posição normalizada dentro da região, $p_{v,\text{global}} \in [0,1]$ representa a posição na sequência completa dos 100 anéis e $\mathbf{e}_{v,q} \in \mathbb{R}^3$ é uma codificação *one-hot*

das regiões (PS = [1,0,0]; EM = [0,1,0]; HAD = [0,0,1]). Ou seja, para uma região contendo n_q nós, a posição local utilizada é

$$p_{v,\text{local}} = \frac{k_v - 1}{n_q - 1}, \qquad k_v = 1, \ldots, n_q, \tag{4.124}$$

enquanto, para o nó v associado ao anel de índice global j, a posição global é

$$p_{v,\text{global}} = \frac{j - 1}{99}. \tag{4.125}$$

Essas variáveis permitem distinguir valores calorimétricos numericamente semelhantes que ocorram em posições diferentes do perfil. Isso é importante porque a relevância de determinada deposição depende de onde ela ocorre no desenvolvimento do chuveiro (FABJAN; GIANOTTI, 2003; ATLAS Collaboration, 2024a). A versão padronizada dos anéis utiliza médias e desvios-padrão calculados exclusivamente na amostra utilizada para o ajuste do modelo dentro da região. As mesmas estatísticas são posteriormente aplicadas às amostras de validação e teste, evitando que informação dessas partições seja utilizada na transformação dos dados (CAWLEY; TALBOT, 2010).

4.4.2 Propagação de mensagens e GraphSAGE

A propagação no ramo gráfico parte diretamente do vetor nodal de sete características definido na Eq. 4.123, $\mathbf{z}_v^{(i)} \in \mathbb{R}^7$ para o nó v. Antes da troca de informação entre nós vizinhos, esse vetor é projetado inicialmente para um espaço latente de dimensão 64,

$$\mathbf{h}_{v,0}^{(i)} = \text{LayerNorm}\left[\text{GELU}\left(\mathbf{W}_{\text{enc}}\mathbf{z}_v^{(i)} + \mathbf{b}_{\text{enc}}\right)\right] \in \mathbb{R}^{64}. \tag{4.126}$$

Primeiramente, o codificador realiza a projeção linear $7 \to 64$, com $\mathbf{W}_{\text{enc}} \in \mathbb{R}^{64\times 7}$ e $\mathbf{b}_{\text{enc}} \in \mathbb{R}^{64}$. A matriz $\mathbf{W}_{\text{enc}}$ e o vetor $\mathbf{b}_{\text{enc}}$ são parâmetros treináveis: seus valores são ajustados a partir dos dados durante a retropropagação do erro.

Em seguida, aplica-se a função GELU (*Gaussian Error Linear Unit*) para introduzir não linearidade à representação interna (HENDRYCKS; GIMPEL, 2016).[3] A normalização de camada (*LayerNorm*) é então aplicada às ativações resultantes (BA; KIROS; HINTON, 2016).[4]

A projeção de 7 características para 64 componentes não acrescenta nova informação física ao evento. Sua função é aumentar a capacidade da representação latente, permitindo que diferentes combinações aprendidas das características nodais sejam disponibilizadas às etapas de propagação. Analogamente, a passagem posterior de 64 para 128 componentes amplia o número de canais latentes disponíveis para representar combinações da informação do próprio nó e de sua vizinhança. Essas dimensões são escolhas arquiteturais do modelo avaliado e não valores determinados pela literatura (GOODFELLOW; BENGIO; COURVILLE, 2016; HAMILTON; YING; LESKOVEC, 2017).

[3] Para uma entrada escalar x, a GELU é definida por $\text{GELU}(x) = x\Phi(x) = \frac{x}{2}\left[1 + \text{erf}(x/\sqrt{2})\right]$, em que $\Phi(\cdot)$ é a função de distribuição acumulada da normal padrão.

[4] Para um vetor de ativações $\mathbf{a} \in \mathbb{R}^d$, $\text{LayerNorm}(\mathbf{a})_k = \gamma_k(a_k - \mu_{\mathbf{a}})/\sqrt{\sigma_{\mathbf{a}}^2 + \varepsilon} + \beta_{\text{LN},k}$, em que a média e a variância são calculadas sobre os componentes da própria camada para cada amostra. Os fatores γ_k e $\beta_{\text{LN},k}$ também são aprendidos durante o treinamento.

O GraphSAGE foi adotado como operador de propagação porque permite combinar explicitamente a representação do próprio nó com uma agregação de sua vizinhança local (HAMILTON; YING; LESKOVEC, 2017), estrutura compatível com a hipótese de dependência local introduzida pelas arestas entre anéis consecutivos. Sua adoção constitui uma escolha arquitetural desta tese e não uma demonstração de superioridade sobre outros operadores de GNN ou sobre alternativas convolucionais aplicadas à sequência Ringer.

A representação inicial codificada $\mathbf{h}_{v,0}^{(i)}$ para o nó v do evento i é então processada por duas camadas GraphSAGE (HAMILTON; YING; LESKOVEC, 2017). Para os nós internos da região, $1 < v < n_q$, a agregação da vizinhança é realizada pela média das representações dos dois nós vizinhos $(v-1, v+1)$,

$$\mathbf{m}_{v,0}^{(i)} = \frac{\mathbf{h}_{v-1,0}^{(i)} + \mathbf{h}_{v+1,0}^{(i)}}{2} \in \mathbb{R}^{64}. \tag{4.127}$$

A atualização após a primeira camada GraphSAGE ($\mathbf{h}_{v,1}^{(i)}$) combina separadamente a representação do próprio nó ($\mathbf{h}_{v,0}^{(i)}$) e a informação agregada de sua vizinhança ($\mathbf{m}_{v,0}^{(i)}$), com aumento dimensional de 64 para 128,

$$\mathbf{h}_{v,1}^{(i)} = \mathbf{W}_{\text{self},1}\mathbf{h}_{v,0}^{(i)} + \mathbf{W}_{\text{neigh},1}\mathbf{m}_{v,0}^{(i)} + \mathbf{b}_1 \in \mathbb{R}^{128}, \tag{4.128}$$

onde $\mathbf{W}_{\text{self},1} \in \mathbb{R}^{128\times 64}$, $\mathbf{W}_{\text{neigh},1} \in \mathbb{R}^{128\times 64}$ e $\mathbf{b}_1 \in \mathbb{R}^{128}$.

Após essa primeira propagação, aplica-se

$$\widetilde{\mathbf{h}}_{v,1}^{(i)} = \text{Dropout}\left[\text{GELU}\left(\mathbf{h}_{v,1}^{(i)}\right)\right] \in \mathbb{R}^{128}. \tag{4.129}$$

A GELU aplicada após a primeira camada GraphSAGE introduz uma não linearidade entre as duas etapas sucessivas de propagação. Como a agregação média e as transformações lineares do GraphSAGE são operações lineares em relação às representações de entrada para uma topologia fixa, essa ativação permite que a segunda camada opere sobre combinações não lineares da informação própria e da informação agregada da vizinhança.

O *dropout* atua como mecanismo de regularização durante o treinamento, anulando aleatoriamente uma fração das ativações e reduzindo a dependência excessiva de unidades específicas (SRIVASTAVA et al., 2014). A probabilidade de *dropout* é um hiperparâmetro da configuração experimental. A literatura justifica o mecanismo, não o valor específico adotado nesta tese.

Para os nós internos, a segunda camada GraphSAGE repete a agregação sobre as representações produzidas pela primeira camada,

$$\mathbf{m}_{v,1}^{(i)} = \frac{\widetilde{\mathbf{h}}_{v-1,1}^{(i)} + \widetilde{\mathbf{h}}_{v+1,1}^{(i)}}{2} \in \mathbb{R}^{128}. \tag{4.130}$$

Nas duas camadas GraphSAGE, os nós nas extremidades de cada região ($v = 1$ ou $v = n_q$) possuem apenas um vizinho. Nesses casos, a agregação pela média reduz-se simplesmente à representação desse único nó vizinho.

Com isso, a representação nodal final pode ser escrita como

$$\mathbf{h}_{v,2}^{(i)} = \mathbf{W}_{\text{self},2}\widetilde{\mathbf{h}}_{v,1}^{(i)} + \mathbf{W}_{\text{neigh},2}\mathbf{m}_{v,1}^{(i)} + \mathbf{b}_2 \in \mathbb{R}^{128}, \tag{4.131}$$

onde $\mathbf{W}_{\text{self},2} \in \mathbb{R}^{128\times128}$, $\mathbf{W}_{\text{neigh},2} \in \mathbb{R}^{128\times128}$ e $\mathbf{b}_2 \in \mathbb{R}^{128}$. Esses também são parâmetros que serão aprendidos no treinamento neural.

Após a segunda aplicação do GraphSAGE, a representação nodal pode depender da informação do próprio nó e de nós situados a até dois saltos no grafo regional. Para um nó interno da cadeia, esse campo receptivo inclui, em particular, $v-2$, $v-1$, v, $v+1$ e $v+2$, respeitados os limites de cada região. O número de camadas GraphSAGE empregado, duas ao todo, e a dimensão latente de 128 componentes pertencem à configuração experimental; não se assume que esses valores sejam universalmente ótimos.

As regiões $q \in \{\text{PS}, \text{EM}, \text{HAD}\}$ utilizam blocos com a mesma estrutura, porém com parâmetros treináveis independentes. Assim, a transformação aprendida para uma região não é compartilhada com as demais, embora o mecanismo de processamento seja o mesmo.

Para evitar sobrecarga notacional, o índice regional q é omitido nos parâmetros do codificador e das camadas GraphSAGE. Assim, $\mathbf{W}_{\text{enc}}$, $\mathbf{b}_{\text{enc}}$, $\mathbf{W}_{\text{self},\ell}$, $\mathbf{W}_{\text{neigh},\ell}$ e $\mathbf{b}_\ell$ devem ser entendidos como conjuntos de parâmetros independentes para PS, EM e HAD.

Em seguida, as representações nodais são condensadas em uma representação regional de dimensão fixa mediante a concatenação entre agregação pela média (*mean pooling*) e agregação pelo máximo (*max pooling*) [5],

$$\mathbf{g}_q^{(i)} = \left[\frac{1}{|\mathcal{V}_q|} \sum_{v\in\mathcal{V}_q} \mathbf{h}_{v,2}^{(i)} \;\middle\|\; \max_{v\in\mathcal{V}_q} \mathbf{h}_{v,2}^{(i)} \right] \in \mathbb{R}^{256}. \tag{4.132}$$

O *mean pooling* resume a resposta latente distribuída ao longo da região, enquanto o *max pooling* retém, componente a componente, as ativações latentes dominantes. Cada operação produz 128 componentes; sua concatenação resulta, portanto, em $\mathbf{g}_q^{(i)} \in \mathbb{R}^{256}$. O *pooling* converte as representações nodais em uma representação regional de dimensão fixa (ZAHEER et al., 2017). A combinação específica entre média e máximo constitui uma escolha arquitetural desta tese.

Finalmente, os três vetores regionais são concatenados,

$$\mathbf{g}^{(i)} = \left[\mathbf{g}_{\text{PS}}^{(i)} \| \mathbf{g}_{\text{EM}}^{(i)} \| \mathbf{g}_{\text{HAD}}^{(i)} \right] \in \mathbb{R}^{768}. \tag{4.133}$$

O vetor $\mathbf{g}^{(i)}$ constitui a saída do ramo gráfico.

A sequência completa desse ramo pode ser acompanhada na parte superior da Figura 14: codificação das características nodais, duas etapas de propagação GraphSAGE, *mean pooling* e *max pooling* em cada região e, finalmente, concatenação dos *embeddings* de PS, EM e HAD. O resultado é o *embedding* gráfico $\mathbf{g}^{(i)} \in \mathbb{R}^{768}$, que será posteriormente escalado e combinado com a representação tabular.

4.4.3 Ramo tabular e descritores derivados dos anéis

A arquitetura proposta não utiliza exclusivamente o ramo gráfico consolidado pela Eq. 4.133. Como sintetizado no ramo tabular da Figura 14, em paralelo é construída uma

[5] Operações como média e máximo são reduções invariantes à permutação dos elementos sobre os quais são calculadas. Isso não significa que a arquitetura ignore a posição dos anéis: posição local, posição global e conectividade já foram incorporadas às representações nodais antes do *pooling*.

representação que preserva os 100 valores dos anéis e acrescenta 20 descritores determinísticos destinados a sintetizar propriedades globais, regionais e posicionais do perfil calorimétrico.

Em calorimetria, o desenvolvimento longitudinal e lateral do chuveiro é tradicionalmente caracterizado por grandezas relacionadas à energia depositada em diferentes regiões ou amostragens, frações e razões de energia e medidas de concentração ou largura do perfil (FABJAN; GIANOTTI, 2003; ATLAS Collaboration, 2019a). A representação Ringer, por sua vez, organiza a energia em anéis ordenados ao longo das amostragens calorimétricas e preserva informação longitudinal e lateral do chuveiro (PINTO; ATLAS Collaboration, 2016). Esses precedentes sustentam o princípio de construir resumos do conteúdo energético, da concentração e da distribuição espacial do perfil, mas não definem o vetor específico de 20 componentes utilizado nesta tese.

O vetor empregado na Etapa III constitui uma construção determinística da arquitetura avaliada e reúne quatro classes de informação: conteúdo energético regional; concentração relativa entre regiões; conteúdo energético das amostragens EM1, EM2 e EM3 e suas contribuições relativas à região EM; e momentos posicionais ponderados dentro de PS, EM e HAD. A composição exata desses descritores pertence, portanto, ao protocolo arquitetural desta tese (SILVA; SIMAS FILHO, 2026).

Dessa forma, seja a região $q \in \{\mathrm{PS}, \mathrm{EM}, \mathrm{HAD}\}$, define-se a soma regional como

$$S_q^{(i)} = \sum_{j \in q} \widetilde{E}_{r,j}^{(i)}, \tag{4.134}$$

e, a soma total, como o somatório das somas regionais,

$$S_{\mathrm{tot}}^{(i)} = S_{\mathrm{PS}}^{(i)} + S_{\mathrm{EM}}^{(i)} + S_{\mathrm{HAD}}^{(i)}. \tag{4.135}$$

Também, as três frações regionais em q são definidas pela equação

$$\mathrm{Frac}_q^{(i)} = \frac{S_q^{(i)}}{S_{\mathrm{tot}}^{(i)}}. \tag{4.136}$$

Duas razões entre respostas regionais são também construídas,

$$R_{\mathrm{HAD/EM}}^{(i)} = \frac{S_{\mathrm{HAD}}^{(i)}}{S_{\mathrm{EM}}^{(i)}}, \tag{4.137}$$

e

$$R_{\mathrm{PS/EM}}^{(i)} = \frac{S_{\mathrm{PS}}^{(i)}}{S_{\mathrm{EM}}^{(i)}}. \tag{4.138}$$

Além das somas completas por região q, a implementação utiliza três janelas fixas dentro do bloco EM,

$$S_{\mathrm{EM1}}^{(i)} = \sum_{j=9}^{72} \widetilde{E}_{r,j}^{(i)}, \tag{4.139}$$

$$S_{\mathrm{EM2}}^{(i)} = \sum_{j=73}^{80} \widetilde{E}_{r,j}^{(i)}, \tag{4.140}$$

e

$$S_{\mathrm{EM3}}^{(i)} = \sum_{j=81}^{88} \widetilde{E}_{r,j}^{(i)}. \tag{4.141}$$

Os termos EM1, EM2 e EM3 correspondem às amostragens físicas da organização Ringer adotada nesta tese (PINTO; ATLAS Collaboration, 2016).

São também incluídas as respectivas razões em relação à soma da região EM,

$$\begin{aligned} R_{\mathrm{EM1/EM}}^{(i)} &= \frac{S_{\mathrm{EM1}}^{(i)}}{S_{\mathrm{EM}}^{(i)}}, \\ R_{\mathrm{EM2/EM}}^{(i)} &= \frac{S_{\mathrm{EM2}}^{(i)}}{S_{\mathrm{EM}}^{(i)}}, \\ R_{\mathrm{EM3/EM}}^{(i)} &= \frac{S_{\mathrm{EM3}}^{(i)}}{S_{\mathrm{EM}}^{(i)}}. \end{aligned} \tag{4.142}$$

A implementação acrescenta ainda seis descritores posicionais ponderados, calculados separadamente para PS, EM e HAD. O uso de primeiros e segundos momentos ponderados pela resposta calorimétrica possui precedente na caracterização da posição e da dispersão de depósitos calorimétricos (ATLAS Collaboration, 2019a; ATLAS Collaboration, 2017). Nesta tese, esse princípio é adaptado à representação Ringer: os pesos são obtidos pela transformação min–max dos valores dos anéis e os momentos são calculados sobre sua coordenada ordinal, não sobre uma distância geométrica física no detector.

Então, seja $p_{q,j} \in [0,1]$ a coordenada local normalizada do j-ésimo anel dentro da região q, com n_q anéis,

$$p_{q,j} = \frac{j-1}{n_q - 1}, \qquad j = 1, \ldots, n_q \tag{4.143}$$

em que o índice j é local à região q. Assim, $\widetilde{E}_{r,j}^{(i)}$ deve ser entendido como o valor do j-ésimo anel da respectiva região, após o particionamento PS–EM–HAD, e não como o índice global na sequência dos 100 anéis. Essa coordenada é exatamente a mesma coordenada ordinal utilizada como $p_{v,\mathrm{local}}$ no ramo gráfico para o nó v correspondente. Sua reutilização no ramo tabular apenas permite construir momentos resumidos do mesmo perfil ordenado.

Seja ainda,

$$w_{q,j}^{(i)} = \frac{\widetilde{E}_{r,j}^{(i)} - \min(\widetilde{\mathbf{E}}_{\mathbf{r,j}})}{\max(\widetilde{\mathbf{E}}_{\mathbf{r,j}}) - \min(\widetilde{\mathbf{E}}_{\mathbf{r,j}})}, \tag{4.144}$$

em que os valores mínimo e máximo correspondem ao anel j na amostra utilizada para estimar essa transformação. Com esses pesos, define-se a média posicional ponderada,

$$\overline{p}_q^{(i)} = \frac{\displaystyle\sum_{j=1}^{n_q} w_{q,j}^{(i)} p_{q,j}}{\displaystyle\sum_{j=1}^{n_q} w_{q,j}^{(i)}}, \tag{4.145}$$

com desvio-padrão posicional,

$$\sigma_{p,q}^{(i)} = \sqrt{\frac{\sum_{j=1}^{n_q} w_{q,j}^{(i)} \left(p_{q,j} - \overline{p}_q^{(i)}\right)^2}{\sum_{j=1}^{n_q} w_{q,j}^{(i)}}}. \tag{4.146}$$

A transformação min–max é utilizada exclusivamente na construção desses pesos posicionais, mapeando para o intervalo $[0, 1]$ os valores contidos na faixa utilizada para estimar a transformação.

Com essas definições, o vetor de 20 descritores utilizado pela arquitetura é

$$\begin{aligned}\mathbf{d}^{(i)} = \Big[& S_{\mathrm{PS}}^{(i)}, S_{\mathrm{EM}}^{(i)}, S_{\mathrm{HAD}}^{(i)}, \mathrm{Frac}_{\mathrm{PS}}^{(i)}, \mathrm{Frac}_{\mathrm{EM}}^{(i)}, \mathrm{Frac}_{\mathrm{HAD}}^{(i)}, R_{\mathrm{HAD/EM}}^{(i)}, R_{\mathrm{PS/EM}}^{(i)}, \\ & S_{\mathrm{EM1}}^{(i)}, S_{\mathrm{EM2}}^{(i)}, S_{\mathrm{EM3}}^{(i)}, R_{\mathrm{EM1/EM}}^{(i)}, R_{\mathrm{EM2/EM}}^{(i)}, R_{\mathrm{EM3/EM}}^{(i)}, \\ & \overline{p}_{\mathrm{PS}}^{(i)}, \overline{p}_{\mathrm{EM}}^{(i)}, \overline{p}_{\mathrm{HAD}}^{(i)}, \sigma_{p,\mathrm{PS}}^{(i)}, \sigma_{p,\mathrm{EM}}^{(i)}, \sigma_{p,\mathrm{HAD}}^{(i)} \Big]^T \in \mathbb{R}^{20},\end{aligned} \tag{4.147}$$

Esses descritores são funções determinísticas dos mesmos 100 anéis. Portanto, não constituem novas observações nem alteram a dimensionalidade externa adotada para comparação entre modelos; para essa arquitetura, permanece $F = 100$. Sua inclusão torna explicitamente disponíveis ao ramo tabular relações simples derivadas do perfil dos anéis, em vez de exigir que essas quantidades sejam reconstruídas exclusivamente pelas transformações internas da rede.

Com essas considerações, o ramo tabular cria inicialmente uma representação da informação dos 100 anéis expandida pela concatenação dos 20 descritores determinísticos produzidos,

$$\mathbf{x}_{\mathrm{tab}}^{(i)} = \left[\mathbf{x}_{\mathrm{full}}^{(i)} \| \mathbf{d}^{(i)}\right] \in \mathbb{R}^{120}. \tag{4.148}$$

4.4.4 Fusão relacional–tabular e treinamento

A Figura 14 fornece uma visão global da sequência formalizada nesta subseção. O ramo tabular transforma $\mathbf{x}_{\mathrm{tab}}^{(i)}$ na representação latente $\mathbf{t}^{(i)}$ e produz duas contribuições escalares, $\alpha_{\mathrm{tab}}^{(i)}$ e $\alpha_{\mathrm{lin}}^{(i)}$. Em paralelo, o *embedding* gráfico $\mathbf{g}^{(i)}$ é escalado pelo parâmetro treinável s_{g} e combinado com $\mathbf{t}^{(i)}$ no estágio de fusão, que produz $\alpha_{\mathrm{fus}}^{(i)}$. A soma dessas três contribuições determina a saída $\alpha_{\mathrm{calib}}^{(i)}$. As equações seguintes especificam cada uma dessas transformações.

O ramo tabular recebe a representação $\mathbf{x}_{\mathrm{tab}}^{(i)} \in \mathbb{R}^{120}$ definida na Eq. 4.148. Seu primeiro estágio realiza três transformações densas sucessivas. A primeira expande a representação de 120 para 256 componentes,

$$\mathbf{h}_{\mathrm{tab},1}^{(i)} = \mathrm{LayerNorm}\left[\mathrm{GELU}\left(\mathbf{W}_{\mathrm{tab},1}\mathbf{x}_{\mathrm{tab}}^{(i)} + \mathbf{b}_{\mathrm{tab},1}\right)\right] \in \mathbb{R}^{256}. \tag{4.149}$$

A segunda transformação preserva a dimensão 256,

$$\mathbf{h}_{\mathrm{tab},2}^{(i)} = \mathrm{LayerNorm}\left[\mathrm{GELU}\left(\mathbf{W}_{\mathrm{tab},2}\mathbf{h}_{\mathrm{tab},1}^{(i)} + \mathbf{b}_{\mathrm{tab},2}\right)\right] \in \mathbb{R}^{256}, \tag{4.150}$$

e a terceira produz a representação tabular final que será utilizada posteriormente na fusão,

$$\mathbf{t}^{(i)} = \mathrm{GELU}\left(\mathbf{W}_{\mathrm{tab},3}\mathbf{h}_{\mathrm{tab},2}^{(i)} + \mathbf{b}_{\mathrm{tab},3}\right) \in \mathbb{R}^{256}. \tag{4.151}$$

As três transformações densas constituem a profundidade selecionada para o ramo tabular desta arquitetura. A primeira projeta a entrada de 120 componentes para o espaço latente de dimensão 256; a segunda acrescenta uma nova transformação não linear mantendo essa largura; e a terceira produz $\mathbf{t}^{(i)}$, representação compartilhada posteriormente pela saída tabular e pelo estágio de fusão. O uso de três transformações, assim como suas larguras, constitui uma escolha arquitetural e não uma necessidade imposta pela literatura. As equações acima representam as transformações determinísticas do ramo; durante o treinamento, *dropout* é aplicado às saídas das duas primeiras normalizações de camada antes de sua propagação para a transformação seguinte.

A partir de $\mathbf{t}^{(i)}$, o ramo tabular não linear reduz inicialmente a representação para 128 componentes,

$$\mathbf{r}_{\text{tab}}^{(i)} = \text{GELU}\left(\mathbf{W}_{\text{tab},4}\mathbf{t}^{(i)} + \mathbf{b}_{\text{tab},4}\right) \in \mathbb{R}^{128}. \tag{4.152}$$

Uma transformação linear final reduz então essa representação a um escalar, produzindo a contribuição do ramo tabular não linear,

$$\alpha_{\text{tab}}^{(i)} = \mathbf{W}_{\text{tab},5}\mathbf{r}_{\text{tab}}^{(i)} + b_{\text{tab},5} \in \mathbb{R}. \tag{4.153}$$

Em paralelo, um caminho puramente linear conecta diretamente a entrada tabular à saída,

$$\alpha_{\text{lin}}^{(i)} = \mathbf{W}_{\text{lin}}\mathbf{x}_{\text{tab}}^{(i)} + b_{\text{lin}} \in \mathbb{R}. \tag{4.154}$$

Esse caminho corresponde a uma camada linear treinada conjuntamente com o restante da arquitetura. Ele não constitui uma regressão linear ajustada separadamente. Sua função é fornecer uma rota direta entre a representação tabular e a saída, em analogia ao princípio geral de caminhos de menor profundidade utilizado em arquiteturas com conexões de atalho (HE et al., 2016).

Nessas transformações, $\mathbf{W}_{\text{tab},1} \in \mathbb{R}^{256\times120}$, $\mathbf{W}_{\text{tab},2}, \mathbf{W}_{\text{tab},3} \in \mathbb{R}^{256\times256}$, $\mathbf{W}_{\text{tab},4} \in \mathbb{R}^{128\times256}$, $\mathbf{W}_{\text{tab},5} \in \mathbb{R}^{1\times128}$ e $\mathbf{W}_{\text{lin}} \in \mathbb{R}^{1\times120}$. Analogamente, $\mathbf{b}_{\text{tab},1}, \mathbf{b}_{\text{tab},2}, \mathbf{b}_{\text{tab},3} \in \mathbb{R}^{256}$, $\mathbf{b}_{\text{tab},4} \in \mathbb{R}^{128}$, $b_{\text{tab},5} \in \mathbb{R}$ e $b_{\text{lin}} \in \mathbb{R}$. Todos esses pesos e vieses são parâmetros treináveis ajustados conjuntamente com os demais parâmetros da arquitetura.

O ramo gráfico, por sua vez, produz $\mathbf{g}^{(i)} \in \mathbb{R}^{768}$, conforme a Eq. 4.133. Antes da fusão, essa representação é multiplicada por um escalar treinável s_{g},

$$\widetilde{\mathbf{g}}^{(i)} = s_{\text{g}}\mathbf{g}^{(i)}, \qquad s_{\text{g}}^{(0)} = 0{,}05. \tag{4.155}$$

A inicialização com $s_{\text{g}}^{(0)} = 0{,}05$ fornece ao ramo gráfico uma escala multiplicativa inicial pequena antes da fusão, enquanto o valor de s_{g} permanece livre para ser ajustado juntamente com os demais parâmetros da rede. O valor 0,05 é um hiperparâmetro de inicialização e não deve ser interpretado como uma contribuição física de 5% do ramo gráfico para a previsão final.

A entrada do estágio de fusão é construída pela concatenação entre a representação gráfica escalada e a representação tabular da Eq. 4.151, produzindo um vetor com 1024 componentes,

$$\mathbf{u}^{(i)} = \left[\widetilde{\mathbf{g}}^{(i)} \| \mathbf{t}^{(i)}\right] \in \mathbb{R}^{1024}. \tag{4.156}$$

O primeiro bloco da fusão reduz essa representação de 1024 para 256 componentes,

$$\mathbf{h}_{\text{fus},1}^{(i)} = \text{LayerNorm}\left[\text{GELU}\left(\mathbf{W}_{\text{fus},1}\mathbf{u}^{(i)} + \mathbf{b}_{\text{fus},1}\right)\right] \in \mathbb{R}^{256}. \tag{4.157}$$

A equação acima representa a transformação determinística desse bloco; durante o treinamento, *dropout* é aplicado a $\mathbf{h}_{\text{fus},1}^{(i)}$ antes da transformação seguinte. Em seguida, a dimensão é reduzida para 128,

$$\mathbf{h}_{\text{fus},2}^{(i)} = \text{GELU}\left(\mathbf{W}_{\text{fus},2}\mathbf{h}_{\text{fus},1}^{(i)} + \mathbf{b}_{\text{fus},2}\right) \in \mathbb{R}^{128}, \tag{4.158}$$

e uma última transformação linear produz a contribuição escalar do estágio de fusão,

$$\alpha_{\text{fus}}^{(i)} = \mathbf{W}_{\text{fus},3}\mathbf{h}_{\text{fus},2}^{(i)} + b_{\text{fus},3} \in \mathbb{R}. \tag{4.159}$$

Nessas transformações: $\mathbf{W}_{\text{fus},1} \in \mathbb{R}^{256\times1024}$, $\mathbf{W}_{\text{fus},2} \in \mathbb{R}^{128\times256}$ e $\mathbf{W}_{\text{fus},3} \in \mathbb{R}^{1\times128}$; $\mathbf{b}_{\text{fus},1} \in \mathbb{R}^{256}$, $\mathbf{b}_{\text{fus},2} \in \mathbb{R}^{128}$ e $b_{\text{fus},3} \in \mathbb{R}$. Esses também são parâmetros que serão aprendidos no treinamento neural.

Embora a notação α_{lin}, α_{tab} e α_{fus} seja utilizada para identificar as três contribuições escalares internas, essas parcelas não são interpretadas individualmente como estimativas físicas independentes do fator de calibração. Em cada propagação direta, sua soma define a saída escalar da arquitetura,

$$\alpha_{\text{calib}}^{(i)} = \alpha_{\text{lin}}^{(i)} + \alpha_{\text{tab}}^{(i)} + \alpha_{\text{fus}}^{(i)}. \tag{4.160}$$

Essa composição implementa a fusão entre um caminho tabular direto e linear, um ramo tabular não linear e um ramo relacional–tabular. O princípio geral de combinação de representações possui precedente em métodos de fusão de informação (CASTANEDO, 2013; MENG et al., 2020; CHEN et al., 2023), enquanto a disposição específica das camadas, dimensões e caminhos constitui a realização arquitetural avaliada nesta tese (SILVA; SIMAS FILHO, 2026).

O alvo supervisionado do treinamento é diretamente $\alpha_{\text{true}}^{(i)}$. A função objetivo da arquitetura avaliada combina o erro quadrático médio com a perda *Smooth L1*, cuja forma quadrática–linear está relacionada à família de perdas robustas de Huber e foi posteriormente empregada em treinamento de redes neurais para regressão (HUBER, 1964; GIRSHICK, 2015; SILVA; SIMAS FILHO, 2026),

$$\mathcal{L} = \lambda_{\text{MSE}}\mathcal{L}_{\text{MSE}} + (1 - \lambda_{\text{MSE}})\,\mathcal{L}_{\text{SL1}}, \tag{4.161}$$

com

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N}\sum_{i=1}^{N}\left(e^{(i)}\right)^2, \qquad e^{(i)} = \alpha_{\text{true}}^{(i)} - \alpha_{\text{calib}}^{(i)}. \tag{4.162}$$

A componente *Smooth L1* empregada pela implementação pode ser escrita como

$$\ell_{\text{SL1}}\left(e;\beta\right) = \begin{cases} \dfrac{e^2}{2\beta}, & |e| < \beta, \\ |e| - \dfrac{\beta}{2}, & |e| \geq \beta, \end{cases} \tag{4.163}$$

e

$$\mathcal{L}_{\text{SL1}} = \frac{1}{N}\sum_{i=1}^{N}\ell_{\text{SL1}}\left(e^{(i)};\beta\right). \tag{4.164}$$

O hiperparâmetro $\lambda_{\mathrm{MSE}} \in [0,1]$ controla a contribuição relativa das duas parcelas: $\lambda_{\mathrm{MSE}} = 1$ recupera o MSE puro, enquanto $\lambda_{\mathrm{MSE}} = 0$ mantém somente a componente *Smooth L1*. O parâmetro $\beta > 0$ determina a transição interna da *Smooth L1*: valores maiores ampliam a região quadrática, enquanto valores menores fazem o regime linear ser alcançado para resíduos de menor magnitude. Os valores concretos de λ_{MSE} e β são hiperparâmetros do protocolo experimental e não constantes determinadas pelas referências bibliográficas. A componente *Smooth L1* apresenta comportamento quadrático para $|e| < \beta$ e crescimento linear para $|e| \geq \beta$, oferecendo uma componente menos sensível a grandes resíduos que o MSE puro. A função combinada, entretanto, permanece assintoticamente quadrática sempre que $\lambda_{\mathrm{MSE}} > 0$, pois o termo MSE continua presente.

Para consolidar o treinamento da arquitetura, denote-se por $\boldsymbol{\theta}$ o conjunto de todos os seus parâmetros treináveis, incluindo matrizes de pesos, vieses, parâmetros de LayerNorm e o escalar s_{g}. Para o estado corrente desses parâmetros, a propagação direta pode ser escrita como

$$\alpha_{\mathrm{calib}}^{(i)} = f_{\mathrm{GNN}}\left(\mathbf{x}_{\mathrm{full}}^{(i)}; \boldsymbol{\theta}\right). \tag{4.165}$$

O ajuste de $\boldsymbol{\theta}$ utiliza o mesmo princípio de retropropagação apresentado na Seção 4.3.2, agora aplicado à função objetivo da Eq. 4.161. A particularidade desta arquitetura está no emprego do AdamW para atualização dos parâmetros,

$$\boldsymbol{\theta}_{t+1} = \mathrm{AdamW}\left(\boldsymbol{\theta}_t, \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\mathcal{B}_t}; \nu, \lambda_{\mathrm{wd}}\right), \tag{4.166}$$

em que ν é a taxa de aprendizado, λ_{wd} é o coeficiente de *weight decay* e $\mathcal{B}_t$ representa o mini-lote utilizado na iteração t. O AdamW mantém o mecanismo adaptativo do Adam, mas desacopla o *weight decay* da atualização determinada pelo gradiente da função objetivo (KINGMA; BA, 2015; LOSHCHILOV; HUTTER, 2017). Para métodos adaptativos, essa operação não é, em geral, equivalente a simplesmente acrescentar uma penalização L_2 à função de perda. O uso de AdamW constitui uma escolha de otimização desta arquitetura, não uma afirmação de superioridade universal sobre Adam.

Em cada execução de treinamento com *early stopping*, uma fração dos dados disponíveis para aquele ajuste é reservada como validação interna. Ao final de cada época, a função de perda é avaliada nessa fração e os parâmetros correspondentes ao melhor valor observado são preservados. O treinamento é interrompido quando a melhoria deixa de superar o critério estabelecido durante o número de épocas definido pela paciência do método. Essa validação interna é utilizada apenas para controlar o treinamento dos pesos e não corresponde ao conjunto independente de teste (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

Ao término do treinamento, seja $\boldsymbol{\theta}^{\star}$ o conjunto de parâmetros retido. Durante a inferência, não ocorre retropropagação e o fator de calibração é obtido diretamente por

$$\alpha_{\mathrm{calib}}^{(i)} = f_{\mathrm{GNN}}\left(\mathbf{x}_{\mathrm{full}}^{(i)}; \boldsymbol{\theta}^{\star}\right). \tag{4.167}$$

Finalmente,

$$E_{\mathrm{calib}}^{(i)} = \alpha_{\mathrm{calib}}^{(i)} E_{\mathrm{fast}}^{(i)}, \tag{4.168}$$

em concordância com a formulação geral da calibração estabelecida na Eq. 3.1.

A arquitetura descrita pela Eq. 4.160 e sintetizada na Figura 14 deve, portanto, ser interpretada como um modelo completo de "fusão relacional–tabular". O ramo gráfico modela relações locais dentro de PS, EM e HAD; o ramo tabular preserva a informação completa e os descritores derivados; o caminho linear fornece uma rota direta; e o estágio de fusão combina representações relacionais e globais (CASTANEDO, 2013; MENG et al., 2020; CHEN et al., 2023).

Essa composição constitui a contribuição arquitetural original da tese (SILVA; SIMAS FILHO, 2026). A originalidade não está individualmente no GraphSAGE, no *pooling*, na GELU, nos descritores ou nas camadas densas. Ela reside na integração *detector-informed* desses elementos para a representação Ringer: separação regional PS–EM–HAD, grafos locais independentes, codificação posicional e regional dos nós, propagação GraphSAGE, agregação média–máximo, descritores globais, regionais e posicionais derivados dos próprios anéis, ramo tabular completo, caminhos de atalho, controle treinável da contribuição gráfica e fusão final para estimação do fator de calibração.

Embora GNNs tenham sido investigadas em aplicações de reconstrução e *trigger* em Física de Altas Energias (DEZOORT et al., 2023; JU et al., 2020), a utilização de propagação local e compartilhamento de parâmetros não garante, por si só, baixa latência operacional. O custo da arquitetura proposta inclui os três blocos gráficos regionais, cada um com duas camadas GraphSAGE, os *poolings*, o ramo tabular e a rede de fusão. A interpretação dos tempos medidos segue as limitações estabelecidas na Seção 4.6.

4.5 Fusão de informação na cadeia de calibração

A arquitetura relacional–tabular da Seção 4.4 constitui a realização mais explícita de fusão no nível do regressor. Em uma perspectiva mais ampla, entretanto, a noção de fusão de informação fornece uma interpretação unificada para os diferentes estágios da cadeia investigada nesta tese. Em sistemas de fusão, informações disponíveis em diferentes representações ou níveis de processamento podem ser combinadas de modo a produzir uma representação, estimativa ou decisão mais informativa (CASTANEDO, 2013; MENG et al., 2020). No problema calorimétrico considerado, essa ideia não corresponde a uma fusão multimodal convencional entre fontes como imagem e texto; a informação é progressivamente agregada e transformada ao longo da própria cadeia de medição e estimação.

O primeiro nível ocorre antes dos regressores discutidos neste capítulo: energias de células calorimétricas são agregadas em anéis segundo a organização definida pela representação Ringer (PINTO; ATLAS Collaboration, 2016). O segundo nível corresponde à representação fornecida ao regressor: os 100 anéis podem ser preservados ou transformados em subconjuntos selecionados ou componentes latentes. O terceiro nível ocorre no próprio regressor, que combina essas características para estimar um único fator por evento. Nas arquiteturas neurais, essa combinação pode ser não linear; na GNN proposta, inclui adicionalmente relações locais explicitamente codificadas e a fusão entre os ramos relacional e tabular. Finalmente, o fator escalar estimado é combinado

com E_{fast} por meio da correção multiplicativa definida na Eq. 3.1.

Essa interpretação evita duas conclusões incorretas. Primeiro, os 100 anéis não representam 100 sensores independentes, mas descritores obtidos pela agregação de muitas células calorimétricas (PINTO; ATLAS Collaboration, 2016). Segundo, uma GNN não "recupera" automaticamente a geometria completa do detector: ela processa somente as relações explicitamente introduzidas na representação e no conjunto de arestas (BATTAGLIA et al., 2018; SILVA; SIMAS FILHO, 2026). A utilidade do viés indutivo relacional depende, portanto, da adequação entre a estrutura codificada e o fenômeno que se pretende modelar.

4.6 Complexidade, generalização e custo computacional

A seleção de um método para calibração rápida não pode ser baseada apenas na capacidade de ajuste. Do ponto de vista de Engenharia Elétrica e de Computação, pelo menos três dimensões precisam ser distinguidas: complexidade estatística, complexidade computacional de treinamento e custo de inferência.

A complexidade estatística está relacionada à flexibilidade da classe de funções. Modelos mais flexíveis podem reduzir viés de aproximação, mas exigem dados e regularização suficientes para controlar variância e sobreajuste (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016). Uma rede com grande número de parâmetros não é inadequada apenas por ser grande, assim como uma árvore pequena não é automaticamente segura; o ponto relevante é se o procedimento de seleção produz desempenho estável em dados independentes. Por essa razão, comparação de modelos deve ser acompanhada por validação apropriada e por estimativas de variabilidade.

O custo de treinamento inclui ajuste de parâmetros, busca de hiperparâmetros, transformações de entrada, reamostragem e validação cruzada. Esse custo influencia a viabilidade de atualizar ou reproduzir o modelo, mas ocorre *offline* no cenário considerado. O custo de inferência corresponde ao processamento necessário após o modelo estar treinado e após a representação de entrada estar disponível. Essa separação é especialmente importante para PCA, ICA, seleção supervisionada e redes neurais: operações realizadas exclusivamente para ajustar o modelo não pertencem à latência online.

Mesmo para a inferência, um tempo medido em CPU de propósito geral deve ser interpretado como um *benchmark* relativo da implementação testada. Ele não inclui necessariamente leitura do detector, transferência de dados, construção completa das características, escalonamento no ambiente de *trigger*, concorrência entre eventos, inicialização de modelos ou comportamento de pior caso. Portanto, valores de tempo obtidos nos experimentos desta tese são usados para comparar modelos no mesmo ambiente computacional e para motivar estudos posteriores de implantação, não para declarar atendimento automático aos requisitos de uma cadeia HLT real.

A dimensionalidade F é outra medida de complexidade relevante. Reduzir F pode diminuir armazenamento, tráfego de memória e número de operações em determinados modelos, mas não existe relação monotônica universal entre número de entradas e latência. Uma representação de cinco componentes que exija uma transformação custosa pode, em determinada implementação,

não ser mais rápida que um seletor direto de dez anéis. Por isso, número de características e tempo de inferência são avaliados como grandezas distintas.

Complexidade e custo, entretanto, não esgotam os requisitos relevantes para um calibrador destinado a um ambiente experimental. Também é necessário caracterizar sua estabilidade diante de perturbações e possíveis mudanças na distribuição dos dados, aspecto discutido na seção seguinte.

4.7 Robustez a ruído, *pile-up* e efeitos instrumentais

Nenhuma das famílias de ML apresentadas neste capítulo possui, por construção, garantia geral de robustez a ruído eletrônico, *pile-up*, vazamento de energia ou mudanças da resposta do detector. Afirmações genéricas do tipo "PCA remove ruído", "Random Forest é robusta a *pile-up*" ou "redes neurais corrigem não linearidades" somente são válidas sob hipóteses adicionais e precisam ser verificadas no domínio de dados relevante (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016).

Se a distribuição operacional das entradas e do alvo difere daquela utilizada para o desenvolvimento do modelo, a minimização do risco empírico em treinamento não garante, por si só, desempenho equivalente no novo regime. Em termos gerais,

$$p_{\text{op}}\left(\mathbf{x}, \alpha_{\text{true}}\right) \neq p_{\text{train}}\left(\mathbf{x}, \alpha_{\text{true}}\right) \tag{4.169}$$

caracteriza uma mudança de distribuição potencialmente capaz de alterar o erro de generalização do calibrador (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016).

A redução de dimensionalidade pode eliminar direções pouco informativas e, em determinadas condições, reduzir sensibilidade a algumas flutuações; ensembles podem reduzir variância; e redes neurais podem representar dependências não lineares (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016). Essas propriedades estatísticas, entretanto, não equivalem a imunidade aos mecanismos físicos discutidos no Capítulo 2. Robustez a μ, a diferentes regiões de η, a intervalos de E_T ou a alterações do ruído deve ser avaliada por amostras controladas ou análises estratificadas.

Essa perspectiva orienta a metodologia dos capítulos seguintes. O desempenho global é complementado por análise regional e por métricas de resolução; a presença de *pile-up* na amostra é distinguida de uma varredura controlada em μ; e resultados obtidos no Lorenzetti não são extrapolados automaticamente para dados experimentais. Quando determinada perturbação não é variada de forma controlada, ela é tratada como limitação do domínio de validade, e não como problema implicitamente resolvido pelo algoritmo.

4.8 Síntese das famílias de modelos

A Tabela 3 resume as principais propriedades das famílias utilizadas na tese. O objetivo não é estabelecer um ranking teórico, mas explicitar os diferentes mecanismos que motivam a comparação experimental.

Tabela 3 – Síntese das famílias de regressão utilizadas na tese e dos principais vieses indutivos relevantes para o problema de calibração.

Família	**Mecanismo principal**	**Vantagem metodológica**	**Limitação principal**
MLR	Mapeamento linear global	Baixa complexidade e alta interpretabilidade	Não representa diretamente interações não lineares
PReg	Expansão polinomial explícita	Introduz não linearidade mantendo ajuste linear nos coeficientes	Crescimento combinatório do espaço de características
DTree	Partição recursiva do espaço	Modela interações e não linearidades locais	Alta variância quando pouco regularizada
BDT	Ensemble aditivo sequencial	Refina resíduos/gradientes e é forte em dados tabulares	Sensível à regularização e ao número de iterações
RF	Média de árvores diversificadas	Reduz variância de árvores individuais	Pode exigir muitas árvores e memória
Híbridos	Correção residual ou empilhamento	Exploram complementaridade entre famílias	Maior complexidade de treinamento e risco de vazamento se mal particionado
DNN	Composição de transformações não lineares	Fusão global e flexível de características	Maior capacidade exige controle de generalização
GNN	Propagação de mensagens sobre relações explícitas	Introduz viés indutivo relacional associado à estrutura dos anéis	Desempenho depende da topologia e da arquitetura escolhidas

A progressão experimental da tese pode, assim, ser interpretada como uma ampliação progressiva das hipóteses de representação e regressão avaliadas. MLR e PReg testam formas funcionais globais simples; árvores e ensembles introduzem partições adaptativas e mecanismos de agregação; os modelos híbridos investigam estrutura residual complementar; DNNs realizam fusão não linear global; e a GNN acrescenta relações locais explicitamente codificadas e fusão relacional–tabular. Em paralelo, CORR, MUTI, PCA e ICA alteram a quantidade e a natureza da informação apresentada aos regressores.

4.9 Conclusão do capítulo

Este capítulo apresentou as famílias de modelos utilizadas para implementar $f_{\mathrm{ML}}(\cdot)$ sobre as representações definidas no Capítulo 3. MLR e regressão polinomial fornecem referências de baixa e intermediária complexidade funcional; árvores de decisão, BDTs e *Random Forests* introduzem partições adaptativas e estratégias de ensemble; e as composições residuais e empilhadas investigam complementaridade entre diferentes regressores.

As DNNs ampliam essa investigação para a fusão não linear global das características. A arquitetura GNN relacional–tabular, proposta na Etapa III, acrescenta um viés indutivo relacional orientado pela organização da representação Ringer e combina processamento em grafo com informação tabular. Sua originalidade reside na composição *detector-informed* desses mecanismos para o problema estudado, e não na proposição de um novo operador genérico de GNN (SILVA; SIMAS FILHO, 2026).

A comparação entre essas famílias deve considerar conjuntamente capacidade estatística, generalização e custo computacional. Da mesma forma, propriedades como robustez a ruído, *pile-up* ou alterações da resposta do sistema não decorrem automaticamente da escolha do regressor e precisam ser avaliadas empiricamente no domínio de aplicação.

Com a formulação do problema e as representações estabelecidas no Capítulo 3 e as famílias de regressão definidas neste capítulo, o Capítulo 5 especifica o desenho experimental que combina $g_{\mathrm{ML}}(\cdot)$ e $f_{\mathrm{ML}}(\cdot)$ nas três etapas da pesquisa.

5 Metodologia Experimental Unificada para Calibração Calorimétrica

Este capítulo apresenta o desenho experimental que integra as três etapas de investigação desenvolvidas nesta tese. O objetivo é separar, de forma explícita, o que permanece comum a todos os estudos — ambiente de simulação, modelagem calorimétrica no Lorenzetti, definição da correção multiplicativa e referência de comparação — daquilo que evoluiu ao longo da pesquisa, como as representações de entrada, as famílias de regressores, a estratégia de segmentação, o procedimento de seleção de hiperparâmetros e o conjunto de métricas de avaliação.

Essa distinção é necessária porque os resultados apresentados nos Capítulos 6, 7 e 8 não foram obtidos sob protocolos historicamente idênticos. O primeiro estudo estabeleceu a viabilidade da calibração baseada em anéis e investigou, entre outros aspectos, treinamento global e treinamento segmentado. Os estudos posteriores mantiveram o mesmo *benchmark* físico, mas adotaram treinamento global, representações de cardinalidade controlada, validação cruzada aninhada dentro da partição de desenvolvimento e uma avaliação mais ampla, orientada à ciência da medição (SILVA et al., 2026b; SILVA et al., 2026a). Portanto, "metodologia unificada" significa uma formulação científica comum com protocolos experimentais.

Do ponto de vista de Engenharia Elétrica e de Computação, o desenho experimental pode ser entendido como uma cadeia de estimação composta por quatro níveis: geração e reconstrução de sinais calorimétricos em um ambiente Monte Carlo; codificação do chuveiro por uma representação de 100 anéis; construção de uma representação completa ou compacta por $g_{\mathrm{ML}}(\cdot)$; e estimação, por $f_{\mathrm{ML}}(\cdot)$, de um fator multiplicativo aplicado à energia rápida de referência. A avaliação considera separadamente qualidade da estimativa, avaliação regional em segmentos de $|\eta|$ e E_{T}, resolução de energia, resposta próxima a limiares de seleção e custo computacional do modelo treinado.

5.1 Princípios do desenho experimental

A metodologia foi organizada segundo cinco princípios.

Primeiro, todas as famílias de modelos são comparadas, dentro de cada etapa experimental, sobre uma mesma interface de entrada e saída. A grandeza corrigida é a energia transversa rápida do objeto eletromagnético, e a saída do regressor é um fator multiplicativo por evento. Essa escolha permite comparar modelos com capacidades distintas sem alterar a definição física da tarefa.

Segundo, a referência denominada *Standard FastCalo* é tratada nesta tese como a estimativa rápida de energia transversa fornecida pela cadeia de reconstrução do *benchmark* Lorenzetti. Ela não representa toda a cadeia oficial de calibração de elétrons do experimento ATLAS e não deve ser interpretada como tal. A calibração de ML investigada aqui é aplicada

sobre essa estimativa de referência e não se propõe a substituir toda a calibração oficial do experimento.

Terceiro, a verdade de Monte Carlo é utilizada somente onde sua disponibilidade é metodologicamente legítima: definição do alvo supervisionado, ajuste de transformações supervisionadas dentro dos dados de treinamento e avaliação quantitativa. Em particular, E_{true} e α_{true} não são entradas de inferência.

Quarto, a partição independente de teste é preservada para avaliação final nas etapas experimentais. Transformações de dados, seleção de características, extração de componentes e seleção de hiperparâmetros são determinadas sem utilizar essa partição. Esse princípio evita vazamento de informação e separa seleção de modelo de estimativa de generalização (CAWLEY; TALBOT, 2010).

Quinto, nenhuma medida isolada é tratada como evidência suficiente de superioridade. RMSE, IQR, resolução relativa, estabilidade em $(|\eta|, E_T)$, comportamento próximo a limiares, análise estatística e custo de inferência respondem a perguntas diferentes. Métricas compostas são utilizadas apenas como instrumentos auxiliares de ordenação e não substituem a apresentação das grandezas físicas e computacionais que as compõem.

Em termos operacionais, cada etapa experimental segue a mesma cadeia de alto nível. Os eventos são produzidos e reconstruídos no ambiente Lorenzetti; a informação calorimétrica é codificada na representação Ringer; o conjunto é separado entre desenvolvimento e teste independente; a representação $g_{\text{ML}}(\cdot)$ é definida utilizando somente os dados permitidos para desenvolvimento; o regressor $f_{\text{ML}}(\cdot)$ é treinado e selecionado segundo o protocolo específico da etapa; e a configuração resultante é aplicada ao conjunto independente para obtenção das métricas de avaliação. As diferenças históricas entre as três etapas, particularmente quanto às representações, aos regressores, à segmentação e ao procedimento de seleção de modelos, são explicitadas na Seção 5.6.

A Figura 15 sintetiza essa cadeia em sua ordem operacional, destacando a função principal de cada etapa, suas entradas e suas saídas. Os blocos constituem uma visão geral do processo experimental; as seções indicadas na própria figura apresentam a formalização e os detalhes metodológicos correspondentes.

5.2 Ambiente Monte Carlo e domínio experimental

5.2.1 *Benchmark* Lorenzetti

Os dados utilizados na sequência principal dos experimentos foram produzidos com o *Lorenzetti Showers Framework*, um ambiente aberto para geração de eventos, transporte de partículas, simulação de calorímetros segmentados, emulação de resposta eletrônica e reconstrução de observáveis calorimétricos (ARAÚJO et al., 2023; PINTO et al., 2022). O conjunto empregado nos estudos foi produzido com a versão 2.0.0 do Lorenzetti. Nessa distribuição, Pythia 8.3 e Geant4 11.2.2 integram o ambiente computacional encapsulado pelo framework; essas ferramentas não devem ser interpretadas como cadeias executadas independentemente do Lorenzetti neste

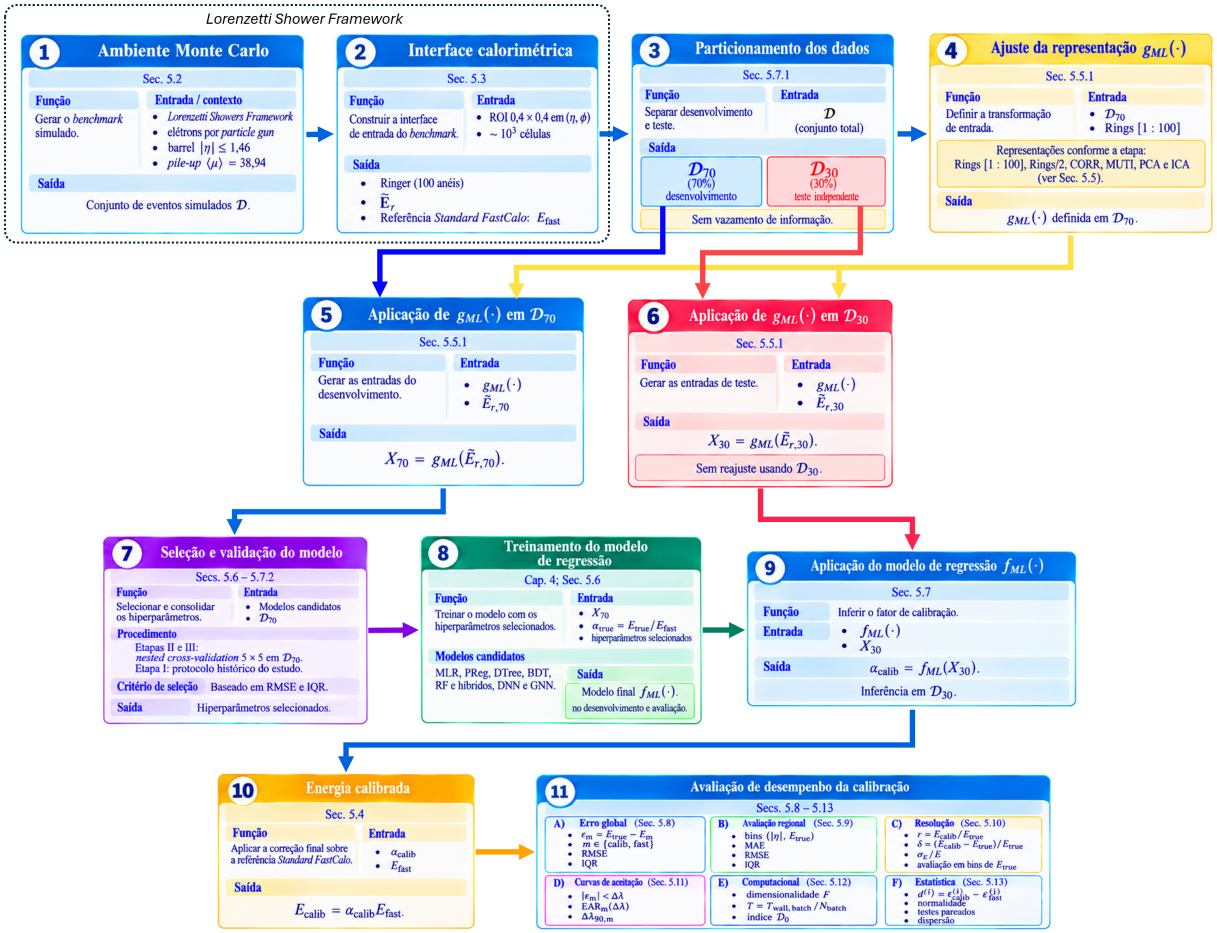


Figura 15 – Fluxo metodológico unificado da calibração calorimétrica. Os blocos seguem a ordem operacional do processo experimental e sintetizam a função principal, as entradas e as saídas de cada etapa. As referências de seção indicam onde cada componente é formalizado.

trabalho (SILVA et al., 2026b). A configuração de simulação foi mantida como referência física comum entre as etapas, evitando uma mudança deliberada do detector simulado. Ainda assim, os protocolos de processamento, seleção e avaliação evoluíram entre os estudos, por isso, diferenças de desempenho entre etapas não são interpretadas como uma ablação controlada exclusivamente das representações ou arquiteturas (SILVA et al., 2026b; SILVA et al., 2026a).

A configuração calorimétrica utilizada no *benchmark* foi definida a partir de características de geometria, materiais e segmentação do sistema calorimétrico do ATLAS, conforme documentado no trabalho original do Lorenzetti e em estudos posteriores que empregaram essa configuração (ARAÚJO et al., 2023; SIMAS FILHO et al., 2025; SILVA et al., 2026b; SILVA et al., 2026a). A Figura 16 apresenta uma vista transversal do calorímetro de amostragem implementado no ambiente de simulação, e a Tabela 4 resume sua cobertura em pseudorapidez, segmentação longitudinal e granularidade das células. A configuração inclui um pré-amostrador e três camadas longitudinais nos sistemas eletromagnético e hadrônico, com granularidade dependente da camada e da região em pseudorapidez.

O Lorenzetti constitui, nesta tese, um *benchmark* detector-inspirado. Ele não substitui a simulação oficial da Colaboração ATLAS, nem os resultados obtidos com essa configuração demonstram desempenho em dados reais do experimento. Essa delimitação é mantida em todo

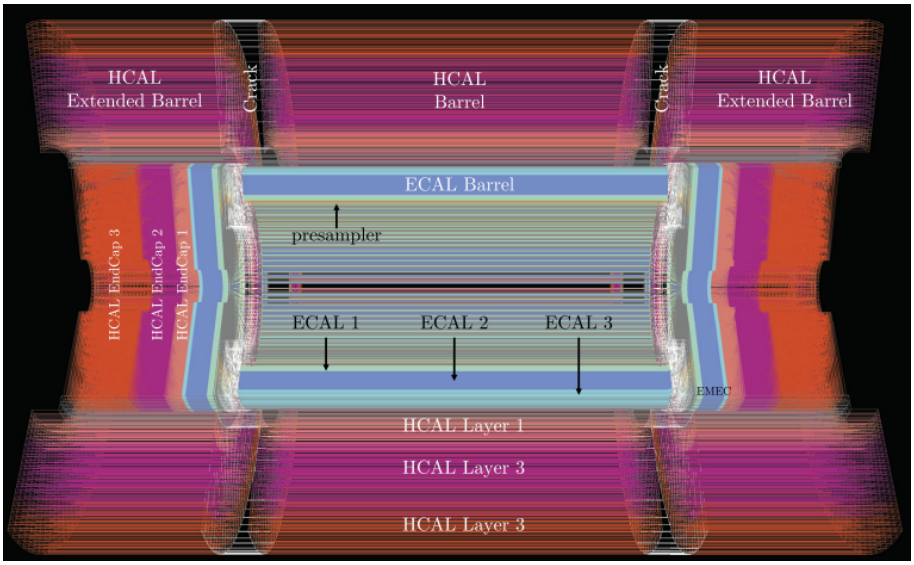


Figura 16 – Vista transversal do calorímetro de amostragem utilizado nas simulações com o *Lorenzetti Showers Framework*. A amostra de elétrons utilizada nesta tese foi restrita a $|\eta| \leq 1{,}46$, alcançando, no limite superior, a vizinhança da transição pelo lado do barril da geometria inspirada no ATLAS.

Fonte: (ARAÚJO et al., 2023).

Tabela 4 – Segmentação, cobertura em $|\eta|$ e granularidade das células da configuração calorimétrica utilizada no *benchmark* Lorenzetti.

Layer	Sampling	Coverage	Granularity ($\Delta\eta \times \Delta\phi$)
Presampler	Barrel	$0.00 < \|\eta\| < 1.58$	0.025×0.1
	End-Cap	$1.50 < \|\eta\| < 1.80$	0.025×0.1
Electromagnetic Calorimeter			
Layer 1	Barrel	$0.00 < \|\eta\| < 1.55$	0.003×0.1
		$1.37 < \|\eta\| < 1.80$	0.003×0.1
	End-Cap	$1.80 < \|\eta\| < 2.00$	0.025×0.1
		$2.00 < \|\eta\| < 2.37$	0.006×0.1
		$2.37 < \|\eta\| < 3.20$	0.1×0.1
Layer 2	Barrel	$0.00 < \|\eta\| < 1.50$	0.025×0.025
	End-Cap	$1.35 < \|\eta\| < 2.50$	0.025×0.025
		$2.50 < \|\eta\| < 3.20$	0.1×0.1
Layer 3	Barrel	$0.00 < \|\eta\| < 1.58$	0.05×0.1
	End-Cap	$1.35 < \|\eta\| < 2.50$	0.05×0.025
		$2.50 < \|\eta\| < 3.20$	0.1×0.1
Hadronic Calorimeter			
Layer 1	Barrel	$0.00 < \|\eta\| < 1.09$	0.1×0.1
	Extended Barrel	$0.94 < \|\eta\| < 1.77$	0.1×0.1
	End-Cap	$1.50 < \|\eta\| < 2.50$	0.1×0.1
		$2.50 < \|\eta\| < 3.20$	0.2×0.2
Layer 2	Barrel	$0.00 < \|\eta\| < 1.09$	0.1×0.1
	Extended Barrel	$0.85 < \|\eta\| < 1.41$	0.1×0.1
	End-Cap	$1.50 < \|\eta\| < 2.50$	0.1×0.1
		$2.50 < \|\eta\| < 3.20$	0.2×0.2
Layer 3	Barrel	$0.00 < \|\eta\| < 0.85$	0.2×0.1
	Extended Barrel	$0.85 < \|\eta\| < 1.41$	0.2×0.1
	End-Cap	$1.50 < \|\eta\| < 2.50$	0.1×0.1
		$2.50 < \|\eta\| < 3.20$	0.2×0.2

Fonte: (ARAÚJO et al., 2023).

o trabalho: as conclusões quantitativas referem-se ao domínio de simulação especificado nesta seção; generalização para simulação oficial, dados experimentais e software ou hardware de *trigger* requer validação própria.

A configuração empregada nos estudos corresponde à região de barril considerada na geração de elétrons individuais. Por essa razão, as análises regionais apresentadas posteriormente alcançam $|\eta| = 1{,}46$. A ausência do intervalo de maior pseudorapidez não representa uma omissão acidental de eventos pertencentes ao conjunto avaliado: trata-se de uma limitação deliberada do domínio do *benchmark*. Consequentemente, nenhuma conclusão desta tese sobre estabilidade em η é extrapolada para regiões de tampa não simuladas na amostra principal.

5.2.2 Amostra de elétrons e cobertura cinemática

A amostra principal contém aproximadamente 3×10^5 eventos reconstruídos de elétrons individuais gerados por uma configuração de *particle gun*. O procedimento injeta partículas com energia e direção previamente definidas no volume do detector simulado e permite cobrir uma região cinemática ampla, da ordem de poucos GeV até aproximadamente 500 GeV (SILVA et al., 2026b; SILVA et al., 2026a). O conjunto de dados utilizado nos estudos é disponibilizado publicamente (SILVA; SIMAS FILHO, 2025).

A utilização de elétrons individuais é uma escolha de desenho experimental. Ela permite isolar o mapeamento entre a informação calorimétrica do candidato e a correção de energia, sem condicionar o conjunto de treinamento à cinemática de um processo ressonante específico. Isso não torna amostras de $Z \to e^+e^-$ desnecessárias: elas constituem uma validação de nível físico distinta, adequada para avaliar posição e largura do pico de massa, caudas, eficiência de seleção e possíveis diferenças entre simulação e dados. Essa validação ressonante não foi incorporada ao *benchmark* principal e é tratada como extensão posterior.

Essa separação também evita uma ambiguidade estatística. Em uma futura amostra $Z \to e^+e^-$, os dois candidatos podem pertencer ao mesmo evento de colisão e, portanto, não devem ser distribuídos independentemente entre treino e teste. O particionamento deverá ocorrer no nível do evento físico, preservando juntos todos os candidatos correlacionados. No *particle gun* utilizado nesta tese, cada entrada corresponde a um único candidato primário e essa dependência intrínseca entre dois elétrons do mesmo decaimento não está presente.

5.2.3 Ruído eletrônico e *pile-up*

O ruído eletrônico é incorporado na etapa de conformação do pulso da simulação, com distribuições gaussianas centradas em zero e desvios-padrão dependentes da camada. O *pile-up* é representado pela sobreposição de eventos de mínimo viés às partículas primárias. A configuração empregada adota como parâmetro de simulação uma luminosidade de 10^{34} $\mathrm{cm}^{-2}\mathrm{s}^{-1}$. Esse valor é parte da configuração histórica do *benchmark*; não é apresentado nesta tese como medida da luminosidade instantânea corrente do LHC ou do ATLAS (ARAÚJO et al., 2023; SILVA et al., 2026b; SILVA et al., 2026a).

O perfil de *pile-up* apresentado na Figura 17 contém 10.010 registros, com média $\langle\mu\rangle =$

38,94 e desvio-padrão 9,999. Esses 10.010 registros pertencem ao perfil usado pela simulação e não correspondem ao número de eventos eletrônicos reconstruídos. A amostra de calibração continua contendo aproximadamente 3×10^5 eventos sob essa configuração (SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026).

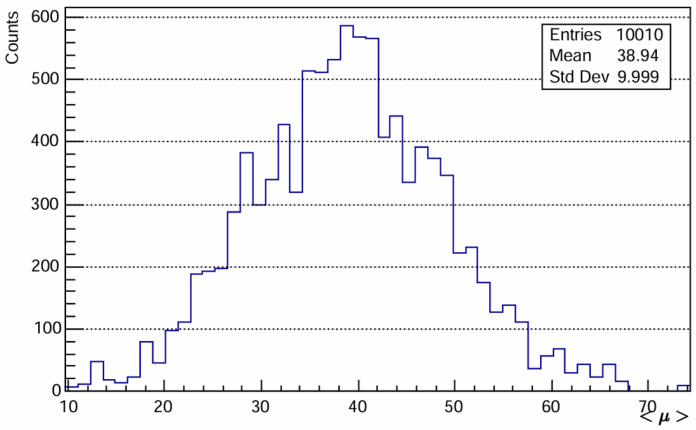


Figura 17 – Distribuição do parâmetro médio de pile-up ($\langle\mu\rangle$) no conjunto de dados simulado com o Lorenzetti utilizado neste trabalho. A distribuição contém 10.010 entradas do perfil de pile-up, com média ($\langle\mu\rangle = 38{,}94$) e desvio padrão (9,999), indicando que o benchmark de calibração inclui um nível substancial de atividade adicional de colisões. Fonte: (SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026).

É essencial distinguir "amostra com *pile-up*" de "estudo de robustez a *pile-up*". Os resultados desta tese são obtidos sob a distribuição de $\langle\mu\rangle$ descrita acima, mas o conjunto não foi gerado como uma varredura independente e controlada de níveis baixo, intermediário e alto de *pile-up*. Assim, pode-se afirmar que os modelos foram comparados em um cenário que contém essa fonte de contaminação, mas não que o desempenho seja invariável em $\langle\mu\rangle$. Uma avaliação em regimes como os esperados para futuras condições de alta luminosidade exige novas amostras e constitui uma camada adicional de validação.

5.2.4 Perturbação não linear controlada

A resposta rápida utilizada no *benchmark* contém uma distorção não linear e não suave visível em torno de 250 GeV. Essa característica foi preservada entre os estudos para funcionar como um teste controlado de capacidade de correção e não deve ser interpretada como reprodução de um artefato específico do detector ATLAS (SILVA et al., 2026a). A manutenção da mesma perturbação permite comparar a evolução dos modelos sob uma condição de resposta idêntica.

Consequentemente, um ganho observado em torno dessa região demonstra capacidade do modelo de aprender a correção dentro do *benchmark*, mas não estabelece, isoladamente, robustez a qualquer não linearidade instrumental. Isolar causalmente o efeito dessa perturbação exigiria comparar amostras idênticas geradas com e sem o mesmo mecanismo de distorção.

5.3 Interface calorimétrica utilizada no *benchmark*

As definições gerais de energia transversa e da representação Ringer foram estabelecidas no Capítulo 2, enquanto a formulação matemática da calibração é apresentada no Capítulo 3.

Esta seção apresenta apenas os elementos específicos da interface calorimétrica utilizada no *benchmark* dos experimentos.

Para cada evento é considerada uma região de interesse de $0{,}4 \times 0{,}4$ em (η, ϕ). Quando as sete camadas calorimétricas da configuração são incluídas, essa região contém aproximadamente 10^3 células. A representação Ringer reduz essa leitura para 100 anéis, preservando a organização radial e longitudinal da energia depositada (PINTO; ATLAS Collaboration, 2016; SILVA et al., 2026b). A distribuição dos 100 anéis entre PS, EM1, EM2, EM3 e as camadas hadrônicas foi apresentada no Capítulo 2.

A construção dos anéis utiliza uma referência associada ao núcleo reconstruído do chuveiro e não informação de verdade de Monte Carlo. Assim, o centro da representação é determinado a partir da própria resposta calorimétrica e do procedimento de reconstrução adotado pelo Ringer/Lorenzetti, e não a partir de E_{true} ou da direção gerada da partícula. A convenção geométrica detalhada de centralização deve permanecer consistente com a implementação utilizada para produzir o conjunto de dados; ela não é tratada aqui como uma variável ajustável pelos modelos de calibração.

5.4 Aplicação da formulação de calibração

O protocolo experimental adota diretamente a formulação estabelecida no Capítulo 3. Para cada evento, $g_{\text{ML}}(\cdot)$ constrói a representação apresentada ao regressor, $f_{\text{ML}}(\cdot)$ estima α_{calib} e a energia corrigida é obtida pela Eq. 3.1. O alvo supervisionado é α_{true}, definido na Eq. 3.3, e está disponível no desenvolvimento porque E_{true} é conhecido na simulação Monte Carlo.

A função de treinamento depende da família de regressor, enquanto a avaliação científica utiliza o conjunto comum de métricas definido neste capítulo. Como demonstrado na Seção 3.1.1, minimizar um erro quadrático não ponderado no fator de calibração não é, em geral, equivalente a minimizar um erro quadrático não ponderado diretamente na energia. Por essa razão, função de treinamento e métricas finais são tratadas separadamente: os resultados são avaliados prioritariamente no domínio de E_{calib}, enquanto grandezas associadas ao fator de calibração são utilizadas também para diagnóstico regional.

Essa separação especifica como a formulação comum é aplicada e como os modelos são treinados, selecionados e avaliados em cada etapa experimental.

5.5 Representações de entrada

A representação completa é denotada por `Rings[1:100]` e corresponde aos 100 anéis normalizados. Nessa condição,

$$g_{\text{ML}}(\cdot) = \mathcal{I}(\cdot), \qquad F = 100, \tag{5.1}$$

em que $\mathcal{I}$ é a transformação identidade.

Nas etapas posteriores da pesquisa, quatro métodos orientados por dados são comparados

sob cardinalidades fixas,

$$m \in \{50, 10, 5, 2\}, \tag{5.2}$$

produzindo CORR-m, MUTI-m, PCA-m e ICA-m. CORR e MUTI preservam variáveis originais; PCA e ICA produzem componentes transformados. A definição matemática desses métodos foi apresentada no Capítulo 3. A utilização da mesma cardinalidade permite separar, de forma mais limpa, o efeito do método de representação do efeito trivial do número de entradas (SILVA et al., 2026a).

Também é utilizada, nas etapas posteriores, uma referência fixa orientada por conhecimento especialista denominada `Rings/2`, com $F = 50$, conforme

$$\texttt{Rings/2} = \texttt{Rings[1:4]} \cup \texttt{Rings[9:40]} \cup \texttt{Rings[73:76]} \cup \texttt{Rings[81:84]} \cup \texttt{Rings[89:94]}, \tag{5.3}$$

totalizando 50 anéis originais. Em termos das regiões calorimétricas, são retidos quatro anéis de PS, 32 de EM1, quatro de EM2, quatro de EM3 e seis anéis hadrônicos, correspondentes à HAD1 completa e aos dois primeiros anéis de HAD2. A representação `Rings/2` é determinística e não utiliza E_{true} para selecionar seus componentes. Ela deve, portanto, ser distinguida das seleções supervisionadas CORR e MUTI e das transformações PCA e ICA.

A primeira etapa da pesquisa empregou uma convenção diferente para parte das representações reduzidas, ou seja, CORR e MUTI foram avaliadas por limiares de relevância, enquanto PCA e ICA foram avaliadas com as cardinalidades $m \in \{100, 10, 5, 2\}$ (SILVA et al., 2026b). Nas três etapas experimentais, entretanto, as componentes obtidas por PCA e ICA foram ordenadas segundo o módulo da correlação de Pearson com E_{true}, utilizando somente os dados permitidos para a construção da representação. A diferença introduzida a partir da Etapa II está, portanto, nas cardinalidades comparadas e na substituição dos limiares de CORR e MUTI por seleções top-m, e não no critério de ordenação das componentes PCA/ICA. Nas Etapas II e III, a cardinalidade fixa da Eq. 5.2 permite comparações mais controladas entre as diferentes estratégias de representação (SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026).

5.5.1 Ajuste da representação e prevenção de vazamento

Toda transformação dependente dos dados deve ser considerada parte do treinamento. Para uma partição de treinamento,

$$g_{\text{ML}} = \mathcal{T}_g\left(\widetilde{\mathbf{E}}_{r,\text{train}}, \mathbf{E}_{\text{true,train}}\right), \tag{5.4}$$

quando o método inclui ordenação supervisionada. Após sua definição, o mesmo operador é aplicado sem reajuste,

$$\begin{aligned} \mathbf{X}_{\text{train}} &= g_{\text{ML}}\left(\widetilde{\mathbf{E}}_{r,\text{train}}\right), \\ \mathbf{X}_{\text{val}} &= g_{\text{ML}}\left(\widetilde{\mathbf{E}}_{r,\text{val}}\right), \\ \mathbf{X}_{\text{test}} &= g_{\text{ML}}\left(\widetilde{\mathbf{E}}_{r,\text{test}}\right). \end{aligned} \tag{5.5}$$

Nas etapas experimentais que utilizam a partição 70/30, o ajuste de $g_{\text{ML}}(\cdot)$ é realizado uma única vez utilizando exclusivamente a partição de desenvolvimento $\mathcal{D}_{70}$. Assim, a seleção por CORR ou MUTI, o ajuste das transformações PCA ou ICA e a ordenação supervisionada das componentes

PCA/ICA segundo sua correlação absoluta com E_{true} utilizam somente os 70% destinados ao desenvolvimento. Uma vez obtido, $g_{\text{ML}}(\cdot)$ permanece fixo durante os procedimentos subsequentes de validação cruzada do regressor e na aplicação ao conjunto de teste independente. A partição $\mathcal{D}_{30}$ não participa do ajuste da representação.

Assim, os rankings de CORR e MUTI, as transformações PCA e ICA e a ordenação supervisionada dos componentes são definidos uma única vez com a partição de desenvolvimento $\mathcal{D}_{70}$ e depois mantidos fixos durante a validação cruzada de $f_{\text{ML}}(\cdot)$ e a aplicação ao teste. Essa escolha impede qualquer uso de $\mathcal{D}_{30}$ na construção da representação, mas implica que a validação cruzada subsequente é condicional a $g_{\text{ML}}(\cdot)$ e não uma validação aninhada de ponta a ponta de $f_{\text{ML}} \circ g_{\text{ML}}$.

5.6 Evolução dos protocolos experimentais

A Tabela 5 resume as principais diferenças entre as três etapas.

Tabela 5 – Evolução do desenho experimental ao longo da tese.

Aspecto	**Etapa I**	**Etapa II**	**Etapa III**
Artigos	(SILVA et al., 2026b)	(SILVA et al., 2026a)	(SILVA; SIMAS FILHO, 2026)
Representações	100 anéis; CORR/MUTI por limiar; PCA/ICA com diferentes números de componentes	100 anéis; Rings/2; CORR, MUTI, PCA e ICA com $m \in \{50, 10, 5, 2\}$	Mesma família de representações compactas para DNN; GNN sobre 100 anéis
Regressores	MLR, PReg, DTree e BDT	DTree, BDT, RF, BDTRF, RFBDT e RFBDTS	DNN e GNN; árvores e híbridos mantidos como referências
Uso de bins	comparação exploratória entre BDT global e BDTs especializados em $(\lvert\eta\rvert, E_{\text{true}})$; E_T na nomenclatura das figuras publicadas	treinamento global; bins somente para avaliação *a posteriori*	treinamento global; bins somente para avaliação *a posteriori*
Particionamento e seleção	70/30; valores publicados avaliados no teste independente de 30%	70/30; nested CV 5×5 dentro dos 70% de treinamento	70/30; nested CV 5×5 dentro dos 70% de treinamento
Avaliação	RMSE, IQR, d_0, D_0, análise regional, resposta a limiar e testes estatísticos	protocolo ampliado com resolução, estabilidade regional, resposta a limiar, estatística pareada e custo de predição	mesmo núcleo ampliado, com comparação neural e relacional

5.6.1 Etapa I: modelos convencionais e segmentação

A primeira etapa investigou regressão linear multivariada, regressão polinomial de segundo grau, árvore de decisão e BDT, além de um BDT treinado em regiões de $(\lvert\eta\rvert, E_T)$ (SILVA et al., 2026b). Na implementação Monte Carlo dessa segmentação, a coordenada de energia transversa utilizada para construir e aplicar os bins foi E_{true}. Assim, o símbolo E_T preservado na

nomenclatura e nas figuras do estudo publicado corresponde, nesse contexto específico, à energia transversa verdadeira do evento. A finalidade era estabelecer se a informação codificada pelos anéis permitia melhorar a estimativa rápida e avaliar se a especialização cinemática proporcionaria vantagem sobre um único modelo global.

Para o estudo segmentado, um algoritmo genético foi utilizado para construir uma partição não uniforme com três intervalos em $|\eta|$ e cinco intervalos em E_{true}. Cada cromossomo codificava os limites internos das duas dimensões.

$$J_{\text{GA}} = \max_b N_b - \min_b N_b, \tag{5.6}$$

a ser minimizado.

A população foi configurada com 100 indivíduos, taxa de mutação de 20%, máximo de 200 gerações e interrupção antecipada após 30 gerações sem melhora da aptidão média. A segmentação resultante foi

$$|\eta| \in [0, 0{,}43, 0{,}83, 1{,}46], \tag{5.7}$$

e

$$E_{\text{true}}\ [\text{GeV}] \in [0, 44{,}7, 71{,}5, 103{,}5, 164{,}3, 499{,}9]. \tag{5.8}$$

Essa segmentação deve ser interpretada no domínio do barril simulado. O limite $|\eta| = 1{,}46$ não pretende representar toda a aceitação do ATLAS.

A comparação entre o BDT global e os BDTs segmentados foi concebida para testar se a especialização em regiões cinemáticas poderia compensar a redução da quantidade de eventos disponível para cada regressor. As duas estratégias introduzem compromissos distintos: a especialização local pode reduzir heterogeneidade dentro de cada modelo, enquanto a fragmentação da amostra reduz a estatística de treinamento, introduz fronteiras discretas entre regiões e pode aumentar a variância de estimação. Não existe garantia matemática de que o treinamento bin a bin seja superior ao treinamento global; o resultado dessa comparação é apresentado no Capítulo 6.

Na implementação da Etapa I, E_{true} também foi utilizada para determinar a qual intervalo de energia pertencia cada evento no esquema segmentado. Embora E_{true} não seja uma entrada do regressor, seu uso no encaminhamento entre modelos especializados é possível apenas no ambiente Monte Carlo. Portanto, a variante binada avaliada nessa etapa deve ser interpretada como um experimento de especialização regional, e não como uma implementação diretamente transferível, sem modificações, para dados experimentais.

Em uma aplicação real ou online, uma quantidade reconstruída disponível antes da correção, como E_{fast}, poderia ser utilizada para realizar esse encaminhamento. Essa substituição é operacionalmente possível, mas não é matematicamente neutra: como E_{fast} possui resolução e viés em relação a E_{true}, eventos podem migrar entre bins próximos às fronteiras. Consequentemente, uma versão operacional baseada em E_{fast} deveria ter suas fronteiras definidas ou reotimizadas nessa variável e ser novamente treinada e validada. As etapas seguintes evitam essa dependência no treinamento ao utilizar um único modelo global e preservar os bins apenas para diagnóstico *a posteriori*.

5.6.2 Etapas II e III: treinamento global e avaliação regional

Na segunda etapa, todos os modelos são treinados globalmente, sem segmentação prévia do conjunto de treinamento (SILVA et al., 2026a). Os intervalos das Eqs. 5.7 e 5.8, com a coordenada energética definida por E_{true} no Monte Carlo, são aplicados somente depois da inferência, para verificar se uma função global apresenta instabilidades locais. Essa alteração evita fragmentação estatística e descontinuidades explícitas entre regressores independentes, sem eliminar a análise da dependência do desempenho com pseudorapidez e energia.

O desenho combina quatro métodos de seleção ou extração com quatro cardinalidades e seis regressores baseados em árvores, além de `Rings[1:100]` e `Rings/2`, totalizando 108 configurações na etapa híbrida (SILVA et al., 2026a). A terceira etapa mantém a mesma interface e estende a comparação para DNNs sobre representações completas e compactas e para uma GNN relacional–tabular sobre a representação completa, preservando os modelos baseados em árvores e híbridos como referências de comparação (SILVA; SIMAS FILHO, 2026).

5.7 Particionamento, validação cruzada e seleção de modelos

5.7.1 Partição independente de teste

Nas três etapas experimentais, o conjunto disponível é inicialmente dividido em 70% para desenvolvimento e 30% para teste independente. Essas partições são denotadas, respectivamente, por $\mathcal{D}_{70}$ e $\mathcal{D}_{30}$. A partição $\mathcal{D}_{30}$ não participa do ajuste das representações, da seleção de hiperparâmetros nem do treinamento dos modelos. Encerrado o desenvolvimento, os modelos e as configurações experimentais previamente definidos são aplicados a $\mathcal{D}_{30}$ para obtenção das métricas finais.

Os rankings apresentados nos capítulos de resultados constituem, portanto, comparações descritivas entre configurações já fixadas quando avaliadas sobre a mesma partição independente. Esses rankings não são reutilizados para reajustar representações, hiperparâmetros ou modelos.

Como múltiplas configurações previamente definidas são inspecionadas sobre a mesma partição $\mathcal{D}_{30}$, a identificação da configuração de menor erro deve ser interpretada como uma ordenação empírica nesse *hold-out*. O conjunto de teste permanece independente do treinamento e da seleção de hiperparâmetros; contudo, uma estimativa adicional do desempenho da configuração que ocupa a primeira posição, estatisticamente independente da própria comparação entre configurações realizada em $\mathcal{D}_{30}$, exigiria uma nova amostra externa.

A Etapa I reportou seus valores finais na partição independente correspondente a 30% do conjunto e preserva o protocolo metodológico documentado no estudo correspondente, sem aplicação retrospectiva do procedimento de validação cruzada aninhada empregado nas etapas posteriores (SILVA et al., 2026b; SILVA et al., 2026a). A separação entre desenvolvimento e teste independente, entretanto, é preservada nas três etapas experimentais. As diferenças entre os estudos concentram-se nas representações, nas famílias de regressores, no uso de segmentação e no protocolo de avaliação, e não na utilização do conjunto de teste para ajuste ou seleção dos modelos.

5.7.2 Validação cruzada aninhada

Nas Etapas II e III, a seleção de hiperparâmetros de $f_{\mathrm{ML}}(\cdot)$ é realizada exclusivamente dentro da partição de desenvolvimento $\mathcal{D}_{70}$ por meio de validação cruzada aninhada (*nested cross-validation*) com cinco *folds* externos e cinco *folds* internos. A Etapa I preserva o protocolo metodológico documentado no estudo correspondente e, portanto, não é incluída retrospectivamente nesse procedimento.

Os dois níveis da validação cruzada aninhada possuem funções distintas. O laço interno é responsável pela seleção dos hiperparâmetros do regressor, enquanto o laço externo avalia, em dados não utilizados nessa seleção, o desempenho e a estabilidade do procedimento de escolha. A partição independente $\mathcal{D}_{30}$ não participa de nenhum desses dois níveis e permanece reservada para a avaliação final.

A Figura 18 sintetiza o procedimento completo adotado, desde a divisão externa de $\mathcal{D}_{70}$ até a definição dos hiperparâmetros utilizados no modelo final.

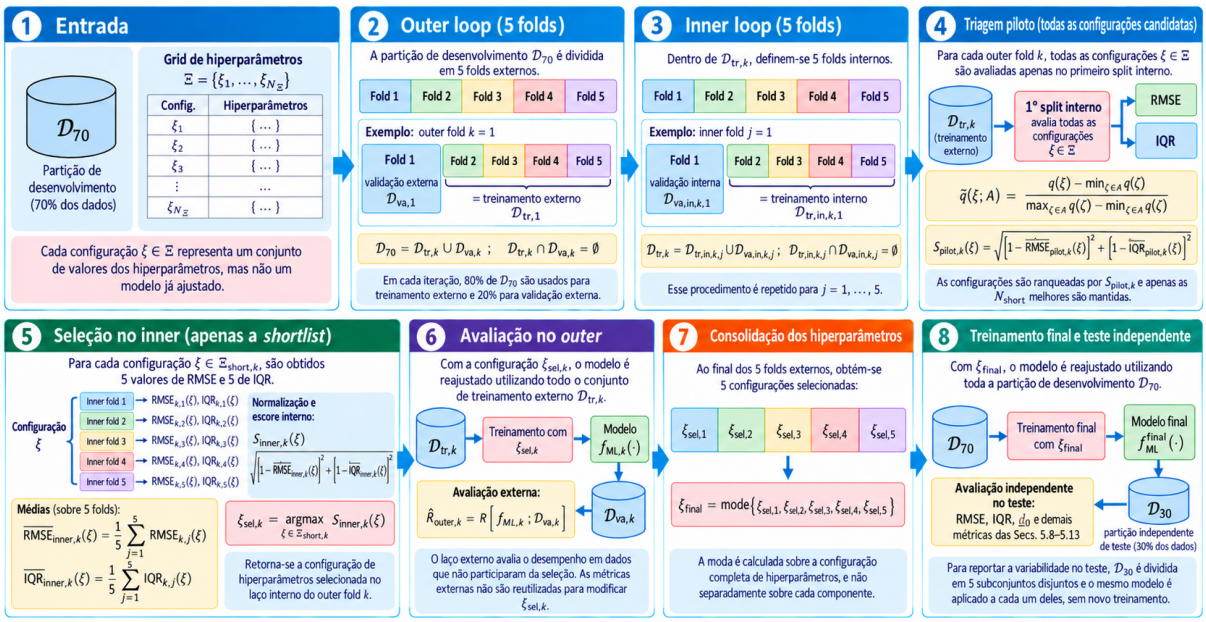


Figura 18 – Fluxo da validação cruzada aninhada utilizada para seleção de hiperparâmetros nas Etapas II e III. Para cada *fold* externo, a busca interna realiza uma triagem inicial das configurações candidatas, forma uma *shortlist*, avalia as configurações retidas nos cinco *folds* internos e seleciona uma configuração de hiperparâmetros. O modelo correspondente é reajustado no conjunto de treinamento externo e avaliado no respectivo conjunto de validação externa. Ao final dos cinco *folds* externos, a configuração final é definida pela moda das cinco configurações selecionadas, sendo então utilizada para o treinamento definitivo em $\mathcal{D}_{70}$ e para a avaliação independente em $\mathcal{D}_{30}$.

Para cada *fold* externo $k \in \{1, \ldots, 5\}$, a partição $\mathcal{D}_{70}$ é dividida temporariamente em um conjunto de treinamento externo $\mathcal{D}_{\mathrm{tr},k}$ e um conjunto de validação externa $\mathcal{D}_{\mathrm{va},k}$, de modo que

$$\mathcal{D}_{70} = \mathcal{D}_{\mathrm{tr},k} \cup \mathcal{D}_{\mathrm{va},k}, \qquad \mathcal{D}_{\mathrm{tr},k} \cap \mathcal{D}_{\mathrm{va},k} = \varnothing. \tag{5.9}$$

Ao longo dos cinco *folds* externos, cada subconjunto exerce uma vez o papel de $\mathcal{D}_{\mathrm{va},k}$, enquanto os quatro subconjuntos restantes formam $\mathcal{D}_{\mathrm{tr},k}$. Assim, em cada iteração externa, 80% de $\mathcal{D}_{70}$ são utilizados como treinamento externo e os 20% restantes como validação externa.

Seja

$$\Xi = \left\{ \boldsymbol{\xi}_1, \boldsymbol{\xi}_2, \ldots, \boldsymbol{\xi}_{N_\Xi} \right\} \tag{5.10}$$

o espaço discreto contendo as N_Ξ configurações candidatas de hiperparâmetros da família de regressão considerada. Cada $\boldsymbol{\xi} \in \Xi$ representa uma configuração completa de valores dos hiperparâmetros necessários para especificar uma realização da família de regressores, mas não corresponde, por si só, a um modelo já ajustado aos dados.

Para cada *fold* externo k, a busca interna é realizada exclusivamente sobre $\mathcal{D}_{\mathrm{tr},k}$. Esse conjunto é dividido em cinco *folds* internos. Para o j-ésimo *fold* interno, $j \in \{1, \ldots, 5\}$, definem-se um conjunto de treinamento interno $\mathcal{D}_{\mathrm{tr,in},k,j}$ e um conjunto de validação interna $\mathcal{D}_{\mathrm{va,in},k,j}$, satisfazendo

$$\mathcal{D}_{\mathrm{tr},k} = \mathcal{D}_{\mathrm{tr,in},k,j} \cup \mathcal{D}_{\mathrm{va,in},k,j}, \qquad \mathcal{D}_{\mathrm{tr,in},k,j} \cap \mathcal{D}_{\mathrm{va,in},k,j} = \varnothing. \tag{5.11}$$

Conforme ilustrado na Figura 18, a busca de hiperparâmetros realizada dentro de cada *fold* externo é composta por duas fases: uma triagem inicial de todas as configurações candidatas e uma avaliação completa, nos cinco *folds* internos, das configurações retidas nessa triagem.

Triagem inicial das configurações candidatas

Na primeira fase, todas as configurações $\boldsymbol{\xi} \in \Xi$ são avaliadas no primeiro *split* da validação interna. Para cada configuração, o regressor é ajustado no conjunto de treinamento desse *split* e aplicado ao respectivo conjunto de validação, produzindo valores de RMSE e IQR.

Como RMSE e IQR possuem escalas numéricas distintas, a comparação conjunta das duas métricas durante a busca é realizada após normalização min–max. Para uma métrica q calculada sobre um conjunto de configurações $\mathcal{A}$, define-se

$$\widetilde{q}(\boldsymbol{\xi}; \mathcal{A}) = \frac{q(\boldsymbol{\xi}) - \min_{\boldsymbol{\zeta} \in \mathcal{A}} q(\boldsymbol{\zeta})}{\max_{\boldsymbol{\zeta} \in \mathcal{A}} q(\boldsymbol{\zeta}) - \min_{\boldsymbol{\zeta} \in \mathcal{A}} q(\boldsymbol{\zeta})}. \tag{5.12}$$

No caso degenerado em que todas as configurações apresentam o mesmo valor da métrica considerada, a implementação atribui valor normalizado nulo a todas elas.

Na etapa piloto, o escore associado à configuração $\boldsymbol{\xi}$ no k-ésimo *fold* externo é definido por

$$S_{\mathrm{pilot},k}(\boldsymbol{\xi}) = \sqrt{\left[1 - \widetilde{\mathrm{RMSE}}_{\mathrm{pilot},k}(\boldsymbol{\xi})\right]^2 + \left[1 - \widetilde{\mathrm{IQR}}_{\mathrm{pilot},k}(\boldsymbol{\xi})\right]^2}. \tag{5.13}$$

Como valores menores de RMSE e IQR produzem valores normalizados próximos de zero, valores maiores de $S_{\mathrm{pilot},k}$ correspondem a configurações mais favoráveis segundo esse critério.

As N_Ξ configurações são ordenadas de forma decrescente segundo $S_{\mathrm{pilot},k}$. Apenas as configurações mais bem posicionadas são encaminhadas para a avaliação completa nos cinco *folds* internos. A cardinalidade efetiva dessa *shortlist* é

$$N_{\mathrm{short}} = \min\left\{ N_\Xi,\, 64,\, \max\left(8,\, \lceil 0{,}2 N_\Xi \rceil\right) \right\}. \tag{5.14}$$

Denota-se por $\Xi_{\mathrm{short},k} \subseteq \Xi$ o conjunto de configurações retidas no k-ésimo *fold* externo. Consequentemente, quando $N_\Xi \leq 8$, todas as configurações seguem para a avaliação completa.

Para espaços de busca maiores, a triagem inicial reduz o número de configurações submetidas aos cinco *folds* internos, diminuindo o custo computacional da busca sem utilizar qualquer informação proveniente da validação externa.

Avaliação completa no laço interno

Cada configuração $\boldsymbol{\xi} \in \Xi_{\text{short},k}$ é então avaliada nos cinco *folds* internos. Para cada $j \in \{1, \ldots, 5\}$, o regressor $f_{\boldsymbol{\xi},k,j}(\cdot)$ é ajustado utilizando $\mathcal{D}_{\text{tr,in},k,j}$ e aplicado a $\mathcal{D}_{\text{va,in},k,j}$.

Assim, para uma mesma configuração $\boldsymbol{\xi}$, são obtidos cinco valores de RMSE e cinco valores de IQR, um par para cada *fold* interno. As métricas são agregadas separadamente por média aritmética:

$$\overline{\text{RMSE}}_{\text{inner},k}(\boldsymbol{\xi}) = \frac{1}{5}\sum_{j=1}^{5} \text{RMSE}_{k,j}(\boldsymbol{\xi}), \tag{5.15}$$

e

$$\overline{\text{IQR}}_{\text{inner},k}(\boldsymbol{\xi}) = \frac{1}{5}\sum_{j=1}^{5} \text{IQR}_{k,j}(\boldsymbol{\xi}). \tag{5.16}$$

A agregação é, portanto, realizada sobre os valores das métricas calculadas separadamente nos cinco *folds*, e não por meio da concatenação das predições de validação dos diferentes *folds* para posterior cálculo de uma única métrica global.

As médias $\overline{\text{RMSE}}_{\text{inner},k}$ e $\overline{\text{IQR}}_{\text{inner},k}$ são então normalizadas entre as configurações pertencentes a $\Xi_{\text{short},k}$ utilizando o mesmo procedimento da Eq. (5.12). Define-se, assim, o escore interno

$$S_{\text{inner},k}(\boldsymbol{\xi}) = \sqrt{\left[1 - \widetilde{\overline{\text{RMSE}}}_{\text{inner},k}(\boldsymbol{\xi})\right]^2 + \left[1 - \widetilde{\overline{\text{IQR}}}_{\text{inner},k}(\boldsymbol{\xi})\right]^2}. \tag{5.17}$$

A configuração selecionada no laço interno associado ao k-ésimo *fold* externo é, portanto,

$$\boldsymbol{\xi}_{\text{sel},k} = \arg\max_{\boldsymbol{\xi} \in \Xi_{\text{short},k}} S_{\text{inner},k}(\boldsymbol{\xi}). \tag{5.18}$$

O símbolo $\boldsymbol{\xi}_{\text{sel},k}$ representa a configuração completa de hiperparâmetros selecionada no laço interno do k-ésimo *fold* externo, e não um modelo já treinado.

É importante distinguir o escore $S_{\text{inner},k}$ da métrica d_0 definida na Seção 5.8. O escore interno utiliza versões normalizadas de RMSE e IQR e possui função exclusivamente comparativa durante a seleção dos hiperparâmetros. Por sua vez, d_0 preserva as magnitudes originais de RMSE e IQR e é utilizado posteriormente como índice descritivo do desempenho absoluto das configurações avaliadas.

Avaliação no laço externo

Uma vez determinada a configuração $\boldsymbol{\xi}_{\text{sel},k}$, o regressor é reajustado utilizando todo o conjunto de treinamento externo $\mathcal{D}_{\text{tr},k}$. Denota-se o modelo resultante por $f_{\text{ML},k}(\cdot)$.

Seja $R[f; \mathcal{D}]$ uma notação genérica para uma medida de desempenho obtida ao avaliar um modelo já ajustado f sobre o conjunto $\mathcal{D}$. O modelo $f_{\text{ML},k}(\cdot)$ é então aplicado ao conjunto de

validação externa $\mathcal{D}_{\mathrm{va},k}$, e seu desempenho é representado genericamente por

$$\widehat{R}_{\mathrm{outer},k} = R\left[f_{\mathrm{ML},k}; \mathcal{D}_{\mathrm{va},k}\right]. \tag{5.19}$$

O conjunto $\mathcal{D}_{\mathrm{va},k}$ não participa da triagem das configurações, da formação da *shortlist* nem da escolha de $\boldsymbol{\xi}_{\mathrm{sel},k}$. Dessa forma, o laço externo possui função exclusivamente avaliativa: ele quantifica o desempenho do procedimento de seleção em dados que permaneceram externos à busca interna. Os resultados obtidos no laço externo não são reutilizados para modificar os hiperparâmetros selecionados (CAWLEY; TALBOT, 2010).

Esse procedimento é repetido independentemente nos cinco *folds* externos. Consequentemente, são obtidas cinco configurações de hiperparâmetros,

$$\boldsymbol{\xi}_{\mathrm{sel},1}, \boldsymbol{\xi}_{\mathrm{sel},2}, \boldsymbol{\xi}_{\mathrm{sel},3}, \boldsymbol{\xi}_{\mathrm{sel},4}, \boldsymbol{\xi}_{\mathrm{sel},5}, \tag{5.20}$$

e cinco avaliações externas para cada métrica considerada. As estatísticas dos *folds* externos caracterizam, assim, o desempenho e a estabilidade do procedimento de seleção de hiperparâmetros, e não apenas o desempenho de uma configuração única previamente fixada.

Consolidação dos hiperparâmetros e treinamento final

Como sintetizado na Figura 18, após a conclusão dos cinco *folds* externos são obtidas cinco configurações de hiperparâmetros selecionadas $\boldsymbol{\xi}_{\mathrm{sel},1}, \ldots, \boldsymbol{\xi}_{\mathrm{sel},5}$. Para o treinamento do modelo final, é necessário consolidá-las em uma única configuração. Na implementação adotada nesta tese, essa configuração é determinada pela moda das cinco configurações completas selecionadas nos respectivos laços internos:

$$\boldsymbol{\xi}_{\mathrm{final}} = \mathrm{mode}\left\{\boldsymbol{\xi}_{\mathrm{sel},1}, \boldsymbol{\xi}_{\mathrm{sel},2}, \boldsymbol{\xi}_{\mathrm{sel},3}, \boldsymbol{\xi}_{\mathrm{sel},4}, \boldsymbol{\xi}_{\mathrm{sel},5}\right\}. \tag{5.21}$$

A moda é calculada sobre a configuração completa de hiperparâmetros, e não separadamente sobre cada componente de $\boldsymbol{\xi}_{\mathrm{sel},k}$. Dessa forma, $\boldsymbol{\xi}_{\mathrm{final}}$ corresponde a uma combinação de hiperparâmetros efetivamente selecionada em pelo menos um dos *folds* externos. Em caso de empate na frequência máxima, a implementação retém a configuração empatada que aparece primeiro na ordem dos *folds* externos, preservando uma regra determinística de desempate. As métricas calculadas nos conjuntos $\mathcal{D}_{\mathrm{va},k}$ não participam dessa consolidação.

Com $\boldsymbol{\xi}_{\mathrm{final}}$ fixado, o regressor é reajustado utilizando exclusivamente a partição completa de desenvolvimento $\mathcal{D}_{70}$. O modelo resultante, $f_{\mathrm{ML}}^{\mathrm{final}}(\cdot)$, é então aplicado à partição independente de teste $\mathcal{D}_{30}$.

O fluxo completo de seleção e avaliação pode, portanto, ser resumido por

$$\mathcal{D}_{70} \longrightarrow \left\{\boldsymbol{\xi}_{\mathrm{sel},1}, \ldots, \boldsymbol{\xi}_{\mathrm{sel},5}\right\} \longrightarrow \boldsymbol{\xi}_{\mathrm{final}} \longrightarrow f_{\mathrm{ML}}^{\mathrm{final}} \longrightarrow \mathcal{D}_{30}. \tag{5.22}$$

Quando mecanismos internos ao próprio regressor, como *early stopping*, requerem uma fração adicional de validação, essa fração é retirada exclusivamente dos dados de desenvolvimento disponíveis naquela etapa de treinamento. Nenhuma observação de $\mathcal{D}_{30}$ participa do ajuste da representação, da seleção de hiperparâmetros ou do treinamento do modelo.

Condicionamento à representação de entrada

Na implementação adotada nesta tese, a validação cruzada aninhada é aplicada à seleção dos hiperparâmetros e à estimação de $f_{\mathrm{ML}}(\cdot)$ condicionada a uma representação $g_{\mathrm{ML}}(\cdot)$ previamente definida exclusivamente a partir de $\mathcal{D}_{70}$.

Portanto, CORR, MUTI, PCA, ICA e as respectivas ordenações, quando utilizadas, não são reajustadas nos *folds* internos ou externos. A representação permanece fixa durante todo o procedimento de validação cruzada do regressor.

Consequentemente, as estatísticas dos cinco *folds* externos caracterizam o desempenho e a estabilidade do procedimento de seleção de $f_{\mathrm{ML}}(\cdot)$ condicionado à representação previamente definida. Elas não constituem uma validação aninhada de ponta a ponta do operador composto $f_{\mathrm{ML}} \circ g_{\mathrm{ML}}$.

Variabilidade das métricas no teste independente

Nas Etapas II e III, após o modelo final estar completamente definido e fixado, a partição $\mathcal{D}_{30}$ é adicionalmente dividida em cinco subconjuntos disjuntos exclusivamente para resumir a variabilidade das métricas finais.

O mesmo modelo $f_{\mathrm{ML}}^{\mathrm{final}}(\cdot)$, sem qualquer novo ajuste, é aplicado aos cinco subconjuntos, e RMSE e IQR são calculados separadamente em cada um deles. Os valores reportados correspondem à média e ao desvio-padrão dessas cinco avaliações.

Essa divisão de $\mathcal{D}_{30}$ não constitui uma nova validação cruzada: não há novo treinamento, nova seleção de hiperparâmetros, nova escolha de representação ou reajuste do modelo em nenhum desses subconjuntos (SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026).

5.8 Métricas de erro global

Para cada evento, define-se o resíduo do método calibrado como

$$\varepsilon_{\mathrm{calib}}^{(i)} = E_{\mathrm{true}}^{(i)} - E_{\mathrm{calib}}^{(i)}, \tag{5.23}$$

e, para a referência,

$$\varepsilon_{\mathrm{fast}}^{(i)} = E_{\mathrm{true}}^{(i)} - E_{\mathrm{fast}}^{(i)}. \tag{5.24}$$

O sinal do resíduo informa a direção do erro, enquanto sua magnitude e sua dispersão quantificam aspectos complementares da qualidade da medida. Um estimador ideal produziria distribuição centrada em zero e com largura mínima.

5.8.1 RMSE

A raiz do erro quadrático médio é

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(\varepsilon^{(i)}\right)^2}. \tag{5.25}$$

O RMSE possui a mesma unidade da energia, penaliza fortemente grandes desvios e incorpora simultaneamente viés e variância do erro.

5.8.2 Quartis e IQR

Para uma variável aleatória X com função distribuição acumulada F_X, o quantil de ordem p pode ser definido por

$$Q_p(X) = \inf\{x : F_X(x) \geq p\}, \qquad 0 < p < 1. \tag{5.26}$$

O intervalo interquartil é

$$\mathrm{IQR}(X) = Q_{0,75}(X) - Q_{0,25}(X). \tag{5.27}$$

Aplicado aos resíduos de energia, o IQR mede a largura dos 50% centrais da distribuição e é menos sensível a caudas e valores extremos que o desvio-padrão. RMSE e IQR não são redundantes: o primeiro penaliza grandes erros quadráticos; o segundo caracteriza robustamente a dispersão central.

5.8.3 Métrica conjunta d_0

Como RMSE e IQR dos resíduos possuem a mesma unidade, define-se

$$d_0 = \sqrt{\mathrm{RMSE}^2 + \mathrm{IQR}^2}. \tag{5.28}$$

O valor d_0 é uma distância descritiva no plano RMSE–IQR. Ele não é uma grandeza física fundamental nem uma função de perda usada obrigatoriamente no treinamento. Seu papel é fornecer uma ordenação auxiliar que favoreça simultaneamente menor erro quadrático e menor dispersão central. As duas componentes são sempre apresentadas separadamente para que a interpretação não dependa do escore agregado.

A notação d_0 é preservada por rastreabilidade com os estudos publicados (SILVA et al., 2026b; SILVA et al., 2026a). Ela não deve ser confundida com o parâmetro de impacto transverso de trajetórias, também convencionalmente denotado por d_0 no contexto do ATLAS. Nesta tese, d_0 designa exclusivamente a métrica auxiliar da Eq. 5.28.

5.9 Avaliação Regional em Segmentos de $|\eta|$ e E_{T} do fator de calibração

Após a avaliação global, configurações selecionadas são analisadas nos bins de $(|\eta|, E_{\mathrm{true}})$ das Eqs. 5.7 e 5.8. Três grandezas complementares são utilizadas. O IQR caracteriza a dispersão da distribuição de α_{calib} dentro de cada região, enquanto o erro absoluto médio (MAE) e o RMSE quantificam o afastamento evento a evento da estimativa em relação a α_{true}. Para um bin contendo N_b eventos,

$$\mathrm{MAE}_{\alpha,b} = \frac{1}{N_b}\sum_{i\in b}\left|\alpha_{\mathrm{true}}^{(i)} - \alpha_{\mathrm{calib}}^{(i)}\right|, \qquad \mathrm{RMSE}_{\alpha,b} = \sqrt{\frac{1}{N_b}\sum_{i\in b}\left(\alpha_{\mathrm{true}}^{(i)} - \alpha_{\mathrm{calib}}^{(i)}\right)^2}. \tag{5.29}$$

O IQR regional, por sua vez, é calculado sobre os valores de α_{calib} no próprio bin segundo a definição geral da Eq. 5.27. Essa distinção evita interpretar a dispersão do fator previsto como

se fosse a mesma quantidade que o erro da previsão do fator (SILVA et al., 2026b; SILVA et al., 2026a).

A análise regional tem função diagnóstica. Uma métrica global pode ocultar regiões nas quais o modelo apresenta maior dispersão ou erro sistemático. A avaliação em bins verifica se o ganho médio é acompanhado por comportamento coerente ao longo do espaço cinemático do *benchmark*. O IQR do fator não substitui a resolução de energia.

Como $\alpha_{\text{true}} = E_{\text{true}}/E_{\text{fast}}$ pequenas flutuações absolutas no denominador podem produzir variações relativas maiores em baixas energias. Por isso, a dispersão de α é interpretada em conjunto com resíduos de energia e com a resolução relativa discutida a seguir.

5.10 Resolução de energia

A avaliação de resolução utiliza a resposta relativa

$$r^{(i)} = \frac{E^{(i)}_{\text{calib}}}{E^{(i)}_{\text{true}}}, \tag{5.30}$$

e o resíduo relativo

$$\delta^{(i)} = \frac{E^{(i)}_{\text{calib}} - E^{(i)}_{\text{true}}}{E^{(i)}_{\text{true}}} = r^{(i)} - 1. \tag{5.31}$$

Como $\delta^{(i)} = r^{(i)} - 1$, as duas grandezas possuem a mesma dispersão. Quando a distribuição da resposta é aproximadamente gaussiana, a resolução relativa de energia pode ser representada pelo desvio-padrão dessa distribuição,

$$\frac{\sigma_E}{E} \approx \sigma_r \approx \sigma_\delta. \tag{5.32}$$

Como distribuições calorimétricas podem apresentar assimetria ou caudas não gaussianas, utiliza-se também, como medida robusta complementar, a largura gaussiana equivalente baseada no intervalo interquartil,

$$\sigma_{\text{eq}} \approx \frac{\text{IQR}(r)}{1{,}349}. \tag{5.33}$$

Nesta tese, a resolução não é obtida pelo ajuste de uma parametrização analítica pré-definida em função da energia. Em vez disso, ela é estimada diretamente a partir da distribuição empírica da resposta no *benchmark*. Para esse cálculo, os eventos são agrupados em intervalos de E_{true}.

Então, seja $\mathcal{B}_\ell$ o conjunto de eventos pertencentes ao ℓ-ésimo intervalo de energia. A resolução relativa associada a esse intervalo é calculada pela dispersão dos valores de $r^{(i)}$ dos eventos nele contidos,

$$\left(\frac{\sigma_E}{E}\right)_\ell = \text{Std}\left(\left\{r^{(i)} \;\middle|\; i \in \mathcal{B}_\ell\right\}\right). \tag{5.34}$$

De forma equivalente, a medida robusta $\sigma_{\text{eq},\ell}$ é obtida aplicando a Eq. 5.33 aos valores de $r^{(i)}$ pertencentes ao mesmo intervalo $\mathcal{B}_\ell$. Dessa forma, cada intervalo de E_{true} produz um valor de resolução, e o conjunto desses valores forma a curva de σ_E/E em função da energia apresentada nos capítulos de resultados.

Para a referência *Standard FastCalo*, aplica-se o mesmo procedimento, substituindo $E^{(i)}_{\text{calib}}$ por $E^{(i)}_{\text{fast}}$, de modo que ambos os métodos são avaliados nos mesmos intervalos de E_{true} e com o mesmo estimador de dispersão.

A análise bin a bin é necessária porque um único valor global de IQR, RMSE ou dispersão não descreve a dependência da precisão calorimétrica com a energia. As curvas de resolução permitem verificar diretamente como a largura relativa da resposta evolui ao longo do espectro e em quais regiões de energia a calibração produz maior ou menor redução de dispersão (FABJAN; GIANOTTI, 2003; ATLAS Collaboration, 2024a).

5.11 Resposta próxima a limiares de seleção

Os estudos associados a esta tese utilizaram curvas de taxa de aceitação de eventos (*Event Acceptance Rate*, EAR), denominadas *turn-on curves* nas respectivas publicações, como uma medida complementar da concentração da resposta energética (SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026). Essas curvas não representam diretamente a eficiência de um limiar operacional fixo de *trigger*; elas quantificam a fração de eventos cuja energia reconstruída permanece dentro de uma tolerância $\Delta\lambda$ em relação à energia verdadeira.

Para o método calibrado e para a referência *Standard FastCalo*, definem-se os resíduos

$$\varepsilon^{(i)}_{\text{calib}} = E^{(i)}_{\text{true}} - E^{(i)}_{\text{calib}}, \qquad \varepsilon^{(i)}_{\text{fast}} = E^{(i)}_{\text{true}} - E^{(i)}_{\text{fast}}. \tag{5.35}$$

De forma genérica, seja $\varepsilon^{(i)}_m = E^{(i)}_{\text{true}} - E^{(i)}_m$, com $m \in \{\text{calib}, \text{fast}\}$. Para uma tolerância positiva $\Delta\lambda$, o evento é considerado aceito quando

$$\left|\varepsilon^{(i)}_m\right| < \Delta\lambda. \tag{5.36}$$

Essa condição equivale a exigir que a energia reconstruída esteja no intervalo $E^{(i)}_{\text{true}} - \Delta\lambda < E^{(i)}_m < E^{(i)}_{\text{true}} + \Delta\lambda$. Assim, $\Delta\lambda$ representa a semi-largura de uma janela simétrica centrada na energia verdadeira de cada evento. Quanto menor a tolerância necessária para conter uma dada fração da amostra, maior é a concentração da resposta reconstruída em torno de E_{true}.

Na implementação utilizada nos estudos, a varredura de $\Delta\lambda$ é limitada por

$$\Delta\lambda_{\max} = 6 \max\left(\sigma_{\varepsilon_{\text{calib}}}, \sigma_{\varepsilon_{\text{fast}}}\right), \tag{5.37}$$

em que o 6 é multiplicado ao desvio-padrão para garantir um grande volume de amostras dentro do intervalo (cerca de 99,9999998% para uma distribuição gaussiana) e o intervalo entre zero e $\Delta\lambda_{\max}$ é discretizado em 1000 valores igualmente espaçados. Para cada valor $\Delta\lambda_s$, a taxa de aceitação é calculada pela fração dos N eventos que satisfazem a Eq. 5.36,

$$\text{EAR}_m(\Delta\lambda_s) = \frac{1}{N}\sum_{i=1}^{N} \mathbb{I}\left(\left|\varepsilon^{(i)}_m\right| < \Delta\lambda_s\right), \tag{5.38}$$

em que $\mathbb{I}(\cdot)$ é a função indicadora, igual a 1 quando a condição é satisfeita e a 0 caso contrário.

Cada ponto da curva utiliza toda a amostra de avaliação, sem separação prévia em intervalos de E_{true}. À medida que $\Delta\lambda$ aumenta, uma fração progressivamente maior dos eventos

satisfaz o critério de aceitação. A avaliação em 1000 pontos e sua representação gráfica por segmentos de reta conferem à curva aparência visualmente suave, sem aplicação de procedimento adicional de ajuste ou suavização.

Para um nível de aceitação q, define-se

$$\Delta\lambda_{q,m} = \min\left\{\Delta\lambda_s : \mathrm{EAR}_m(\Delta\lambda_s) \geq q\right\}. \tag{5.39}$$

Nos estudos desta tese utiliza-se $q = 0{,}90$. Dessa forma, $\Delta\lambda_{90}$ representa, à resolução da varredura numérica, a menor semi-largura da janela em torno de E_{true} que contém pelo menos 90% dos eventos. Essa grandeza corresponde aproximadamente ao percentil de 90% da distribuição de $|\varepsilon_m|$. Consequentemente, valores menores de $\Delta\lambda_{90}$ indicam uma resposta energética mais concentrada e complementam as informações fornecidas por RMSE, IQR e resolução relativa.

Essa análise deve ser interpretada como uma caracterização da concentração da resposta energética no *benchmark*, e não como uma medida completa da eficiência de um menu operacional de *trigger*. Um limiar real de seleção é fixo e unilateral, enquanto a EAR empregada aqui utiliza uma janela bilateral centrada na verdade de Monte Carlo. Além disso, a amostra principal não contém uma população representativa de fundos necessária para avaliar simultaneamente eficiência de sinal e aceitação de fundo. Uma avaliação operacional de *trigger* exigiria, portanto, um estudo específico com limiares fixos e amostras apropriadas de sinal e fundo.

5.12 Avaliação computacional

A avaliação computacional separa três conceitos: dimensionalidade de entrada, custo de treinamento e custo de predição do modelo treinado.

A dimensionalidade F caracteriza exclusivamente o número de características externas fornecidas ao regressor; ela não constitui uma medida da complexidade interna da arquitetura. Dois modelos com o mesmo F podem possuir números de parâmetros treináveis, requisitos de memória, profundidades e custos aritméticos substancialmente diferentes. Para uma GNN construída a partir de `Rings[1:100]`, considera-se $F = 100$ porque existem 100 fontes externas de entrada, embora a arquitetura construa internamente descritores e representações adicionais.

O treinamento é realizado *offline* e inclui ajuste de parâmetros, validação cruzada e busca de hiperparâmetros. Seu custo é relevante para reprodutibilidade e manutenção do modelo, mas não integra a latência online. Já o tempo T reportado nos capítulos de resultados corresponde ao tempo de predição amortizado por evento. Seja $T_{\mathrm{wall,batch}}$ o tempo de relógio (*wall-clock time*) decorrido para processar o lote completo de teste e seja N_{batch} o número de eventos processados nesse lote. Define-se, então,

$$T = \frac{T_{\mathrm{wall,batch}}}{N_{\mathrm{batch}}}. \tag{5.40}$$

Por exemplo, um conjunto de 302.619 eventos produz, na divisão 70/30 utilizada nos experimentos, 211.833 eventos na partição de treinamento e 90.786 eventos na partição de testes. Os tempos amortizados de predição reportados para o *hold-out* utilizam como denominador o número de eventos efetivamente processados nessa partição, $N_{\mathrm{batch}} = 90.786$. Determinadas implementações

podem realizar internamente a inferência em minilotes, mas o tempo final é normalizado pelo número total de candidatos processados.

As medições foram realizadas em uma plataforma com processador Intel Core i7-7500U, 20 GB de memória DDR4 e SSD de 1 TB. Os tempos reportados para comparação de modelos correspondem à inferência em CPU. A presença de uma GPU no computador de desenvolvimento não é utilizada como argumento de desempenho para a etapa crítica de inferência.

Esses valores não incluem necessariamente obtenção dos dados, construção online das células e anéis, transferências de memória, carregamento do modelo, concorrência entre eventos, quantização, integração ao software do experimento ou latência de pior caso. Portanto, não se converte um valor medido nessa plataforma em uma previsão de latência no HLT por simples fator de escala. Demonstrar compatibilidade operacional requer medir a cadeia implementada no hardware e software de destino.

Para a referência *Standard FastCalo*, adota-se no ranking $F_{\text{fast}} = 1$, correspondente à própria estimativa E_{fast}, e $T_{\text{fast}} = 0$, indicando ausência de uma etapa adicional de inferência de ML. Essas convenções são utilizadas exclusivamente para definir a referência dos critérios comparativos: não significam que a reconstrução que produz E_{fast} possua dimensionalidade física unitária ou custo computacional nulo (SILVA et al., 2026b; SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026).

5.12.1 Métrica composta D_0

Define-se,

$$D_0 = \sqrt{\text{IQR}^2_{(N)} + \text{RMSE}^2_{(N)} + F^2_{(N)} + T^2_{(N)}}. \tag{5.41}$$

onde o subscrito (N) indica normalização por min–max. Os valores mínimo e máximo utilizados nessa normalização são obtidos no conjunto de configurações comparadas dentro da respectiva etapa experimental. A normalização resolve a incompatibilidade dimensional antes da agregação, mas não transforma D_0 em uma grandeza física. Os pesos iguais representam uma decisão de engenharia, não uma propriedade física do problema.

Por essas razões, D_0 é utilizado somente como critério transparente de ordenação dentro de um conjunto experimental específico. Valores de D_0 obtidos em etapas distintas não são comparados diretamente quando os conjuntos de modelos e as faixas de normalização diferem. As conclusões científicas são sustentadas pelos componentes RMSE, IQR, F e T, pelo d_0 e pelas análises físicas complementares, não pelo D_0 isoladamente.

Consequentemente, a presença de F em D_0 não transforma esse índice em uma medida completa de complexidade arquitetural. Em particular, D_0 não deve ser utilizado para afirmar equivalência computacional entre modelos de famílias distintas que possuam o mesmo número de entradas externas.

5.13 Validação estatística

A validação estatística tem como propósito verificar se as diferenças observadas entre a energia calibrada e a referência *Standard FastCalo* apresentam evidência estatística compatível com uma alteração sistemática da distribuição dos resíduos, e não apenas com flutuações amostrais. Essa análise complementa as métricas descritivas de desempenho, como RMSE, IQR e resolução de energia, avaliando formalmente duas propriedades de interesse: o deslocamento da distribuição dos resíduos e a redução de sua dispersão após a calibração. Como o número de eventos é elevado, a significância estatística é interpretada em conjunto com a magnitude dos efeitos observados, e não como evidência isolada de relevância prática.

Como $E^{(i)}_{\text{fast}}$ e $E^{(i)}_{\text{calib}}$ são obtidos para o mesmo evento, as comparações com a referência possuem estrutura pareada. Define-se

$$d^{(i)} = \varepsilon^{(i)}_{\text{calib}} - \varepsilon^{(i)}_{\text{fast}}. \tag{5.42}$$

Antes da inferência paramétrica, a forma das distribuições de $\varepsilon_{\text{fast}}$, $\varepsilon_{\text{calib}}$ e d é avaliada com testes de D'Agostino–Pearson e Anderson–Darling, complementados por gráficos Q–Q. Como as amostras são grandes e os resíduos apresentam desvios de normalidade, resultados paramétricos são acompanhados por métodos pareados não paramétricos ou por reamostragem (D'AGOSTINO; PEARSON, 1973; ANDERSON; DARLING, 1954).

5.13.1 Deslocamento do resíduo

Nas Etapas I, II e III, a comparação direcional do resíduo é formulada como

$$H_0 : \mu_d \geq 0 \qquad \text{versus} \qquad H_1 : \mu_d < 0, \tag{5.43}$$

em que $\mu_d = \mathbb{E}[d]$. O subíndice d é mantido explicitamente para distinguir μ_d, que representa a média da diferença pareada dos resíduos, do parâmetro de *pile-up* μ utilizado anteriormente na tese. As duas grandezas não possuem relação entre si.

São utilizados os testes z e t pareados para a hipótese formulada sobre a média μ_d, enquanto o teste de postos sinalizados de Wilcoxon é empregado como verificação não paramétrica complementar de deslocamento da distribuição pareada (WILCOXON, 1945). A interpretação dessa hipótese requer cuidado. Um valor negativo de μ_d demonstra um deslocamento do resíduo em relação à referência; ele não demonstra, por identidade matemática, que todo erro ficou mais próximo de zero. No *benchmark* considerado, a direção do viés da referência é estabelecida empiricamente e a interpretação do deslocamento é feita em conjunto com a média dos resíduos e, principalmente, com RMSE, IQR e resolução. Dessa forma, o teste de localização não é utilizado como substituto de uma métrica de magnitude do erro.

5.13.2 Comparação de variâncias

Para a dispersão do resíduo, utiliza-se a razão

$$R_{\sigma^2} = \frac{\sigma^2_{\text{calib}}}{\sigma^2_{\text{fast}}}, \tag{5.44}$$

com hipótese direcional

$$H_0 : R_{\sigma^2} \geq 1 \qquad \text{versus} \qquad H_1 : R_{\sigma^2} < 1. \tag{5.45}$$

Como as duas séries de resíduos são pareadas, o teste de Pitman–Morgan é utilizado como referência principal para comparação de variâncias correlacionadas (PITMAN, 1939; MORGAN, 1939). Intervalos por *bootstrap* pareado complementam a inferência (DAVISON; HINKLEY, 1997). O teste F clássico é mantido apenas como comparação paramétrica de referência, pois sua interpretação é mais sensível às hipóteses de normalidade que não são satisfeitas pelos resíduos avaliados.

O teste de Pitman–Morgan incorpora explicitamente a correlação entre as duas séries, mas não é tratado nesta tese como um procedimento distribuição-livre. Por esse motivo, a avaliação de normalidade precede a interpretação inferencial e, quando são identificados desvios relevantes das hipóteses paramétricas, o resultado é confrontado com o *bootstrap* pareado. A decisão sobre diferença de dispersão não é baseada em um único teste, mas interpretada conjuntamente com a razão de variâncias e com as métricas de resolução e dispersão.

Todos os testes utilizam nível de significância $\alpha = 0{,}05$. Para os testes paramétricos de localização, são reportados estatística, valor-p e intervalo unilateral de 95%; para Wilcoxon, a tese registra a decisão qualitativa como verificação não paramétrica complementar; e, na comparação de variâncias, são reportados R_{σ^2} e o limite superior do intervalo unilateral associado ao procedimento principal, complementados pelo *bootstrap* pareado. A conclusão inferencial é expressa como "rejeitar" ou "não rejeitar" H_0.

O tamanho da amostra torna possível obter valores-p extremamente pequenos mesmo para diferenças de pequena importância prática. Por isso, significância estatística não é interpretada isoladamente. As decisões inferenciais são acompanhadas pela magnitude das diferenças em RMSE, IQR, razão de variâncias, resolução e resposta a limiar, bem como pela avaliação de estabilidade regional. A relevância prática deve, portanto, ser estabelecida a partir da combinação entre significância estatística e tamanho do efeito observado nos capítulos de resultados. Como diferentes configurações são examinadas ao longo dos estudos, os valores-p reportados para as configurações representativas são utilizados como evidência complementar nas comparações apresentadas e não como um procedimento de controle global do erro de múltiplas comparações sobre todo o conjunto de modelos avaliados.

5.14 Reprodutibilidade e implementação

A implementação foi organizada em uma cadeia de preparação de dados, construção da representação, treinamento, seleção de hiperparâmetros, inferência e avaliação. O conjunto simulado empregado nos experimentos é público (SILVA; SIMAS FILHO, 2025), e as implementações utilizam bibliotecas consolidadas de computação científica e aprendizado de máquina. Por exemplo, os modelos de *gradient boosting* utilizam LightGBM (KE et al., 2017).

Para assegurar rastreabilidade, o Apêndice A documenta o ambiente de software, as bibliotecas utilizadas, as sementes pseudoaleatórias, os espaços de busca de hiperparâmetros, as

configurações finais rastreáveis e o procedimento mínimo necessário para reproduzir os resultados consolidados.

Nas etapas que utilizam procedimentos estocásticos, sementes fixas são empregadas para tornar reproduzíveis as partições e inicializações documentadas. A reprodutibilidade, contudo, não deve ser confundida com ausência de variabilidade estatística. Resultados dependem da amostra Monte Carlo, do procedimento de treinamento e da realização das variáveis aleatórias; por isso, a avaliação independente e as medidas de dispersão continuam necessárias mesmo quando a execução é determinística sob uma semente fixa.

O custo de construção dos anéis não é atribuído aos regressores. Ao comparar tempos de $f_{\mathrm{ML}}(\cdot)$, mede-se o custo incremental do modelo após a disponibilidade da representação. Uma avaliação de implantação completa deve contabilizar também $g_{\mathrm{ML}}(\cdot)$ quando houver transformação em inferência, construção do Ringer, movimentação de dados e demais componentes da cadeia.

5.15 Limitações e níveis de validade

A metodologia foi desenhada para responder às questões de pesquisa da tese dentro de um ambiente controlado. Para impedir extrapolações indevidas, as principais limitações são explicitadas a seguir.

1. **Simulação versus dados.** A verdade E_{true} e o alvo α_{true} existem apenas em Monte Carlo. Não foi realizada nesta tese uma calibração *in situ* com dados reais ou ajuste de $Z \to e^+e^-$.

2. **Domínio geométrico.** A amostra principal de elétrons está restrita ao barril do *benchmark*. O desempenho não é demonstrado para toda a aceitação do ATLAS.

3. ***Pile-up.*** A amostra contém *pile-up*, mas não constitui uma varredura controlada de $\langle\mu\rangle$. Portanto, não se demonstra invariância a diferentes regimes de ocupação.

4. **Fundo e taxa de *trigger*.** O conjunto principal é composto por elétrons e não permite medir a taxa de jatos aceitos como elétrons. As curvas de aceitação descrevem resposta energética de sinal, não a eficiência e a taxa completas de um menu operacional.

5. **Validação de processo físico.** A avaliação é realizada no nível do candidato individual. Não se demonstra, nesta etapa, a melhoria de massa invariante em $Z \to e^+e^-$ ou em outros processos.

6. **Hardware de destino.** Tempos de predição em CPU de propósito geral não estabelecem latência em HLT. Uma conclusão de implantação requer testes na plataforma de destino e medição ponta a ponta.

7. **Arquitetura GNN.** A comparação DNN–GNN é uma comparação entre arquiteturas completas. Sem ablações de arestas, ramos tabulares, descritores derivados e controles pareados em número de parâmetros, não se atribui causalmente eventual diferença de desempenho apenas à topologia do grafo.

Essas limitações não invalidam o *benchmark*; elas definem o alcance das inferências que podem ser realizadas. A tese demonstra desempenho relativo de diferentes estratégias de calibração sob uma mesma resposta simulada e investiga compromissos de representação e modelagem. Validação externa é uma etapa posterior e distinta.

5.16 Relação entre o protocolo e as questões de pesquisa

O desenho experimental foi estruturado para que cada questão de pesquisa do Capítulo 1 possua evidência observável. A RQ1 é examinada pela comparação entre `Rings[1:100]`, `Rings/2`, CORR, MUTI, PCA e ICA. A RQ2 é respondida pelos regressores convencionais da primeira etapa. A RQ3 é investigada pelos ensembles residuais e empilhados. A RQ4 corresponde à avaliação das DNNs sobre entradas completas e compactas. A RQ5 é tratada pela comparação entre processamento neural tabular e a arquitetura relacional–tabular baseada em grafos. A RQ6 é avaliada pelo conjunto de métricas de erro, resolução, estabilidade regional, dimensionalidade e custo de predição.

Essa correspondência evita transformar os capítulos de resultados em uma sequência de rankings algorítmicos. Cada experimento passa a ter uma função explícita dentro da hipótese central da tese: determinar como a informação calorimétrica preservada na representação e a capacidade do estimador interagem na correção evento a evento da energia rápida.

5.17 Conclusão do capítulo

Este capítulo consolidou a metodologia experimental da tese e explicitou sua evolução ao longo dos três estudos. O núcleo comum é formado por um *benchmark* Monte Carlo Lorenzetti inspirado na calorimetria do ATLAS, uma amostra ampla de elétrons individuais, uma interface de 100 anéis e uma correção multiplicativa da estimativa Standard FastCalo. Sobre esse núcleo, diferentes operadores $g_{\mathrm{ML}}(\cdot)$ constroem representações completas ou compactas e diferentes funções treinadas $f_{\mathrm{ML}}(\cdot)$ estimam fatores de calibração por evento.

A consolidação também separou claramente o protocolo de (SILVA et al., 2026b) dos procedimentos posteriores (SILVA et al., 2026a; SILVA; SIMAS FILHO, 2026). A investigação inicial de treinamento segmentado e a otimização de bins por algoritmo genético são preservadas como parte da evolução da pesquisa.

Nas etapas posteriores, o ajuste de $g_{\mathrm{ML}}(\cdot)$ é realizado exclusivamente na partição de desenvolvimento, seguido por *nested cross-validation* 5×5 aplicada a $f_{\mathrm{ML}}(\cdot)$ nessa mesma partição e por avaliação final no teste independente. A Etapa I preserva o protocolo documentado no estudo original, com os valores científicos finais obtidos na partição independente de teste, sem atribuição retrospectiva da *nested cross-validation* utilizada nas etapas subsequentes.

A avaliação foi ampliada de métricas globais de erro para uma abordagem que inclui resolução relativa, comportamento regional, resposta próxima a limiares, análise estatística pareada e custo computacional. RMSE e IQR fornecem medidas complementares; d_0 resume apenas o plano de erro; D_0 é tratado como índice de engenharia dependente do conjunto

comparado; e o tempo medido em CPU é interpretado como custo amortizado do modelo treinado, não como latência do HLT.

Por fim, foram explicitados os limites de validade do estudo: o conjunto contém *pile-up*, mas não uma varredura controlada em $\langle\mu\rangle$; não há amostra de fundo suficiente para determinar taxa de *trigger*; a amostra principal está restrita ao barril; não foi realizada validação com dados reais ou em hardware de destino; e a etapa GNN não constitui uma ablação causal da topologia. Com esse protocolo estabelecido, o Capítulo 6 apresenta a primeira etapa experimental, centrada em representações reduzidas e regressores convencionais, seguida pelas extensões híbridas e neurais nos capítulos subsequentes.

6 Calibração com Modelos Convencionais e Redução de Dimensionalidade

Este capítulo apresenta os resultados da primeira etapa experimental da pesquisa, publicada na *IEEE Transactions on Nuclear Science* (TNS) em 2026 (SILVA et al., 2026b). O objetivo desta etapa foi avaliar se a informação calorimétrica codificada nos 100 anéis poderia ser utilizada para corrigir, evento a evento, a estimativa rápida de energia transversa e investigar em que medida representações compactas preservariam o desempenho de calibração.

As grandezas calorimétricas e a convenção para as energias transversais foram estabelecidas no Capítulo 2; a formulação do fator de calibração e os métodos de representação foram apresentados no Capítulo 3; e o protocolo experimental foi consolidado no Capítulo 5. Assim, o foco aqui é a evidência experimental produzida na Etapa I: o comportamento da resposta de referência, a informação contida nas representações, o desempenho dos regressores, o efeito da segmentação, a estabilidade regional, o compromisso entre erro e custo computacional, a resposta a limiar e a validação estatística.

6.1 Escopo da Etapa I

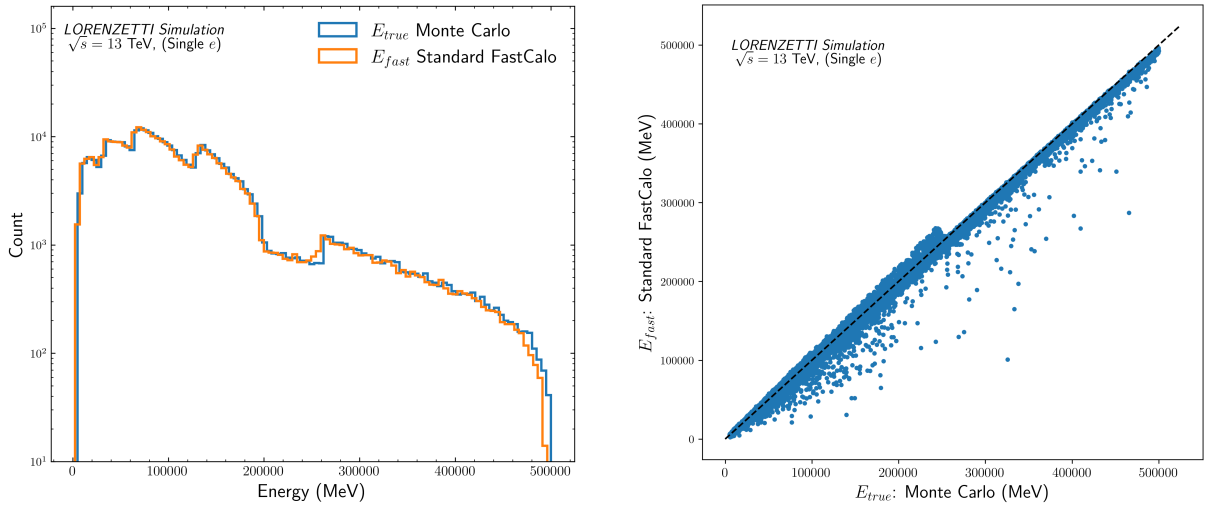
A Etapa I investigou quatro famílias de regressão: regressão linear multivariada (MLR), regressão polinomial de segundo grau (PReg), árvore de decisão (DTree) e *Gradient Boosted Decision Trees* (BDT). Esses modelos foram combinados com a representação completa de 100 anéis e com representações obtidas por correlação linear (CORR), informação mútua (MUTI), análise de componentes principais (PCA) e análise de componentes independentes (ICA). O BDT também foi avaliado em uma variante segmentada no espaço cinemático definido para o estudo, conforme o protocolo histórico descrito na Seção 5.6.1.

Os resultados apresentados neste capítulo correspondem ao protocolo da Etapa I e às avaliações realizadas na partição independente de teste correspondente a 30% do conjunto (SILVA et al., 2026b). A amostra é composta por aproximadamente 3×10^5 eventos simulados de elétrons individuais, e as representações e regressores são comparados sob o mesmo *benchmark*, permitindo avaliar diretamente o efeito da redução de dimensionalidade e da escolha do modelo sobre a calibração.

6.2 Resposta de referência do Standard FastCalo

A primeira questão experimental é verificar se a relação entre E_{fast} e E_{true} apresenta estrutura que possa ser explorada por um calibrador baseado em aprendizado de máquina. A Figura 19 apresenta as distribuições marginais e o gráfico de dispersão utilizados na Etapa I.

Embora as distribuições globais de E_{true} e E_{fast} apresentem formas semelhantes, a relação



(a) **(b)**

Figura 19 – Caracterização da resposta rápida no *benchmark* da Etapa I: (a) distribuições de E_{true} e E_{fast} no intervalo estudado; (b) relação evento a evento entre as duas grandezas. Observa-se dispersão da resposta e uma alteração mais pronunciada na região de aproximadamente 250 GeV, compondo o cenário de calibração avaliado pelos modelos. Adaptado de (SILVA et al., 2026b).

evento a evento evidencia dispersão e uma resposta não linear, incluindo uma alteração mais pronunciada na região de aproximadamente 250 GeV. Essa estrutura estabelece um cenário não trivial para a calibração: um modelo útil precisa reduzir a dispersão da estimativa rápida e, simultaneamente, acomodar variações locais da resposta ao longo do intervalo de energia estudado.

Os resultados apresentados nas seções seguintes mostram que os modelos baseados em árvores, em particular os BDTs, foram capazes de explorar a informação contida nos anéis e reduzir substancialmente os erros em relação ao Standard FastCalo. A análise dessa melhoria começa pela identificação de quais anéis ou componentes transformados concentram a informação mais relevante para a tarefa de calibração.

6.3 Informação dos anéis e representações compactas

A Figura 20 resume a relação entre a representação de 100 anéis e a variável de referência utilizada para construir as representações compactas da Etapa I. CORR e MUTI operam diretamente sobre os anéis originais e, portanto, permitem associar os atributos selecionados às regiões calorimétricas. PCA e ICA, por outro lado, produzem componentes transformados e seus índices não correspondem a posições físicas individuais no calorímetro.

A Tabela 6 resume as representações avaliadas. Para uniformidade de nomenclatura ao longo da tese, as configurações completas de PCA e ICA são denotadas, respectivamente, por `PCA-100` e `ICA-100`. No protocolo da Etapa I, os componentes de PCA e ICA utilizados nas representações reduzidas foram ordenados por relevância em relação a E_{true}, e as configurações `PCA-`m e `ICA-`m correspondem às m componentes retidas após essa ordenação (SILVA et al., 2026b).

As técnicas de seleção produziram reduções agressivas da dimensionalidade. CORR reteve

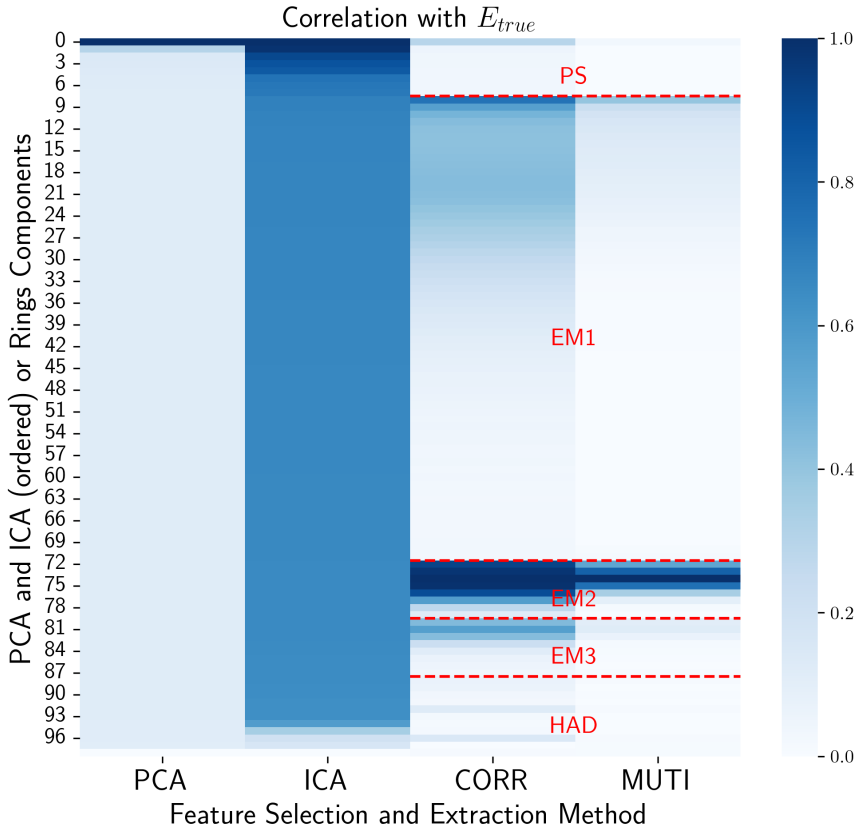


Figura 20 – Mapa de relevância das variáveis ou componentes empregado na Etapa I para CORR, MUTI, PCA e ICA. As fronteiras entre regiões calorimétricas têm interpretação física somente para CORR e MUTI, que atuam sobre os anéis originais. Componentes PCA e ICA são combinações transformadas e não possuem correspondência um a um com as posições dos anéis. Adaptado de (SILVA et al., 2026b).

Tabela 6 – Representações avaliadas na Etapa I. Para CORR e MUTI, os índices referem-se aos anéis originais. Para PCA e ICA, indicam componentes transformados.

Representação	**Variáveis/componentes retidos**	F
Rings[1:100]	Rings[1:100]	100
CORR-50	Rings[8, 9, 72, 73, 74, 75, 76, 77, 81]	9
CORR-70	Rings[8, 72, 73, 74, 75, 76]	6
CORR-80	Rings[72, 73, 74, 75, 76]	5
CORR-90	Rings[72, 73, 74, 75]	4
MUTI-50	Rings[72, 73, 74, 75]	4
MUTI-70	Rings[73, 74, 75]	3
MUTI-80	Rings[73, 74]	2
MUTI-90	Rings[74]	1
PCA-100	PCA[1:100]	100
PCA-10	PCA[1:10]	10
PCA-5	PCA[1:5]	5
PCA-2	PCA[1:2]	2
ICA-100	ICA[1:100]	100
ICA-10	ICA[1:10]	10
ICA-5	ICA[1:5]	5
ICA-2	ICA[1:2]	2

de nove a quatro anéis conforme o limiar utilizado, enquanto MUTI chegou a representações de apenas um ou dois anéis. Um resultado particularmente informativo é que `CORR-90` e `MUTI-50` selecionaram o mesmo conjunto $[72, 73, 74, 75]$, o que explica a forte sobreposição observada posteriormente entre suas respostas.

Pela convenção estabelecida na Eq. 2.10, esses anéis se concentram na transição entre o final da camada EM1 e o início da EM2, região na qual o chuveiro eletromagnético deposita parcela relevante de sua energia. Esse resultado fornece uma interpretação física para a eficiência das seleções baseadas em CORR e MUTI: uma pequena fração da representação original concentra informação fortemente associada ao fator de calibração.

PCA e ICA fornecem uma perspectiva complementar. Em vez de selecionar anéis individuais, essas técnicas reorganizam a informação em um espaço transformado. A questão experimental, portanto, deixa de ser apenas quais anéis devem ser mantidos e passa a incluir quanto da capacidade preditiva pode ser preservada quando a representação é substituída por um número reduzido de componentes latentes. Essa questão é respondida diretamente pela comparação de desempenho apresentada a seguir.

6.4 Desempenho global da calibração

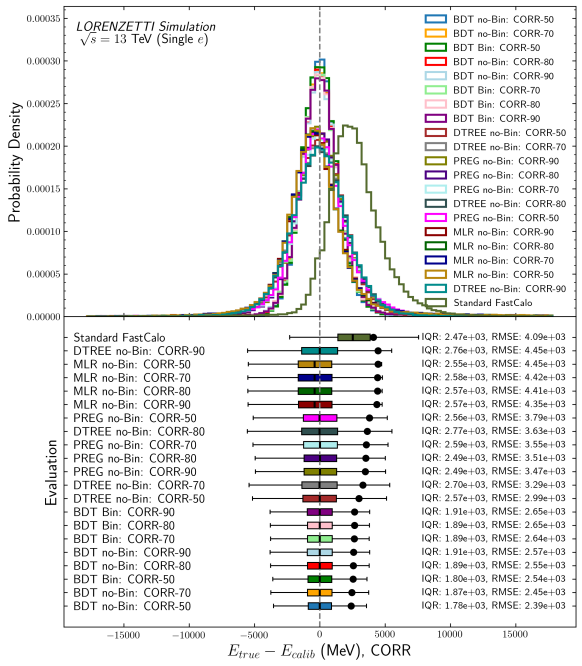
A Figura 21 apresenta as distribuições do erro $\varepsilon_{\text{calib}} = E_{\text{true}} - E_{\text{calib}}$ para as quatro famílias de representação avaliadas. Os boxplots devem ser lidos em conjunto com o RMSE: o IQR caracteriza a dispersão da região central da distribuição, enquanto o RMSE atribui maior peso aos desvios de maior magnitude.

As distribuições mostram que as melhores configurações se concentram entre os BDTs sem segmentação. Em comparação com MLR, PReg e DTree, os BDTs produziram distribuições mais estreitas e menores valores de RMSE nas representações de maior desempenho. Esse comportamento indica que, no conjunto estudado, a relação entre a estrutura dos depósitos calorimétricos e o fator de correção é suficientemente não linear para favorecer o conjunto de árvores impulsionadas.

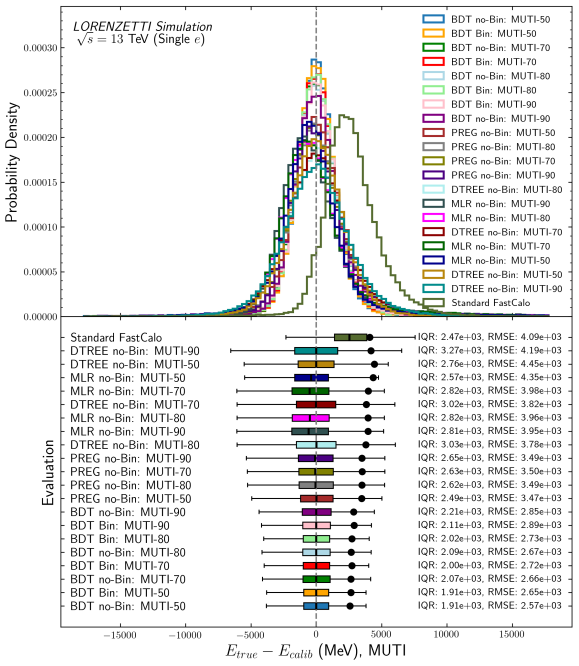
A Tabela 7 consolida as configurações de maior destaque da Etapa I no conjunto de teste independente. As porcentagens correspondem às reduções relativas ao *Standard FastCalo* da própria etapa.

Entre as estratégias baseadas em seleção dos anéis originais, `BDT no-Bin: CORR-50` reduziu o IQR em 27,94% e o RMSE em 41,56%, enquanto `BDT no-Bin: MUTI-50` alcançou reduções de 22,67% e 37,16%, respectivamente. Esses resultados já mostram que representações com nove ou quatro entradas podem melhorar substancialmente a referência.

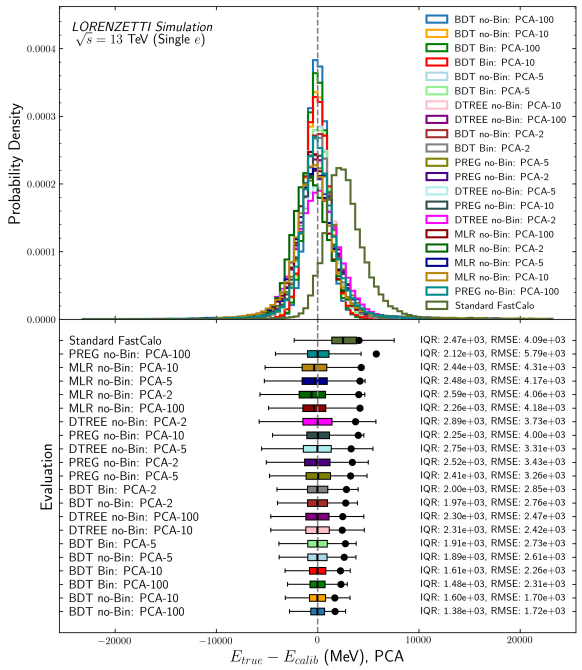
Quando a entrada foi substituída por componentes transformados, os ganhos aumentaram. `BDT no-Bin: ICA-100` reduziu o IQR em 40,49% e o RMSE em 49,88%. As configurações baseadas em PCA apresentaram os melhores resultados globais da etapa: `BDT no-Bin: PCA-100` atingiu o menor d_0, 2,21 GeV, correspondente a uma redução de 53,85%, enquanto `BDT no-Bin: PCA-10` apresentou o menor RMSE, 1,70 GeV, com redução de 58,44% em relação ao *Standard FastCalo* (SILVA et al., 2026b).



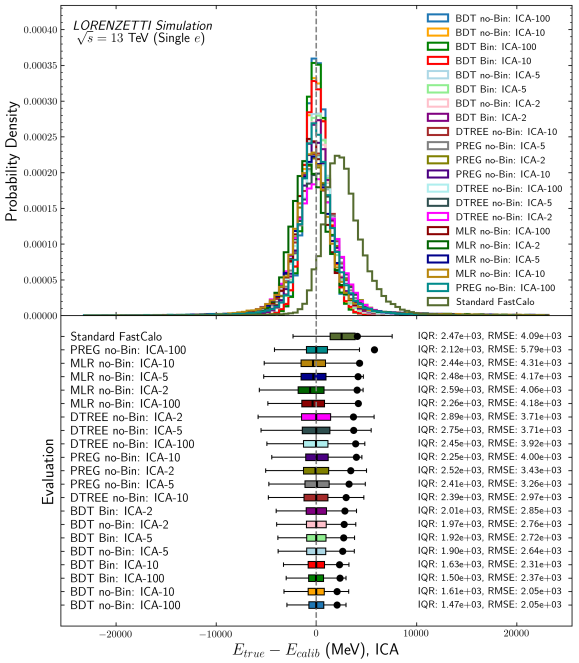
(a) CORR



(b) MUTI



(c) PCA



(d) ICA

Figura 21 – Distribuições do erro de calibração e boxplots para combinações representativas de regressão e redução de dimensionalidade na Etapa I: (a) correlação; (b) informação mútua; (c) PCA; (d) ICA. O ponto indicado nos gráficos originais representa o RMSE, enquanto a largura da caixa corresponde ao IQR. Adaptado de (SILVA et al., 2026b).

Tabela 7 – Desempenho global das configurações de maior destaque da Etapa I no conjunto de teste independente. As porcentagens correspondem à redução relativa ao *Standard FastCalo* da mesma etapa. Excluindo o *Standard FastCalo* os valores estão ordenados Δd_0 de forma decrescente.

Método	**IQR (GeV)**	**RMSE (GeV)**	d_0 **(GeV)**	**ΔIQR**	**ΔRMSE**	Δd_0
Standard FastCalo	2,47	4,09	4,78	–	–	–
BDT no-Bin: PCA-100	1,38	1,72	2,21	44,13%	57,95%	53,85%
BDT no-Bin: PCA-10	1,60	1,70	2,33	35,22%	58,44%	51,14%
BDT no-Bin: ICA-100	1,47	2,05	2,52	40,49%	49,88%	47,20%
BDT no-Bin: ICA-10	1,61	2,05	2,61	34,82%	49,88%	45,44%
BDT no-Bin: CORR-50	1,78	2,39	2,98	27,94%	41,56%	37,63%
BDT no-Bin: CORR-70	1,87	2,45	3,08	24,29%	40,10%	35,49%
BDT no-Bin: MUTI-50	1,91	2,57	3,20	22,67%	37,16%	32,98%
BDT Bin: MUTI-50	1,91	2,65	3,27	22,67%	35,21%	31,63%

A comparação entre PCA-100 e PCA-10 evidencia o principal resultado de compactação desta etapa. A representação com dez componentes produziu o menor RMSE mesmo utilizando apenas um décimo da dimensionalidade da representação completa em PCA. Por outro lado, PCA-100 manteve menor IQR e menor d_0. Portanto, o ganho obtido com a compactação depende da métrica de interesse: reduzir a dimensionalidade não implica necessariamente perda relevante de capacidade preditiva, mas a configuração mais compacta não domina simultaneamente todos os critérios.

Em conjunto, os resultados mostram uma progressão consistente: as seleções CORR e MUTI já superam a referência com poucos anéis; ICA amplia os ganhos ao explorar componentes latentes; e PCA fornece as melhores combinações de RMSE, IQR e d_0 entre as representações avaliadas. Essa evidência sustenta a utilização de representações compactas nas etapas seguintes da pesquisa.

6.5 Treinamento global e treinamento segmentado

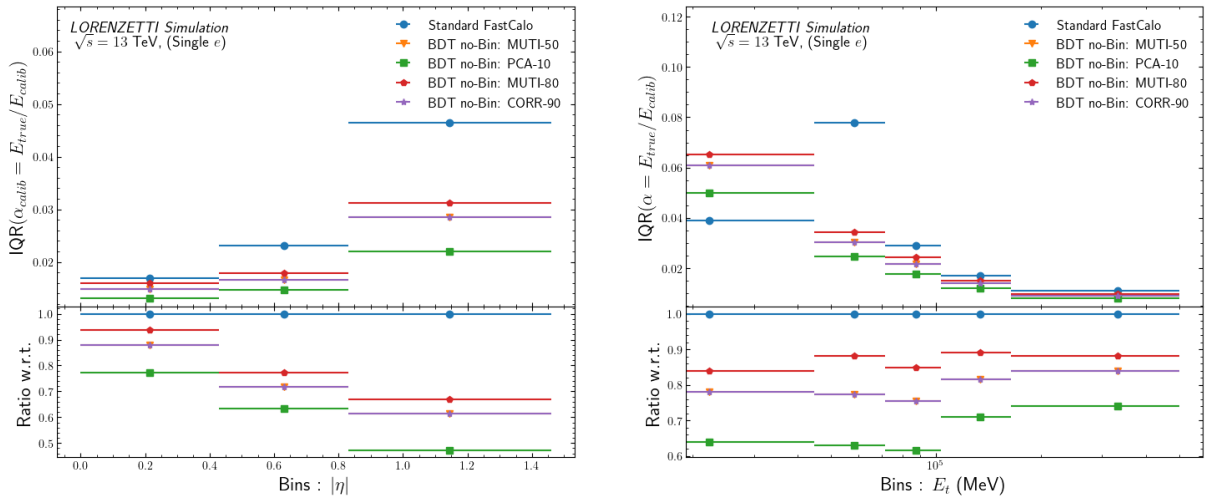
A Etapa I também avaliou se a especialização do BDT em regiões do espaço $(|\eta|, E_{\text{true}})$ produziria ganho em relação ao treinamento global. O mecanismo de construção dos 15 segmentos é descrito na Seção 5.6.1; nesta seção, interessa o efeito dessa escolha sobre o desempenho observado.

Na comparação diretamente disponível na Tabela 7, `BDT no-Bin: MUTI-50` obteve RMSE de 2,57 GeV e $d_0 = 3{,}20$ GeV, enquanto `BDT Bin: MUTI-50` apresentou RMSE de 2,65 GeV e $d_0 = 3{,}27$ GeV. Para essa representação, portanto, o treinamento global foi numericamente superior no conjunto de teste.

Esse resultado mostra que a segmentação não produz ganho automático. A especialização regional pode reduzir a heterogeneidade local do problema, mas também divide a amostra disponível entre regressores independentes. No conjunto avaliado, o benefício potencial da segmentação não compensou essa fragmentação estatística, e o BDT global permaneceu competitivo ou superior. A constatação contribuiu para a evolução posterior da metodologia, na qual as regiões passaram a ser usadas principalmente como diagnóstico de estabilidade do modelo global.

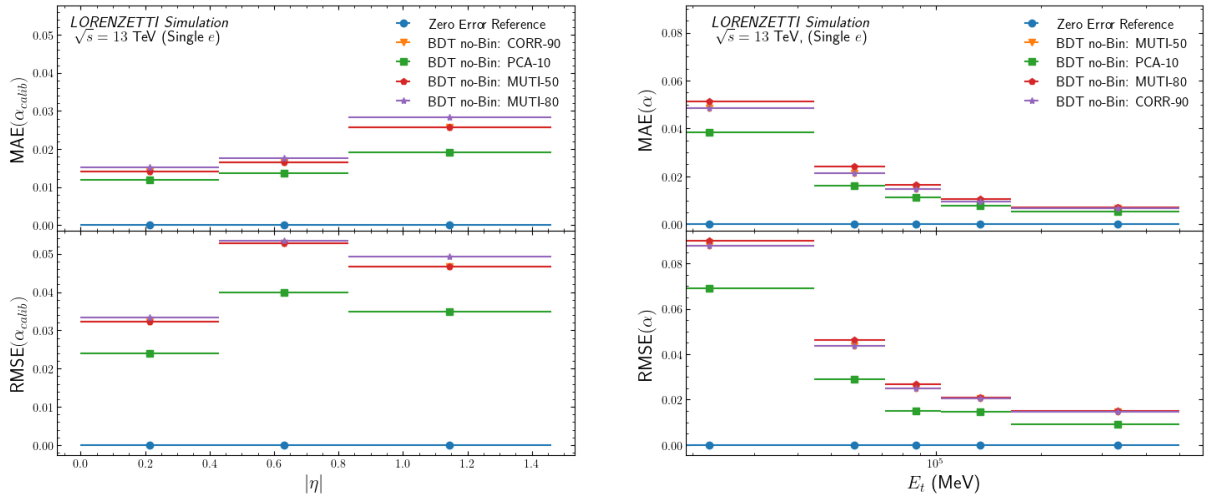
6.6 Análise Regional do Fator de Calibração em Segmentos de $|\eta|$ e E_T

Além das métricas globais, as configurações de melhor compromisso foram examinadas em função de $|\eta|$ e da energia transversa utilizada nos bins da Etapa I. Essa análise permite verificar se o desempenho agregado esconde degradações sistemáticas em regiões específicas do espaço cinemático.



(a) $|\eta|$ **(b)** E_T

Figura 22 – IQR do fator de calibração nas regiões de (a) pseudorapidez e (b) energia transversa utilizadas na Etapa I. A referência relativa do *Standard FastCalo* é fixada em unidade nos painéis normalizados. Adaptado de (SILVA et al., 2026b).



(a) $|\eta|$ **(b)** E_T

Figura 23 – MAE e RMSE do fator estimado α_{calib} em relação a α_{true} nas regiões de (a) $|\eta|$ e (b) E_T. Adaptado de (SILVA et al., 2026b).

A Figura 22 mostra que a dispersão do fator de calibração tende a aumentar com $|\eta|$ dentro da região de barril considerada. Em energia, observa-se comportamento oposto: o IQR do fator diminui nos bins de maior E_T. A Figura 23 apresenta tendência compatível, com redução de MAE e RMSE do fator à medida que a energia aumenta (SILVA et al., 2026b).

Também se observa forte sobreposição entre `CORR-90` e `MUTI-50`, consequência direta de

ambas utilizarem os mesmos quatro anéis. Esse resultado reforça que, quando diferentes critérios de seleção convergem para o mesmo subconjunto de atributos, o comportamento subsequente do regressor tende a ser semelhante.

Na região de menor energia, a maior dispersão do fator deve ser interpretada levando em conta sua natureza multiplicativa: flutuações em E_{fast} têm maior impacto relativo quando o denominador é pequeno. Assim, as tendências regionais do fator complementam, e não substituem, as métricas globais calculadas diretamente no domínio da energia.

A análise regional mostra, portanto, que o ganho global não é uniforme em todo o espaço cinemático. O desempenho depende da região de incidência e da escala de energia, o que motiva a inclusão de diagnósticos regionais mais sistemáticos nas etapas seguintes da tese.

6.7 Compromisso entre erro, dimensionalidade e custo de predição

A Etapa I também investigou se os ganhos de calibração poderiam ser preservados com representações pequenas e modelos de inferência relativamente leves. A Figura 24 apresenta quatro visões complementares: RMSE versus IQR, d_0 versus tempo de predição, d_0 versus número de atributos e o ranking pelo índice D_0.

A Tabela 8 resume configurações compactas representativas desse compromisso. O tempo T corresponde à medição de predição do modelo treinado no ambiente computacional utilizado na Etapa I.

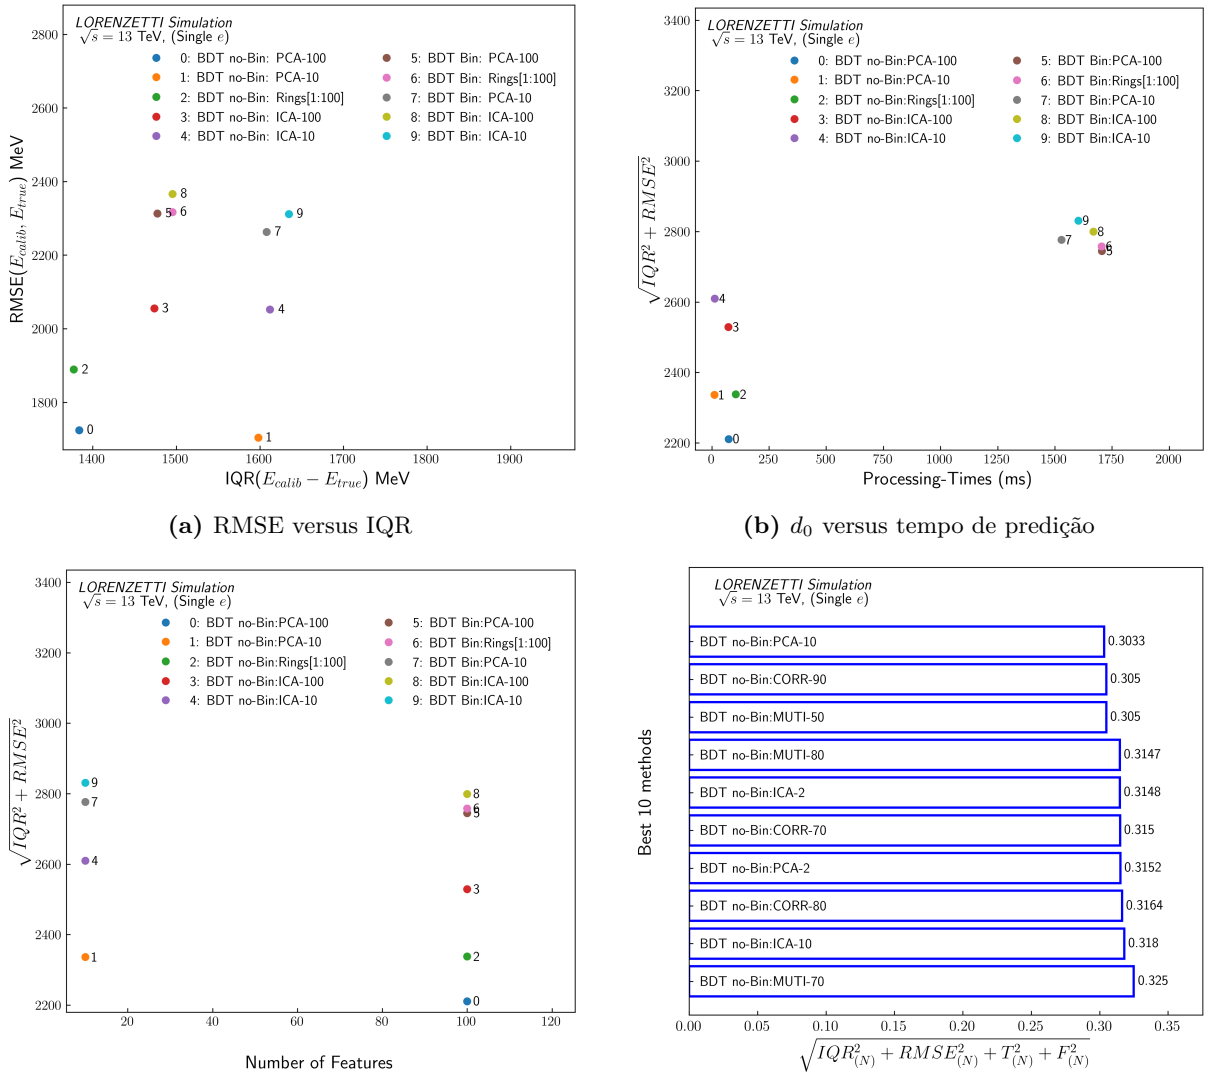
Tabela 8 – Configurações compactas destacadas pelo compromisso de engenharia na Etapa I. T é o tempo de predição medido no ambiente computacional do estudo e não a latência de ponta a ponta de um sistema de *trigger*.

Método	d_0 **(GeV)**	Δd_0	T **(ms/evento)**	F
Standard FastCalo	4,78	–	–	–
BDT no-Bin: PCA-10	2,33	51,14%	9,35	10
BDT no-Bin: CORR-90	3,20	33,00%	3,29	4
BDT no-Bin: MUTI-50	3,20	32,98%	4,35	4
BDT no-Bin: MUTI-80	3,39	29,05%	2,22	2
BDT no-Bin: ICA-2	3,39	29,05%	1,91	2

A configuração `BDT no-Bin: PCA-10` combina o menor RMSE da etapa com dez componentes e tempo de predição de 9,35 ms por evento. Configurações ainda menores reduzem mais o custo computacional: `CORR-90` utiliza quatro atributos e apresenta 3,29 ms por evento; `MUTI-50`, também com quatro atributos, apresenta 4,35 ms; e `MUTI-80` e `ICA-2`, com duas entradas, atingem 2,22 ms e 1,91 ms, respectivamente (SILVA et al., 2026b).

Esses valores evidenciam uma fronteira de compromisso entre precisão, dimensionalidade e custo. PCA-100 fornece o menor d_0 entre as configurações de maior desempenho, PCA-10 preserva desempenho muito próximo com apenas dez componentes e as representações com dois a quatro atributos sacrificam parte da precisão em troca de menor dimensionalidade e menor tempo de predição.

O índice D_0 complementa essa leitura ao combinar RMSE, IQR, dimensionalidade e tempo



(a) RMSE versus IQR

(b) d_0 versus tempo de predição

(c) d_0 versus número de atributos

(d) ranking pelo índice D_0

Figura 24 – Compromissos entre qualidade de calibração, dimensionalidade e tempo de predição medidos na Etapa I. O índice D_0 deve ser interpretado apenas como critério de ordenação normalizado dentro do conjunto comparado, e não como grandeza física ou requisito universal de implantação. Adaptado de (SILVA et al., 2026b).

após normalização. Seu papel nesta etapa é ordenar configurações segundo um compromisso de engenharia; por isso, a interpretação permanece apoiada também nas quatro quantidades individuais. O resultado relevante é que diferentes configurações ocupam regiões distintas dessa fronteira e que não existe uma solução única que domine simultaneamente precisão e custo.

Os tempos medidos representam o custo de inferência no ambiente computacional do estudo. Assim, são úteis para comparar as configurações entre si e mostram que os ganhos de calibração podem ser obtidos com modelos compactos, embora não constituam, isoladamente, uma medição da latência de ponta a ponta de uma cadeia operacional de *trigger*.

6.8 Resposta a limiar e aceitação de eventos

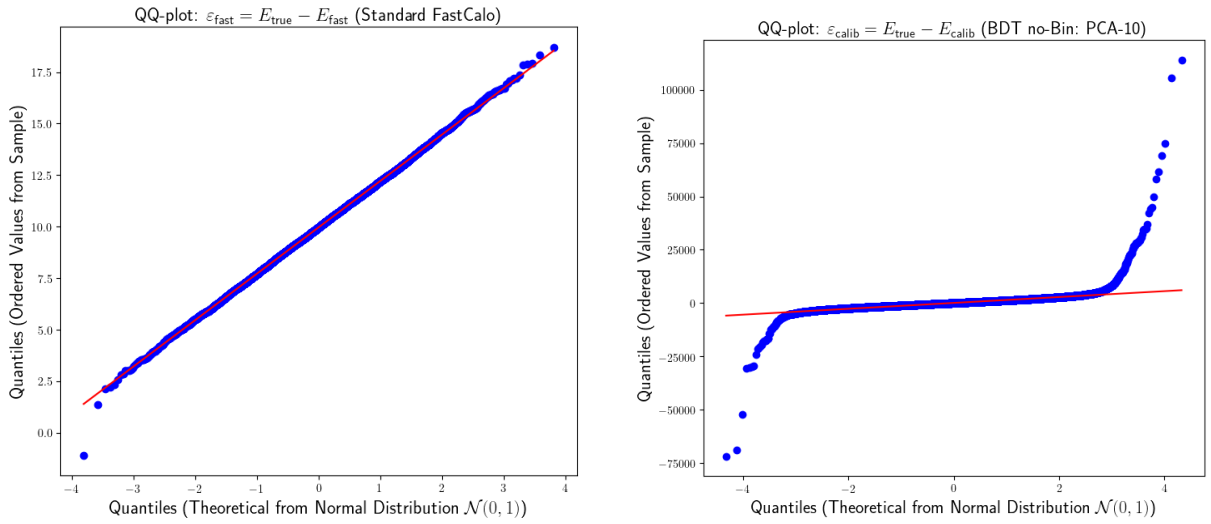
A análise de aceitação publicada para a Etapa I comparou `BDT no-Bin: PCA-10` ao Standard FastCalo. Na convenção de $\Delta\lambda$ empregada nesse estudo, o modelo calibrado atingiu 90% de aceitação em aproximadamente 2,05 GeV, enquanto a referência atingiu o mesmo nível em aproximadamente 5,51 GeV. No ponto de maior separação entre as curvas, em torno de $\Delta\lambda = 1{,}69$ GeV, a configuração baseada em BDT apresentou aceitação próxima de 85%, contra aproximadamente 30% para o *Standard FastCalo* (SILVA et al., 2026b).

O deslocamento observado é consistente com a redução dos erros de calibração: uma distribuição reconstruída mais concentrada em torno da referência modifica a migração dos elétrons em torno do critério de aceitação. Dessa forma, o ganho observado nas métricas globais também se manifesta em uma resposta de seleção mais favorável para a amostra de sinal considerada na Etapa I.

Essa análise caracteriza a resposta dos elétrons no *benchmark*. A quantificação do impacto sobre eficiência de sinal e taxa de fundo de uma cadeia operacional requer, adicionalmente, uma amostra representativa de fundo e critérios completos de identificação. Essa delimitação é retomada de forma concisa na Seção 6.10.

6.9 Validação estatística

A validação estatística foi realizada de forma pareada porque E_{fast} e E_{calib} são avaliados para os mesmos eventos. Os testes de D'Agostino–Pearson e Anderson–Darling rejeitaram normalidade para as distribuições de resíduos e suas diferenças pareadas, com $p < 10^{-16}$ nas configurações examinadas. A Figura 25 ilustra os desvios nas caudas para a referência e para uma das configurações de melhor desempenho.



(a) Standard FastCalo **(b)** BDT no-Bin: PCA-10

Figura 25 – Gráficos Q–Q representativos para os resíduos da referência e da configuração `BDT no-Bin: PCA-10`. Os desvios nas caudas justificam o uso complementar de inferência não paramétrica e *bootstrap*. Adaptado de (SILVA et al., 2026b).

Para a diferença pareada d definida no Capítulo 5, a Tabela 9 apresenta os resultados do

teste z pareado e do teste de Wilcoxon. O teste t pareado produziu resultados numericamente equivalentes aos do teste z nesta amostra e, por concisão, não é repetido na tabela.

Tabela 9 – Inferência pareada para o deslocamento do resíduo na Etapa I. Os intervalos são unilaterais de 95%. "Rejeita" significa rejeição de H_0 no nível de significância adotado.

Método	z	p_z	**IC$_{95\%}$ para μ_d (MeV)**	**Wilcoxon: decisão**
BDT no-Bin: PCA-10	-351,7106	$< 10^{-300}$	$(-\infty, -2731{,}04]$	Rejeita H_0
BDT no-Bin: CORR-90	-540,8462	$< 10^{-300}$	$(-\infty, -2688{,}43]$	Rejeita H_0
BDT no-Bin: MUTI-80	-623,1838	$< 10^{-300}$	$(-\infty, -2644{,}00]$	Rejeita H_0
BDT no-Bin: MUTI-50	-540,8462	$< 10^{-300}$	$(-\infty, -2688{,}43]$	Rejeita H_0

Em todas as configurações apresentadas, a hipótese nula para o deslocamento foi rejeitada com ampla margem. Esses resultados mostram que a distribuição dos resíduos após a calibração difere sistematicamente da referência. A interpretação do ganho, entretanto, não depende apenas do sinal desse deslocamento: ela é feita em conjunto com as reduções observadas de RMSE e IQR e com a análise de dispersão.

A Tabela 10 apresenta as razões de variância observadas e o limite superior do intervalo unilateral associado ao teste de Pitman–Morgan. O *bootstrap* pareado BCa foi utilizado como verificação robusta, preservando a estrutura pareada das observações.

Tabela 10 – Comparação da variância dos resíduos na Etapa I. A razão é $R_{\sigma^2} = \sigma^2_{\text{calib}}/\sigma^2_{\text{fast}}$; valores inferiores a 1 indicam menor variância após calibração.

Método	R_{σ^2}	**redução de variância**	**limite superior IC$_{95\%}$ PM**
BDT no-Bin: PCA-10	0,3230	67,70%	0,3472
BDT no-Bin: CORR-90	0,7349	26,51%	0,7642
BDT no-Bin: MUTI-80	0,7914	20,86%	0,8147
BDT no-Bin: MUTI-50	0,7349	26,51%	0,7642

Todos os limites superiores permanecem abaixo da unidade, fornecendo evidência de menor variância dos resíduos após a calibração para as configurações avaliadas. Para `BDT no-Bin: PCA-10`, por exemplo, a razão de variâncias é 0,3230, correspondente a uma redução de aproximadamente 67,7% da variância em relação ao Standard FastCalo. CORR-90, MUTI-80 e MUTI-50 também apresentam razões inferiores à unidade.

O *bootstrap* pareado com 5000 reamostragens conduziu à mesma decisão qualitativa, com menor valor de p resolvível igual a $1/5000 = 0{,}0002$. A convergência entre métricas de efeito e procedimentos estatísticos distintos reforça que as diferenças observadas não se explicam apenas por flutuações amostrais.

Como a amostra é grande, valores de p muito pequenos devem ser interpretados em conjunto com a magnitude dos efeitos. Neste capítulo, a relevância prática é sustentada principalmente pelas reduções de RMSE e IQR, pela diminuição de d_0 e pelas razões de variância, enquanto os testes de hipótese fornecem suporte inferencial às diferenças observadas.

6.10 Escopo dos resultados da Etapa I

Os resultados desta etapa foram obtidos no *benchmark* Monte Carlo descrito no Capítulo 5, com elétrons individuais e presença de *pile-up* na configuração simulada. O estudo não realizou uma varredura controlada de desempenho em função do nível de *pile-up*; portanto, os resultados não quantificam a robustez da calibração frente a diferentes regimes de ocupação.

A avaliação também não inclui dados experimentais nem uma amostra de fundo adequada para estimar taxas de jatos reconstruídos como elétrons. Essas limitações definem o domínio empírico da Etapa I, mas não alteram suas conclusões centrais dentro do conjunto avaliado: os modelos de calibração reduziram substancialmente o erro do Standard FastCalo, representações compactas preservaram grande parte desse ganho e os BDTs sem segmentação produziram os melhores desempenhos entre as famílias convencionais investigadas.

6.11 Conclusão do capítulo

A primeira etapa experimental mostrou que a informação calorimétrica codificada na representação Ringer permite aprender uma correção evento a evento capaz de reduzir substancialmente o erro da estimativa *Standard FastCalo* no *benchmark* avaliado. Entre os regressores convencionais investigados, os BDTs sem segmentação concentraram os melhores resultados.

A extração por PCA apresentou o melhor desempenho global. `BDT no-Bin: PCA-100` obteve o menor d_0, com redução de 53,85% em relação ao Standard FastCalo, enquanto `BDT no-Bin: PCA-10` atingiu o menor RMSE, 1,70 GeV, correspondente a uma redução de 58,44%, utilizando somente dez componentes. As configurações baseadas em ICA, CORR e MUTI também reduziram de forma expressiva o erro, mostrando que diferentes formas de compactação preservam informação relevante para a calibração.

A comparação entre treinamento global e segmentado mostrou que o aumento de especialização regional não resultou automaticamente em melhor desempenho. Paralelamente, a análise regional evidenciou dependências do fator de calibração com $|\eta|$ e energia, enquanto a avaliação de custo mostrou que configurações com poucos atributos podem manter ganhos relevantes com menores tempos de predição. A análise de aceitação também apresentou deslocamento favorável da curva para a configuração `BDT no-Bin: PCA-10` em relação ao Standard FastCalo.

Por fim, os testes estatísticos pareados forneceram suporte às diferenças observadas nas métricas de erro e dispersão. Em conjunto, esses resultados estabelecem a principal conclusão da Etapa I: representações calorimétricas compactas e modelos não lineares podem melhorar significativamente a calibração rápida de energia no domínio simulado considerado.

A partir desses resultados, o capítulo seguinte amplia a investigação para *ensembles* baseados em *Random Forest* e BDT, aprendizado residual e modelos empilhados, mantendo a calibração baseada em anéis e expandindo o protocolo de avaliação.

7 Calibração com Ensembles e Aprendizado Residual

Este capítulo apresenta os resultados da segunda etapa experimental da pesquisa, publicada na revista *Measurement* em 2026 (SILVA et al., 2026a). A Etapa I estabeleceu que a representação Ringer contém informação suficiente para melhorar a estimativa rápida de energia transversa e que parte relevante desse ganho pode ser preservada em representações compactas. A Etapa II amplia essa investigação ao introduzir *Random Forest*, aprendizado residual e combinação de modelos, além de avaliar de forma mais ampla o compromisso entre precisão, dimensionalidade e custo de predição.

As definições da calibração, das representações e das famílias de regressão foram apresentadas nos Capítulos 3 e 4, enquanto o protocolo experimental é formalizado no Capítulo 5. O foco deste capítulo é, portanto, a evidência produzida pela Etapa II: quais representações e arquiteturas reduziram mais o erro, quanto o aprendizado residual acrescentou em relação aos modelos individuais, como o desempenho se comporta regionalmente e em resolução de energia, e quais configurações oferecem os melhores compromissos entre qualidade e compactação.

7.1 Escopo da Etapa II

A Etapa II compara seis famílias de regressão baseadas em árvores: DTree, BDT, *Random Forest* (RFOR) e três combinações de *ensemble*. No BDTRF, o BDT fornece a primeira estimativa e a *Random Forest* aprende a correção residual; no RFBDT, a ordem é invertida; e no RFBDTS as previsões de *Random Forest* e BDT são combinadas por um meta-regressor linear regularizado. O objetivo experimental é verificar se mecanismos de redução de variância, *boosting*, correção residual e empilhamento exploram informação complementar na calibração baseada em anéis.

A comparação utiliza `Rings[1:100]`, `Rings/2` e representações CORR, MUTI, PCA e ICA com cardinalidades controladas $m \in \{50, 10, 5, 2\}$. Com seis regressores, esse desenho produz 108 configurações experimentais (SILVA et al., 2026a). Todos os modelos são treinados globalmente; as regiões de $(|\eta|, E_T)$ são utilizadas apenas na avaliação *a posteriori*. A seleção de hiperparâmetros permanece restrita a $\mathcal{D}_{70}$, e os resultados finais são obtidos na partição independente $\mathcal{D}_{30}$, conforme o protocolo da Seção 5.7.2.

Além de RMSE, IQR e d_0, a Etapa II incorpora o índice D_0, a resolução relativa de energia, diagnósticos regionais, resposta a limiar, análise evento a evento, inferência estatística pareada e custo de predição. Essa ampliação permite avaliar não apenas a melhor precisão absoluta, mas também a existência de soluções compactas que preservem parte substancial do ganho.

7.2 Representações com cardinalidade controlada

A Tabela 11 resume as representações avaliadas. A utilização das mesmas cardinalidades para CORR, MUTI, PCA e ICA permite separar o efeito do método de representação do simples efeito do número de entradas.

Tabela 11 – Representações avaliadas na Etapa II. Para CORR e MUTI, m corresponde ao número de anéis originais retidos; para PCA e ICA, corresponde ao número de componentes transformados.

Representação	**Regra de construção**	F
Rings[1:100]	representação completa	100
Rings/2	subamostragem determinística por região calorimétrica	50
CORR-m	m anéis com maior relevância por correlação	50; 10; 5; 2
MUTI-m	m anéis com maior informação mútua	50; 10; 5; 2
PCA-m	m componentes principais	50; 10; 5; 2
ICA-m	m componentes independentes	50; 10; 5; 2

A cardinalidade controlada torna comparáveis dois regimes de interesse. No primeiro, preservam-se muitos atributos ou a representação completa para maximizar a informação disponível ao regressor. No segundo, a entrada é reduzida a cinco, dez ou até dois atributos/componentes, permitindo verificar quanto desempenho pode ser mantido em um espaço de baixa dimensão.

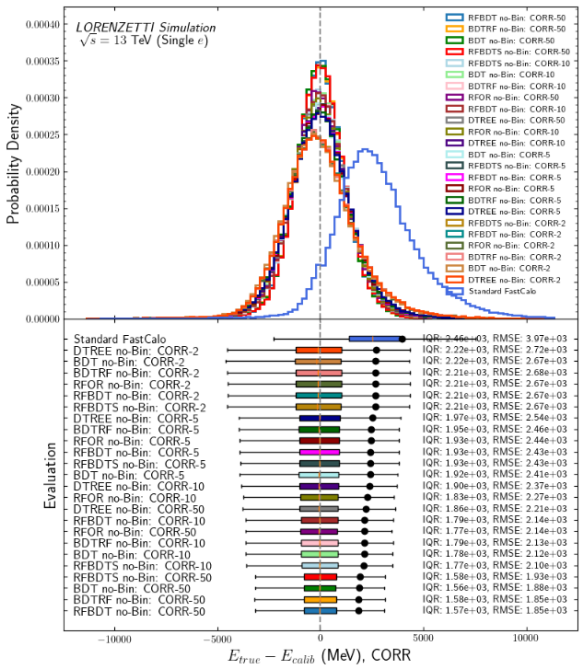
CORR e MUTI selecionam anéis originais, enquanto PCA e ICA fornecem componentes latentes. Assim, resultados semelhantes para uma mesma cardinalidade não significam representações equivalentes: eles indicam que diferentes mecanismos de seleção ou extração podem concentrar informação preditiva suficiente para a tarefa de calibração. A consequência experimental dessa escolha é analisada diretamente pelas distribuições de erro.

7.3 Desempenho global da calibração

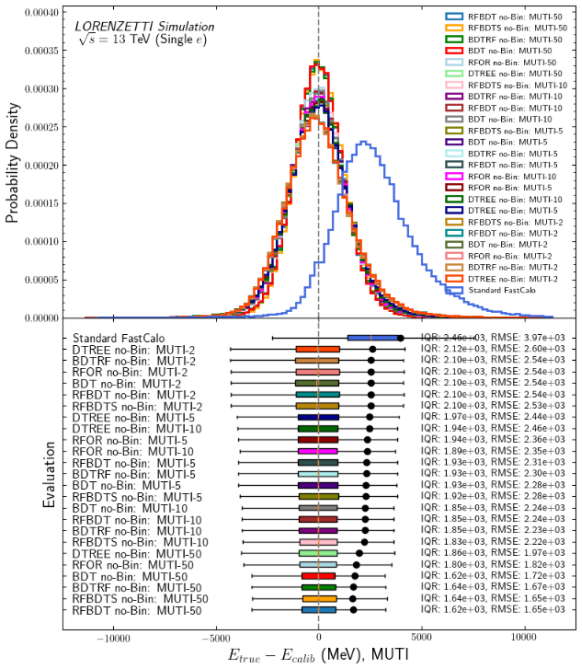
A Figura 26 apresenta as distribuições do erro $\varepsilon_{\text{calib}} = E_{\text{true}} - E_{\text{calib}}$ para CORR, MUTI, PCA e ICA. Em todas as famílias, as configurações de aprendizado de máquina deslocam a maior parte da densidade para a região de menor erro e reduzem a dispersão em relação ao Standard FastCalo.

A comparação por família mostra que o ganho não depende de uma única forma de representação. Para CORR, a melhor configuração publicada foi `RFBDT no-Bin: CORR-50`, com reduções de aproximadamente 36,2% no IQR e 53,4% no RMSE. A versão `RFBDTS no-Bin: CORR-10` preservou parcela relevante desse ganho com apenas dez anéis, alcançando reduções de aproximadamente 28,1% e 47,1%, respectivamente (SILVA et al., 2026a).

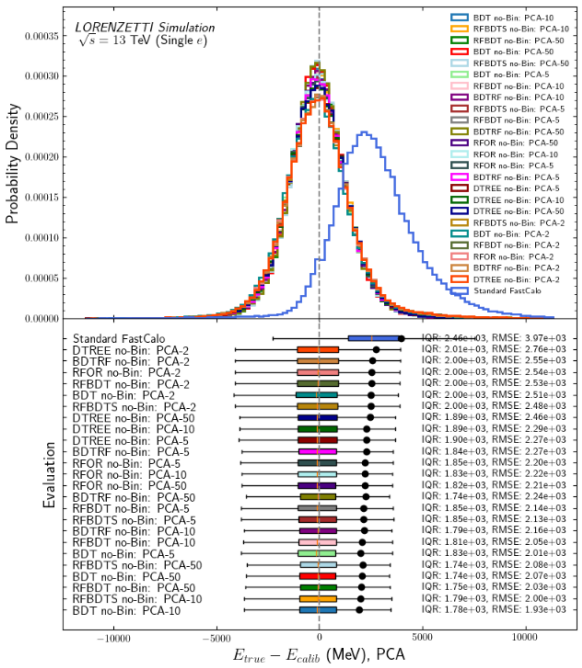
Com MUTI, `RFBDT no-Bin: MUTI-50` apresentou a maior redução de RMSE entre as configurações reduzidas dessa família, aproximadamente 58,4%, acompanhada de redução de cerca de 34,2% no IQR. A configuração `RFBDTS no-Bin: MUTI-10` manteve ganhos relevantes com uma representação cinco vezes menor. Esses resultados mostram que, para seleção de anéis originais, reter um conjunto maior tende a favorecer a máxima precisão, embora a redução para dez atributos ainda conserve parte substancial do desempenho.



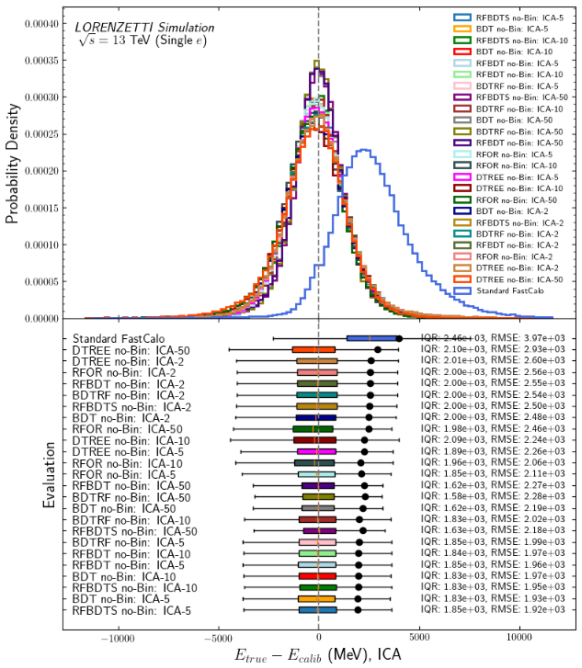
(a) CORR



(b) MUTI



(c) PCA



(d) ICA

Figura 26 – Distribuições do erro de calibração $E_{\text{true}} - E_{\text{calib}}$ e boxplots correspondentes para as representações (a) CORR, (b) MUTI, (c) PCA e (d) ICA na Etapa II. Nos boxplots, a largura da caixa representa o IQR e o marcador preto indica o RMSE. Adaptado de (SILVA et al., 2026a).

Nas representações latentes, o comportamento é diferente. `BDT no-Bin: PCA-10` reduziu o RMSE em pouco mais de 51% e o IQR em aproximadamente 28%, enquanto PCA-5 permaneceu próxima utilizando metade dos componentes. Para ICA, configurações com cinco componentes também alcançaram reduções de RMSE superiores a 51%, mostrando que um espaço latente muito menor que os 100 anéis pode preservar grande parte da informação útil à calibração (SILVA et al., 2026a).

Quando todas as representações são consideradas em conjunto, porém, os melhores valores absolutos são obtidos com os 100 anéis. `RFBDT no-Bin: Rings[1:100]` apresentou RMSE de 1562,75 MeV e $d_0 = 2092{,}11$ MeV, correspondentes a reduções de 60,61% e aproximadamente 55,17% em relação ao *Standard FastCalo* da Etapa II. O IQR foi reduzido em 43,39%. A configuração `BDT no-Bin: Rings[1:100]` permaneceu muito próxima, com RMSE de 1579,93 MeV, redução de 60,17%, e IQR ligeiramente menor, com redução de 43,64%.

O resultado global evidencia, portanto, dois regimes. A representação completa fornece a maior qualidade absoluta, enquanto PCA e ICA permitem compactação agressiva com perda moderada de desempenho. Essa separação será retomada na análise conjunta de erro, dimensionalidade e custo de predição.

7.4 Aprendizado residual e efeito da ordem dos *ensembles*

O menor RMSE e o menor d_0 da etapa foram obtidos pelo RFBDT, no qual a *Random Forest* produz a primeira estimativa e o BDT aprende a correção residual. Esse resultado é compatível com a existência, no conjunto avaliado, de estrutura residual explorável após a previsão inicial.

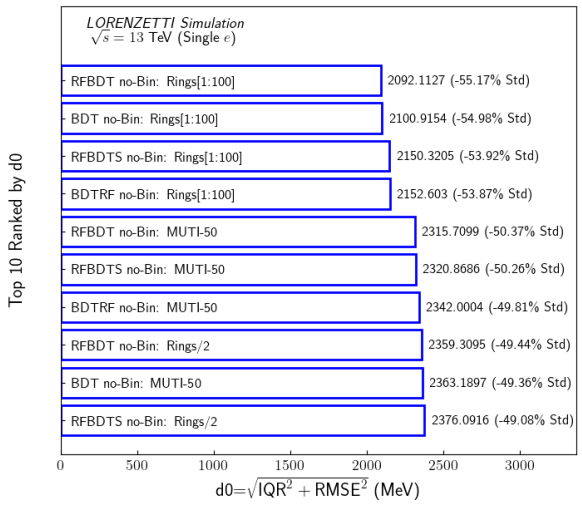
A magnitude desse ganho, entretanto, é pequena quando comparada ao BDT completo. Em relação a `BDT no-Bin: Rings[1:100]`, o RFBDT melhora a redução relativa de RMSE de 60,17% para 60,61% e reduz d_0 de 2100,92 para 2092,11 MeV, enquanto o BDT apresenta IQR ligeiramente menor. Assim, o RFBDT apresenta uma melhoria numérica mensurável sobre uma referência já muito forte, mas não altera a ordem de grandeza do desempenho.

A ordem dos estimadores também se mostrou relevante empiricamente: entre as arquiteturas residuais, a sequência *Random Forest*→BDT produziu o melhor desempenho absoluto. Os modelos empilhados, por sua vez, aparecem de forma competitiva em representações reduzidas, como CORR-10, MUTI-10 e ICA-5, mostrando que a combinação de estimadores também pode ser útil quando o objetivo inclui compactação. Em conjunto, esses resultados indicam que o benefício dos *ensembles* depende tanto da arquitetura quanto da representação fornecida ao regressor.

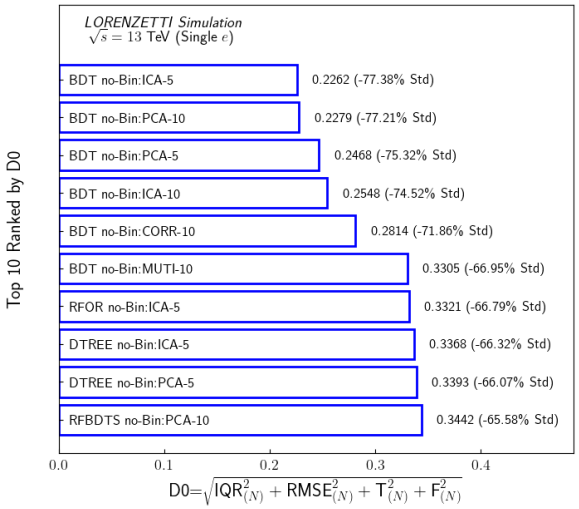
7.5 Compromisso entre erro, dimensionalidade e custo de predição

A Figura 27 apresenta as configurações mais bem classificadas segundo d_0 e D_0. O primeiro critério enfatiza RMSE e IQR; o segundo incorpora também a dimensionalidade F e o tempo de predição T. A diferença entre os rankings torna explícita a fronteira entre máxima

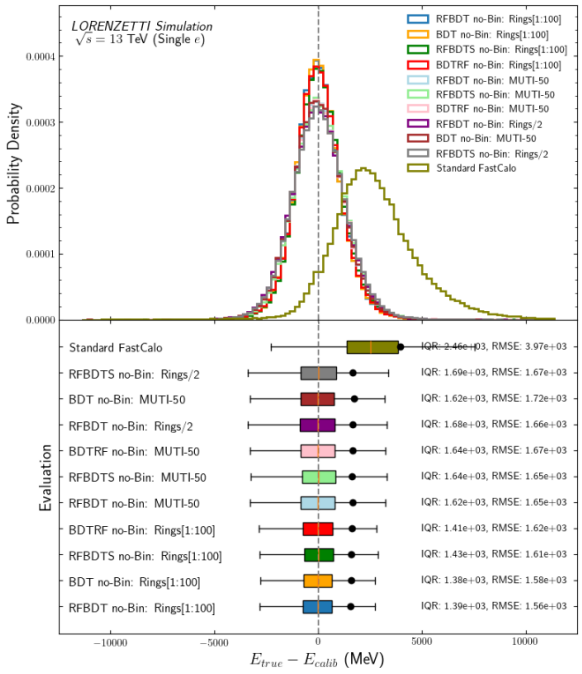
qualidade de calibração e compactação.



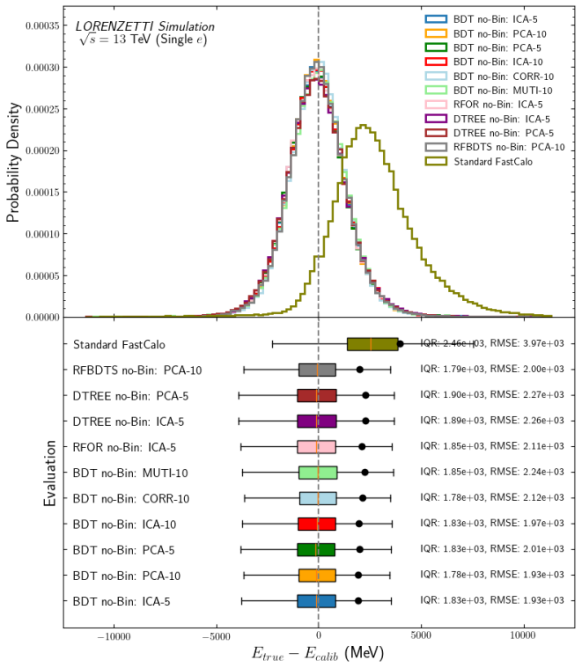
(a) Ranking por d_0



(b) Ranking por D_0



(c) Resíduos das configurações selecionadas por d_0



(d) Resíduos das configurações selecionadas por D_0

Figura 27 – Comparação das configurações mais bem classificadas segundo d_0 e D_0. Os painéis superiores apresentam os rankings e os painéis inferiores as distribuições do erro das configurações correspondentes. Adaptado de (SILVA et al., 2026a).

A Tabela 12 reúne quatro configurações representativas dessa fronteira: os dois modelos completos que dominam o ranking por d_0 e duas representações latentes compactas favorecidas pelo compromisso expresso em D_0.

Sob d_0, `RFBDT no-Bin: Rings[1:100]` e `BDT no-Bin: Rings[1:100]` apresentam os menores erros. Sob D_0, `BDT no-Bin: ICA-5` e `BDT no-Bin: PCA-10` tornam-se mais favoráveis por combinar reduções de RMSE superiores a 51% com apenas cinco e dez componentes. PCA-10 apresenta pequena vantagem em erro, enquanto ICA-5 utiliza metade da dimensionalidade.

A comparação também evidencia o custo do segundo estágio residual. O RFBDT completo

Tabela 12 – Desempenho das quatro configurações representativas da Etapa II. As porcentagens são reduções relativas ao *Standard FastCalo* da mesma etapa. T é o tempo médio amortizado de predição por evento reportado na publicação.

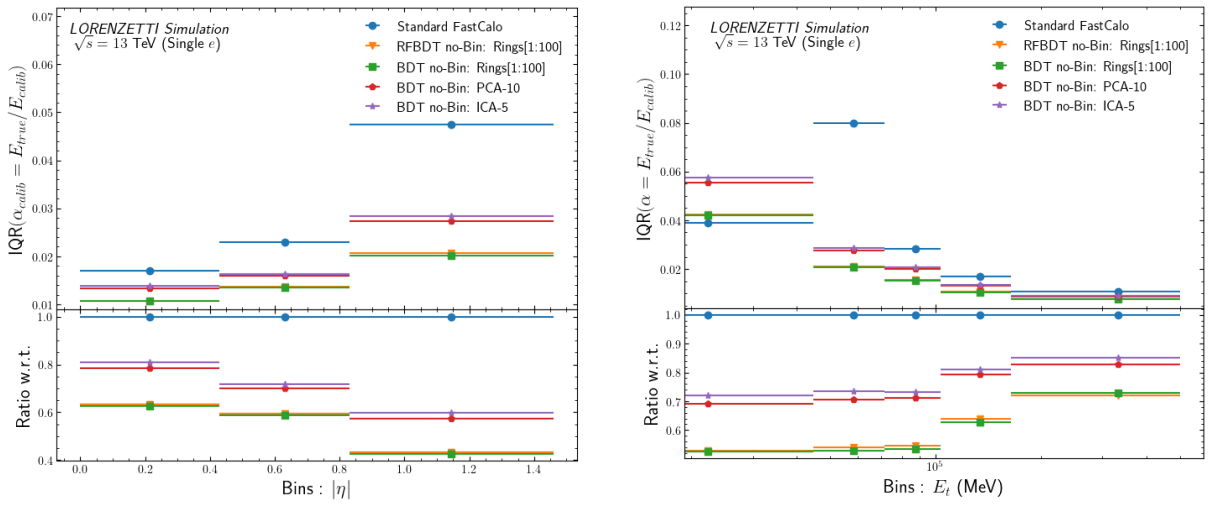
Configuração	IQR (MeV)	ΔIQR	RMSE (MeV)	ΔRMSE	T (ms/evento)	F	d_0 (MeV)	D_0
Standard FastCalo	$2457{,}11 \pm 9{,}89$	–	$3967{,}12 \pm 6{,}74$	–	0	1	4666,42	1,00
BDT no-Bin: ICA-5	$1831{,}83 \pm 7{,}10$	25,45%	$1933{,}91 \pm 6{,}40$	51,25%	$4{,}00 \times 10^{-3}$	5	2663,76	0,23
BDT no-Bin: PCA-10	$1779{,}06 \pm 7{,}01$	27,60%	$1931{,}01 \pm 6{,}40$	51,32%	$6{,}92 \times 10^{-3}$	10	2625,62	0,23
BDT no-Bin: Rings[1:100]	$1384{,}80 \pm 5{,}26$	43,64%	$1579{,}93 \pm 5{,}24$	60,17%	$5{,}95 \times 10^{-2}$	100	2100,92	1,03
RFBDT no-Bin: Rings[1:100]	$1390{,}96 \pm 5{,}76$	43,39%	$1562{,}75 \pm 5{,}19$	60,61%	$2{,}08 \times 10^{-1}$	100	2092,11	1,29

obtém o menor d_0, mas apresenta maior tempo de predição que o BDT completo no mesmo *benchmark*. Assim, a escolha entre as duas configurações depende do peso atribuído ao ganho incremental de precisão em relação ao custo adicional da arquitetura.

Os valores de T correspondem à predição do modelo treinado no ambiente CPU do estudo e são utilizados como medida comparativa entre configurações. Dentro desse contexto, a Etapa II demonstra que tanto modelos completos quanto representações compactas ocupam pontos relevantes da fronteira desempenho–complexidade: os primeiros maximizam a qualidade absoluta e os segundos reduzem fortemente a dimensionalidade preservando grande parte do ganho.

7.6 Estabilidade regional do fator de calibração

Os modelos da Etapa II são treinados globalmente, e os bins de $(|\eta|, E_T)$ são utilizados somente após a inferência para verificar a estabilidade da calibração em diferentes regiões do espaço cinemático. A Figura 28 mostra o IQR do fator de calibração para as configurações selecionadas.



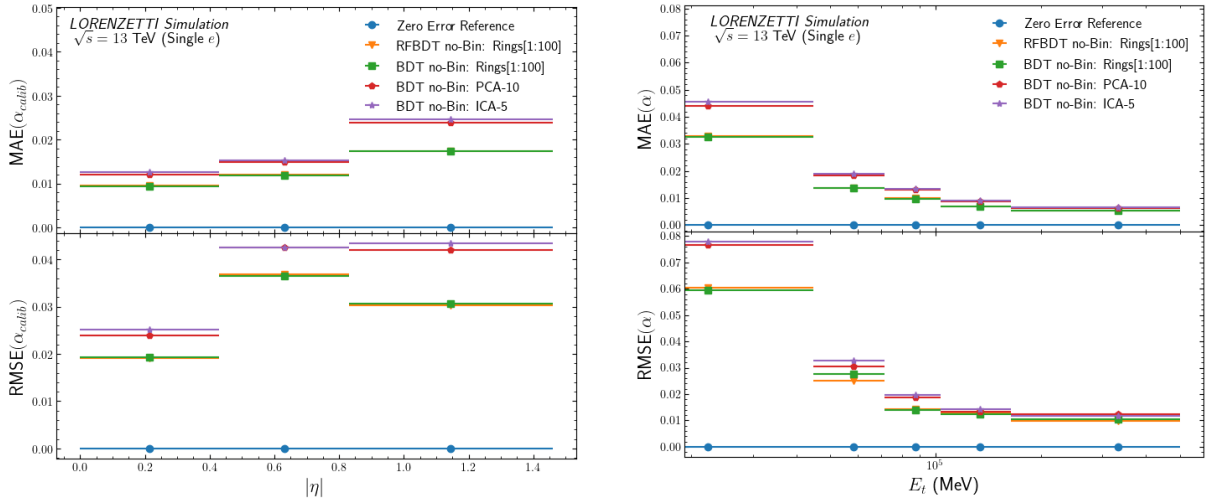
(a) $|\eta|$ **(b)** E_T

Figura 28 – IQR do fator de calibração para as configurações selecionadas, avaliado *a posteriori* em regiões de (a) $|\eta|$ e (b) E_T. Os modelos foram treinados globalmente; os bins são utilizados apenas como diagnóstico de estabilidade. Adaptado de (SILVA et al., 2026a).

A dispersão do fator aumenta com $|\eta|$ dentro do barril e tende a diminuir à medida que E_T cresce. No primeiro intervalo de energia, o *Standard FastCalo* pode apresentar IQR do fator localmente menor que algumas configurações de ML. Esse comportamento é compatível com a

maior sensibilidade do fator multiplicativo a flutuações de E_{fast} quando a energia é baixa e não contradiz as reduções globais observadas diretamente no erro de energia.

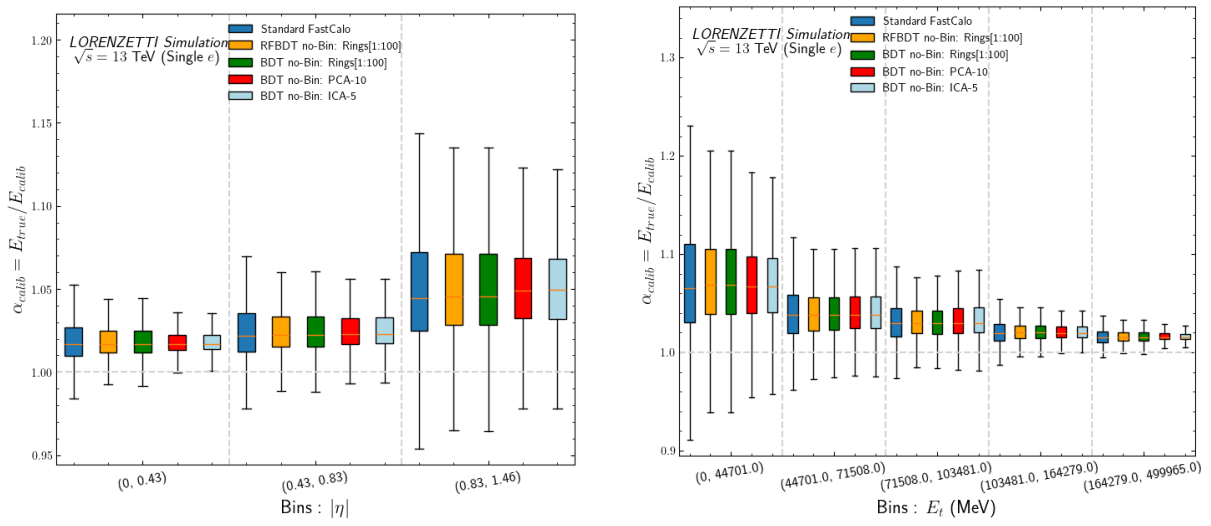
A Figura 29 complementa a análise com MAE e RMSE de α_{calib} em relação a α_{true}. As duas métricas aumentam com $|\eta|$ e diminuem com a energia, mas as configurações selecionadas mantêm evolução regular ao longo dos bins avaliados.



(a) $|\eta|$ **(b)** E_T

Figura 29 – MAE e RMSE do fator estimado α_{calib} em relação a α_{true} nas regiões de (a) $|\eta|$ e (b) E_T. Adaptado de (SILVA et al., 2026a).

As distribuições completas dos fatores, apresentadas na Figura 30, confirmam essas tendências. A dispersão cresce com $|\eta|$ e diminui com E_T, enquanto as medianas das previsões acompanham a dependência regional da referência.



(a) $|\eta|$ **(b)** E_T

Figura 30 – Distribuições de α_{calib} para as configurações selecionadas nas regiões de (a) $|\eta|$ e (b) E_T. A largura das caixas representa o IQR e as linhas verticais tracejadas indicam as fronteiras dos bins. Adaptado de (SILVA et al., 2026a).

Em conjunto, os três diagnósticos mostram que o treinamento global não produz instabilidades localizadas pronunciadas nas regiões avaliadas. A análise regional, portanto, reforça os

resultados globais e mostra que a calibração preserva comportamento sistemático ao longo do domínio de barril e de energia considerado.

7.7 Resolução relativa de energia

A resolução relativa de energia permite verificar se a redução observada em RMSE e IQR também se traduz em uma resposta mais precisa ao longo da escala de energia. A Figura 31 apresenta σ_E/E em função de E_{true} para o *Standard FastCalo* e para as quatro configurações selecionadas.

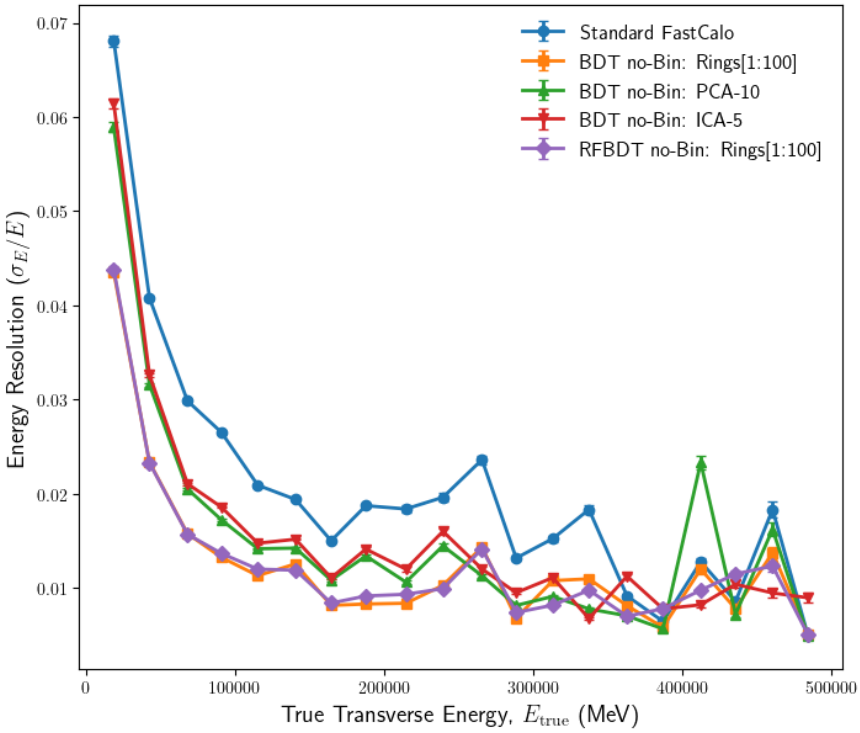


Figura 31 – Resolução relativa de energia σ_E/E em função de E_{true} para *Standard FastCalo* e para as quatro configurações selecionadas na Etapa II. Adaptado de (SILVA et al., 2026a).

As configurações de ML melhoram a resolução em grande parte do intervalo estudado, com diferenças mais pronunciadas nas regiões de baixa e média energia. Em energias mais altas, as curvas se aproximam e as flutuações locais tornam-se mais visíveis. A Tabela 13 resume os valores médios reportados.

Tabela 13 – Resolução relativa de energia das configurações selecionadas na Etapa II. As porcentagens correspondem à melhoria relativa ao *Standard FastCalo* no mesmo conjunto de teste.

Configuração	σ_E/E	$\Delta(\sigma_E/E)$
Standard FastCalo	$(2{,}46 \times 10^{-2}) \pm 5{,}80 \times 10^{-5}$	–
BDT no-Bin: ICA-5	$(1{,}67 \times 10^{-2}) \pm 3{,}90 \times 10^{-5}$	31,98%
BDT no-Bin: PCA-10	$(1{,}67 \times 10^{-2}) \pm 3{,}90 \times 10^{-5}$	32,05%
BDT no-Bin: Rings[1:100]	$(1{,}37 \times 10^{-2}) \pm 3{,}20 \times 10^{-5}$	44,36%
RFBDT no-Bin: Rings[1:100]	$(1{,}35 \times 10^{-2}) \pm 3{,}20 \times 10^{-5}$	44,96%

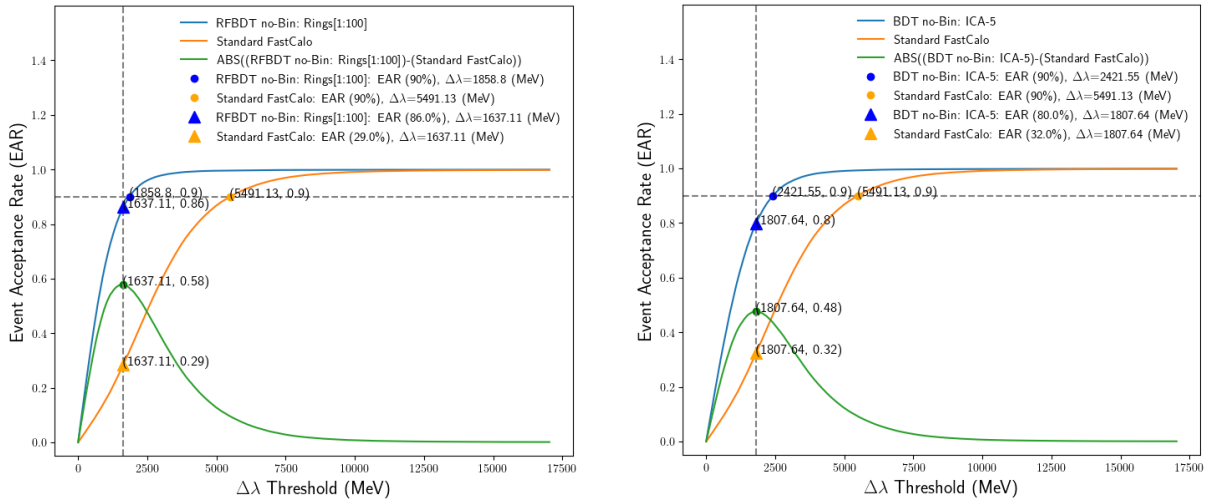
O RFBDT completo apresenta a maior melhoria, 44,96%, seguido de perto pelo BDT completo, com 44,36%. Essa diferença de apenas 0,60 ponto percentual reproduz o padrão

observado no RMSE: o estágio residual melhora a precisão, mas o ganho adicional sobre o BDT completo é pequeno.

As configurações compactas também apresentam redução expressiva da resolução relativa. `BDT no-Bin: PCA-10` melhora σ_E/E em 32,05%, enquanto `BDT no-Bin: ICA-5` alcança 31,98%. Portanto, a informação preservada em cinco ou dez componentes é suficiente para produzir uma melhoria relativa de aproximadamente 32% na resolução em comparação com a referência, mantendo dimensionalidade muito menor que a representação completa.

7.8 Resposta a limiar e aceitação de eventos

A resposta a limiar complementa as métricas de erro ao avaliar a concentração da resposta em torno da energia de referência. Conforme definido na Seção 5.11, a Figura 32 apresenta a taxa de aceitação em função de $\Delta\lambda$ para o RFBDT completo e para a configuração compacta ICA-5.



(a) RFBDT no-Bin: Rings[1:100] **(b)** BDT no-Bin: ICA-5

Figura 32 – Curvas de aceitação da Etapa II para (a) o RFBDT com 100 anéis e (b) o BDT com ICA-5, ambas comparadas ao Standard FastCalo. As curvas apresentam a taxa de aceitação em função de $\Delta\lambda$ segundo a convenção definida na Seção 5.11. Adaptado de (SILVA et al., 2026a).

Os valores de $\Delta\lambda_{90}$ são apresentados na Tabela 14.

Tabela 14 – Resposta a limiar das configurações selecionadas na Etapa II. $\Delta\lambda_{90}$ representa o valor necessário para atingir 90% de aceitação na convenção definida na Seção 5.11.

Configuração	$\Delta\lambda_{90}$ **(MeV)**	**redução relativa**
Standard FastCalo	5491,13	–
BDT no-Bin: ICA-5	2421,55	55,90%
BDT no-Bin: PCA-10	2353,34	57,14%
BDT no-Bin: Rings[1:100]	1858,80	66,15%
RFBDT no-Bin: Rings[1:100]	1858,80	66,15%

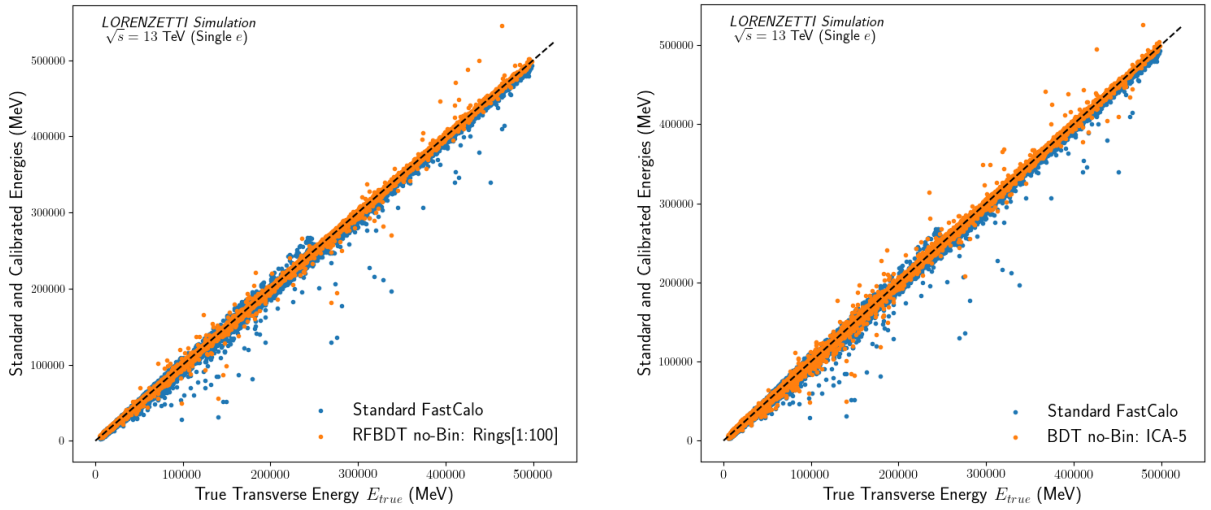
Os dois modelos com os 100 anéis atingem 90% de aceitação com $\Delta\lambda_{90} = 1858{,}80$ MeV, contra 5491,13 MeV para o Standard FastCalo, correspondendo a uma redução de 66,15%. A configuração `BDT no-Bin: PCA-10` reduz esse valor em 57,14%, e `BDT no-Bin: ICA-5` em 55,90% (SILVA et al., 2026a).

A diferença também é observada em pontos intermediários das curvas. Para o RFBDT completo, em $\Delta\lambda = 1637{,}11$ MeV, a aceitação é aproximadamente 86%, contra 29% para a referência. Para ICA-5, em $\Delta\lambda = 1807{,}64$ MeV, a aceitação é aproximadamente 80%, enquanto o *Standard FastCalo* atinge cerca de 32% (SILVA et al., 2026a). Assim, tanto o modelo de maior desempenho absoluto quanto a representação compacta apresentam transições mais estreitas que a referência.

Esses resultados são consistentes com a melhoria de RMSE, IQR e resolução relativa: distribuições mais concentradas exigem menor tolerância para incluir a mesma fração de eventos. Como a amostra avaliada é composta por elétrons e não contém fundo representativo, a análise caracteriza a resposta de aceitação do sinal no *benchmark*; eficiência e taxa de fundo de um menu operacional exigem uma avaliação adicional.

7.9 Linearidade e consistência evento a evento

A Figura 33 compara diretamente E_{calib} e E_{true} para o RFBDT completo e para a configuração compacta ICA-5, utilizando o *Standard FastCalo* como referência.



(a) RFBDT no-Bin: Rings[1:100] **(b)** BDT no-Bin: ICA-5

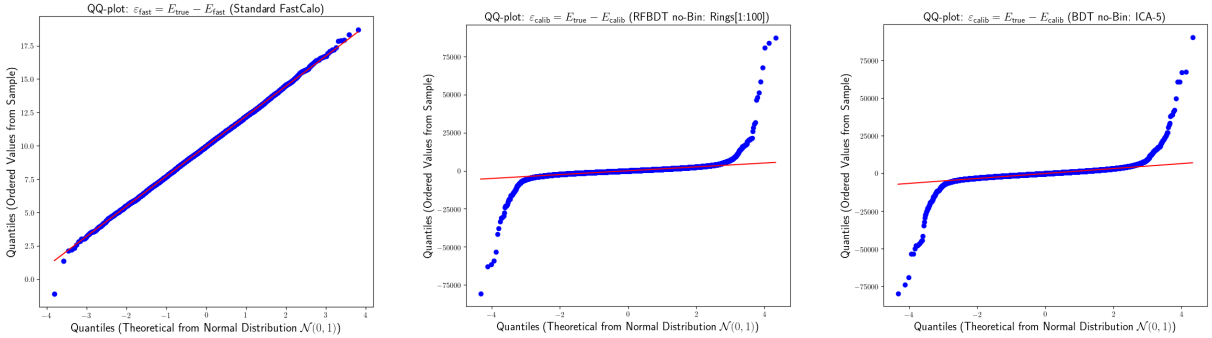
Figura 33 – energia transversa calibrada em função de E_{true} para duas configurações representativas da Etapa II, comparadas ao Standard FastCalo. A linha diagonal tracejada representa a resposta ideal $E_{\text{calib}} = E_{\text{true}}$. Adaptado de (SILVA et al., 2026a).

O RFBDT completo apresenta a nuvem de pontos mais concentrada em torno da diagonal ideal e menor ocorrência de grandes desvios, em concordância com seu RMSE, d_0 e resolução relativa. O BDT com ICA-5 apresenta dispersão maior que o modelo completo, mas permanece visivelmente mais próximo da diagonal que o *Standard FastCalo* mesmo utilizando apenas cinco componentes.

A análise evento a evento confirma, portanto, a leitura das métricas agregadas: a calibração reduz a dispersão da resposta ao longo de todo o intervalo de energia, e a representação compacta retém uma parcela substancial dessa melhoria.

7.10 Validação estatística

Como E_{fast} e E_{calib} são avaliados nos mesmos eventos, a comparação estatística é pareada. Os testes de D'Agostino–Pearson e Anderson–Darling rejeitam normalidade para os resíduos e suas diferenças, com $p < 10^{-16}$ nas configurações examinadas. Os gráficos Q–Q da Figura 34 mostram desvios nas caudas, justificando o uso complementar de procedimentos robustos.



(a) Standard FastCalo **(b)** RFBDT: Rings[1:100] **(c)** BDT: ICA-5

Figura 34 – Gráficos Q–Q representativos para os resíduos do *Standard FastCalo* e de duas configurações da Etapa II. Os desvios nas caudas justificam o uso complementar de inferência não paramétrica e *bootstrap*. Adaptado de (SILVA et al., 2026a).

A Tabela 15 apresenta os resultados para o deslocamento da distribuição dos resíduos. O teste z pareado de grande amostra e o teste de Wilcoxon conduzem à rejeição da hipótese nula nas quatro configurações selecionadas.

Tabela 15 – Inferência pareada para o deslocamento do resíduo na Etapa II. Os intervalos para μ_d são unilaterais de 95%.

Configuração	z	p_z	**IC$_{95\%}$ para μ_d (MeV)**	**Wilcoxon: decisão**
BDT no-Bin: Rings[1:100]	-341,67	$< 10^{-300}$	$(-\infty, -2759{,}49]$	Rejeita H_0
BDT no-Bin: PCA-10	-303,83	$< 10^{-300}$	$(-\infty, -2837{,}66]$	Rejeita H_0
BDT no-Bin: ICA-5	-345,97	$< 10^{-300}$	$(-\infty, -2855{,}17]$	Rejeita H_0
RFBDT no-Bin: Rings[1:100]	-328,64	$< 10^{-300}$	$(-\infty, -2761{,}62]$	Rejeita H_0

Esses testes estabelecem um deslocamento estatisticamente detectável da distribuição calibrada em relação à referência. A evidência de melhoria é interpretada conjuntamente com RMSE, IQR, resolução relativa e dispersão, evitando atribuir todo o significado físico ao sinal de uma única estatística de localização.

A Tabela 16 apresenta as razões de variância e os intervalos associados ao teste de Pitman–Morgan.

Tabela 16 – Comparação da variância dos resíduos na Etapa II. Valores de $R_{\sigma^2} < 1$ indicam menor variância após calibração.

Configuração	R_{σ^2}	**redução de variância**	**limite superior IC$_{95\%}$ PM**
BDT no-Bin: Rings[1:100]	0,3096	69,04%	0,3416
BDT no-Bin: PCA-10	0,4617	53,83%	0,5319
BDT no-Bin: ICA-5	0,4627	53,73%	0,5122
RFBDT no-Bin: Rings[1:100]	0,3029	69,71%	0,3325

Todos os valores de R_{σ^2} são inferiores à unidade. O RFBDT completo apresenta a menor razão, 0,3029, correspondente a redução de 69,71% da variância dos resíduos; o BDT completo alcança 69,04%, enquanto PCA-10 e ICA-5 reduzem a variância em 53,83% e 53,73%, respectivamente. Os limites superiores de Pitman–Morgan permanecem abaixo da unidade em todas as configurações.

O *bootstrap* pareado BCa com 5000 reamostragens conduz à mesma decisão qualitativa. Em conjunto com as reduções de RMSE, IQR e resolução, esses resultados mostram que os ganhos observados não se resumem a uma única métrica de desempenho e são acompanhados por redução consistente da dispersão dos resíduos.

7.11 Escopo dos resultados da Etapa II

Os resultados da Etapa II foram obtidos no *benchmark* Monte Carlo descrito no Capítulo 5, com *pile-up* incluído segundo a distribuição simulada. Como o estudo não realizou uma varredura controlada em $\langle\mu\rangle$, os resultados caracterizam o desempenho sob essa condição de ocupação e não quantificam invariância a diferentes regimes de *pile-up*.

A avaliação também não inclui dados experimentais nem uma amostra de fundo adequada para medir taxas de jatos reconstruídos como elétrons. Da mesma forma, os tempos de predição representam o custo do modelo treinado no ambiente CPU do estudo. Essas condições delimitam o domínio empírico da etapa sem alterar seus resultados centrais: os modelos baseados em árvores melhoram substancialmente a estimativa rápida, o RFBDT apresenta pequena melhoria em algumas métricas em relação ao BDT completo e representações compactas preservam parte expressiva desse desempenho.

7.12 Conclusão do capítulo

A segunda etapa experimental mostrou que a ampliação da calibração para *Random Forest*, aprendizado residual e modelos empilhados produz ganhos adicionais e, principalmente, esclarece a fronteira entre máxima qualidade de reconstrução e compactação da representação.

O melhor desempenho absoluto foi obtido por `RFBDT no-Bin: Rings[1:100]`. Em relação ao *Standard FastCalo* da Etapa II, essa configuração reduziu o RMSE em 60,61%, o IQR em 43,39%, melhorou a resolução relativa em 44,96% e reduziu $\Delta\lambda_{90}$ em 66,15%. O `BDT no-Bin: Rings[1:100]` permaneceu muito próximo e apresentou IQR ligeiramente menor, mostrando que o ganho incremental observado com o RFBDT é pequeno diante de uma configuração BDT já muito competitiva.

No regime compacto, `BDT no-Bin: ICA-5` sintetiza o compromisso entre desempenho e dimensionalidade: com apenas cinco componentes, reduziu o RMSE em 51,25%, o IQR em 25,45%, melhorou a resolução relativa em 31,98% e reduziu $\Delta\lambda_{90}$ em 55,90%. `BDT no-Bin: PCA-10` apresentou comportamento muito próximo, com ligeira vantagem nas métricas de erro e resolução, utilizando dez componentes.

A análise regional mostrou evolução regular das configurações selecionadas ao longo dos

bins de $|\eta|$ e energia, enquanto a comparação evento a evento evidenciou maior concentração de E_{calib} em torno de E_{true}. A validação estatística pareada confirmou redução substancial da variância dos resíduos nas quatro configurações representativas.

Em conjunto, a Etapa II estabelece que a representação completa continua favorecendo a maior precisão absoluta, mas que espaços latentes de cinco ou dez componentes preservam parcela significativa do ganho com menor dimensionalidade. O ganho incremental observado com o aprendizado residual é pequeno em algumas métricas e deve ser interpretado em conjunto com o custo adicional do segundo estágio. Esses resultados fornecem a base experimental para a Etapa III, na qual a calibração é estendida a modelos neurais e a uma arquitetura relacional baseada em grafos.

8 Calibração Neural e Fusão de Informação

Este capítulo apresenta os resultados da terceira etapa experimental da pesquisa, descrita no manuscrito *Multi-Stage Neural Information Fusion for Fast Energy Calibration in Segmented Particle-Detector Calorimeters*, submetido à revista *Information Fusion* (SILVA; SIMAS FILHO, 2026). Após as etapas anteriores estabelecerem a viabilidade da calibração baseada em anéis e ampliarem a modelagem com *ensembles* e aprendizado residual, a Etapa III investiga a fusão neural da informação calorimétrica por meio de DNNs e de uma arquitetura GNN relacional–tabular.

As definições da calibração, das representações e das arquiteturas neurais foram apresentadas nos Capítulos 3 e 4, enquanto o protocolo experimental é formalizado no Capítulo 5. O foco deste capítulo é, portanto, a evidência produzida pela Etapa III: o desempenho das DNNs em representações completas e compactas, o resultado obtido pela GNN com os 100 anéis, a estabilidade regional, a resolução de energia, a resposta a limiar, a consistência estatística e o compromisso entre precisão, dimensionalidade e custo de predição.

8.1 Escopo da Etapa III

A Etapa III mantém o problema de calibração multiplicativa das etapas anteriores e modifica a capacidade de representação do regressor. As DNNs são avaliadas com `Rings[1:100]` e com representações CORR, MUTI, PCA e ICA de cardinalidade controlada. A GNN é avaliada com a representação externa completa de 100 anéis, a partir da qual a arquitetura constrói internamente grafos regionais e uma ramificação tabular antes da fusão final.

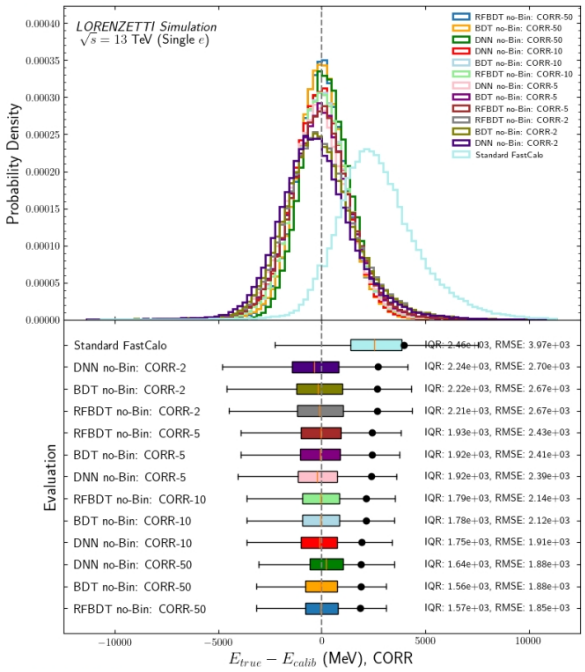
A comparação é realizada sob o mesmo princípio experimental da Etapa II: treinamento global, regiões de $(|\eta|, E_T)$ utilizadas apenas na avaliação *a posteriori*, seleção de hiperparâmetros restrita a $\mathcal{D}_{70}$ e avaliação final em $\mathcal{D}_{30}$, conforme a Seção 5.7.2. Dessa forma, as diferenças observadas nesta etapa podem ser interpretadas principalmente em função das representações e arquiteturas avaliadas, sem alterar o benchmark de referência.

A DNN completa e a GNN utilizam os mesmos 100 anéis como entrada externa, mas processam essa informação de forma distinta. A DNN trata o perfil como vetor tabular, enquanto a GNN combina processamento relacional em grafos regionais com descritores derivados e uma ramificação tabular. Essa diferença é relevante para interpretar os resultados: a comparação mede o desempenho das arquiteturas completas, e não constitui uma ablação isolada do efeito das arestas ou da propagação de mensagens.

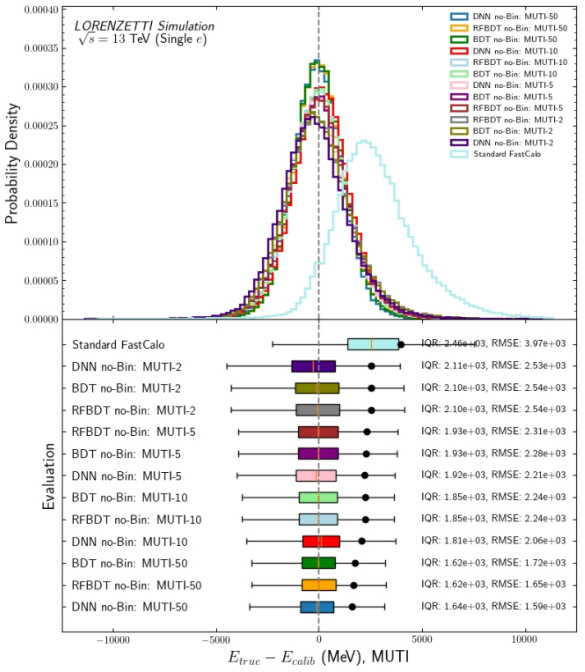
8.2 Fusão neural em representações completas e compactas

A primeira análise verifica quanto desempenho as DNNs preservam quando os 100 anéis são substituídos por subconjuntos selecionados ou componentes latentes. A Figura 35 apresenta as distribuições do erro de calibração para CORR, MUTI, PCA e ICA. Em todas as famílias,

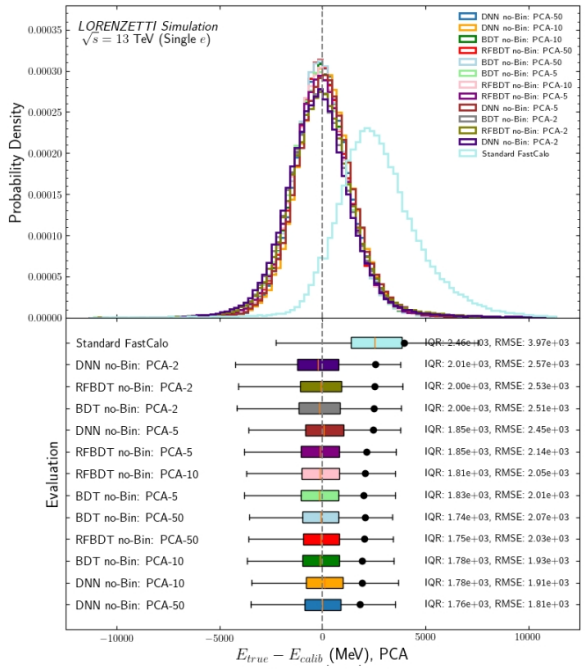
as configurações neurais deslocam a maior parte da distribuição para a região de menor erro e reduzem a dispersão em relação ao Standard FastCalo.



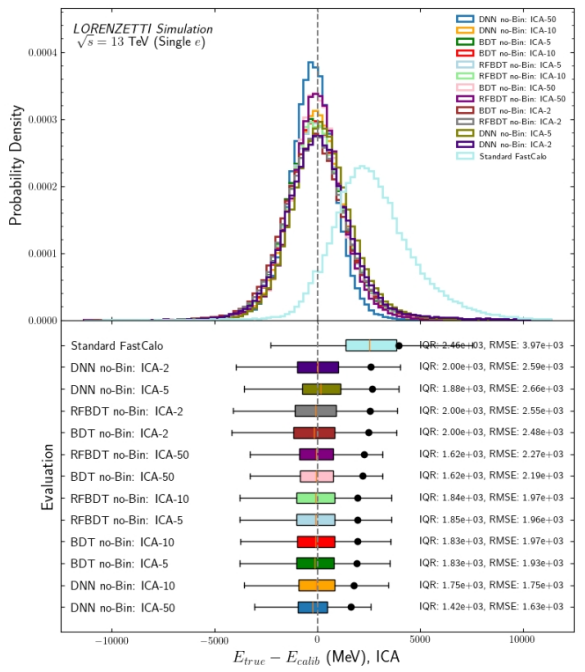
(a) CORR



(b) MUTI



(c) PCA



(d) ICA

Figura 35 – Distribuições do erro $E_{\text{true}} - E_{\text{calib}}$ e boxplots correspondentes para as representações (a) CORR, (b) MUTI, (c) PCA e (d) ICA na Etapa III. Os gráficos preservam as referências não neurais avaliadas no mesmo *benchmark*, permitindo contextualizar o desempenho das DNNs. Nos boxplots, a caixa representa o IQR e o marcador preto indica o RMSE. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

A comparação por família mostra que a compactação pode preservar uma fração elevada do ganho. Em CORR, `DNN no-Bin: CORR-10` utiliza somente dez anéis e reduz o IQR em 28,83% e o RMSE em 51,96%. O grupo CORR também mantém uma referência forte baseada em árvores,

`RFBDT no-Bin: CORR-50`, mas a configuração neural de dez entradas fornece um compromisso particularmente relevante entre redução de erro e dimensionalidade (SILVA; SIMAS FILHO, 2026).

Em MUTI, `DNN no-Bin: MUTI-50` apresenta o maior ganho neural da família, com reduções de 33,33% no IQR e 59,95% no RMSE. A redução para dez anéis ainda preserva ganhos importantes: `DNN no-Bin: MUTI-10` reduz o IQR em 26,42% e o RMSE em 48,11%. O resultado mostra que a seleção por informação mútua identifica subconjuntos informativos, embora a máxima precisão dessa família ainda se beneficie de uma cardinalidade maior.

Nas representações latentes, `DNN no-Bin: PCA-50` reduz o IQR em 28,46% e o RMSE em 54,41%, enquanto PCA-10 mantém reduções de 27,64% e 51,89%, respectivamente. Para ICA, os ganhos são ainda maiores: `DNN no-Bin: ICA-50` reduz o IQR em 42,28% e o RMSE em 58,94%, e a configuração compacta `DNN no-Bin: ICA-10` preserva reduções de 28,61% e 55,76% com apenas dez componentes (SILVA; SIMAS FILHO, 2026).

O resultado dessa análise é duplo. Primeiro, as DNNs exploram de forma eficaz tanto variáveis selecionadas quanto componentes transformados. Segundo, a informação útil à calibração não está distribuída de forma uniforme pelos 100 anéis: representações com dez entradas ainda produzem reduções de RMSE superiores a 50% em CORR, PCA e ICA. Entre as alternativas compactas posteriormente selecionadas pelo compromisso desempenho–custo, ICA-10 se destaca pela maior redução de RMSE.

8.3 Desempenho global e comparação entre DNN e GNN

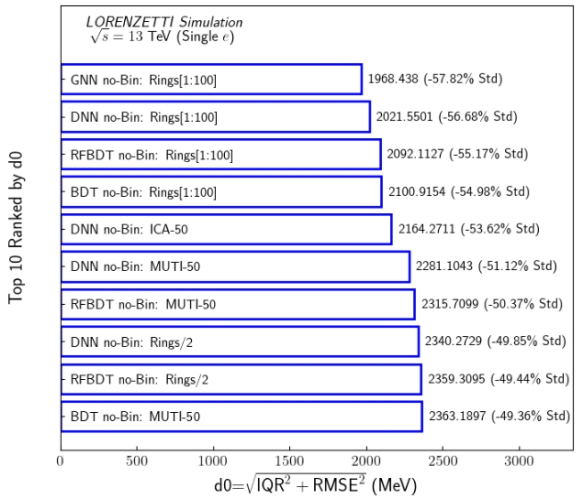
A Figura 36 reúne as configurações mais bem classificadas segundo d_0 e D_0. O primeiro critério evidencia a qualidade de calibração em RMSE e IQR, enquanto o segundo acrescenta a dimensionalidade de entrada F e o tempo amortizado de predição T. A diferença entre os rankings separa claramente os modelos de maior precisão absoluta das soluções compactas.

A Tabela 17 sintetiza os dois regimes observados: GNN e DNN com os 100 anéis representam o regime de máxima qualidade absoluta, enquanto DNN ICA-10 e DNN CORR-10 representam o regime compacto. Os valores de T correspondem ao tempo amortizado de predição do modelo treinado em CPU, após as características estarem disponíveis.

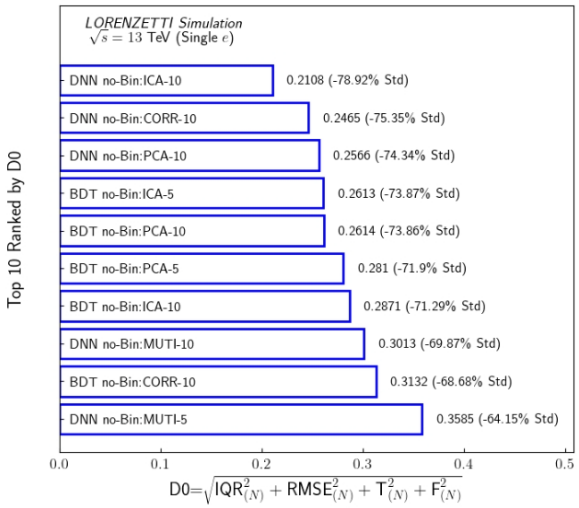
Tabela 17 – Desempenho das quatro configurações neurais representativas da Etapa III. F é a dimensionalidade externa de entrada; T é o tempo amortizado de predição medido no *benchmark* CPU.

Configuração	IQR (MeV)	RMSE (MeV)	IQR red.	RMSE red.	T (ms/evento)	F	d_0 (MeV)	D_0
Standard FastCalo	$2457{,}11 \pm 9{,}89$	$3967{,}12 \pm 6{,}74$	–	–	0	1	4666,42	1,00
DNN no-Bin: CORR-10	$1748{,}78 \pm 6{,}95$	$1905{,}63 \pm 6{,}31$	28,83%	51,96%	$1{,}38 \times 10^{-3}$	10	2586,43	0,25
DNN no-Bin: ICA-10	$1754{,}19 \pm 6{,}81$	$1754{,}95 \pm 5{,}82$	28,61%	55,76%	$1{,}52 \times 10^{-3}$	10	2481,34	0,21
DNN no-Bin: Rings[1:100]	$1419{,}48 \pm 5{,}73$	$1439{,}35 \pm 4{,}75$	42,23%	63,72%	$4{,}05 \times 10^{-3}$	100	2021,55	1,00
GNN no-Bin: Rings[1:100]	$1404{,}90 \pm 5{,}28$	$1378{,}77 \pm 4{,}57$	42,82%	65,25%	$1{,}53 \times 10^{-1}$	100	1968,44	1,17

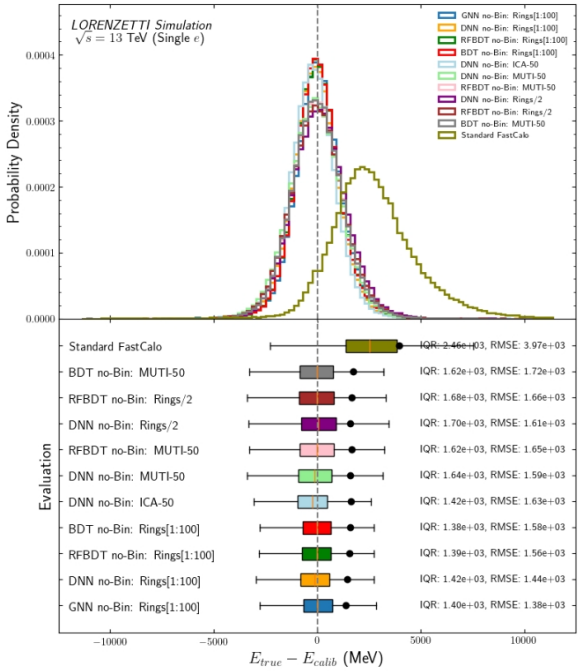
A configuração `GNN no-Bin: Rings[1:100]` obtém o menor erro global da Etapa III. O d_0 diminui de 4.666,42 MeV para 1.968,44 MeV, redução de 57,82% em relação ao Standard FastCalo. O RMSE é reduzido em 65,25% e o IQR em 42,82%. A `DNN no-Bin: Rings[1:100]` permanece muito próxima, com reduções de 63,72% no RMSE e 42,23% no IQR e $d_0 = 2.021{,}55$ MeV (SILVA;



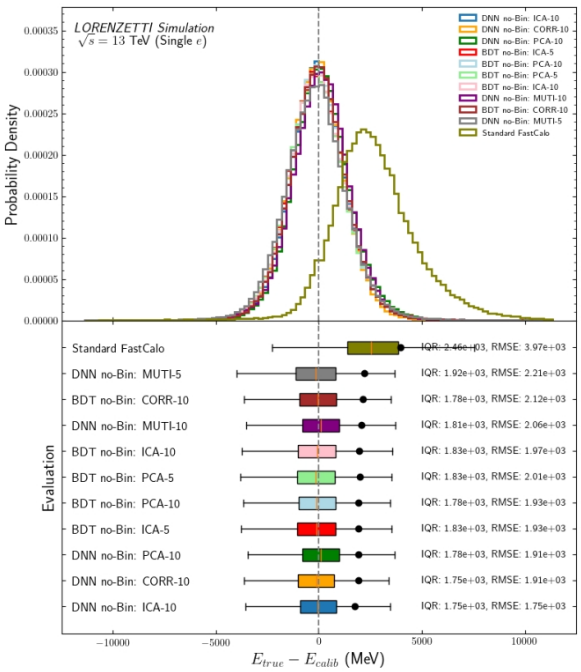
(a) Ranking por d_0



(b) Ranking por D_0



(c) Erros das configurações selecionadas por d_0



(d) Erros das configurações selecionadas por D_0

Figura 36 – Comparação das configurações da Etapa III segundo d_0 e D_0: (a) dez melhores configurações por d_0; (b) dez melhores por D_0; (c) distribuições de erro associadas ao ranking por d_0; (d) distribuições associadas ao ranking por D_0. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

SIMAS FILHO, 2026).

A diferença entre os dois modelos completos é pequena em comparação com o ganho obtido sobre a referência. Tomando a DNN como base, a GNN reduz o RMSE em 60,58 MeV, o IQR em 14,58 MeV e d_0 em 53,11 MeV, correspondendo a melhorias adicionais de aproximadamente 4,21%, 1,03% e 2,63%, respectivamente. A GNN, porém, apresenta $T = 1{,}53 \times 10^{-1}$ ms/evento, contra $4{,}05 \times 10^{-3}$ ms/evento da DNN completa, diferença de aproximadamente 37,8 vezes no benchmark CPU.

Esse contraste caracteriza o resultado central da comparação neural: a arquitetura relacional–tabular alcança as melhores estimativas pontuais de RMSE e d_0, enquanto a DNN completa fornece desempenho muito próximo com custo de predição substancialmente menor. Como as arquiteturas diferem em mais elementos do que apenas a conectividade do grafo, o experimento estabelece uma comparação de desempenho entre modelos completos, não uma atribuição causal do ganho a um único componente interno.

As configurações compactas ocupam uma região diferente da fronteira. `DNN no-Bin: ICA-10` reduz o RMSE em 55,76% e apresenta $D_0 = 0{,}21$, enquanto `DNN no-Bin: CORR-10` reduz o RMSE em 51,96% e apresenta $D_0 = 0{,}25$. Assim, a Etapa III reproduz de forma ainda mais clara a tendência observada nas etapas anteriores: preservar toda a informação favorece a máxima precisão, enquanto representações de baixa dimensão permanecem competitivas quando compactação e custo entram no critério de escolha.

Como referência de progressão da tese, o melhor híbrido da Etapa II, `RFBDT no-Bin: Rings[1:100]`, apresentou RMSE de 1.562,75 MeV e $d_0 = 2.092{,}11$ MeV. A DNN completa reduz esses valores para 1.439,35 MeV e 2.021,55 MeV, enquanto a GNN os reduz para 1.378,77 MeV e 1.968,44 MeV. O IQR do RFBDT, entretanto, permanece ligeiramente menor que o das duas arquiteturas neurais, mostrando que a evolução entre etapas é mais pronunciada em RMSE e resolução do que em todos os indicadores de dispersão simultaneamente.

8.4 Compromisso entre desempenho, dimensionalidade e custo

A Figura 37 resume os ganhos relativos das quatro configurações neurais selecionadas. Os modelos completos apresentam as maiores melhorias em RMSE, IQR e resolução, enquanto ICA-10 e CORR-10 preservam ganhos expressivos com apenas dez entradas.

A Figura 38 explicita a mesma fronteira ao relacionar d_0, tempo de predição e dimensionalidade. A GNN ocupa a região de menor d_0, a DNN completa permanece próxima com custo muito menor e as duas DNNs compactas concentram-se na região de menor dimensionalidade e menor tempo de predição.

O conjunto dos resultados mostra que não existe uma única configuração que maximize simultaneamente todos os objetivos. Para máxima precisão, os 100 anéis e os modelos neurais completos são favorecidos. Quando dimensionalidade e custo de predição recebem maior peso, ICA-10 e CORR-10 tornam-se alternativas mais atraentes. Essa fronteira desempenho–complexidade é uma das conclusões centrais da Etapa III.

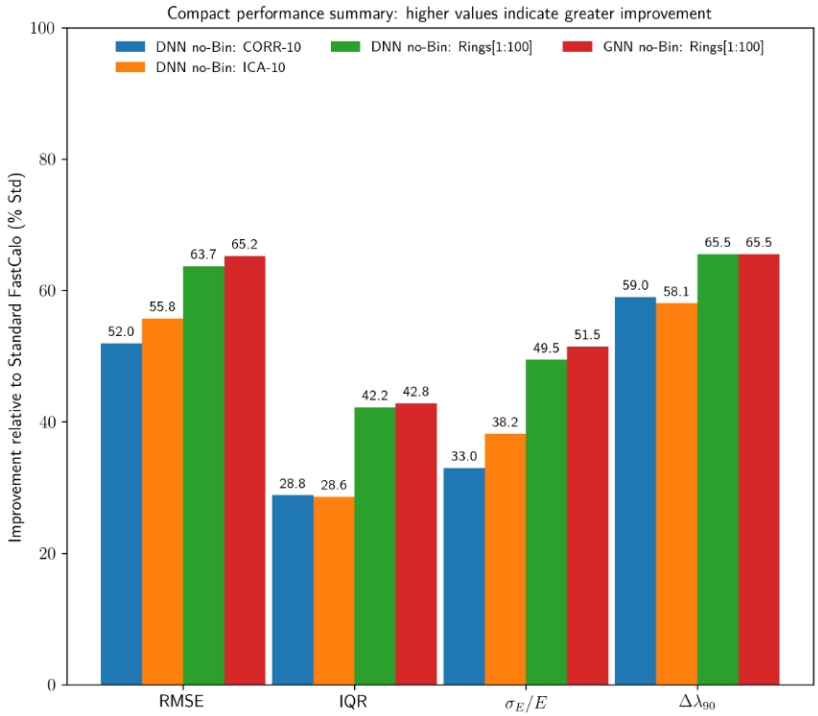


Figura 37 – Síntese dos ganhos relativos das configurações representativas da Etapa III em RMSE, IQR, resolução relativa de energia e deslocamento associado à resposta a limiar. Valores maiores representam maior melhoria em relação ao Standard FastCalo. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

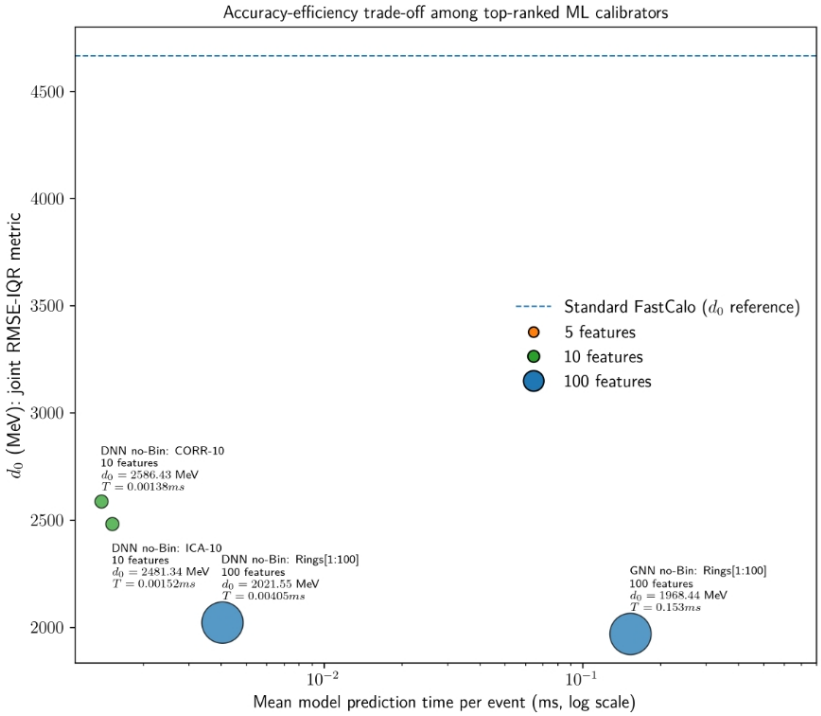
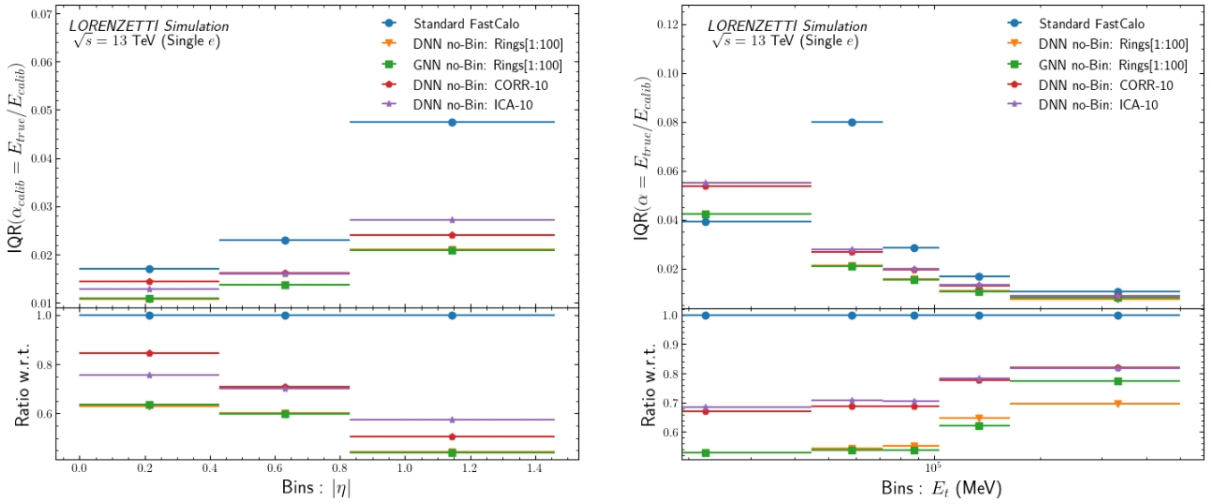


Figura 38 – Compromisso entre qualidade da calibração e custo de predição para configurações representativas da Etapa III. O eixo vertical apresenta d_0, o eixo horizontal apresenta o tempo de predição amortizado em CPU e o tamanho dos marcadores representa a dimensionalidade externa F. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

8.5 Estabilidade regional do fator de calibração

Os modelos são treinados globalmente, e os bins de $(|\eta|, E_T)$ são utilizados após a inferência para verificar se o desempenho agregado é acompanhado por comportamento regional regular. A Figura 39 mostra o IQR do fator de calibração nas regiões avaliadas.



(a) $|\eta|$ **(b)** E_T

Figura 39 – IQR do fator de calibração nas regiões de (a) $|\eta|$ e (b) E_T para as configurações selecionadas da Etapa III. Os painéis relativos utilizam *Standard FastCalo* como referência unitária. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

A dispersão do fator tende a aumentar com $|\eta|$ e a diminuir à medida que E_T cresce. As configurações neurais acompanham a tendência geral da referência, indicando que o treinamento global preserva a dependência regional dominante do fator de correção. No primeiro intervalo de energia, *Standard FastCalo* apresenta localmente menor IQR de α que alguns modelos, mas esse comportamento ocorre no fator multiplicativo e não reverte o ganho observado diretamente na energia calibrada.

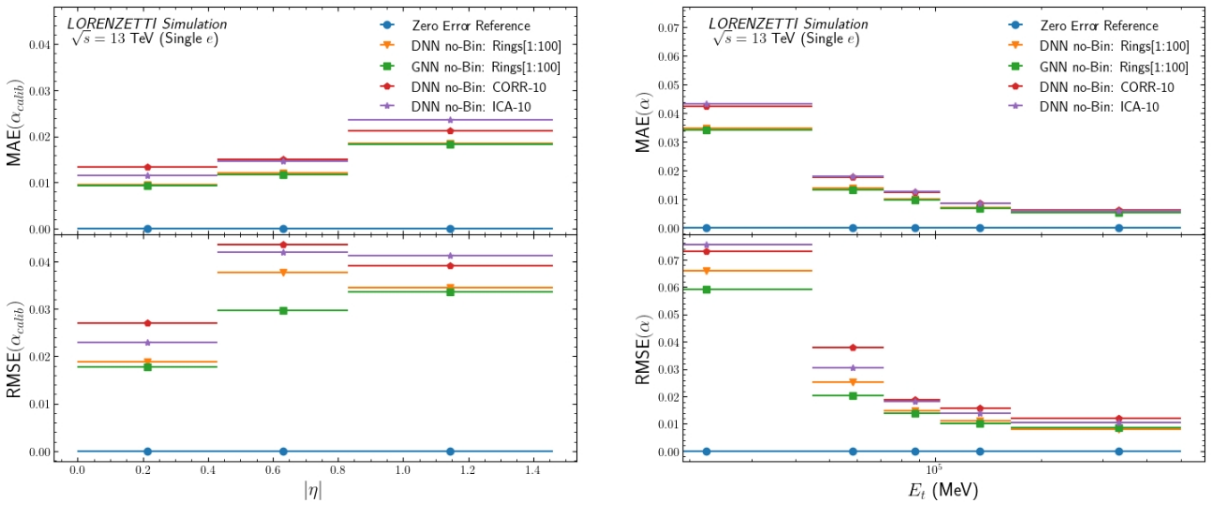
A Figura 40 complementa a análise com MAE e RMSE de α_{calib} em relação a α_{true}. Os erros aumentam com $|\eta|$ e diminuem com a energia, reproduzindo a mesma estrutura regional observada no IQR.

Os boxplots da Figura 41 mostram a distribuição completa dos fatores previstos. As medianas acompanham o comportamento regional da referência e a dispersão cresce nas regiões em que a estimação do fator é mais difícil.

Em conjunto, IQR, MAE, RMSE e boxplots não revelam instabilidades localizadas pronunciadas que contradigam o desempenho global. A análise regional, portanto, reforça a adequação do treinamento global para o benchmark avaliado e mostra em quais regiões a estimação do fator permanece mais desafiadora.

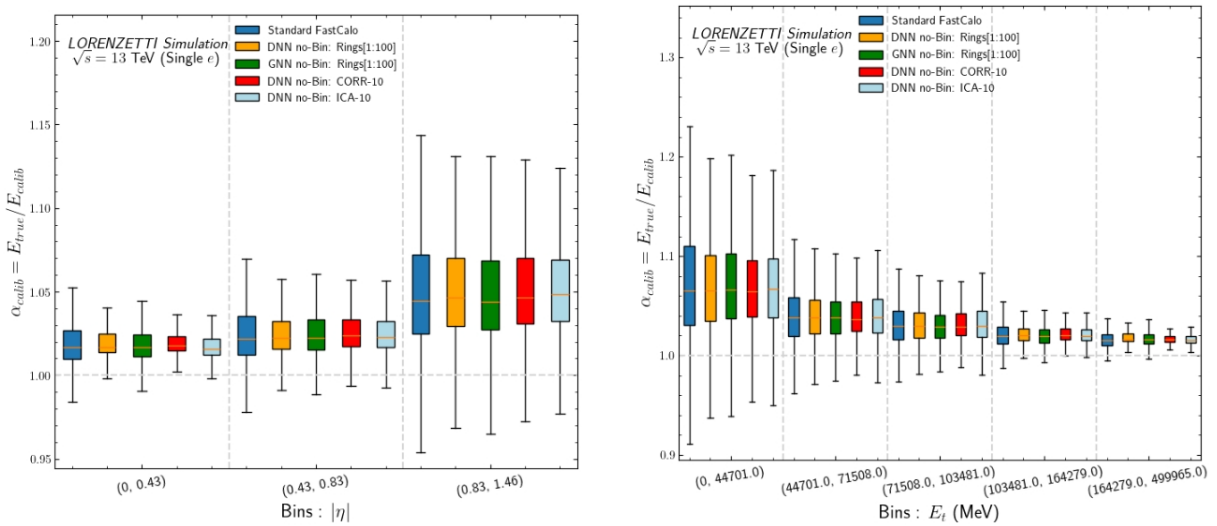
8.6 Resolução relativa de energia

A Figura 42 apresenta a resolução relativa de energia em função de E_{true}. As quatro configurações selecionadas melhoram a resolução em grande parte do intervalo estudado, com os



(a) $|\eta|$ **(b)** E_T

Figura 40 – MAE e RMSE do fator previsto α_{calib} em relação a α_{true} nos bins de (a) $|\eta|$ e (b) E_T. A referência de erro nulo representa $\alpha_{\text{calib}} = \alpha_{\text{true}}$. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).



(a) $|\eta|$ **(b)** E_T

Figura 41 – Distribuição de α_{calib} para as configurações selecionadas nos bins de (a) $|\eta|$ e (b) E_T. A largura das caixas representa o IQR. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

maiores ganhos nas regiões de baixa e média energia.

Os modelos completos apresentam os menores valores de σ_E/E na maior parte do espectro. A GNN é mais favorável em grande parte das regiões de baixa e média energia, enquanto a DNN completa se torna comparável e, em alguns intervalos, ligeiramente melhor em energias mais altas. A ordenação entre as duas arquiteturas, portanto, não é invariável com E_{true}.

A Tabela 18 resume os valores agregados. A GNN completa melhora a resolução relativa em 51,46% em relação ao Standard FastCalo, e a DNN completa em 49,46%. Mesmo com apenas dez entradas, ICA-10 e CORR-10 alcançam melhorias de 38,20% e 32,98%, respectivamente.

A resolução confirma a mesma hierarquia observada nas métricas globais: a representação completa maximiza a precisão, enquanto os modelos compactos retêm parte substancial do ganho. A pequena diferença agregada entre GNN e DNN completa, $1{,}19 \times 10^{-2}$ contra $1{,}24 \times 10^{-2}$,

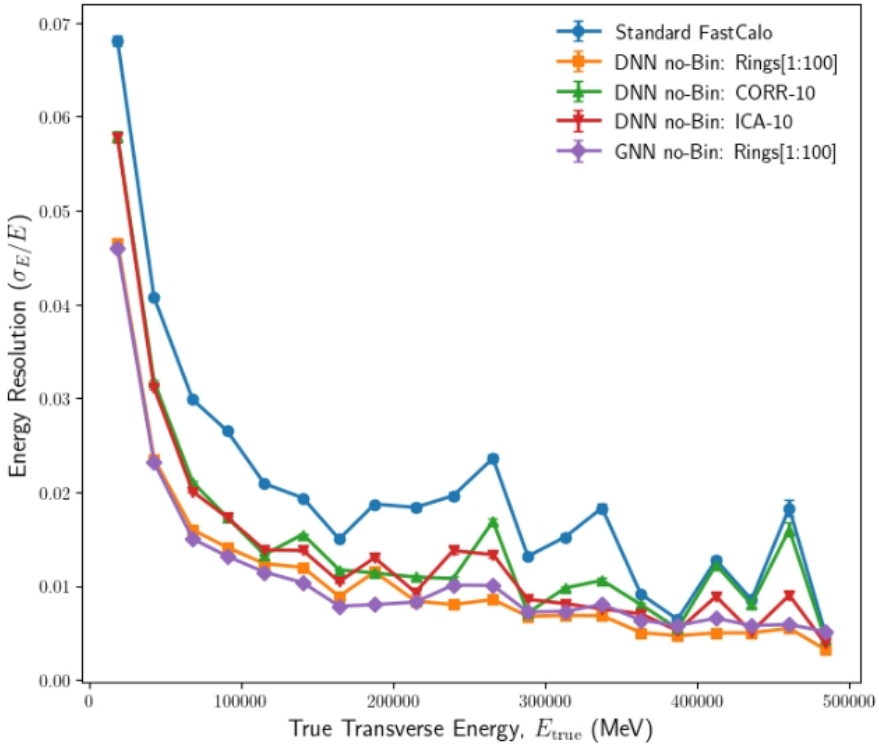


Figura 42 – Resolução relativa de energia σ_E/E em função de E_{true} para *Standard FastCalo* e as quatro configurações neurais selecionadas na Etapa III. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

Tabela 18 – Resumo da resolução relativa de energia para as configurações selecionadas da Etapa III.

Configuração	σ_E/E	**melhoria relativa**
Standard FastCalo	$2{,}46 \times 10^{-2} \pm 5{,}80 \times 10^{-5}$	–
DNN no-Bin: CORR-10	$1{,}65 \times 10^{-2} \pm 3{,}90 \times 10^{-5}$	32,98%
DNN no-Bin: ICA-10	$1{,}52 \times 10^{-2} \pm 3{,}60 \times 10^{-5}$	38,20%
DNN no-Bin: Rings[1:100]	$1{,}24 \times 10^{-2} \pm 2{,}90 \times 10^{-5}$	49,46%
GNN no-Bin: Rings[1:100]	$1{,}19 \times 10^{-2} \pm 2{,}80 \times 10^{-5}$	51,46%

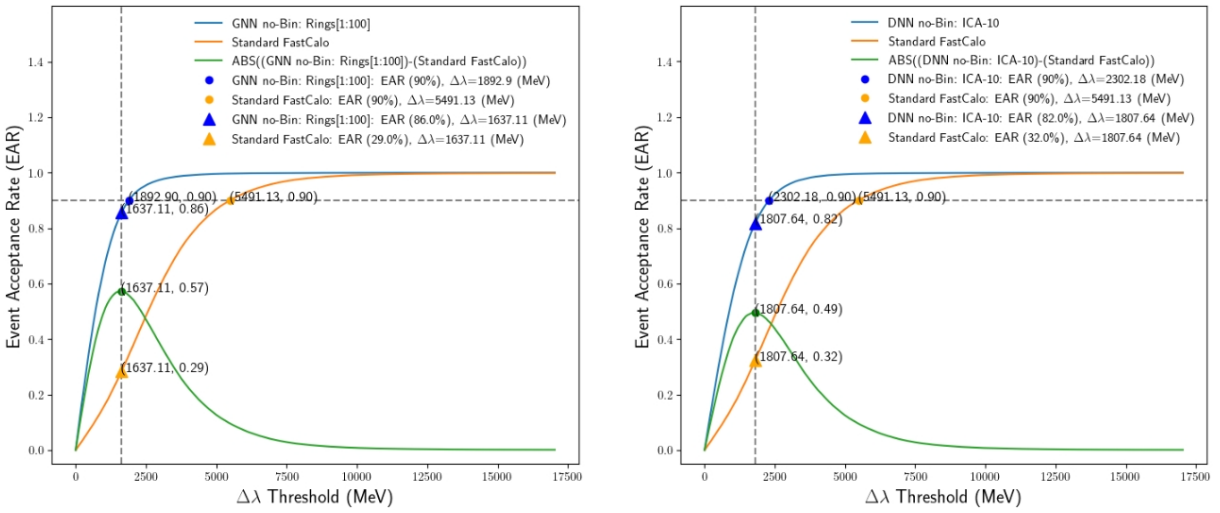
também reforça que o ganho adicional da arquitetura relacional é incremental.

8.7 Resposta a limiar e aceitação de eventos

A Figura 43 apresenta a taxa de aceitação de eventos em função de $\Delta\lambda$ para a GNN completa e para a DNN ICA-10, comparadas ao Standard FastCalo. Uma transição mais estreita corresponde a menor valor de $\Delta\lambda$ para alcançar a mesma taxa de aceitação.

A Tabela 19 reúne os valores de $\Delta\lambda_{90}$ das quatro configurações selecionadas.

Os dois modelos completos atingem 90% de aceitação com $\Delta\lambda_{90} = 1.892{,}90$ MeV, contra 5.491,13 MeV para Standard FastCalo, uma redução de 65,53%. A DNN CORR-10 reduz o deslocamento em 59,01% e a DNN ICA-10 em 58,07%. Em pontos intermediários reportados no manuscrito, a GNN atinge 86% de aceitação em $\Delta\lambda = 1.637{,}11$ MeV, enquanto a referência atinge 29%; para ICA-10, a aceitação é 82% em $\Delta\lambda = 1.807{,}64$ MeV, contra 32% da referência (SILVA; SIMAS FILHO, 2026).



(a) GNN no-Bin: Rings[1:100] **(b)** DNN no-Bin: ICA-10

Figura 43 – Curvas de aceitação para (a) GNN com os 100 anéis e (b) DNN com ICA-10, ambas comparadas ao Standard FastCalo. As linhas e marcadores indicam pontos de operação representativos utilizados para quantificar a aceitação em função de $\Delta\lambda$. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

Tabela 19 – Resposta a limiar das configurações selecionadas da Etapa III. $\Delta\lambda_{90}$ representa o valor necessário para atingir 90% de aceitação na convenção definida na Seção 5.11.

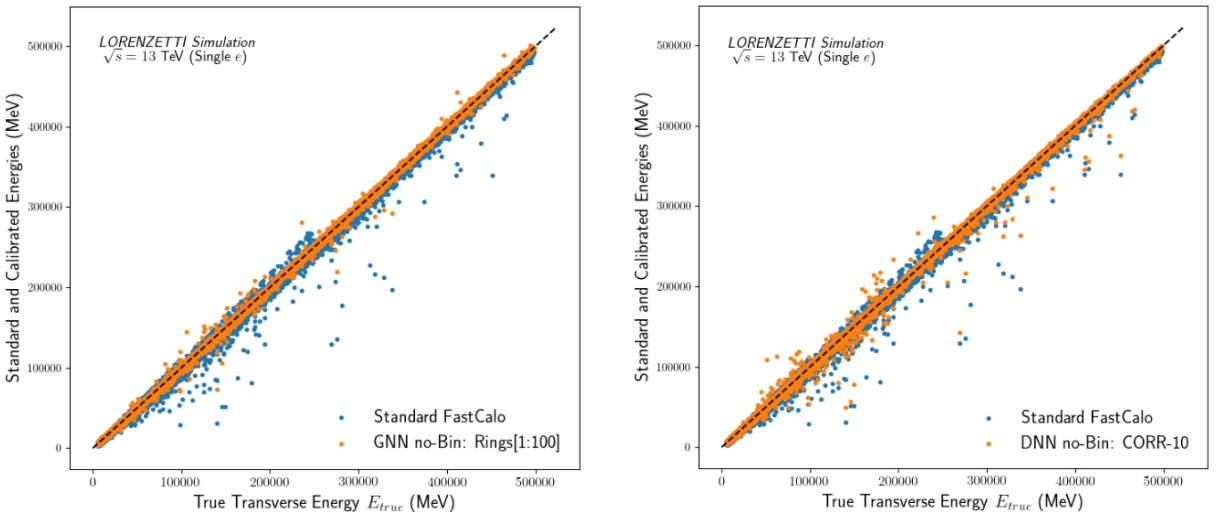
Configuração	**$\Delta\lambda_{90}$ (MeV)**	**redução relativa**
Standard FastCalo	5491,13	–
DNN no-Bin: CORR-10	2251,02	59,01%
DNN no-Bin: ICA-10	2302,18	58,07%
DNN no-Bin: Rings[1:100]	1892,90	65,53%
GNN no-Bin: Rings[1:100]	1892,90	65,53%

Esses resultados mostram que a redução do erro global também se manifesta em uma resposta mais concentrada na vizinhança do valor verdadeiro. Conforme a definição da Seção 5.11, $\Delta\lambda_{90}$ é empregado aqui como indicador de concentração da resposta energética. A ausência de uma amostra representativa de fundo impede convertê-lo, isoladamente, em uma medida completa de desempenho de um menu operacional de *trigger*.

8.8 Linearidade e consistência evento a evento

A Figura 44 compara a energia reconstruída com E_{true} para a GNN completa e a DNN CORR-10. Nos dois casos, a calibração concentra os eventos mais próximos da diagonal ideal em relação ao Standard FastCalo.

A GNN completa apresenta a concentração visual mais estreita entre as configurações mostradas, em concordância com seu menor RMSE e d_0. A DNN CORR-10 também reduz claramente a dispersão com apenas dez anéis selecionados. A análise evento a evento conecta, assim, as reduções das métricas escalares a uma aproximação mais estreita da resposta ideal ao longo do intervalo de energia.

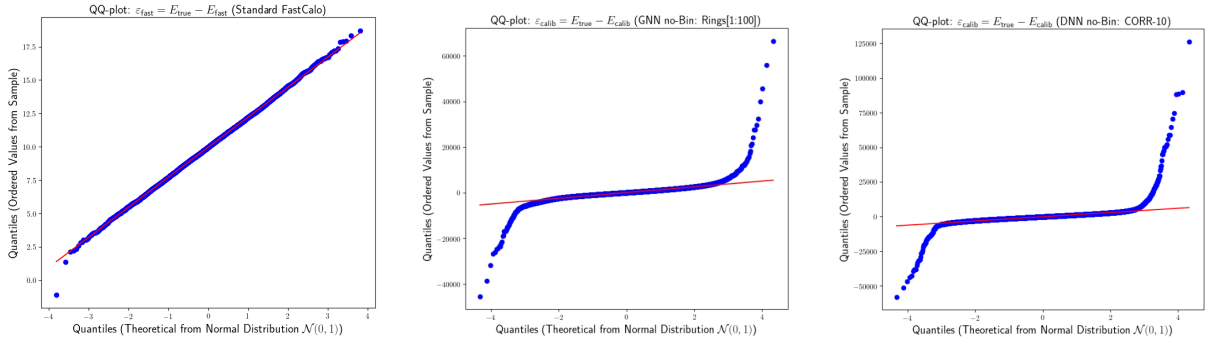


(a) GNN no-Bin: Rings[1:100] **(b)** DNN no-Bin: CORR-10

Figura 44 – energia transversa calibrada em função de E_{true} para duas configurações representativas da Etapa III, comparadas ao Standard FastCalo. A linha diagonal tracejada representa a resposta ideal $E_{\text{calib}} = E_{\text{true}}$. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

8.9 Validação estatística

Os testes de D'Agostino–Pearson e Anderson–Darling rejeitam normalidade para os resíduos e para suas diferenças pareadas nas configurações selecionadas, com $p < 10^{-16}$. Os gráficos Q–Q da Figura 45 mostram desvios evidentes nas caudas, justificando o uso conjunto de testes pareados paramétricos, não paramétricos e de *bootstrap*.



(a) Standard FastCalo **(b)** GNN: Rings[1:100] **(c)** DNN: CORR-10

Figura 45 – Gráficos Q–Q representativos para os resíduos do Standard FastCalo, da GNN completa e da DNN CORR-10. Os desvios nas caudas sustentam o uso complementar de inferência não paramétrica e *bootstrap*. Fonte: elaborado a partir de (SILVA; SIMAS FILHO, 2026).

Para o deslocamento do resíduo, a hipótese é a definida na Eq. 5.43. A Tabela 20 apresenta o teste z pareado de grande amostra e a decisão do Wilcoxon; o teste t pareado conduz à mesma decisão.

Em todas as configurações, a hipótese nula é rejeitada com ampla margem. Os intervalos unilaterais permanecem inteiramente abaixo de zero, confirmando um deslocamento estatisticamente detectável do resíduo calibrado em relação ao Standard FastCalo. Esse resultado é complementar às métricas de magnitude de erro e não substitui RMSE, IQR ou resolução.

A redução de dispersão é avaliada pela razão $R_{\sigma^2} = \sigma^2_{\text{calib}}/\sigma^2_{\text{fast}}$. A Tabela 21 mostra os

Tabela 20 – Inferência pareada para o deslocamento do resíduo na Etapa III. Os intervalos para μ_d são unilaterais de 95%.

Configuração	z	p_z	**IC$_{95\%}$ para μ_d (MeV)**	**Wilcoxon: decisão**
DNN no-Bin: Rings[1:100]	-324,5005	$< 10^{-300}$	$(-\infty; -2866{,}32]$	Rejeita H_0
DNN no-Bin: CORR-10	-392,2214	$< 10^{-300}$	$(-\infty; -2859{,}67]$	Rejeita H_0
DNN no-Bin: ICA-10	-325,9147	$< 10^{-300}$	$(-\infty; -2779{,}70]$	Rejeita H_0
GNN no-Bin: Rings[1:100]	-317,7842	$< 10^{-300}$	$(-\infty; -2721{,}46]$	Rejeita H_0

resultados do teste pareado de Pitman–Morgan.

Tabela 21 – Comparação da variância dos resíduos na Etapa III. Valores de $R_{\sigma^2} < 1$ indicam menor variância após calibração.

Configuração	R_{σ^2}	**redução de variância**	**limite superior IC$_{95\%}$ PM**
DNN no-Bin: Rings[1:100]	0,2555	74,45%	0,2850
DNN no-Bin: CORR-10	0,4492	55,08%	0,4861
DNN no-Bin: ICA-10	0,3820	61,80%	0,4174
GNN no-Bin: Rings[1:100]	0,2356	76,44%	0,2555

Todas as razões de variância são inferiores à unidade. A GNN completa apresenta $R_{\sigma^2} = 0{,}2356$, correspondente a uma redução de 76,44% da variância dos resíduos; a DNN completa alcança 74,45%, ICA-10 61,80% e CORR-10 55,08%. O *bootstrap* pareado BCa com 5000 reamostragens produz a mesma decisão qualitativa, com limites superiores de 0,2847, 0,4851, 0,4174 e 0,2551, respectivamente (SILVA; SIMAS FILHO, 2026).

A validação estatística converge, portanto, com a análise de desempenho: as configurações neurais não apenas reduzem RMSE e IQR, mas também produzem distribuições residuais substancialmente menos dispersas que a referência. Entre os modelos completos, a diferença GNN–DNN permanece pequena em termos absolutos, enquanto ambos apresentam forte redução de variância em relação ao Standard FastCalo.

8.10 Implicação para reconstrução de massa invariante

Os resultados de resolução obtidos no nível do candidato permitem estimar analiticamente como a componente energética pode se propagar para observáveis de nível superior. Para dois candidatos eletromagnéticos aproximadamente sem massa, a massa invariante pode ser escrita como

$$m_{ee}^2 = 2E_{\mathrm{calib},a}E_{\mathrm{calib},b}\left[\cosh(\Delta\eta) - \cos(\Delta\phi)\right], \tag{8.1}$$

em que a e b representam os dois candidatos. Mantendo os termos angulares fixos e considerando pequenas perturbações, a propagação de primeira ordem fornece

$$\frac{\delta m_{ee}}{m_{ee}} \approx \frac{1}{2}\left(\frac{\delta E_a}{E_a} + \frac{\delta E_b}{E_b}\right). \tag{8.2}$$

Se os dois resíduos relativos tiverem variâncias semelhantes e correlação pequena,

$$\mathrm{Var}\left(\frac{\delta m_{ee}}{m_{ee}}\right) \approx \frac{1}{2}\mathrm{Var}\left(\frac{\delta E}{E}\right). \tag{8.3}$$

Nessa aproximação, a redução de σ_E/E de $2{,}46 \times 10^{-2}$ para $1{,}19 \times 10^{-2}$ obtida pela GNN completa reduz na mesma proporção a contribuição energética aproximada para σ_m/m, de $2{,}46 \times 10^{-2}/\sqrt{2}$ para $1{,}19 \times 10^{-2}/\sqrt{2}$. O resultado estabelece uma ligação analítica entre a melhoria da calibração no nível do candidato e a resolução de uma ressonância reconstruída.

Essa propagação não substitui uma análise com eventos $Z \to e^+e^-$. Uma validação ressonante completa precisa incorporar as correlações angulares, seleção do par, radiação no estado final, fundo e ajuste da distribuição de massa. Assim, o resultado desta seção quantifica somente a contribuição energética esperada a partir da resolução medida na amostra de elétrons individuais.

8.11 Escopo dos resultados da Etapa III

A Etapa III foi avaliada com *pile-up* incluído, em uma configuração cujo perfil apresenta média $\langle\mu\rangle = 38{,}94$ e desvio-padrão 9,999. Portanto, RMSE, IQR, resolução, resposta a limiar e validação estatística já refletem essa atividade adicional simulada. Como não foi realizada uma varredura controlada em μ, os resultados caracterizam o desempenho sob essa distribuição específica e não uma invariância da calibração a diferentes regimes de ocupação.

Também permanecem fora do escopo desta etapa a validação em dados experimentais, a região de *endcap*, a avaliação com fundo representativo e a medição de latência de ponta a ponta em hardware de destino. O tempo T mede apenas a predição amortizada do modelo treinado no benchmark CPU. Para a GNN, a comparação com a DNN avalia as arquiteturas completas; identificar a contribuição individual do grafo, dos descritores e dos diferentes ramos requer um estudo de ablação específico.

8.12 Conclusão do capítulo

A Etapa III mostra que a fusão neural amplia o desempenho da calibração baseada em anéis e preserva a existência de soluções compactas. Entre as representações reduzidas, DNNs com dez entradas continuam altamente competitivas: ICA-10 reduz o RMSE em 55,76% e CORR-10 em 51,96%, demonstrando que uma fração substancial da informação relevante permanece acessível em espaços de baixa dimensão.

Com os 100 anéis, `GNN no-Bin: Rings[1:100]` alcança o melhor desempenho absoluto da etapa, com RMSE de 1.378,77 MeV, IQR de 1.404,90 MeV e $d_0 = 1.968{,}44$ MeV. Em relação ao Standard FastCalo, as reduções são de 65,25% no RMSE, 42,82% no IQR e 57,82% em d_0. A mesma configuração melhora a resolução relativa em 51,46% e reduz a variância dos resíduos em 76,44%. A DNN completa permanece próxima nesses indicadores e apresenta custo de predição muito menor, evidenciando que o ganho adicional da arquitetura relacional vem acompanhado de maior custo computacional.

Os resultados regionais, as curvas de resolução, a resposta a limiar, os *scatter plots* e a validação estatística apontam na mesma direção: a melhoria não se restringe a uma única métrica agregada. Os modelos neurais reduzem o erro evento a evento, estreitam a distribuição residual e melhoram a precisão dependente da energia. Ao mesmo tempo, ICA-10 e CORR-10 mostram que parte substancial desse ganho pode ser preservada com 90% de redução na dimensionalidade externa em relação aos 100 anéis.

A principal conclusão da Etapa III é, portanto, a existência de uma nova fronteira desempenho–complexidade: a GNN relacional–tabular fornece a maior precisão absoluta no benchmark, a DNN completa oferece desempenho próximo com custo muito menor e DNNs compactas preservam ganhos expressivos com apenas dez entradas. Com essa etapa, encerra-se a progressão experimental principal da tese e o Capítulo 9 integra os resultados das três etapas para responder globalmente às questões de pesquisa e à hipótese central.

9 Síntese, Discussão e Conclusões

Este capítulo integra os resultados apresentados nos Capítulos 6, 7 e 8 à luz do problema científico, da hipótese e das questões de pesquisa formuladas no Capítulo 1. O objetivo é sintetizar o que as três etapas experimentais demonstraram em conjunto, identificar os compromissos entre representação, capacidade de modelagem e custo computacional e delimitar o alcance das conclusões obtidas.

A Etapa I, publicada na *IEEE Transactions on Nuclear Science* (SILVA et al., 2026b), estabeleceu a viabilidade da calibração baseada em anéis com regressores convencionais e redução de dimensionalidade. A Etapa II, publicada na revista *Measurement* (SILVA et al., 2026a), ampliou a investigação para *Random Forests*, aprendizado residual e *stacked models*. A Etapa III, apresentada em manuscrito submetido à revista *Information Fusion* (SILVA; SIMAS FILHO, 2026), estendeu a cadeia para DNNs e para uma arquitetura GNN relacional–tabular.

As três etapas preservam o mesmo núcleo físico e a mesma formulação geral de calibração, mas não constituem uma ablação arquitetural controlada entre si. Por essa razão, a síntese entre etapas privilegia as reduções relativas ao *Standard FastCalo* dentro de cada protocolo e utiliza as comparações absolutas principalmente quando as condições experimentais são suficientemente próximas. Essa distinção permite interpretar a evolução da pesquisa sem atribuir a uma única alteração metodológica efeitos que não foram isolados experimentalmente.

9.1 Visão integrada da investigação

A tese foi construída em torno de uma pergunta central: a distribuição espacial da energia em um calorímetro segmentado, codificada por uma representação em anéis, contém informação suficiente para corrigir evento a evento a estimativa rápida de energia transversa? No domínio do *benchmark* estudado, os resultados das três etapas fornecem resposta afirmativa.

A cadeia de calibração preservada ao longo da tese pode ser resumida por

$$\mathbf{x} = g_{\mathrm{ML}}\left(\widetilde{\mathbf{E}}_r\right), \qquad \alpha_{\mathrm{calib}} = f_{\mathrm{ML}}\left(\mathbf{x}\right), \qquad E_{\mathrm{calib}} = \alpha_{\mathrm{calib}} E_{\mathrm{fast}}, \tag{9.1}$$

onde $\widetilde{\mathbf{E}}_r$ representa o perfil normalizado de anéis, $g_{\mathrm{ML}}(\cdot)$ preserva ou transforma essa representação e $f_{\mathrm{ML}}(\cdot)$ estima o fator multiplicativo de calibração. A evolução experimental ocorreu principalmente pela mudança da representação fornecida ao regressor e pelo aumento da diversidade das famílias de modelos avaliadas.

A Etapa I mostrou que regressores não lineares, especialmente BDTs, exploram informação dos anéis capaz de reduzir substancialmente o erro do *Standard FastCalo* e que representações compactas podem preservar grande parte desse ganho. A Etapa II mostrou que *ensembles* e aprendizado residual podem produzir melhoria incremental sobre regressores individuais, embora a diferença para um BDT completo tenha sido pequena. A Etapa III mostrou que DNNs funcionam bem tanto com representações completas quanto compactas e que a arquitetura GNN

relacional–tabular apresentou, no protocolo dessa etapa, os menores valores de RMSE e d_0 e a menor resolução relativa entre as configurações avaliadas.

A síntese dessas três etapas revela uma fronteira empírica entre qualidade de reconstrução, dimensionalidade da representação e custo de inferência. A representação completa favorece o desempenho absoluto, enquanto representações compactas preservam parcela substancial do ganho com menor dimensionalidade. A escolha de uma configuração depende, portanto, do conjunto de requisitos da aplicação, e não de um único ranking algorítmico.

9.2 Evolução dos resultados ao longo das três etapas

9.2.1 Configurações representativas de maior desempenho por etapa

A Tabela 22 resume uma configuração representativa de melhor desempenho de cada etapa. Por melhor desempenho entenda aqui menores RMSE e IQR absolutos implicando em menores d_0. Comparativamente ao *Standard FastCalo*, correspondem às configurações que apresentaram maiores reduções percentuais do ΔRMSE e ΔIQR. Na Etapa I, `BDT no-Bin: PCA-100` foi selecionada por apresentar o menor d_0 daquele estudo; a configuração PCA-10 apresentou RMSE ligeiramente menor e é retomada na análise de compactação. Nas Etapas II e III, são apresentados os modelos de menor d_0.

Tabela 22 – Evolução das configurações representativas de melhor desempenho em cada etapa. As porcentagens correspondem a reduções relativas ao *Standard FastCalo* da própria etapa. A Etapa I utiliza o protocolo descrito no Capítulo 5; por isso, os valores devem ser comparados entre etapas principalmente por suas reduções relativas, e não como uma ablação controlada de arquitetura.

Etapa	**Família**	**Configuração representativa**	F	**ΔRMSE**	**ΔIQR**	Δd_0	$\Delta(\sigma_E/E)$
I	BDT	BDT no-Bin: PCA-100	100	57,95%	44,13%	53,85%	–
II	RFBDT	RFBDT no-Bin: Rings[1:100]	100	60,61%	43,39%	55,17%	44,96%
III	GNN relacional–tabular	GNN no-Bin: Rings[1:100]	100	65,25%	42,82%	57,82%	51,46%

As configurações representativas apresentam reduções crescentes de RMSE e d_0 ao longo da evolução experimental, enquanto o IQR permanece em uma faixa semelhante. A redução de IQR é de 44,13% na Etapa I, 43,39% na Etapa II e 42,82% na Etapa III. Portanto, a evolução observada não corresponde a uma melhora monotônica de todas as métricas: os maiores avanços aparecem no erro quadrático e, nas Etapas II e III, também na resolução relativa de energia.

O comportamento distinto de RMSE e IQR é informativo. Como o RMSE atribui maior peso a desvios de maior magnitude, sua redução mais acentuada é compatível com uma diminuição mais forte da contribuição de erros grandes, enquanto a largura da região central da distribuição, caracterizada pelo IQR, varia menos. Esse resultado reforça a necessidade de interpretar conjuntamente RMSE, IQR, d_0, resolução e a forma das distribuições residuais.

Nas Etapas II e III, cujos protocolos são mais próximos, o RFBDT completo (com os 100 anéis) apresentou RMSE de 1.562,75 MeV e d_0 = 2.092,11 MeV. A DNN completa atingiu RMSE de 1.439,35 MeV com d_0 = 2.021,55 MeV, e a GNN completa teve RMSE de 1.378,77 MeV e d_0 = 1.968,44 MeV. Em relação ao RFBDT, as diferenças correspondem a reduções de aproximadamente 7,90% no RMSE e 3,37% no d_0 para a DNN. Para a GNN os valores de redução foram de 11,77% e 5,91% em RMSE e d_0, respectivamente. O IQR, contudo,

permanece ligeiramente menor no RFBDT. A comparação mostra que as arquiteturas neurais deslocaram principalmente a fronteira de RMSE e resolução, sem dominar todas as métricas simultaneamente.

9.2.2 Representações compactas

A segunda tendência recorrente é a preservação de desempenho sob forte redução de dimensionalidade. A Tabela 23 reúne configurações compactas representativas com cinco ou dez entradas externas.

Tabela 23 – Configurações compactas representativas ao longo da tese. As porcentagens são reduções relativas ao *Standard FastCalo* da própria etapa.

Etapa	**Configuração**	F	**Tipo de representação**	**ΔRMSE**	**ΔIQR**	Δd_0
I	BDT no-Bin: PCA-10	10	latente	58,44%	35,22%	51,14%
II	BDT no-Bin: ICA-5	5	latente	51,25%	25,45%	42,92%
III	DNN no-Bin: ICA-10	10	latente	55,76%	28,61%	46,83%

A Etapa I mostrou que dez componentes PCA eram suficientes para alcançar o menor RMSE daquele estudo. Na Etapa II, ICA-5 preservou redução de RMSE superior a 51% utilizando apenas cinco componentes, enquanto PCA-10 apresentou erro ligeiramente menor com dimensionalidade duas vezes maior. Na Etapa III, ICA-10 manteve redução de RMSE de 55,76% com dez componentes.

Esses resultados não estabelecem uma dimensionalidade universalmente suficiente, mas mostram que, no domínio avaliado, parte substancial da informação preditiva pode ser concentrada em espaços de baixa dimensão. Ao mesmo tempo, as representações completas permanecem favorecidas quando o objetivo é o melhor desempenho absoluto. A compactação deve, portanto, ser interpretada como um ponto de operação na fronteira desempenho–complexidade, e não como evidência de que os demais anéis sejam fisicamente irrelevantes.

9.2.3 Capacidade do modelo e estrutura residual

A comparação entre as famílias de modelos mostra que ganhos substanciais já são obtidos quando a informação dos anéis é disponibilizada a regressores não lineares, enquanto mecanismos adicionais produzem incrementos de magnitude menor.

Na Etapa II, o RFBDT completo (com 100 anéis) reduziu o RMSE em 60,61% comparativamente ao *Standard FastCalo*, contra 60,17% do BDT completo. O RFBDT apresentou, portanto, uma melhoria numérica mensurável, mas pequena, sobre uma referência já muito forte. Na Etapa III, a DNN completa reduziu o RMSE em 63,72%, enquanto a GNN relacional–tabular atingiu 65,25%, uma diferença de 1,53 pontos percentuais em favor da GNN.

A trajetória experimental indica, assim, retornos adicionais progressivamente menores quando se acrescentam mecanismos mais especializados, como aprendizado residual ou fusão relacional–tabular. Como as etapas não constituem uma ablação controlada entre si, esses resultados devem ser lidos como evolução empírica da pesquisa. A contribuição prática é mostrar

que o ganho incremental precisa ser ponderado pelo custo computacional e pela complexidade de validação da arquitetura.

9.3 Fronteira desempenho–complexidade

Um resultado central da tese é a inexistência de uma configuração dominante quando qualidade da calibração, dimensionalidade e custo computacional são considerados simultaneamente.

No regime de máxima qualidade absoluta dentro de cada protocolo, os melhores resultados das Etapas II e III utilizam os 100 anéis. Na Etapa III, a GNN completa fornece o menor RMSE e a melhor resolução relativa entre as configurações avaliadas, enquanto a DNN completa permanece próxima com custo de predição substancialmente menor no mesmo *benchmark*. No regime de compactação, representações com cinco ou dez entradas preservam reduções de RMSE superiores a 50% em diferentes etapas.

O índice D_0, definido na Seção 5.12.1, é útil para ordenar configurações dentro de um conjunto comparado, mas não constitui uma escala física comum entre capítulos. Da mesma forma, os tempos de predição correspondem aos ambientes computacionais em que foram medidos e devem ser utilizados para comparar configurações dentro desses contextos.

A consequência de engenharia é direta: uma aplicação orientada à máxima precisão favorece modelos completos; restrições de dimensionalidade, movimentação de dados ou simplicidade tornam representações compactas particularmente relevantes; e requisitos de latência operacional exigem medição de ponta a ponta em hardware e software representativos da cadeia de destino.

9.4 Respostas às questões de pesquisa

9.4.1 RQ1 — Informação e compactação

A RQ1 investigou se a representação baseada em anéis fornece informação útil para calibração evento a evento e quanto do desempenho pode ser preservado após sua redução. Nas três etapas, modelos alimentados com informação derivada dos anéis reduziram substancialmente o RMSE em relação ao *Standard FastCalo*. Além disso, configurações com cinco ou dez entradas preservaram reduções de RMSE superiores a 50% em diferentes etapas.

A resposta à RQ1 é, portanto, que a representação em anéis contém informação preditiva relevante e que uma parcela substancial desse conteúdo pode ser concentrada em representações compactas. A representação completa, contudo, permanece vantajosa quando o objetivo é maximizar a qualidade absoluta.

9.4.2 RQ2 — Regressores convencionais

A RQ2 examinou como modelos lineares, polinomiais e baseados em árvores exploram as representações completa e compactas. A Etapa I mostrou que os BDTs concentraram os melhores

resultados entre as famílias convencionais e operaram eficazmente tanto sobre a representação completa quanto sobre espaços reduzidos, com destaque para PCA-100 e PCA-10.

A comparação entre treinamento global e segmentado mostrou ainda que a dependência da resposta com $|\eta|$ e E_T não implica vantagem automática para regressores independentes por bin. No conjunto avaliado, o treinamento global permaneceu competitivo ou superior, e as etapas posteriores passaram a utilizar os bins principalmente como diagnóstico regional.

9.4.3 RQ3 — Aprendizado híbrido

A RQ3 investigou se correção residual e *stacked models* conseguem explorar estrutura remanescente de regressores individuais. O RFBDT completo atingiu o menor RMSE e o menor d_0 da Etapa II, resultado compatível com a existência de estrutura residual explorável pelo segundo estágio.

O ganho sobre o BDT completo, porém, foi pequeno e não ocorreu de forma uniforme em todas as métricas. A resposta à RQ3 é, portanto, que o aprendizado residual pode produzir ganho incremental, mas seu benefício deve ser avaliado em relação ao custo adicional da arquitetura.

9.4.4 RQ4 — Fusão neural

A RQ4 examinou o desempenho de DNNs sobre representações completas e compactas. A DNN completa reduziu o RMSE em 63,72% e melhorou a resolução relativa em 49,46%, enquanto ICA-10 e CORR-10 mantiveram reduções de RMSE de 55,76% e 51,96%, respectivamente.

Assim, as DNNs foram eficazes nos dois regimes de representação. A representação completa forneceu o melhor desempenho da família, enquanto as versões compactas preservaram grande parcela do ganho com redução de 90% na dimensionalidade externa em relação aos 100 anéis.

9.4.5 RQ5 — Estrutura relacional

A RQ5 comparou a arquitetura GNN relacional–tabular completa a uma DNN tabular sobre a representação de 100 anéis. A GNN obteve as menores estimativas pontuais de RMSE e d_0 e a melhor resolução relativa da Etapa III, enquanto a DNN completa permaneceu próxima e apresentou menor custo de predição.

A resposta sustentada pelo experimento é que a arquitetura relacional–tabular é competitiva e desloca numericamente a fronteira de desempenho da Etapa III. Como a GNN combina ramo em grafo, descritores derivados, ramo tabular, *pooling* e conexões de atalho, a comparação realizada não isola a contribuição causal da topologia do grafo.

9.4.6 RQ6 — Compromissos de engenharia

A RQ6 investigou os compromissos entre erro, dispersão, resolução, estabilidade regional, dimensionalidade e custo de inferência. Os resultados mostram dois regimes recorrentes: modelos completos para máxima precisão e representações compactas para menor dimensionalidade com perda controlada de desempenho.

A estabilidade regional acrescenta uma dimensão adicional: os modelos preservam globalmente a correção, mas apresentam variações de erro com $|\eta|$ e energia. Dessa forma, a seleção de um calibrador deve considerar simultaneamente qualidade global, comportamento regional, dimensionalidade e custo computacional.

9.5 Avaliação da hipótese central

A hipótese formulada no Capítulo 1 estabelece que a distribuição estruturada dos depósitos de energia transversa, codificada em anéis, contém informação utilizável para estimar correções evento a evento de E_{fast} e que modelos supervisionados capazes de explorar essa representação podem reduzir o erro e a dispersão em relação ao *Standard FastCalo*.

No domínio experimental desta tese, a hipótese é suportada pelas evidências. O suporte decorre da convergência de resultados obtidos por diferentes famílias de modelos e representações. Nas três etapas, as configurações de maior destaque reduziram substancialmente o RMSE; adicionalmente, foram observadas reduções de IQR, d_0 e, nas Etapas II e III, melhora da resolução relativa de energia.

A segunda parte da hipótese também é sustentada: a informação pode ser fortemente compactada sem perda proporcional de desempenho, mas a preservação da representação completa continua vantajosa quando se busca máxima precisão. A evidência, portanto, favorece uma fronteira contínua entre compactação e qualidade de reconstrução.

O alcance dessa conclusão é o domínio experimental definido nesta tese. A validade externa para dados reais, outras regiões do detector, diferentes regimes de *pile-up* e implantação operacional é discutida de forma concentrada na Seção 9.9.

9.6 Objetivos alcançados e contribuições consolidadas

A análise conjunta permite verificar os oito objetivos específicos formulados na Seção 1.6.2. A Tabela 24 preserva a mesma estrutura e numeração estabelecidas no Capítulo 1.

As contribuições científicas resultantes podem ser sintetizadas em seis eixos. O primeiro é a consolidação de uma formulação comum que preserva o mesmo problema físico enquanto representação e regressor são modificados. O segundo é a caracterização sistemática da relação entre dimensionalidade e qualidade de calibração, mostrando a existência de pontos compactos competitivos.

O terceiro é a quantificação do valor incremental do aprendizado residual e dos *stacked models*: a Etapa II mostrou que estruturas adicionais podem ser exploradas, mas que o retorno sobre um BDT completo é pequeno. O quarto é a extensão da cadeia para fusão neural, com DNNs eficientes em representações completas e compactas.

O quinto é a proposição e avaliação de uma arquitetura GNN relacional–tabular concebida para a organização regional e local da representação Ringer. Sua originalidade está na composição *detector-informed* de grafos regionais, propagação local, *pooling*, descritores derivados, ramo tabular e fusão final, e não na proposição de um novo operador genérico de GNN.

Tabela 24 – Verificação dos objetivos específicos da tese.

Obj.	Objetivo sintetizado	Evidência obtida
1	Formalização do problema	Formulação comum por $g_{\mathrm{ML}}(\cdot)$, $f_{\mathrm{ML}}(\cdot)$ e $E_{\mathrm{calib}} = \alpha_{\mathrm{calib}} E_{\mathrm{fast}}$, preservada nas três etapas.
2	Representação da informação	Caracterização dos 100 anéis e avaliação de CORR, MUTI, PCA, ICA, Rings/2 e representação completa; configurações com 5–10 entradas permaneceram competitivas.
3	Etapa I — regressores convencionais	Comparação de MLR, PReg, DTree e BDT sobre representações completas e compactas, incluindo treinamento global e segmentado.
4	Etapa II — *ensembles* e aprendizado residual	Avaliação de RF, BDTRF, RFBDT e RFBDTS e quantificação do ganho incremental do RFBDT sobre o BDT completo.
5	Etapa III — fusão neural e relacional	Avaliação de DNNs completas e compactas e proposição da arquitetura GNN relacional–tabular; a GNN completa obteve o menor RMSE e o menor d_0 da etapa.
6	Avaliação da medição	Comparação por RMSE, IQR, d_0, resolução relativa de energia e estabilidade regional, com resposta próxima a limiares como diagnóstico complementar.
7	Avaliação estatística e computacional	Aplicação de procedimentos estatísticos pareados e medidas de dispersão, além da caracterização de dimensionalidade e custo de predição sem equipará-lo à latência operacional.
8	Validade externa	Delimitação explícita do alcance quanto a Monte Carlo, dados experimentais, diferentes regimes de *pile-up*, outras regiões do detector, fundo e implantação.

O sexto eixo é a ampliação da própria noção de desempenho: a tese combina erro global, dispersão, resolução relativa, estabilidade regional, inferência estatística pareada, dimensionalidade e custo computacional. Essa integração transforma a comparação de regressores em uma análise de engenharia da calibração.

9.7 Implicações para calorimetria rápida e seleção por limiar

9.7.1 O que a calibração corrige

A calibração proposta atua como uma correção adicional sobre a estimativa E_{fast} já disponível no *benchmark*. Sua contribuição é incorporar ao fator de correção informação sobre a distribuição espacial do chuveiro codificada nos anéis. Assim, o resultado da tese deve ser interpretado como melhoria da estimativa rápida de energia a partir de informação calorimétrica estruturada, e não como substituição das etapas anteriores de formação de células, *clusters* ou reconstrução do objeto.

9.7.2 Resolução e comportamento próximo a limiares

As reduções simultâneas de RMSE e resolução relativa mostram que os modelos produzem respostas energéticas mais concentradas no *benchmark*. As curvas de aceitação em função de $\Delta\lambda$, formalizadas na Seção 5.11, fornecem uma visualização complementar desse efeito e, nas três etapas, deslocam-se favoravelmente para as configurações calibradas.

Essa análise caracteriza a concentração do erro para a amostra de elétrons estudada. A

tradução para um ponto de operação real de *trigger* requer adicionalmente um limiar físico fixo, eficiência de sinal e aceitação ou rejeição de fundo. Esses requisitos pertencem ao próximo nível de validação operacional, sintetizado nas Seções 9.9 e 9.11.

9.7.3 Propagação para observáveis físicos

A melhora da resolução de energia no nível do candidato possui implicação direta para observáveis construídos a partir de elétrons. Conforme mostrado no Capítulo 8, a propagação analítica de incerteza indica redução esperada da contribuição energética para a resolução da massa invariante de um par e^+e^-.

Essa relação fornece uma ponte entre a calibração evento a evento e uma futura validação ressonante. A tese estabelece a implicação analítica, enquanto a verificação direta sobre a posição, largura e caudas de uma ressonância requer uma amostra dedicada de $Z \to e^+e^-$.

9.8 Síntese da evidência estatística

A análise estatística foi construída de forma pareada, uma vez que E_{fast} e E_{calib} são avaliados para os mesmos eventos. Como as distribuições residuais apresentam desvios de Gaussianidade, particularmente nas caudas, a interpretação não se apoia em um único teste ou em significância estatística isolada.

Os testes aplicados à diferença pareada entre os resíduos caracterizam o deslocamento da distribuição, enquanto RMSE, IQR, razão de variâncias e resolução relativa quantificam aspectos complementares da magnitude e da dispersão dos erros. A convergência dessas evidências sustenta a melhora observada após a calibração.

Na Etapa III, por exemplo, a variância residual da GNN completa correspondeu a 23,56% da variância do *Standard FastCalo*, equivalendo a uma redução de 76,44%. A DNN completa apresentou redução de 74,45%. Esses efeitos acompanham as reduções de RMSE e a melhora da resolução relativa e são mais informativos sobre relevância prática do que valores de p extremamente pequenos considerados isoladamente.

Nas Etapas II e III, os desvios-padrão reportados para RMSE e IQR são obtidos a partir de cinco subconjuntos disjuntos do teste independente com o mesmo modelo final. Eles caracterizam a variabilidade das métricas dentro desse teste fixado e não a incerteza total associada a novos treinamentos, novas amostras ou mudanças de domínio.

9.9 Domínio de validade e limitações

9.9.1 Monte Carlo versus dados experimentais

O treinamento supervisionado utiliza α_{true}, definido a partir de E_{true} e E_{fast} conforme o Capítulo 5. Como E_{true} é disponível em Monte Carlo e não é diretamente observável em dados experimentais, a transferência da estratégia para dados reais exige uma referência apropriada.

Amostras ressonantes, como $Z \to e^+e^-$, e mapeamentos para uma reconstrução de maior fidelidade são possibilidades para estudos posteriores, mas correspondem a novos experimentos. Os ganhos quantitativos apresentados nesta tese devem ser interpretados como desempenho relativo no ambiente simulado utilizado.

9.9.2 *Pile-up*

O *benchmark* contém *pile-up*, com $\langle\mu\rangle = 38{,}94$ e desvio-padrão 9,999. Entretanto, não foi realizada uma varredura controlada de μ. Consequentemente, a tese não quantifica como RMSE, IQR, resolução ou estabilidade regional evoluem quando a ocupação é alterada independentemente.

A robustez frente a diferentes regimes de *pile-up* permanece, portanto, uma questão de validação externa e não uma conclusão derivada da presença de *pile-up* na amostra principal.

9.9.3 Cobertura geométrica e fidelidade do detector

Os resultados principais são restritos à região de barril do *benchmark*, aproximadamente $|\eta| \leq 1{,}46$. A extensão ao *endcap* exige nova validação devido às diferenças de geometria, material, granularidade e resposta.

Da mesma forma, o Lorenzetti fornece um ambiente aberto e reprodutível inspirado na calorimetria do ATLAS, mas não corresponde à cadeia oficial de simulação e reconstrução do experimento. Assim, os valores quantitativos obtidos caracterizam o *benchmark* empregado.

9.9.4 Latência e implantação

Os tempos apresentados nos Capítulos 6, 7 e 8 correspondem à predição dos modelos treinados nos ambientes computacionais utilizados. Eles são úteis para comparar configurações dentro desses contextos, mas não representam a latência de ponta a ponta de uma cadeia de *trigger*.

Uma avaliação de implantação deve incluir construção das características, movimentação de memória, inferência, concorrência, *throughput*, latência média e de pior caso e efeitos de representação numérica ou quantização. Essa etapa é necessária para transformar os resultados de custo relativo em uma conclusão operacional.

9.10 Alcance das conclusões

A Tabela 25 distingue resultados medidos diretamente no *benchmark*, implicações analíticas e afirmações que requerem validação adicional. Essa separação resume o alcance científico das conclusões sem misturar níveis diferentes de evidência.

A tabela torna explícita a separação entre o que foi observado diretamente, o que decorre de uma relação analítica e o que permanece como hipótese de generalização. Essa distinção permite preservar a força dos resultados obtidos sem extrapolar seu domínio experimental.

Tabela 25 – Alcance das principais conclusões da tese.

Afirmação	**Evidência disponível**	**Interpretação**
Anéis contêm informação útil para corrigir E_{fast}	Evidência empírica no *benchmark*	Diferentes famílias de modelos reduzem erro e dispersão relativamente ao *Standard FastCalo*.
Representações compactas preservam parte relevante do ganho	Evidência empírica no *benchmark*	Cinco a dez entradas fornecem pontos competitivos de desempenho–compactação nas condições estudadas.
Modelos neurais deslocam a fronteira de RMSE e d_0	Evidência empírica no protocolo da Etapa III	DNN e GNN completas apresentam menores RMSE e d_0 que o melhor híbrido da Etapa II, sob protocolos posteriores semelhantes, sem constituir ablação controlada entre etapas.
A topologia do grafo é responsável pelo ganho da GNN	Requer validação arquitetural adicional	A comparação atual é entre arquiteturas completas; ablações são necessárias para atribuição causal.
A calibração é robusta a diferentes valores de μ	Requer validação de domínio	Há *pile-up* na amostra, mas não uma varredura controlada de ocupação.
A calibração melhora a massa reconstruída do Z	Implicação analítica	A contribuição energética da resolução deve diminuir sob as hipóteses da propagação; falta validação ressonante direta.
Os modelos atendem à latência de produção do HLT	Requer validação operacional	Os tempos medidos são *benchmarks* de predição; falta ensaio de ponta a ponta.
Os ganhos se transferem para dados reais	Requer validação experimental	São necessários dados experimentais, referências *in situ* e controle de diferenças simulação–dados.

9.11 Perspectivas e trabalhos futuros

A continuidade da pesquisa deve priorizar experimentos que ampliem o domínio de validade e permitam atribuir de forma mais precisa os ganhos observados.

9.11.1 Validação de domínio e fidelidade

O primeiro eixo consiste em variar controladamente o nível de *pile-up*, ampliar a cobertura ao *endcap* e utilizar simulações de maior fidelidade. A comparação deve acompanhar RMSE, IQR, resolução, caudas e estabilidade regional, permitindo verificar se a fronteira entre representações completas e compactas se mantém quando ocupação, geometria e resposta instrumental são alteradas.

9.11.2 Validação ressonante e dados experimentais

O segundo eixo é a validação com $Z \to e^+e^-$. Em Monte Carlo, essa amostra permite medir diretamente a propagação da calibração para posição, largura e caudas da massa invariante; em dados, procedimentos *in situ* e estratégias de *tag-and-probe* permitem estudar diferenças entre

simulação e experimento. O particionamento deve preservar o evento ressonante como unidade, evitando separar os dois candidatos do mesmo decaimento entre treinamento e teste.

9.11.3 Validação operacional

O terceiro eixo reúne fundo, eficiência e implantação. Amostras de jatos que possam passar pelos critérios de identificação são necessárias para estudar simultaneamente eficiência de elétrons e taxa de fundo em um limiar físico fixo. Em paralelo, a validação computacional deve medir construção da representação e inferência como uma única cadeia, incluindo *throughput*, latência média e de pior caso, memória, quantização, vetorização, paralelismo e concorrência.

9.11.4 Validação arquitetural e novas fontes de informação

O quarto eixo é separar os efeitos dos componentes arquiteturais e ampliar a fusão de informação. Para a GNN, ablações do ramo em grafo, ramo tabular, descritores derivados e conectividade devem ser comparadas a controles de capacidade semelhante. Curvas de aprendizagem podem quantificar a eficiência estatística das famílias de modelos. Variáveis de trajetória, E/p, propriedades do *cluster* ou estimativas de μ podem ser incorporadas posteriormente em estudos incrementais que permitam atribuir o ganho de cada nova fonte de informação.

9.12 Conclusão geral

Esta tese investigou a calibração evento a evento da energia transversa rápida de elétrons utilizando a informação espacial do chuveiro eletromagnético codificada em anéis. Sob uma formulação comum, três etapas experimentais ampliaram progressivamente as representações e as famílias de regressores, permitindo estudar como quantidade de informação, capacidade de modelagem e custo computacional interagem no problema de calibração.

A Etapa I estabeleceu que a representação em anéis permite reduzir substancialmente o erro do *Standard FastCalo* e que a compactação pode preservar grande parte desse ganho. A Etapa II mostrou que aprendizado residual e *ensembles* híbridos podem produzir melhoria incremental, embora a diferença para um BDT completo seja pequena. A Etapa III mostrou que DNNs exploram eficazmente representações completas e compactas e que a arquitetura GNN relacional–tabular apresentou os menores valores de RMSE e d_0 e a melhor resolução relativa entre as configurações avaliadas nessa etapa.

A configuração `GNN no-Bin: Rings[1:100]` reduziu o RMSE em 65,25% e o IQR em 42,82% em relação ao *Standard FastCalo* da Etapa III, melhorou a resolução relativa em 51,46% e reduziu a variância residual em 76,44%. A DNN completa permaneceu próxima com menor custo de predição no mesmo *benchmark*. Em paralelo, configurações compactas com cinco ou dez entradas preservaram reduções de RMSE superiores a 50% em diferentes etapas.

O resultado mais geral da tese é, portanto, a demonstração de uma fronteira desempenho–complexidade para calibradores baseados em informação calorimétrica estruturada. A representação completa favorece máxima precisão; representações compactas oferecem pontos de operação

com forte redução de dimensionalidade; e arquiteturas mais complexas podem produzir ganhos adicionais cujo valor depende do custo e dos requisitos de aplicação.

A hipótese central é suportada no domínio experimental estudado por evidências provenientes de diferentes famílias de modelos e métricas complementares. O alcance dessas conclusões permanece restrito ao *benchmark* utilizado; a validação em dados experimentais, diferentes regimes de ocupação e uma cadeia operacional de *trigger* constitui a etapa seguinte da pesquisa.

Do ponto de vista científico, a tese estabelece que a representação em anéis é uma fonte efetiva de informação para calibração supervisionada de energia. Do ponto de vista de engenharia, mostra que não existe uma solução única para todos os requisitos: a configuração apropriada depende do equilíbrio entre precisão, compactação, estabilidade e custo computacional. Essa síntese encerra a investigação experimental principal e define uma base objetiva para sua extensão a condições progressivamente mais próximas de um experimento real.

Referências

ABREU, H. et al. Performance of the electronic readout of the atlas liquid argon calorimeters. *Journal of Instrumentation*, v. 5, p. P09003, 2010. Disponível em: <http://dx.doi.org/10.1088/1748-0221/5/09/P09003>.

AGOSTINELLI, S.; ALLISON, J. et al. Geant4—a simulation toolkit. *Nucl. Instrum. Meth. A*, v. 506, n. 3, p. 250–303, 2003. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0168900203013688>.

ALBERTSSON, K. et al. Machine learning in high energy physics community white paper. *Journal of Physics: Conference Series*, v. 1085, n. 2, p. 022008, 2018. Disponível em: <https://iopscience.iop.org/article/10.1088/1742-6596/1085/2/022008>.

ALICE Collaboration. The ALICE experiment at the CERN LHC. *Journal of Instrumentation*, v. 3, n. 08, p. S08002, 2008. Disponível em: <https://doi.org/10.1088/1748-0221/3/08/S08002>.

ALVES, A. S. O.; SILVA, P. R. A.; SIMAS FILHO, E. F. et al. Energy calibration for high-rate online electron selection using gradient boosted decision trees and expert calorimetry information. in portuguese: Calibração de energia para a seleção online de elétrons com alta taxa e utilizando um conjunto de Árvores de decisão com reforço por gradiente e informação especialista de calorimetria. In: *Anais do 16 Congresso Brasileiro de Inteligência Computacional*. Salvador, BA: SBIC, 2023. p. 1–8. Disponível em: <https://sbia.org.br/wp-content/uploads/2023/10/pdf/CBIC_2023_paper145.pdf>.

ALVES, A. S. O.; SILVA, P. R. A.; SIMAS FILHO, E. F. et al. Calibração de energia para seleção online de eventos em detector com elevado empilhamento de sinais utilizando um ensemble de gbdts. *Anais do XXV Congresso Brasileiro de Automática (CBA 2024)*, Sociedade Brasileira de Automática (SBA), 2024. Disponível em: <https://www.sba.org.br/cba2024/papers/paper_1040.pdf>.

ANDERSON, T. W.; DARLING, D. A. A test of goodness of fit. *Journal of the American Statistical Association*, v. 49, n. 268, p. 765–769, 1954. Disponível em: <https://www.jstor.org/stable/2281537>.

ARAÚJO, M. et al. Lorenzetti showers - a general-purpose framework for supporting signal reconstruction and triggering with calorimeters. *Computer Physics Communications*, Elsevier, v. 286, p. 108671, Feb 2023. ISSN 0010-4655. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0010465523000164>.

ARBUZOV, A. B. Quantum field theory and the electroweak standard model. In: *Proceedings of the European School of High-Energy Physics*. [s.n.], 2017. Lecture notes. Disponível em: <https://doi.org/10.48550/arXiv.1801.05670>.

ATLAS Collaboration. The ATLAS experiment at the CERN Large Hadron Collider. *Journal of Instrumentation*, IOP Publishing, v. 3, n. 08, p. S08003–S08003, aug 2008. Disponível em: <https://doi.org/10.1088/1748-0221/3/08/s08003>.

ATLAS Collaboration. The ATLAS simulation infrastructure. *European Physical Journal C*, v. 70, p. 823–874, 2010. Disponível em: <https://doi.org/10.1140/epjc/s10052-010-1429-9>.

ATLAS Collaboration. Readiness of the ATLAS Tile Calorimeter for LHC collisions. *Eur. Phys. J. C*, v. 70, p. 1193–1236, 2010. Disponível em: <https://cds.cern.ch/record/1282535>.

ATLAS Collaboration. The ATLAS liquid argon calorimeter: Overview and performance. *J. Phys.: Conf. Ser.*, v. 293, p. 012044, 2011. Disponível em: <https://iopscience.iop.org/article/10.1088/1742-6596/293/1/012044>.

ATLAS Collaboration. Observation of a new particle in the search for the Standard Model Higgs boson with the ATLAS detector at the LHC. *Physics Letters B*, v. 716, n. 1, p. 1–29, 2012. Disponível em: <https://doi.org/10.1016/j.physletb.2012.08.020>.

ATLAS Collaboration. Topological cell clustering in the ATLAS calorimeters and its performance in LHC run 1. *The European Physical Journal C*, v. 77, n. 7, p. 490, 2017. Disponível em: <https://doi.org/10.1140/epjc/s10052-017-5004-5>.

ATLAS Collaboration. Operation and performance of the ATLAS Tile Calorimeter in Run 1. *European Physical Journal C*, v. 78, n. 12, p. 987, 2018. Disponível em: <https://doi.org/10.1140/epjc/s10052-018-6374-z>.

ATLAS Collaboration. Electron reconstruction and identification in the ATLAS experiment using the 2015 and 2016 LHC proton–proton collision data at $\sqrt{s} = 13$ TeV . *The European Physical Journal C*, Springer Science and Business Media LLC, v. 79, n. 8, ago. 2019. ISSN 1434-6052. Disponível em: <http://dx.doi.org/10.1140/epjc/s10052-019-7140-6>.

ATLAS Collaboration. Search for high-mass dilepton resonances using 139 fb^{-1} of pp collision data collected at $\sqrt{s} = 13$ tev with the atlas detector. *Physics Letters B*, v. 796, p. 68–87, 2019. ISSN 0370-2693. Disponível em: <https://doi.org/10.1016/j.physletb.2019.07.016>.

ATLAS Collaboration. Performance of electron and photon triggers in ATLAS during LHC Run 2. *The European Physical Journal C*, Springer Science and Business Media LLC, v. 80, n. 1, jan. 2020. ISSN 1434-6052. Disponível em: <http://dx.doi.org/10.1140/epjc/s10052-019-7500-2>.

ATLAS Collaboration. Evidence for Higgs boson decays to a low-mass dilepton system and a photon in pp collisions at $\sqrt{s} = 13$ TeV with the ATLAS detector. *Physics Letters B*, v. 819, p. 136412, 2021. ISSN 0370-2693. Disponível em: <https://doi.org/10.1016/j.physletb.2021.136412>.

ATLAS Collaboration. *Point Cloud Deep Learning Methods for Pion Reconstruction in the ATLAS Experiment*. Geneva, 2022. Disponível em: <https://cds.cern.ch/record/2825379>.

ATLAS Collaboration. Electron and photon energy calibration with the ATLAS detector using LHC Run 2 data. *Journal of Instrumentation*, v. 19, n. 02, p. P02009, 2024. Disponível em: <https://iopscience.iop.org/article/10.1088/1748-0221/19/02/P02009>.

ATLAS Collaboration. The ATLAS trigger system for LHC Run 3 and trigger performance in 2022. *Journal of Instrumentation*, IOP Publishing, v. 19, n. 06, p. P06029, jun. 2024. ISSN 1748-0221. Disponível em: <http://dx.doi.org/10.1088/1748-0221/19/06/P06029>.

BA, J. L.; KIROS, J. R.; HINTON, G. E. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016. Disponível em: <https://doi.org/10.48550/arXiv.1607.06450>.

BALDI, P.; SADOWSKI, P.; WHITESON, D. Searching for exotic particles in high-energy physics with deep learning. *Nature communications*, Nature Publishing Group, v. 5, p. 4308, 2014. Disponível em: <https://www.nature.com/articles/ncomms5308>.

BATTAGLIA, P. W. et al. Relational inductive biases, deep learning, and graph networks. *arXiv preprint arXiv:1806.01261*, 2018.

BISHOP, C. M. *Pattern Recognition and Machine Learning*. Springer, 2006. Disponível em: <https://link.springer.com/book/9780387310732>.

BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://link.springer.com/article/10.1023/A:1010933404324>.

BRONSTEIN, M. M. et al. Geometric deep learning: Going beyond euclidean data. *IEEE Signal Processing Magazine*, v. 34, n. 4, p. 18–42, 2017. Disponível em: <https://doi.org/10.48550/arXiv.1611.08097>.

BRÜNING, O.; BURKHARDT, H.; MYERS, S. The Large Hadron Collider. *Progress in Particle and Nuclear Physics*, v. 67, n. 3, p. 705–734, 2012. ISSN 0146-6410. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0146641012000695>.

CASTANEDO, F. A review of data fusion techniques. *The Scientific World Journal*, v. 2013, p. 704504, 2013. Disponível em: <https://doi.org/10.1155/2013/704504>.

CAWLEY, G. C.; TALBOT, N. L. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, v. 11, p. 2079–2107, 2010. Disponível em: <https://dl.acm.org/doi/10.5555/1756006.1859921>.

CHEN, Z. et al. Learnable graph convolutional network and feature fusion for multi-view learning. *Information Fusion*, v. 95, p. 109–119, 2023. ISSN 1566-2535. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1566253523000532>.

CMS Collaboration. Observation of a new boson at a mass of 125 GeV with the CMS experiment at the LHC. *Physics Letters B*, v. 716, n. 1, p. 30–61, 2012. ISSN 0370-2693. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0370269312008581>.

CNPq. *Portaria CNPq nº 2.664, de 6 de março de 2026: Institui a Política de Integridade na Atividade Científica do CNPq*. Brasília, DF, 2026. Disponível em: <https://www.in.gov.br/web/dou/-/portaria-cnpq-n-2.664-de-6-de-marco-de-2026-691779232>. Acesso em: 29 out. 2026.

COVER, T. M.; THOMAS, J. A. *Elements of Information Theory*. [S.l.]: John Wiley & Sons, 1991.

D'AGOSTINO, R. B.; PEARSON, E. S. Tests for departure from normality. empirical results for the distributions of b_2 and $\sqrt{b_1}$. *Biometrika*, v. 60, n. 3, p. 613–622, 1973. Disponível em: <https://www.jstor.org/stable/2335012>.

DAVISON, A. C.; HINKLEY, D. V. *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997. Disponível em: <https://doi.org/10.1017/CBO9780511802843>.

DEZOORT, G. et al. Graph neural networks at the large hadron collider. *Nature Reviews Physics*, Nature Publishing Group, v. 5, p. 281–303, maio 2023. Published: 17 April 2023, Accepted: 18 February 2023. Disponível em: <https://doi.org/10.1038/s42254-023-00569-0>.

DOBBS, M.; HANSEN, J. B. The HepMC C++ Monte Carlo event record for High Energy Physics. *Comput. Phys. Commun.*, v. 134, p. 41–46, 2001. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0010465500001892?via%3Dihub>.

EVANS, L. R.; BRYANT, P. Lhc machine. *JINST*, v. 3, p. S08001, 2008. Disponível em: <https://cds.cern.ch/record/1129806>.

FABJAN, C. W.; GIANOTTI, F. Calorimetry for particle physics. *Reviews of Modern Physics*, v. 75, n. 4, p. 1243–1286, 2003. Disponível em: <https://doi.org/10.1103/RevModPhys.75.1243>.

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, Institute of Mathematical Statistics, v. 29, n. 5, p. 1189–1232, 2001. Disponível em: <https://projecteuclid.org/journals/annals-of-statistics/volume-29/issue-5/Greedy-function-approximation-A-gradient-boosting-machine/10.1214/aos/1013203451.full>.

GABALDóN, C.; on behalf of the ATLAS LAr Collaboration. Electronic calibration of the ATLAS LAr calorimeter and commissioning with cosmic muon signals. *Journal of Physics: Conference Series*, IOP Publishing, v. 160, p. 012050, apr 2009. Disponível em: <https://doi.org/10.1088/1742-6596/160/1/012050>.

GÉRON, A. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. 2nd. ed. O'Reilly Media, Inc., 2019. ISBN 9781492032649. Disponível em: <https://www.oreilly.com/library/view/hands-on-machine-learning/9781492032632/>.

GIRSHICK, R. Fast r-cnn. In: *Proceedings of the IEEE International Conference on Computer Vision*. [s.n.], 2015. p. 1440–1448. Disponível em: <https://doi.org/10.1109/ICCV.2015.169>.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. First. [S.l.]: The MIT Press, 2016.

GRAY, H. M. Future colliders for the high-energy frontier. *Reviews in Physics*, v. 6, p. 100053, 2021. ISSN 2405-4283. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2405428321000022>.

GRIFFITHS, D. J. *Introduction to Elementary Particles*. 2nd. ed. New York, NY: Wiley-VCH, 2008.

HAMILTON, W. L.; YING, R.; LESKOVEC, J. Inductive representation learning on large graphs. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems*. [s.n.], 2017. (NIPS'17, v. 30), p. 1025–1035. Disponível em: <https://doi.org/10.48550/arXiv.1706.02216>.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction, Second Edition*. Springer, 2009. Disponível em: <https://link.springer.com/book/10.1007/978-0-387-84858-7>.

HAYKIN, S. *Neural Networks and Learning Machines*. Prentice Hall, 2009. Disponível em: <https://www.pearson.com/en-us/subject-catalog/p/neural-networks-and-learning-machines/P200000003278/9780133002553>.

HE, K. et al. Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2016. p. 770–778.

HENDRYCKS, D.; GIMPEL, K. Gaussian error linear units (GELUs). *arXiv preprint arXiv:1606.08415*, 2016. Disponível em: <https://doi.org/10.48550/arXiv.1606.08415>.

HOGBEN, L. (Ed.). *Handbook of Linear Algebra*. 2. ed. Boca Raton: Chapman and Hall/CRC, 2013. ISBN 9781466507289. Disponível em: <http://www2.fiit.stuba.sk/~kvasnicka/QuantumComputing/Hogben-Handbook%20of%20Linear%20Algebra-(CRC%20press,%202007).pdf>.

HUBER, P. J. Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, v. 35, n. 1, p. 73–101, 1964. Disponível em: <https://projecteuclid.org/journalArticle/Download?urlId=10.1214%2Faoms%2F1177703732>.

HYVÄRINEN, A.; KARHUNEN, J.; OJA, E. *Independent Component Analysis*. John Wiley & Sons, 2001. Disponível em: <https://onlinelibrary.wiley.com/doi/book/10.1002/0471221317>.

HYVÄRINEN, A.; OJA, E. A fast fixed-point algorithm for independent component analysis. *Neural Computation*, v. 9, n. 7, p. 1483–1492, 1997. Disponível em: <https://ieeexplore.ieee.org/document/6797075>.

JOLLIFFE, I. T. *Principal Component Analysis*. New York, NY, USA: Springer, 2002. Disponível em: <https://link.springer.com/book/10.1007/b98835>.

JU, X. et al. *Graph Neural Networks for Particle Reconstruction in High Energy Physics detectors*. 2020. Disponível em: <https://arxiv.org/abs/2003.11603>.

KE, G. et al. Lightgbm: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, v. 30, p. 3146–3154, 2017. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf>.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. *International Conference on Learning Representations (ICLR)*, 2015. Disponível em: <https://arxiv.org/abs/1412.6980>.

KOMISKE, P. T.; METODIEV, E. M.; THALER, J. Energy flow networks: Deep sets for particle jets. *Journal of High Energy Physics*, v. 2019, n. 01, p. 121, 2019. Disponível em: <https://doi.org/10.48550/arXiv.1810.05165>.

KRASKOV, A.; STÖGBAUER, H.; GRASSBERGER, P. Estimating mutual information. *Physical review E*, APS, v. 69, n. 6, p. 066138, 2004. Disponível em: <https://doi.org/10.48550/arXiv.cond-mat/0305641>.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015. Disponível em: <https://doi.org/10.1038/nature14539>.

LHCb Collaboration. The LHCb Detector at the LHC. *Journal of Instrumentation*, v. 3, n. 08, p. S08005, 2008. Disponível em: <https://doi.org/10.1088/1748-0221/3/08/S08005>.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. *arXiv*, 2017. Disponível em: <https://doi.org/10.48550/arXiv.1711.05101>.

MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, Springer, v. 5, n. 4, p. 115–133, 1943. Disponível em: <https://www.cs.cmu.edu/~./epxing/Class/10715/reading/McCulloch.and.Pitts.pdf>.

MENG, T. et al. A survey on machine learning for data fusion. *Information Fusion*, v. 57, p. 115–129, 2020. ISSN 1566-2535. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1566253519303902>.

METROPOLIS, N.; ULAM, S. The Monte Carlo Method. *Journal of the American Statistical Association*, American Statistical Association, Taylor & Francis, Ltd., v. 44, n. 247, p. 335–341, 1949. ISSN 01621459, 1537274X. Disponível em: <http://www.jstor.org/stable/2280232>.

MITSOU, V. A.; on behalf of the MoEDAL Collaboration. The MoEDAL experiment at the LHC: status and results. *Journal of Physics: Conference Series*, IOP Publishing, v. 873, n. 1, p. 012010, jul 2017. Disponível em: <https://dx.doi.org/10.1088/1742-6596/873/1/012010>.

MORGAN, W. A. A test for the significance of the difference between the two variances in a sample from a normal bivariate population. *Biometrika*, v. 31, p. 13–19, 1939. Disponível em: <https://www.jstor.org/stable/2334972>.

OPENAI. *ChatGPT*. 2026. Sistema de inteligência artificial generativa. Disponível em: <https://chatgpt.com/>. Acesso em: 29 out. 2026.

ORELLANA, G. E.; ATLAS Collaboration. *Projected ATLAS Electron and Photon Trigger Performance in Run 3*. Geneva, 2021. Disponível em: <https://cds.cern.ch/record/2730417>.

PEQUENAO, J.; SCHAFFNER, P. *How ATLAS detects particles: diagram of particle paths in the detector*. 2013. Disponível em: <https://cds.cern.ch/record/1505342>.

PERKINS, D. H. *Introduction to High Energy Physics*. 4th. ed. Cambridge, UK: Cambridge University Press, 2009. Disponível em: <https://doi.org/10.1017/CBO9780511809040>.

PINTO, J. V. da F.; ATLAS Collaboration. *Ring-shaped Calorimetry Information for a Neural EGamma Identification with ATLAS Detector*. Geneva, 2016. Disponível em: <https://cds.cern.ch/record/2142761>.

PINTO, J. V. da F. et al. *lorenzetti-hep/lorenzetti: Version 2.0.0*. Zenodo, 2022. Accessed: 2025-04-30. Disponível em: <https://github.com/lorenzetti-hep/lorenzetti>.

PITMAN, E. J. G. A note on normal correlation. *Biometrika*, v. 31, p. 9–12, 1939. Disponível em: <https://www.jstor.org/stable/2334971>.

QASIM, S. R. et al. End-to-end multi-particle reconstruction in high occupancy imaging calorimeters with graph neural networks. *The European Physical Journal C*, v. 82, p. 753, 2022.

QASIM, S. R. et al. Learning representations of irregular particle-detector geometry with distance-weighted graph networks. *The European Physical Journal C*, v. 79, n. 608, 2019. Disponível em: <https://doi.org/10.1140/epjc/s10052-019-7113-9>.

QU, H.; GOUSKOS, L. Particlenet: Jet tagging via particle clouds. *Physical Review D*, v. 101, n. 056019, p. 1–11, 2020. Disponível em: <https://doi.org/10.48550/arXiv.1902.08570>.

QUINLAN, J. R. Induction of decision trees. *Machine Learning*, Springer, v. 1, n. 1, p. 81–106, 1986. Disponível em: <https://link.springer.com/article/10.1007/BF00116251>.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. *Nature*, Nature Publishing Group, v. 323, n. 6088, p. 533–536, 1986. Disponível em: <https://doi.org/10.1038/323533a0>.

SCARSELLI, F. et al. The graph neural network model. *IEEE Transactions on Neural Networks*, IEEE, v. 20, n. 1, p. 61–80, 2008. Disponível em: <https://ieeexplore.ieee.org/document/4700287>.

SEIXAS, J. et al. Neural second-level trigger system based on calorimetry. *Computer Physics Communications*, v. 95, n. 2, p. 143–157, 1996. ISSN 0010-4655. Disponível em: <https://cds.cern.ch/record/278995/files/ecp-95-006.pdf>.

SHLOMI, J.; BATTAGLIA, P.; VLIMANT, J.-R. Graph neural networks in particle physics. *Machine Learning: Science and Technology*, IOP Publishing, v. 2, n. 2, p. 021001, dec 2020. Disponível em: <https://doi.org/10.1088/2632-2153/abbf9a>.

SILVA, P. R. A. et al. Hybrid tree-based machine learning for calorimetric energy calibration using the lorenzetti showers framework. *Measurement*, v. 290, p. 122771, 2026. ISSN 0263-2241. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0263224126024802>.

SILVA, P. R. A. et al. Machine learning for energy calibration in high energy physics experiments using the lorenzetti showers framework. *IEEE Transactions on Nuclear Science*, v. 73, n. 5, p. 1853–1875, 2026. Disponível em: <https://doi.org/10.1109/TNS.2026.3686269>.

SILVA, P. R. A.; SIMAS FILHO, E. F. *Lorenzetti Shower Simulation Dataset*. https://github.com/PauloRASpro/Lorenzetti-Shower-Simulation, 2025. Disponível em: <https://github.com/PauloRASpro/Lorenzetti-Shower-Simulation>.

SILVA, P. R. A.; SIMAS FILHO, E. F. Multi-stage neural information fusion for fast energy calibration in segmented particle-detector calorimeters. Manuscript submitted to Elsevier Information Fusion. Preprint avaliable at SSRN. 2026. Disponível em: <https://dx.doi.org/10.2139/ssrn.7552903>.

SIMAS FILHO, E. F. et al. Ring-like calorimeter information for energy calibration in electron trigger at a highly segmented detector using gradient boosted decision trees. *Journal of Instrumentation*, IOP Publishing, v. 20, n. 06, p. P06051, jun 2025. Disponível em: <https://dx.doi.org/10.1088/1748-0221/20/06/P06051>.

SIMAS FILHO, E. F. et al. A proposal for online event selection calibration in the ATLAS detector using gradient boosted decision trees. in portuguese: Uma proposta para calibração do sistema online de seleção de eventos no detector ATLAS utilizando gradient boosted decision trees. In: *Anais do 15 Congresso Brasileiro de Inteligência Computacional*. Joinville, SC: SBIC, 2021. p. 1–8. Disponível em: <http://dx.doi.org/10.21528/CBIC2021-149>.

SIMAS FILHO, E. F. de. *Análise Não-Linear de Componentes Independentes para uma Filtragem Online Baseada em Calorimetria de Alta Energia e com Fina Segmentação*. Tese (Doutorado) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil, 2010.

SJÖSTRAND, T.; MRENNA, S.; SKANDS, P. A brief introduction to PYTHIA 8.1. *Computer Physics Communications*, Elsevier BV, v. 178, n. 11, p. 852–867, jun. 2008. ISSN 0010-4655. Disponível em: <http://dx.doi.org/10.1016/j.cpc.2008.01.036>.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, v. 15, n. 56, p. 1929–1958, 2014. Disponível em: <https://www.jmlr.org/papers/volume15/srivastava14a/srivastava14a.pdf?utm_content=buffer79b4>.

STRANG, G. *Introduction to Linear Algebra*. 6. ed. [S.l.]: Wellesley-Cambridge Press, 2023. ISBN 9781733146678.

TAKAHASHI, F. et al. Review of particle physics. *International Journal of Modern Physics A*, World Scientific, v. 41, n. 22, p. 2630011, 2026. Disponível em: <https://doi.org/10.1142/S0217751X26300115>.

TIBERIO, A.; on behalf of the LHCf Collaboration. The LHCf experiment at the Large Hadron Collider: status and prospects. *PoS*, ICRC2023, p. 444, 2023. Disponível em: <http://cds.cern.ch/record/2868230>.

TING, K. M.; WITTEN, I. H. Stacked generalization: When does it work? In: *Proceedings of the 15th International Joint Conference on Artificial Intelligence (IJCAI)*. [s.n.], 1997. p. 866–871. Disponível em: <https://www.ijcai.org/Proceedings/97-2/Papers/011.pdf>.

TOTEM Collaboration. The totem experiment at the cern large hadron collider. *Journal of Instrumentation*, v. 3, n. 08, p. S08007, 2008. Disponível em: <https://doi.org/10.1088/1748-0221/3/08/S08007>.

UFBA. *Guia para Uso Ético e Responsável da Inteligência Artificial Generativa na Universidade Federal da Bahia*. Salvador, 2025. Disponível em: <https://www.ufba.br/sites/portal.ufba.br/files/guia_para_uso_etico_e_responsavel_da_inteligencia_artificial_generativa_na_universidade_federal_da_bahia.pdf>. Acesso em: 29 out. 2026.

WIGMANS, R. New developments in calorimetric particle detection. *Progress in Particle and Nuclear Physics*, Elsevier BV, v. 103, p. 109–161, nov. 2018. ISSN 0146-6410. Disponível em: <http://dx.doi.org/10.1016/j.ppnp.2018.07.003>.

WILCOXON, F. Individual comparisons by ranking methods. *Biometrics Bulletin*, v. 1, n. 6, p. 80–83, 1945. Disponível em: <https://www.jstor.org/stable/3001968>.

WOLPERT, D. H. Stacked generalization. *Neural Networks*, v. 5, n. 2, p. 241–259, 1992. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0893608005800231>.

ZAHEER, M. et al. Deep sets. In: *Advances in Neural Information Processing Systems*. [s.n.], 2017. v. 30, p. 3391–3401. Disponível em: <https://doi.org/10.48550/arXiv.1703.06114>.

A Reprodutibilidade

A.1 Escopo e princípio de rastreabilidade

Este apêndice registra somente as informações complementares necessárias à rastreabilidade computacional dos experimentos e que não são recuperadas diretamente das formulações apresentadas no corpo da tese. As definições físicas, os operadores de representação, as arquiteturas dos modelos, o protocolo de particionamento e validação, as métricas e os procedimentos estatísticos permanecem definidos nos Capítulos 2–5 e constituem a referência principal para qualquer reimplementação.

Por essa razão, não são reproduzidos aqui pseudocódigos das etapas experimentais, dos modelos híbridos ou da arquitetura GNN. A correção residual, o *stacking*, a construção relacional–tabular, a validação cruzada aninhada e as métricas de avaliação já são especificados matematicamente e metodologicamente nos capítulos correspondentes. Repetir essas operações em forma algorítmica criaria uma segunda especificação do mesmo procedimento e aumentaria o risco de divergência entre o texto principal e o apêndice.

O conteúdo mantido neste apêndice é, portanto, restrito a: ambiente computacional preservado, associação entre famílias de modelos e implementações utilizadas, contagens do conjunto de dados, sementes pseudoaleatórias, espaços de busca de hiperparâmetros e configurações finais que puderam ser verificadas nos registros dos experimentos.

A rastreabilidade não é homogênea entre as três etapas da tese. A Etapa I preserva o protocolo histórico documentado no estudo correspondente e não possui registro completo de configurações finais para todas as famílias e representações. A Etapa II possui os espaços de busca consolidados e configurações finais arquivadas para modelos representativos. A Etapa III possui registro dos espaços de busca das DNNs e do refinamento final da GNN, além das configurações finais utilizadas nas principais representações avaliadas. Quando uma informação não foi preservada de forma verificável, ela não é reconstruída retrospectivamente neste apêndice.

A.2 Ambiente computacional e implementações

O ambiente atualmente preservado para consolidação das etapas finais registra Python 3.13.5 em ambiente Conda. Não foi preservado um *lockfile* completo contendo as versões de todas as dependências utilizadas ao longo das execuções históricas; portanto, versões ausentes não são inferidas retrospectivamente e o registro atual não deve ser interpretado como evidência de que todas as etapas foram executadas sob exatamente o mesmo conjunto de versões.

As medições de referência em CPU foram realizadas em computador com processador Intel Core i7-7500U, 20 GB de memória DDR4 e SSD de 1 TB. Esses dados são relevantes principalmente para a interpretação dos tempos de predição. Conforme discutido na Seção 5.12, os valores reportados constituem medidas relativas no ambiente utilizado e não equivalem à

latência ponta a ponta de uma cadeia de *trigger*.

A Tabela 26 registra as implementações principais empregadas nas famílias de regressão. Bibliotecas auxiliares como NumPy, pandas, SciPy, joblib e ferramentas de visualização foram utilizadas no processamento numérico, organização dos dados, inferência estatística, paralelização e geração de figuras, mas não definem, por si só, as famílias de modelos comparadas.

Tabela 26 – Mapeamento entre famílias de modelos e implementações computacionais utilizadas.

Modelo	Implementação principal	Observação
MLR	`LinearRegression` (scikit-learn)	regressão linear multivariada;
PReg	`PolynomialFeatures` + `LinearRegression` (scikit-learn)	grau polinomial fixado em 2;
DTree	`DecisionTreeRegressor` (scikit-learn)	árvore de regressão;
BDT	`LGBMRegressor` (LightGBM)	*gradient boosting* utilizado isoladamente e nos modelos híbridos;
RF	`RandomForestRegressor` (scikit-learn)	Random Forest utilizada isoladamente e nos modelos híbridos;
BDTRF / RFBDT	scikit-learn + LightGBM	composições de aprendizado residual definidas no Capítulo 4;
RFBDTS	RF + BDT + `Ridge`	modelo empilhado com predições OOB/OOF, conforme o Capítulo 4;
DNN	`MLPRegressor` (scikit-learn)	rede neural profunda tabular utilizada na Etapa III;
GNN	PyTorch + PyTorch Geometric	arquitetura relacional–tabular com operação GraphSAGE definida no Capítulo 4.

A.3 Conjunto de dados e separação desenvolvimento–teste

O conjunto principal contém 302.619 eventos reconstruídos. A separação 70/30 utilizada nos experimentos corresponde a 211.833 eventos na partição de desenvolvimento $\mathcal{D}_{70}$ e 90.786 eventos na partição independente de teste $\mathcal{D}_{30}$. O papel dessas partições e as restrições de uso de $\mathcal{D}_{30}$ são definidos na Seção 5.7.1.

Para reconstruir as entradas dos experimentos devem ser preservadas, no mínimo, a energia verdadeira E_{true}, a estimativa rápida E_{fast}, os 100 valores da representação Ringer e as variáveis utilizadas nos diagnósticos regionais. A correspondência evento a evento entre essas grandezas deve ser mantida.

Os 100 valores Ringer são utilizados na convenção fornecida pelos arquivos experimentais. No pipeline executado nesta tese não foi introduzida uma segunda normalização global dos 100 anéis antes da aplicação de $g_{\text{ML}}(\cdot)$ e $f_{\text{ML}}(\cdot)$. As transformações de representação e suas regras de ajuste são as definidas nos Capítulos 3 e 5.

Nenhuma regra numérica adicional de *clipping*, substituição de valores ou regularização de denominadores é acrescentada retrospectivamente neste apêndice. Quando determinado detalhe de implementação não foi preservado de forma verificável, essa limitação documental é mantida explicitamente em vez de ser preenchida por uma convenção posterior.

A.4 Protocolo experimental e determinismo

O protocolo experimental deve ser reproduzido conforme o Capítulo 5. Em particular, $\mathcal{D}_{30}$ permanece isolado até a avaliação final; $g_{\mathrm{ML}}(\cdot)$ é definido utilizando somente $\mathcal{D}_{70}$ e permanece fixo durante a seleção de $f_{\mathrm{ML}}(\cdot)$; e, nas Etapas II e III, a seleção de hiperparâmetros do regressor segue a validação cruzada aninhada 5×5, incluindo a triagem piloto, a *shortlist*, a seleção nos cinco *folds* internos, a avaliação externa e a consolidação final pela moda das cinco configurações selecionadas. A Etapa I permanece vinculada ao protocolo histórico do estudo correspondente e não recebe retrospectivamente a nested CV das etapas posteriores.

A semente pseudoaleatória base registrada é 0 nos estimadores e rotinas que expõem o parâmetro `random_state`. Quando uma rotina interna requer sementes distintas para *folds* ou repetições, elas devem permanecer determinísticas e consistentes com o particionamento empregado. A reprodução do mesmo particionamento não elimina, contudo, a variabilidade associada ao treinamento de modelos estocásticos ou a diferenças entre versões de bibliotecas.

As equações e convenções para RMSE, IQR, d_0, resolução relativa, EAR, $\Delta\lambda_{90}$, tempo amortizado de predição e inferência estatística não são repetidas neste apêndice. Para reprodução desses resultados deve-se utilizar diretamente as definições e os procedimentos das Seções 5.8–5.13.

A.5 Hiperparâmetros e configurações arquivadas

As tabelas desta seção constituem o núcleo operacional deste apêndice. Elas registram os espaços de busca efetivamente documentados e, quando disponível, a configuração final arquivada. Valores únicos representam parâmetros fixados; conjuntos com mais de um valor representam alternativas avaliadas. Não são apresentados "melhores parâmetros" reconstruídos a partir de memória ou inferidos retrospectivamente.

A.5.1 Etapa I — modelos convencionais e BDT

MLR não possui hiperparâmetro estrutural selecionado e PReg utiliza grau polinomial 2. Para DTree e BDT, a Tabela 27 registra o espaço consolidado preservado. O estudo da Etapa I não arquivou uma tabela completa de configurações finais para todas as famílias e representações; por isso, o apêndice não atribui retrospectivamente uma configuração final ausente.

Tabela 27 – Espaços consolidados de hiperparâmetros para os regressores da Etapa I.

Modelo	**Espaço de busca / parâmetros fixos**
MLR	sem hiperparâmetro estrutural selecionado;
PReg	`degree`$\in \{2\}$;
DTree	`min_samples_leaf`$\in \{24, 32\}$; `min_samples_split`$\in \{24, 32\}$; `max_features`=1.0; `criterion=squared_error`; `max_depth`=10; `ccp_alpha`=0;
BDT	`num_leaves`$\in \{127, 255\}$; `min_child_samples`$\in \{24, 32\}$; `feature_fraction`=1.0; `bagging_fraction`=0.7; `bagging_freq`=1; `learning_rate`=0.05; `lambda_l1`=0; `lambda_l2`=0; `max_depth`=10; `min_gain_to_split`=0; `n_estimators`=1000; `objective=regression`; `boosting_type=gbdt`; `random_state`=0.

A reprodução histórica da Etapa I deve seguir o protocolo e os artefatos do estudo correspondente. Aplicar atualmente o procedimento de nested CV 5×5 a essa etapa caracterizaria uma nova análise e não a reprodução dos valores originalmente publicados.

A.5.2 Etapa II — árvores, aprendizado residual e *stacking*

A Tabela 28 reúne os espaços de busca e parâmetros fixos documentados para as principais famílias da Etapa II. O parâmetro `n_folds`=3 do RFBDTS pertence exclusivamente à construção interna das predições utilizadas pelo meta-regressor e não substitui os cinco *folds* internos e externos da validação cruzada aninhada.

Tabela 28 – Espaços consolidados de busca para as principais famílias da Etapa II.

Modelo	Espaço de busca / parâmetros fixos
DTree	mesmo espaço consolidado da Tabela 27;
BDT	`num_leaves`$\in \{127, 255\}$; `min_child_samples`$\in \{24, 32\}$; `n_estimators`=1000; `learning_rate`=0.05; `max_depth`=10; `feature_fraction`=1.0; `bagging_fraction`=0.7; `bagging_freq`=1; `lambda_l1`=0; `lambda_l2`=0; `min_gain_to_split`=0; `objective=regression`; `boosting_type=gbdt`; `random_state`=0;
RF	`min_samples_leaf`$\in \{24, 32\}$; `min_samples_split`$\in \{24, 32\}$; `n_estimators`=500; `max_depth`=10; `max_features`=1.0; `max_samples`=0.7; `bootstrap=True`; `ccp_alpha`=0; `random_state`=0;
BDTRF / RFBDT	componente RF: `rf_n_estimators`=1000, `rf_max_depth`=10, `rf_min_samples_leaf`$\in \{24, 32\}$, `rf_min_samples_split`$\in \{24, 32\}$, `rf_max_features`=1.0, `rf_max_samples`=0.7, `rf_bootstrap=True`; componente BDT: `gb_num_leaves`$\in \{127, 255\}$, `gb_min_child_samples`$\in \{24, 32\}$, `gb_feature_fraction`=1.0, `gb_bagging_fraction`=0.7, `gb_bagging_freq`=1, `gb_learning_rate`=0.05, `gb_lambda_l2`=0, `gb_n_estimators`=1000; `val_fraction`=0.1; `early_stopping_rounds`=50; `random_state`=0;
RFBDTS	componentes RF e BDT com a mesma estrutura acima; `meta_alpha`=1.0; `n_folds`=3; `early_stopping_rounds`=30; `val_fraction_full`=0.1; `random_state`=0.

Foram preservadas configurações finais completas para modelos representativos da Etapa II. Como os demais parâmetros dessas configurações são fixos e já constam da Tabela 28, a Tabela 29 registra somente os valores selecionados entre as alternativas efetivamente variáveis.

Tabela 29 – Valores selecionados nas configurações finais arquivadas para modelos representativos da Etapa II. Os demais parâmetros permanecem nos valores fixos da Tabela 28.

Modelo	Representação	Valores selecionados
RFBDT	Rings[1:100]	`rf_min_samples_leaf`=24; `rf_min_samples_split`=24; `gb_num_leaves`=127; `gb_min_child_samples`=24;
RFBDT	PCA-5	`rf_min_samples_leaf`=24; `rf_min_samples_split`=24; `gb_num_leaves`=127; `gb_min_child_samples`=24;
BDT	Rings[1:100]	`num_leaves`=127; `min_child_samples`=24;
BDT	PCA-5	`num_leaves`=255; `min_child_samples`=32.

Essas configurações representam os registros finais preservados para os casos indicados. O apêndice não apresenta parâmetros finais não arquivados para outras combinações como se tivessem sido recuperados posteriormente.

A.5.3 Etapa III — DNN e GNN

Os modelos baseados em árvores utilizados como referência na Etapa III preservam as famílias de configuração da Etapa II. A busca adicional concentra-se nas DNNs e na arquitetura GNN relacional–tabular.

A.5.3.1 DNN

A Tabela 30 reúne o espaço de busca e as configurações finais das três representações neurais principais. Como vários parâmetros permaneceram fixos durante a busca, eles são

apresentados na mesma tabela para tornar a configuração final reconstruível sem duplicar uma segunda tabela com os mesmos valores.

Tabela 30 – Espaço de busca e hiperparâmetros selecionados para as DNNs representativas da Etapa III.

Hiperparâmetro	**Valores avaliados**	**Rings[1:100]**	**CORR-10**	**ICA-10**
`n_layers`	$\{4, 8, 16, 32\}$	16	16	16
`width`	$\{100, 200, 300\}$	100	200	200
`shape`	{constant, halving}	constant	halving	halving
`min_width`	$\{16\}$	16	16	16
`activation`	{relu}	relu	relu	relu
`alpha`	$\{10^{-3}\}$	0.001	0.001	0.001
`learning_rate_init`	$\{10^{-3}\}$	0.001	0.001	0.001
`batch_size`	$\{512\}$	512	512	512
`max_iter`	$\{200\}$	200	200	200
`solver`	{adam}	adam	adam	adam
`early_stopping`	{True}	True	True	True
`validation_fraction`	$\{0.1\}$	0.1	0.1	0.1
`n_iter_no_change`	$\{20\}$	20	20	20
`random_state`	$\{0\}$	0	0	0

A.5.3.2 GNN

A GNN foi desenvolvida progressivamente. A Tabela 31 registra somente o estágio final de refinamento associado aos resultados consolidados. Parâmetros com um único valor já haviam sido fixados antes desse refinamento e, portanto, não representam uma busca exaustiva sobre arquiteturas alternativas.

Tabela 31 – Espaço final de refinamento e configuração selecionada para GNN no-Bin: Rings[1:100] na Etapa III.

Hiperparâmetro	**Valores avaliados**	**Selecionado**
`node_hidden`	$\{64\}$	64
`graph_hidden`	$\{128\}$	128
`tab_hidden`	$\{256\}$	256
`num_graph_layers`	$\{2\}$	2
`ring_hops`	$\{1\}$	1
`graph_scale_init`	$\{0.05\}$	0.05
`dropout`	$\{0.05\}$	0.05
`epochs`	$\{65\}$	65
`batch_size`	$\{256\}$	256
`lr`	$\{10^{-3}\}$	0.001
`weight_decay`	$\{10^{-6}\}$	10^{-6}
`early_stopping_patience`	$\{12\}$	12
`validation_fraction`	$\{0.10, 0.15\}$	0.10
`min_delta`	$\{10^{-8}\}$	10^{-8}
`lambda_mse`	$\{0.65, 0.70, 0.75\}$	0.70
`huber_beta`	$\{1.00, 1.10\}$	1.10
`max_train_samples`	$\{300000\}$	300000
`scale_y`	{True}	True
`random_state`	$\{0\}$	0
`device`	{cpu}	cpu

O parâmetro `max_train_samples`=300000 atua como limite superior da implementação e não altera a cardinalidade efetiva de $\mathcal{D}_{70}$, que contém 211.833 eventos. Assim, ele não deve ser interpretado como indicação de que 300.000 eventos foram utilizados simultaneamente no treinamento final.

As tabelas anteriores devem ser interpretadas conjuntamente com as formulações e o protocolo experimental do corpo da tese. Elas fornecem as escolhas computacionais que não podem ser deduzidas apenas das equações, enquanto os capítulos principais permanecem como

referência normativa para a ordem das operações, as transformações de entrada, a construção das arquiteturas e a avaliação dos resultados.

B Questões Científicas e Metodológicas Recorrentes

B.1 Escopo do apêndice

Este apêndice é um roteiro de consulta rápida para questões científicas e metodológicas recorrentes que apareceram durante a revisão dos artigos bem como no exame de qualificação. Ele não constitui um segundo capítulo teórico: não rederiva equações, não reexpõe formalizações completas e não introduz resultados novos.

Cada resposta apresenta apenas a conclusão necessária para responder à pergunta e indica, em *Onde na tese*, o capítulo, a seção e, quando útil, a equação em que o argumento completo está desenvolvido. Questões de implementação remetem adicionalmente ao Apêndice A. Assim, em caso de qualquer diferença de nível de detalhe, prevalece a formulação dos Capítulos 1–9.

B.2 Problema científico, contribuição e originalidade

1. **Qual é, em uma frase, o problema científico da tese?**

   A tese investiga se a informação espacial codificada nos anéis calorimétricos pode ser usada para corrigir, evento a evento, a estimativa rápida de energia transversa, quantificando simultaneamente qualidade de reconstrução e custo de implementação.

   Onde na tese: Capítulo 1, Seções 1.3–1.5; Capítulo 5, Seções 5.1 e 5.16; Capítulo 9, Seção 9.5.

2. **Qual é a hipótese central e ela foi confirmada?**

   A hipótese é que a distribuição estruturada dos depósitos calorimétricos contém informação utilizável para corrigir E_{fast} e que modelos supervisionados podem reduzir erro e dispersão relativamente ao Standard FastCalo. No domínio do benchmark estudado, a hipótese é suportada empiricamente por três etapas experimentais e por diferentes famílias de regressores.

   Onde na tese: Capítulo 1, Seção 1.4; Capítulo 9, Seção 9.5.

3. **Se PCA, ICA, BDT, Random Forest, DNN e GNN já existem, onde está a originalidade da tese?**

   A originalidade está na metodologia integrada aplicada à calibração por anéis, na comparação sistemática entre compactação e desempenho, nas composições residuais/empilhadas e na arquitetura GNN relacional–tabular específica para a interface Ringer. Não se reivindica a invenção das famílias genéricas de algoritmos.

   Onde na tese: Capítulo 1, Seção 1.7; Capítulo 9, Seção 9.6.

4. **A GNN proposta é original mesmo utilizando GraphSAGE?**

Sim, no nível da composição arquitetural proposta para a representação Ringer. GraphSAGE é um operador existente; a contribuição está na integração PS–EM–HAD, grafos locais, *pooling*, descritores tabulares e fusão para estimar o fator de calibração.

Onde na tese: Capítulo 1, Seção 1.7; Capítulo 4, Seção 4.4.3; Capítulo 8, Seção 8.1; Capítulo 9, Seções 9.6 e 9.4.5; Apêndice A, Subseção A.5.3, Tabelas 31 e 31.

5. **Por que caracterizar o problema como fusão de informação?**

   A cadeia combina informação em níveis sucessivos: células são agregadas em anéis; os anéis podem ser preservados ou transformados em representações compactas; e o regressor funde a representação resultante em uma estimativa escalar de correção. Na GNN, há ainda fusão explícita entre informação relacional e tabular.

   Onde na tese: Capítulo 1, Seções 1.1–1.2; Capítulo 4, Seção 4.5; Capítulo 8, Seções 8.1–8.2; Capítulo 9, Seção 9.1.

6. **Se o ATLAS já dispõe de procedimentos sofisticados de calibração, por que investigar ML para esse problema?**

   A tese não parte da premissa de falha das calibrações existentes. Ela testa uma questão mais restrita: se a informação espacial preservada nos anéis contém estrutura preditiva adicional para uma correção evento a evento de E_{fast}.

   Onde na tese: Capítulo 1, Seção 1.2; Capítulo 4, Seção 4.5; Capítulo 9, Seção 9.7.1.

7. **O Standard FastCalo usado como referência corresponde a uma calibração oficial do ATLAS que foi deliberadamente "desligada"?**

   Não. A tese não define o Standard FastCalo como a cadeia oficial do ATLAS com alguma calibração removida. Ele é a estimativa rápida de energia transversa fornecida pelo benchmark Lorenzetti e adotada como referência comum dos experimentos.

   Onde na tese: Capítulo 1, Seção 1.3; Capítulo 2, Subseção 2.4.2; Capítulo 5, Seções 5.1 e 5.4.

8. **Por que a tese não utiliza resultados publicados de outros estudos de deep learning como baseline numérico direto?**

   Porque uma comparação numérica controlada exige o mesmo conjunto de dados, geometria, observáveis, alvo, particionamento e métricas. Trabalhos externos são utilizados como contexto metodológico, mas não foram reproduzidos no benchmark Lorenzetti; por isso, os baselines numéricos da tese permanecem internos ao mesmo ambiente experimental.

   Onde na tese: Capítulo 1, Seções 1.2 e 1.7; Capítulo 9, Seções 9.2 e 9.10.

B.3 Física, calorimetria e cadeia de reconstrução

1. **Qual é a diferença entre o papel do LHC e o do ATLAS?**

   O LHC acelera e faz colidir os feixes de prótons. O ATLAS é um experimento instalado em um dos pontos de colisão e mede os produtos dessas interações por meio de diferentes

subsistemas detectores. A tese utiliza o ATLAS como referência instrumental e não atribui a ele a função de acelerador.

Onde na tese: Capítulo 2, Seções 2.2.1 e 2.2.2.

2. **Qual é a hierarquia entre células, clusters e anéis?**

   As células são unidades elementares de leitura calorimétrica. A reconstrução calorimétrica agrega células em objetos, como clusters. A representação Ringer utiliza células de uma região de interesse ao redor do núcleo do chuveiro para construir anéis por camada.

   Onde na tese: Capítulo 2, Seções 2.4.1, 2.4.2 e 2.7.1; Capítulo 5, Seção 5.3.

3. **Como ruído eletrônico, pile-up, vazamento e cross-talk podem afetar a calibração?**

   Esses efeitos modificam a energia medida ou sua distribuição espacial. O ruído eletrônico perturba sinais de células; o pile-up adiciona atividade de outras interações; vazamentos impedem que toda a energia seja contida no volume ativo considerado; e cross-talk pode introduzir resposta correlacionada entre canais vizinhos.

   Onde na tese: Capítulo 2, Seções 2.5 e 2.7.1; Capítulo 4, Seção 4.7; Capítulo 5, Seção 5.2.3.

4. **Por que o Filtro Ótimo aparece na tese e quais simplificações foram adotadas?**

   O Filtro Ótimo contextualiza como amostras digitalizadas podem ser convertidas em estimativas de energia no nível de célula. A formulação apresentada é deliberadamente esquemática. Implementações completas podem impor, além da restrição de ganho, condições relacionadas à derivada temporal do pulso e ao pedestal.

   Onde na tese: Capítulo 2, Seção 2.4.1.

5. **Por que LCW e GSC não são centrais na cadeia estudada?**

   A tese é focada em elétrons e em uma correção multiplicativa aplicada à estimativa rápida do benchmark Lorenzetti. Ela não tenta reproduzir toda a cadeia de calibração de objetos hadrônicos ou de jatos do ATLAS. Procedimentos como LCW e GSC pertencem a outros contextos de reconstrução e não constituem a referência que está sendo corrigida neste trabalho.

   Onde na tese: Capítulo 2, Seções 2.4 e 2.6; Capítulo 5, Seções 5.1 e 5.4.

B.4 Lorenzetti, ATLAS e validade do benchmark

1. **Os resultados desta tese são resultados do experimento ATLAS?**

   Não. O Lorenzetti foi configurado com características geométricas e de segmentação inspiradas na calorimetria eletromagnética do ATLAS, mas não é a cadeia oficial de simulação e reconstrução da colaboração. Os resultados quantitativos são resultados do benchmark Lorenzetti considerado.

   Onde na tese: Capítulo 1, Seção 1.3; Capítulo 2, Seção 2.8; Capítulo 5, Seção 5.2.1; Capítulo 9, Seção 9.9.3.

2. **Se a avaliação experimental é realizada no Lorenzetti, por que o ATLAS é apresentado em detalhe ao longo da tese?**

   O ATLAS fornece a referência física e instrumental do problema; o Lorenzetti é o ambiente aberto e detector-inspirado usado para a avaliação quantitativa. A tese mantém explicitamente essa distinção para não equiparar o *benchmark* à cadeia oficial do experimento.

   Onde na tese: Capítulo 1, Seções 1.1 e 1.3; Capítulo 2, Seções 2.6, 2.7 e 2.8; Capítulo 5, Seção 5.2.1.

3. **Por que usar Lorenzetti em vez da simulação oficial do ATLAS?**

   O Lorenzetti foi escolhido por oferecer um ambiente aberto, configurável e reprodutível com acesso às estruturas necessárias à pesquisa. Essa escolha favorece reprodutibilidade, mas não implica maior fidelidade que a simulação oficial do ATLAS.

   Onde na tese: Capítulo 2, Seção 2.8; Capítulo 5, Seção 5.2.1; Capítulo 5, Seção 5.14.

4. **Por que a tese não foi treinada e validada diretamente com dados experimentais do ATLAS?**

   Porque o alvo supervisionado e a avaliação evento a evento usam verdade de Monte Carlo. Uma validação em dados reais exige referências experimentais próprias, como calibração *in situ*, ressonâncias conhecidas e estudos de diferenças simulação–dados; por isso, ela é tratada como validação externa futura.

   Onde na tese: Capítulo 3, Seção 3.1; Capítulo 5, Seção 5.15; Capítulo 9, Seções 9.9.1, 9.9.3 e 9.11.2.

5. **A tese demonstra que a simulação Lorenzetti reproduz integralmente os dados reais do ATLAS?**

   Não. O Lorenzetti é tratado como benchmark detector-inspirado e não como substituto validado da cadeia oficial. A tese preserva a mesma configuração entre as etapas para permitir comparação controlada dos métodos de ML.

   Onde na tese: Capítulo 5, Seções 5.2.1 e 5.15; Capítulo 9, Seções 9.9.1 e 9.9.3.

6. **A metodologia pode ser aplicada a outros calorímetros?**

   A interface matemática é transferível a sistemas segmentados que disponibilizem uma representação em anéis ou descritores equivalentes e uma referência de calibração. Entretanto, os ganhos numéricos observados nesta tese não são automaticamente transferíveis. Outra geometria, materiais, granularidade ou resposta exigem novo treinamento e validação.

   Onde na tese: Capítulo 1, Seção 1.3; Capítulo 5, Seções 5.2.1 e 5.15; Capítulo 9, Seções 9.9.3 e 9.11.1.

7. **Por que a análise termina em $|\eta| \simeq 1{,}46$ se o ATLAS possui cobertura maior?**

   Porque a amostra principal utilizada na tese foi restrita a $|\eta| \leq 1{,}46$, cobrindo a região de barril e alcançando, no limite superior, a vizinhança da transição pelo lado do barril da geometria inspirada no ATLAS. Esse limite não representa a aceitação total do experimento.

A tese, portanto, não extrapola a estabilidade observada nesse domínio para as regiões de maior $|\eta|$ do endcap.

Onde na tese: Capítulo 5, Seções 5.2.1–5.2.2; Capítulo 9, Seção 9.9.3.

8. **Por que usar elétrons individuais de *particle gun* em vez de $Z \to e^+e^-$?**

   O *particle gun* isola a calibração de um único candidato e permite cobertura controlada de energia e direção. $Z \to e^+e^-$ é uma validação física complementar, especialmente para massa invariante e estudos em dados.

   Onde na tese: Capítulo 5, Seção 5.2.2; Capítulo 8, Seção 8.10; Capítulo 9, Seções 9.7.3 e 9.11.2.

9. **A descontinuidade em torno de 250 GeV pode favorecer artificialmente algum modelo?**

   A resposta rápida do benchmark contém uma perturbação não linear controlada nessa região. Ela foi mantida igual entre os estudos para permitir comparação sob a mesma resposta. O ganho nessa região demonstra capacidade de correção dentro do benchmark, não realismo de um artefato específico do ATLAS.

   Onde na tese: Capítulo 5, Seção 5.2.4; Capítulo 6, Seção 6.2; Capítulo 9, Seções 9.9.3 e 9.11.1.

B.5 Representação Ringer e redução de dimensionalidade

1. **Como os 100 anéis estão distribuídos entre as camadas calorimétricas?**

   A convenção da tese utiliza PS: 1–8, EM1: 9–72, EM2: 73–80, EM3: 81–88, HAD1: 89–92, HAD2: 93–96 e HAD3: 97–100. Cada anel agrega a energia transversa das células que o compõem.

   Onde na tese: Capítulo 2, Seção 2.7.1; Capítulo 5, Seção 5.3.

2. **Em que camada está o Ringer 74 e por que ele pode aparecer como relevante?**

   Na convenção usada na tese, o Ringer 74 pertence à EM2. Essa é uma região na qual uma fração importante da energia de um chuveiro eletromagnético é tipicamente depositada. A relevância observada por CORR ou MUTI é empírica dentro do benchmark; ela não implica que um único anel tenha importância universal para todos os regimes.

   Onde na tese: Capítulo 2, Seção 2.7.1; Capítulo 6, Seção 6.3.

3. **Os anéis usados pelos modelos já estão normalizados?**

   A formulação adota a convenção de anéis normalizados, mas os arquivos experimentais foram usados na forma já processada em que foram recebidos. O pipeline da tese não revalidou evento a evento a soma unitária nem aplicou uma segunda renormalização global.

   Onde na tese: Capítulo 2, Seção 2.7.1; Capítulo 5, Seção 5.3; Apêndice A, Seção A.3.

4. **Se os anéis normalizados não carregam explicitamente a escala absoluta, como o modelo pode corrigir uma resposta dependente da energia?**

   O regressor não recebe E_{fast} nem uma energia não normalizada como entrada. Ele estima α_{calib} a partir de correlações entre a morfologia normalizada do chuveiro e a correção requerida; a escala absoluta reaparece somente quando α_{calib} é multiplicado por E_{fast}. Uma não linearidade puramente dependente da energia, sem assinatura correlacionada no perfil normalizado, não seria identificável por esse conjunto de entradas.

   Onde na tese: Capítulo 2, Seção 2.7.1; Capítulo 3, Seções 3.1 e 3.1.1; Capítulo 5, Seções 5.3 e 5.4.

5. **Se o Ringer já reduz mais de mil células a 100 anéis, por que reduzir novamente?**

   Porque 100 variáveis ainda podem ser excessivas para determinados requisitos de inferência, armazenamento ou simplicidade. A segunda redução investiga quanto da informação preditiva pode ser preservada com muito menos entradas. Os resultados mostram que representações com cinco ou dez entradas permanecem competitivas, embora a representação completa favoreça a melhor precisão absoluta em etapas posteriores.

   Onde na tese: Capítulo 3, Seção 3.2; Capítulos 6, 7 e 8; Capítulo 9, Seções 9.2.2, 9.3 e 9.4.1.

6. **Qual é a diferença entre CORR/MUTI e PCA/ICA?**

   CORR e MUTI selecionam anéis originais; PCA e ICA produzem componentes transformados. Nos experimentos, as componentes PCA/ICA reduzidas são priorizadas pela correlação absoluta com E_{true} usando apenas os dados de desenvolvimento permitidos; o procedimento completo está no Capítulo 3.

   Onde na tese: Capítulo 3, Seções 3.3–3.4; Capítulo 5, Seções 5.5 e 5.5.1.

7. **Por que CORR/MUTI e a ordenação de PCA/ICA usam E_{true} se o alvo do regressor é α_{true}?**

   Essa escolha é uma heurística supervisionada de relevância em relação à escala energética e preserva o protocolo dos estudos sequenciais da tese. Ela não é apresentada como seleção ótima para prever α_{true}. Comparar ordenações por E_{true}, α_{true} ou critérios condicionais exigiria um novo experimento de representação.

   Onde na tese: Capítulo 3, Seção 3.2; Capítulo 5, Seções 5.5 e 5.5.1.

8. **Os métodos de redução de dimensionalidade podem ser reutilizados para identificação de elétrons?**

   É plausível investigar isso, mas calibração e identificação são tarefas diferentes. O fato de uma representação ser informativa para regressão não demonstra que seja ótima para classificação. Essa extensão requer métricas próprias de classificação, amostras de fundo e avaliação de eficiência e rejeição.

   Onde na tese: Capítulo 2, Seção 2.7.2; Capítulo 9, Seção 9.11.4.

B.6 Formulação da calibração

1. **O que exatamente é E_{fast}?**

   É a estimativa rápida de energia transversa fornecida pela cadeia de reconstrução do benchmark Lorenzetti e utilizada como referência Standard FastCalo. Ela não deve ser interpretada como toda a cadeia oficial de calibração de elétrons do ATLAS.

   Onde na tese: Capítulo 1, Seção 1.3; Capítulo 2, Seção 2.4.2; Capítulo 5, Seções 5.1 e 5.3.

2. **A calibração proposta substitui a reconstrução rápida existente?**

   Não. O modelo recebe informação derivada do objeto calorimétrico e estima um fator adicional α_{calib}. A energia final é $E_{\text{calib}} = \alpha_{\text{calib}} E_{\text{fast}}$.

   Onde na tese: Capítulo 5, Seção 5.4; Capítulo 9, Seção 9.7.1.

3. **Por que prever $\alpha_{\text{true}} = E_{\text{true}}/E_{\text{fast}}$ em vez de prever diretamente E_{true}?**

   A parametrização multiplicativa é conveniente para integrar a correção à energia rápida existente e fornece uma interpretação direta do fator de calibração. Entretanto, a tese demonstra que minimizar MSE no fator não é matematicamente equivalente a minimizar MSE em energia, pois os erros energéticos recebem peso proporcional a E_{fast}^2.

   Onde na tese: Capítulo 3, Seção 3.1.1; Capítulo 5, Seção 5.4.

4. **Por que a tese escreve E_{true}, E_{fast} e E_{calib} se trabalha com energia transversa?**

   É uma convenção notacional herdada dos estudos associados. Nos capítulos experimentais, essas três grandezas representam energias transversais; o subscrito T é omitido para evitar notação excessivamente carregada.

   Onde na tese: Capítulo 2, Seção 2.4.2; Capítulo 3, Seção 3.1.

5. **Os ganhos de RMSE podem ser atribuídos apenas à remoção de um viés médio do Standard FastCalo?**

   Não é possível fazer essa atribuição com o desenho experimental atual. A média da diferença pareada entre resíduos não é, por si só, o viés do Standard FastCalo; além disso, a tese observa reduções substanciais de variância residual. Entretanto, não foi incluído um controle de escala constante nem um regressor de baixa capacidade baseado apenas em (E_{fast}, η), de modo que o ganho incremental dos anéis além de uma recalibração otimizada simples não foi isolado causalmente.

   Onde na tese: Capítulo 5, Seções 5.8.1 e 5.13; Capítulo 8, Seção 8.9; Capítulo 9, Seções 9.8 e 9.10.

6. **Como o método poderia ser usado em dados reais se E_{true} não existe?**

   O treinamento desta tese usa verdade de Monte Carlo. Em dados reais, a referência teria de ser substituída por um protocolo experimental apropriado; as alternativas e limitações são discutidas nos capítulos indicados abaixo.

   Onde na tese: Capítulo 2, Seção 2.4.2; Capítulo 3, Seção 3.1; Capítulo 5, Seção 5.15; Capítulo 9, Seções 9.9.1 e 9.11.2.

B.7 Particionamento, nested CV e prevenção de vazamento

1. **Qual é o protocolo de separação dos dados?**

   Nas três etapas, o conjunto é separado em 70% para desenvolvimento e 30% para teste independente. A partição de teste não é utilizada para selecionar representação, hiperparâmetros ou modelos; ela é aplicada após o desenvolvimento para estimar desempenho final.

   Onde na tese: Capítulo 5, Seções 5.6–5.7.1; Apêndice A, Seções A.3–A.4.

2. **Como funciona a nested cross-validation 5×5?**

   Nas Etapas II e III, cada *fold* externo executa uma nova busca interna. Primeiro, todas as configurações candidatas passam por uma triagem no primeiro *split* interno; as mais bem classificadas formam uma *shortlist*, que é então avaliada nos cinco *folds* internos. A configuração selecionada é reajustada em todo o treinamento externo e avaliada na respectiva validação externa. Repetido o procedimento nos cinco *folds* externos, obtêm-se cinco configurações $\boldsymbol{\xi}_{\text{sel},k}$; a configuração final é a moda dessas cinco configurações completas, sem utilizar as métricas externas nem $\mathcal{D}_{30}$ para essa escolha.

   Onde na tese: Capítulo 5, Seção 5.7.2; Apêndice A, Seção A.4.

3. **$g_{\text{ML}}(\cdot)$ também é reajustado dentro de cada fold externo?**

   Não. $g_{\text{ML}}(\cdot)$ é ajustado uma única vez em $\mathcal{D}_{70}$ e mantido fixo durante a nested CV de $f_{\text{ML}}(\cdot)$; por isso, a avaliação externa é condicionada à representação previamente definida.

   Onde na tese: Capítulo 5, Seções 5.5.1 e 5.7.2; Apêndice A, Seção A.4.

4. **Usar E_{true} para ordenar CORR, MUTI ou componentes introduz vazamento de informação?**

   Não há vazamento para $\mathcal{D}_{30}$ porque qualquer uso de E_{true} na construção/ordenação da representação é restrito a $\mathcal{D}_{70}$. A consequência metodológica é que a nested CV avalia f_{ML} condicionado ao g_{ML} já fixado, e não o pipeline completo de ponta a ponta.

   Onde na tese: Capítulo 1, Seção 1.3; Capítulo 5, Seções 5.1 e 5.5.1.

5. **Por que usar nested CV em vez de uma única validação cruzada?**

   Porque o mesmo conjunto de folds não deve servir simultaneamente para escolher hiperparâmetros e para estimar o desempenho do procedimento de seleção. O loop interno realiza a escolha; o externo avalia a configuração selecionada em dados não usados naquele ajuste interno, reduzindo viés de seleção.

   Onde na tese: Capítulo 5, Seção 5.7.2.

6. **As cinco subdivisões do conjunto de teste são uma segunda cross-validation?**

   Não. A partição independente de teste é apenas subdividida em cinco subconjuntos disjuntos para que RMSE e IQR sejam calculados separadamente e resumidos por média e desvio-padrão. O modelo já está fixado: não há novo treinamento, seleção de hiperparâmetros ou reajuste em qualquer desses subconjuntos.

Onde na tese: Capítulo 5, Seção 5.7.2.

7. **Quais espaços de busca e hiperparâmetros finais foram utilizados?**

   Os espaços consolidados e as configurações finais rastreáveis estão documentados separadamente para as três etapas no Apêndice de Reprodutibilidade. Grades exploratórias que não participaram dos resultados finais são explicitamente excluídas.

   Onde na tese: Apêndice A, Seção A.5.

8. **Qual é a diferença entre predições fora da amostra, OOF e OOB?**

   Predição fora da amostra é o conceito geral; OOF a obtém por folds e OOB pela amostragem *bootstrap* da Random Forest. Nesta tese, OOF/OOB são mecanismos internos dos modelos compostos e não correspondem ao teste independente.

   Onde na tese: Capítulo 4, Seções 4.2.1 e 4.2.2.

9. **OOF ou OOB correspondem ao conjunto independente de teste?**

   Não. OOF e OOB são mecanismos internos aos dados permitidos para desenvolvimento. O conjunto independente de teste permanece isolado até a avaliação final.

   Onde na tese: Capítulo 5, Seções 5.7.1 e 5.7.2; Capítulo 4, Seção 4.2.2; Apêndice A, Seção A.4.

10. **Se já existe nested cross-validation, por que ainda são necessárias predições OOF/OOB nos modelos de segundo nível?**

    Porque as finalidades são diferentes. A nested CV separa seleção de hiperparâmetros e avaliação interna do procedimento de seleção de $f_{\mathrm{ML}}(\cdot)$. Já OOF/OOB são usados dentro da construção de arquiteturas de segundo nível para gerar, evento a evento, predições dos modelos-base sem treinamento direto naquela observação.

    Onde na tese: Capítulo 5, Seção 5.7.2; Capítulo 4, Seção 4.2.2.

11. **Por que não treinar o segundo estágio diretamente com as predições in-sample do primeiro modelo?**

    Porque um modelo flexível tende a produzir erros artificialmente pequenos nos próprios eventos usados em seu ajuste. O segundo estágio seria então treinado sobre uma distribuição de resíduos ou predições mais otimista que aquela encontrada para eventos novos.

    Onde na tese: Capítulo 4, Seções 4.2.1 e 4.2.2.

B.8 Modelos convencionais, árvores e aprendizado híbrido

1. **Por que LightGBM foi adotado como implementação comum dos BDTs?**

   A escolha cria uma referência controlada para todos os modelos de *gradient boosting*. O objetivo da tese não é comparar bibliotecas de boosting, mas comparar estratégias de representação e regressão. XGBoost e CatBoost são alternativas plausíveis, porém uma comparação entre implementações constituiria outro experimento.

   Onde na tese: Capítulo 4, Seção 4.1.4; Capítulo 7, Seção 7.1; Apêndice A, Seções A.2–A.5.

2. **O que torna BDTRF e RFBDT modelos "híbridos"?**

   São modelos sequenciais de correção residual. O primeiro regressor fornece uma estimativa inicial; o segundo aprende o resíduo remanescente. BDTRF usa BDT seguido de Random Forest; RFBDT inverte essa ordem.

   Onde na tese: Capítulo 4, Seção 4.2.1; Capítulo 7, Seções 7.1 e 7.4; Apêndice A, Seção A.5.2.

3. **Como RFBDTS evita treinar o meta-regressor com predições excessivamente otimistas?**

   O meta-regressor Ridge recebe predições fora da amostra dos modelos-base: OOB para Random Forest e OOF para BDT. Assim, o segundo nível não aprende diretamente sobre predições in-sample dos modelos-base.

   Onde na tese: Capítulo 4, Seção 4.2.2; Capítulo 7, Seção 7.1; Apêndice A, Seção A.5.2.

4. **Se RFBDT foi o melhor da Etapa II, por que o ganho sobre BDT foi pequeno?**

   O resultado é compatível com a interpretação de que o BDT completo já captura parcela substancial da estrutura preditiva disponível nos 100 anéis e de que a correção residual explora apenas a estrutura remanescente. O experimento, entretanto, não isola causalmente essa explicação.

   Onde na tese: Capítulo 7, Seções 7.4 e 7.12; Capítulo 9, Seções 9.2.3 e 9.4.3.

5. **Qual é a diferença conceitual entre aprendizado residual e *stacked models*?**

   No aprendizado residual, o segundo regressor é treinado para prever o erro remanescente do primeiro, e a saída final é a soma da predição inicial com a correção aprendida. Em *stacked models*, as próprias predições dos modelos-base formam as entradas de um meta-regressor, que aprende uma regra de combinação.

   Onde na tese: Capítulo 4, Seções 4.2.1 e 4.2.2.

6. **BDTRF e RFBDT contêm os mesmos dois algoritmos. Por que a ordem pode alterar o resultado?**

   Porque o primeiro modelo define qual estrutura permanece no alvo residual apresentado ao segundo. Trocar a ordem modifica, portanto, o problema aprendido no segundo estágio; as duas composições não são comutativas.

   Onde na tese: Capítulo 4, Seção 4.2.1; Capítulo 7, Seções 7.4 e 7.12.

7. **Por que o segundo regressor residual recebe novamente x, em vez de receber apenas a primeira predição?**

   Porque o segundo estágio deve modelar a estrutura ainda presente no resíduo em função das características de entrada. Fornecê-lo apenas com a primeira predição descartaria informação potencialmente útil; a formulação completa está na Seção 4.2.1.

   Onde na tese: Capítulo 4, Seção 4.2.1.

8. **No RFBDTS, o Ridge escolhe evento a evento qual modelo é mais confiável? Seus pesos precisam somar um?**

   Não. O Ridge empregado aprende uma combinação afim **global** e regularizada das predições de RF e BDT. Os coeficientes não são condicionados ao evento e a implementação não impõe positividade nem soma unitária; portanto, o RFBDTS não é uma média convexa nem um mecanismo de *gating* dinâmico.

   Onde na tese: Capítulo 4, Seção 4.2.2.

B.9 DNN e arquitetura GNN relacional–tabular

1. **Por que avaliar DNNs depois dos modelos baseados em árvores?**

   As DNNs testam se maior capacidade de representação não linear pode explorar o perfil completo e as representações compactas além do que foi obtido por árvores e ensembles. A progressão dos capítulos permite verificar ganhos incrementais sem alterar o problema físico de calibração.

   Onde na tese: Capítulo 4, Seção 4.3; Capítulo 8, Seções 8.1–8.3; Capítulo 9, Seção 9.4.4.

2. **Por que a GNN é aplicada aos 100 anéis e não aos componentes PCA/ICA?**

   A ramificação em grafo explora a organização local e regional dos anéis originais. Componentes PCA/ICA são combinações latentes e não preservam uma correspondência um a um com posições físicas ou vizinhanças calorimétricas. Uma GNN sobre componentes transformados exigiria outra definição de grafo e responderia a outra questão metodológica.

   Onde na tese: Capítulo 3, Seção 3.4; Capítulo 4, Seção 4.4.3; Capítulo 8, Seções 8.1–8.2.

3. **Por que dividir o grafo em PS, EM e HAD?**

   A divisão incorpora conhecimento da estrutura longitudinal do calorímetro. As relações locais são definidas dentro de regiões com papéis instrumentais diferentes, evitando tratar todos os 100 índices como uma sequência homogênea sem significado físico.

   Onde na tese: Capítulo 4, Seção 4.4.3; Apêndice A, Seção A.5.3.2.

4. **A comparação GNN–DNN prova que as arestas do grafo causam o ganho observado?**

   Não. A GNN completa também possui descritores derivados, ramo tabular, conexões de atalho, *pooling* e fusão. Atribuir causalmente o ganho ao grafo exigiria controles como GNN sem ramo gráfico, apenas ramo gráfico, remoção dos descritores, DNN com entradas equivalentes e modelos de capacidade comparável. Esses controles constituem novos experimentos de ablação; a tese compara as arquiteturas completas.

   Onde na tese: Capítulo 4, Seções 4.4.4 e 4.5; Capítulo 8, Seções 8.1 e 8.3; Capítulo 9, Seções 9.4.5, 9.10 e 9.11.4.

5. **Se a GNN é mais lenta e melhora pouco em relação à DNN, por que considerá-la relevante?**

Porque ela testa um viés indutivo relacional diferente e, na Etapa III, apresentou as menores estimativas pontuais de RMSE, d_0 e resolução entre as configurações neurais destacadas. A diferença em relação à DNN completa é modesta e sua incerteza específica não foi quantificada por uma comparação pareada direta GNN–DNN.

Onde na tese: Capítulo 8, Seções 8.3–8.4; Capítulo 9, Seção 9.3.

6. **Qual é a principal diferença conceitual entre a DNN e a GNN avaliadas nesta tese?**

   A DNN recebe a representação como um vetor e aprende fusão não linear global entre suas entradas. A GNN introduz adicionalmente uma estrutura relacional explícita: determinados anéis trocam informação por *message passing* segundo uma topologia fixa, e o resultado relacional é posteriormente combinado com informação tabular global.

   Onde na tese: Capítulo 4, Seções 4.3, 4.4 e 4.5.

7. ***Backpropagation*, Adam/AdamW e *early stopping* fazem parte da inferência online?**

   Não. Esses mecanismos pertencem ao treinamento offline: *backpropagation* calcula gradientes, o otimizador atualiza parâmetros e *early stopping* determina quando interromper o ajuste. Depois do treinamento, a inferência utiliza apenas a propagação direta com os parâmetros fixados.

   Onde na tese: Capítulo 4, Seções 4.3.2, 4.4.4 e 4.6; Apêndice A, Subseção A.5.3.

B.10 Detalhamento da arquitetura GNN relacional–tabular

1. **O que representam os nós e as arestas da GNN, e a topologia é aprendida?**

   Cada nó corresponde a um anel da representação Ringer. As arestas são relações bidirecionais fixas entre índices consecutivos dentro de cada macro-região PS, EM ou HAD. A topologia não é inferida evento a evento; o que varia entre eventos são as características nodais.

   Onde na tese: Capítulo 4, Seção 4.4.1.

2. **Existem arestas entre PS, EM e HAD? Os três blocos GraphSAGE compartilham todos os parâmetros?**

   Não. Na arquitetura selecionada não há arestas entre macro-regiões. PS, EM e HAD possuem blocos GraphSAGE estruturalmente equivalentes, mas com parâmetros treináveis próprios; a informação das três regiões é combinada somente depois do processamento e do *pooling* regionais.

   Onde na tese: Capítulo 4, Seções 4.4.1 e 4.4.2.

3. **Quais são as sete características de cada nó e por que aparecem duas versões da energia do anel?**

   O vetor nodal possui sete componentes: duas representações do valor do anel, duas posições normalizadas e três indicadores *one-hot* da região. A definição exata está na Eq. 4.123; não é necessário repeti-la aqui.

Onde na tese: Capítulo 4, Seção 4.4.1.

4. **A agregação média do GraphSAGE distingue explicitamente o vizinho à esquerda do vizinho à direita?**

   Não como tipos de aresta distintos. A média é simétrica em relação à ordem dos vizinhos. A arquitetura, entretanto, fornece posição local, posição global e identidade regional como características nodais, de modo que a localização estrutural do nó permanece disponível.

   Onde na tese: Capítulo 4, Seções 4.4.1 e 4.4.2; Capítulo 9, Subseção 9.11.4.

5. **Por que utilizar duas camadas GraphSAGE?**

   Com arestas entre vizinhos imediatos, duas etapas de propagação fornecem um campo receptivo local de até dois saltos dentro de cada macro-região. A escolha mantém o ramo relacional relativamente compacto e foi a configuração selecionada no estudo. A tese não demonstra que duas camadas sejam universalmente ótimas; profundidade e conectividade podem ser objeto de ablação futura.

   Onde na tese: Capítulo 4, Seção 4.4.2; Apêndice A, Subseção A.5.3, Tabelas 31 e 31.

6. **Por que combinar *mean pooling* e *max pooling*, e de onde vêm as 768 dimensões do ramo gráfico?**

   O *mean pooling* resume a atividade latente distribuída e o *max pooling* preserva ativações dominantes. A dimensionalidade resultante é consequência direta do tamanho latente e da concatenação regional definidos na Eq. 4.132.

   Onde na tese: Capítulo 4, Seção 4.4.2.

7. **Quais são os 20 descritores do ramo tabular e eles constituem novas medições?**

   Os 20 descritores resumem conteúdo energético regional, relações entre regiões/amostragens e momentos posicionais. Eles são funções determinísticas dos mesmos 100 anéis, não novas medições; a lista completa está na Eq. 4.147.

   Onde na tese: Capítulo 4, Seções 4.4.3 e 4.4.4.

8. **Se os anéis são normalizados para soma unitária, as frações PS, EM e HAD não são redundantes com as somas regionais?**

   Sob soma global exatamente unitária, algumas grandezas tornam-se algebricamente redundantes. Como essa propriedade não foi revalidada evento a evento nos arquivos usados, a arquitetura foi mantida na forma implementada; a discussão completa está na Seção 4.4.3.

   Onde na tese: Capítulo 4, Seção 4.4.3.

9. **As somas S_{EM1}, S_{EM2} e S_{EM3} correspondem às amostragens físicas EM1, EM2 e EM3? E os momentos posicionais medem uma distância física?**

   Essas grandezas agregam os anéis associados às amostragens EM1, EM2 e EM3 segundo o mapeamento fixado para a representação Ringer. Os índices e as definições exatas estão na Seção 4.4.3, e não são repetidos neste apêndice.

   Onde na tese: Capítulo 4, Seção 4.4.3.

10. **Se a GNN já recebe os anéis, por que manter também um ramo tabular e descritores explícitos?**

    Porque os dois ramos processam a mesma informação externa sob vieses diferentes. O grafo privilegia relações locais e regionais; o ramo tabular preserva acesso global ao perfil completo e a sumários construídos. Essa complementaridade é uma hipótese arquitetural.

    Onde na tese: Capítulo 4, Seções 4.4.4 e 4.5; Capítulo 9, Subseção 9.4.5.

11. **Qual é a função do escalar treinável s_{g} e por que ele é inicializado em 0,05?**

    s_{g} controla a contribuição do caminho gráfico no modelo completo. Sua definição e a inicialização utilizada estão na Eq. 4.155; o resultado da tese não é interpretado como uma ablação isolada desse parâmetro.

    Onde na tese: Capítulo 4, Seção 4.4.4; Apêndice A, Subseção A.5.3, Tabela 31.

12. **Como a GNN é treinada e quais desses mecanismos desaparecem na inferência?**

    O treinamento utiliza os mecanismos descritos na Seção 4.4.4, incluindo otimização, regularização e parada antecipada. Na inferência permanecem apenas as transformações necessárias ao *forward*; procedimentos usados exclusivamente para atualização de parâmetros ou monitoramento de validação não são executados.

    Onde na tese: Capítulo 4, Seção 4.4.4; Apêndice A, Subseção A.5.3, Tabelas 31 e 31.

13. **Por que GraphSAGE e não GCN, GAT ou uma CNN 1D?**

    GraphSAGE fornece uma forma direta de agregar vizinhanças locais e é compatível com a hipótese relacional testada. GCN, GAT e CNNs 1D são alternativas legítimas; em particular, os grafos regionais adotados são essencialmente cadeias, de modo que uma CNN 1D constitui um controle arquitetural relevante.

    Onde na tese: Capítulo 4, Seção 4.4.2; Capítulo 9, Subseções 9.4.5 e 9.11.4.

14. **A GNN é invariante à permutação dos 100 anéis ou recupera a geometria completa do calorímetro?**

    Não. A arquitetura preserva a ordem dos anéis por meio das características posicionais e das arestas fixas, e processa apenas a topologia explicitamente construída; ela não é uma reconstrução automática da geometria tridimensional completa do calorímetro.

    Onde na tese: Capítulo 4, Seções 4.4.1 e 4.5; Capítulo 9, Subseção 9.4.5.

B.11 Métricas, estatística e interpretação dos resultados

1. **Por que utilizar RMSE e IQR conjuntamente?**

    RMSE e IQR capturam aspectos diferentes da distribuição do erro: o primeiro penaliza fortemente grandes desvios e o segundo descreve a dispersão central de forma robusta. A tese usa ambos para evitar que a avaliação dependa de uma única característica da distribuição.

    Onde na tese: Capítulo 5, Seções 5.8.1–5.8.2; Capítulo 9, Seção 9.8.

2. **Se RMSE e IQR podem ser correlacionados, qual é a utilidade de d_0?**

   d_0 é apenas um escore auxiliar para ordenar conjuntamente RMSE e IQR. Sua definição está na Eq. 5.28; as duas métricas continuam sendo apresentadas separadamente.

   Onde na tese: Capítulo 5, Seção 5.8.3; Capítulos 6, 7 e 8.

3. **Como D_0 combina RMSE, IQR, número de entradas e tempo se essas grandezas possuem unidades diferentes?**

   D_0 normaliza as grandezas dentro do conjunto comparado antes de combiná-las. A definição, os pesos e a limitação de comparabilidade entre experimentos estão na Seção 5.12.1 e na Eq. 5.41.

   Onde na tese: Capítulo 5, Seção 5.12.1.

4. **Foi realizada uma análise de sensibilidade dos pesos de D_0?**

   Não como experimento independente. Por isso, D_0 é utilizado apenas como índice auxiliar de ranking e suas conclusões não são usadas isoladamente. RMSE, IQR, d_0, F, T, resolução e análises regionais são sempre apresentados separadamente.

   Onde na tese: Capítulo 5, Seção 5.12.1; Capítulo 9, Seção 9.3.

5. **Por que foi necessário introduzir resolução relativa de energia além de IQR e RMSE absolutos?**

   Porque a resposta calorimétrica depende da energia. A resolução relativa permite comparar a largura da resposta em diferentes escalas energéticas e responde diretamente à crítica de que métricas absolutas podem ocultar dependência com E. Ela complementa, e não substitui, as métricas globais.

   Onde na tese: Capítulo 5, Seção 5.10; Capítulo 7, Seção 7.7; Capítulo 8, Seção 8.6.

6. **Como a resolução relativa de energia é calculada na tese?**

   A resolução é calculada a partir da resposta relativa em bins de E_{true}, usando o mesmo procedimento para o modelo calibrado e para Standard FastCalo. A definição completa está nas Eqs. 5.30–5.34.

   Onde na tese: Capítulo 5, Seção 5.10.

7. **Por que os testes estatísticos são pareados?**

   Porque E_{fast} e E_{calib} são avaliados para o mesmo evento. Ignorar esse pareamento descartaria a correlação intraevento e produziria um teste menos adequado ao desenho experimental.

   Onde na tese: Capítulo 5, Seção 5.13; Seções 6.9, 7.10 e 8.9.

8. **Por que utilizar testes paramétricos se os resíduos não são gaussianos?**

   A normalidade é examinada e os desvios são reconhecidos. Por isso, os resultados paramétricos são acompanhados por Wilcoxon, Pitman–Morgan e/ou bootstrap pareado. A decisão científica não depende de um único teste paramétrico.

   Onde na tese: Capítulo 5, Seções 5.13.1–5.13.2; Capítulo 9, Seção 9.8.

9. **Valores-p extremamente pequenos não são apenas consequência dos cerca de 300 mil eventos?**

   A grande amostra aumenta o poder estatístico e pode tornar efeitos pequenos detectáveis. Por isso, significância não é interpretada isoladamente. A tese prioriza também tamanho do efeito e relevância prática por meio de RMSE, IQR, resolução, razão de variâncias e estabilidade regional.

   Onde na tese: Capítulo 5, final da Seção 5.13; Capítulo 9, Seção 9.8.

10. **Um valor negativo de μ_d prova que o módulo do erro diminuiu evento a evento?**

    Não. $\mu_d < 0$ caracteriza um deslocamento da distribuição dos resíduos segundo a convenção adotada. A redução da magnitude do erro é sustentada por RMSE, IQR, resolução e variância residual, não pelo sinal da média de d isoladamente.

    Onde na tese: Capítulo 5, Seção 5.13.1; Seções 6.9, 7.10 e 8.9.

11. **Por que a tese não afirma superioridade estatística da GNN sobre a DNN?**

    Porque os desvios-padrão apresentados para RMSE e IQR nas Etapas II e III vêm de subdivisões do mesmo teste com um único modelo final, e não de treinamentos independentes. Um teste sobre os dois vetores de predição avaliaria apenas aqueles modelos ajustados; uma afirmação sobre superioridade arquitetural exigiria múltiplos treinamentos e uma comparação direta previamente definida. Por isso, a diferença GNN–DNN é tratada como descritiva.

    Onde na tese: Capítulo 8, Seções 8.3 e 8.9; Capítulo 9, Seções 9.8 e 9.10.

12. **Por que a melhoria percentual da resolução relativa não precisa coincidir com a melhoria do IQR?**

    Porque são medidas distintas. O IQR usado nas métricas globais caracteriza a região central do resíduo absoluto em energia, enquanto σ_E/E é obtido da dispersão da resposta relativa e sua dependência com E_{true} é examinada por intervalos de energia. As curvas da tese são medidas empíricas referenciadas à verdade de Monte Carlo do benchmark e não devem ser interpretadas como uma parametrização experimental completa do detector do tipo $a/\sqrt{E} \oplus b \oplus c/E$.

    Onde na tese: Capítulo 5, Seções 5.8.2 e 5.10; Capítulo 8, Seção 8.6; Capítulo 9, Seções 9.8 e 9.7.2.

13. **A tese fornece incerteza preditiva calibrada para cada evento?**

    Não. Os modelos produzem estimativas pontuais de α_{calib}. RMSE, IQR, razão de variâncias, *bootstrap* e estabilidade regional quantificam incerteza ou dispersão em nível de amostra, mas não fornecem intervalos preditivos evento a evento. Métodos como regressão quantílica, modelos heteroscedásticos, ensembles ou predição conformal exigiriam novo treinamento e avaliação específica de cobertura.

    Onde na tese: Capítulo 5, Seção 5.13; Capítulo 9, Seções 9.8, 9.9 e 9.11.4.

14. **Por que não comparar diretamente os valores absolutos de D_0 ou mesmo de Standard FastCalo entre os três artigos?**

    Porque os valores absolutos dependem do protocolo e, no caso de D_0, também do conjunto usado na normalização. As comparações entre etapas são feitas prioritariamente por métricas físicas/descritivas e reduções relativas, conforme discutido nos capítulos de resultados e conclusão.

    Onde na tese: Capítulo 5, Seção 5.12.1; Capítulo 6, Seção 6.11; Capítulo 9, Seção 9.2.

B.12 Binning, segmentação e dependência regional

1. **Por que o BDT global pode superar modelos treinados por bins se a resposta depende de η e E_T?**

    Porque a especialização local reduz heterogeneidade, mas também reduz a amostra disponível por regressor, introduz fronteiras discretas e pode aumentar variância. Um modelo global não linear pode aprender dependências contínuas sem fragmentar a estatística. Não existe garantia matemática de que binning seja superior.

    Onde na tese: Capítulo 5, Seção 5.6.1; Capítulo 6, Seção 6.5; Capítulo 9, Seção 9.4.2.

2. **Qual foi o papel do algoritmo genético na Etapa I?**

    O algoritmo genético não selecionou o modelo de calibração. Ele construiu uma partição não uniforme em $|\eta|$ e E_{true} com número fixo de regiões, buscando equilíbrio estatístico entre bins. Essa segmentação foi utilizada para comparar treinamento global com treinamento especializado.

    Onde na tese: Capítulo 5, Seção 5.6.1; Capítulo 6, Seção 6.5.

3. **Como o esquema binado poderia ser utilizado em dados reais se E_{true} não está disponível?**

    A variante segmentada da Etapa I, tal como avaliada, utiliza E_{true} para determinar o intervalo energético e é, portanto, específica do estudo Monte Carlo. Em uma aplicação real, E_{fast} poderia ser utilizada como variável de encaminhamento porque está disponível antes da aplicação da correção proposta.

    Onde na tese: Capítulo 5, Seção 5.6.1.

4. **Por que as Etapas II e III abandonam treinamento por bins, mas continuam mostrando resultados regionais?**

    Porque os bins passam a funcionar como diagnóstico *a posteriori*. Um único modelo é treinado globalmente, e depois RMSE, IQR, MAE, resolução ou α_{calib} são avaliados em regiões de $|\eta|$ e E_{true} para verificar estabilidade sem fragmentar o treinamento.

    Onde na tese: Capítulo 5, Seção 5.6.2; Capítulo 7, Seção 7.6; Capítulo 8, Seção 8.5.

5. **Por que uma aparente vantagem local do Standard FastCalo no IQR de α em baixa energia não invalida a calibração?**

Porque o IQR do fator α e o erro de energia respondem a grandezas diferentes, especialmente em baixa energia. A tese interpreta essa aparente vantagem local junto com RMSE, IQR do erro e resolução, e não como evidência de pior calibração global.

Onde na tese: Capítulo 6, Seção 6.6; Capítulo 7, Seção 7.6; Capítulo 8, Seção 8.5.

B.13 Trigger, resposta a limiar e fundo

1. **Qual é a diferença entre eficiência de sinal e taxa de trigger?**

   Eficiência mede a fração de elétrons de interesse aceita. Taxa depende também da abundância e da resposta de fundos, particularmente jatos. Uma calibração que melhora a energia de elétrons não demonstra, por si só, redução da taxa total do trigger.

   Onde na tese: Capítulo 2, Seção 2.6.4; Capítulo 5, Seção 5.15; Capítulo 9, Seções 9.7.2 e 9.11.3.

2. **Seria melhor enviesar a calibração para energias ligeiramente maiores a fim de não perder elétrons no trigger?**

   Não é possível decidir isso apenas com a amostra de elétrons. Um viés positivo pode recuperar eficiência de sinal, mas também pode aumentar a aceitação de jatos ou outros fundos. Uma função de perda assimétrica só deve ser definida depois de conhecer a função de custo operacional completa.

   Onde na tese: Capítulo 9, Seções 9.7.2 e 9.11.3.

3. **Como as curvas de aceitação são construídas e o que representa $\Delta\lambda_{90}$?**

   Para cada valor da varredura de $\Delta\lambda$, a EAR é a fração dos mesmos N eventos da amostra de avaliação que satisfazem $|\varepsilon_m^{(i)}| < \Delta\lambda$. $\Delta\lambda_{90}$ é o primeiro ponto da grade que atinge 90% de aceitação. A curva é, portanto, uma caracterização da concentração do resíduo e não uma eficiência de *trigger* obtida com limiar operacional fixo.

   Onde na tese: Capítulo 5, Seção 5.11; Capítulos 7 e 8, Seções 7.8 e 8.7.

4. **Como $\Delta\lambda$ se relaciona com um limiar físico de energia e por que as curvas publicadas ainda exigem ressalva operacional?**

   Nesta análise, $\Delta\lambda$ é uma tolerância associada a uma janela bilateral móvel, não um limiar operacional fixo de *trigger*. A distinção formal está na Seção 5.11; sem uma amostra representativa de fundo, essas curvas não determinam rejeição de jatos nem taxa global do *trigger*.

   Onde na tese: Capítulo 5, Seção 5.11; Capítulo 6, Seção 6.8; Capítulo 7, Seção 7.8; Capítulo 8, Seção 8.7.

5. **Por que manter os números de turn-on se há essa limitação?**

   Por rastreabilidade científica dos artigos. Os números permanecem identificados como resultados publicados, mas não são usados isoladamente como evidência primária da hipótese da tese nem como medida definitiva de eficiência de um trigger operacional.

Onde na tese: Capítulo 7, Seção 7.8; Capítulo 8, Seção 8.7; Capítulo 9, Seção 9.7.2.

6. **A tese verificou se a calibração aumenta a aceitação de jatos identificados como elétrons?**

   Não. A amostra principal é composta por elétrons individuais e não contém uma população de fundo apropriada para medir rejeição de jatos, pureza ou taxa global. Essa é uma das validações futuras prioritárias.

   Onde na tese: Capítulo 5, Seção 5.15; Seções 7.11 e 8.11; Capítulo 9, Seção 9.11.3.

B.14 Pile-up, ruído e robustez

1. **Há pile-up no conjunto de dados e o que representam as 10.010 entradas do perfil?**

   Sim. O perfil de *pile-up* possui 10.010 registros, com $\langle\mu\rangle = 38{,}94$ e desvio-padrão 9,999. Esses registros descrevem o perfil usado pela simulação e não correspondem um a um aos 302.619 eventos eletrônicos reconstruídos. A presença de *pile-up* caracteriza o cenário avaliado, mas não constitui uma varredura de robustez em diferentes níveis de ocupação.

   Onde na tese: Capítulo 5, Seção 5.2.3; Capítulo 9, Seção 9.9.2.

2. **Isso demonstra robustez a pile-up?**

   Não. O conjunto não foi gerado como uma varredura controlada de níveis independentes de μ. A tese demonstra desempenho sob a distribuição de pile-up considerada, não invariância a mudanças de ocupação.

   Onde na tese: Capítulo 5, Seções 5.2.3 e 5.15; Capítulo 9, Seções 9.9.2 e 9.11.1.

3. **PCA ou ICA podem ser interpretadas como métodos de mitigação de pile-up?**

   Não com base nos experimentos realizados. Elas são técnicas de extração de características. O fato de modelos compactos permanecerem competitivos em uma amostra com pile-up não demonstra que os componentes tenham removido causalmente a contaminação.

   Onde na tese: Capítulo 4, Seção 4.7; Capítulo 7, Seção 7.11; Capítulo 9, Seção 9.9.2.

4. **O método foi testado para $\langle\mu\rangle = 140$ ou 200?**

   Não. A tese declara explicitamente que não há evidência para extrapolar os resultados a esses regimes. Uma varredura controlada de μ é trabalho futuro.

   Onde na tese: Capítulo 9, Seções 9.9.2 e 9.11.1.

5. **A arquitetura GNN deve ser mais robusta a *pile-up* por utilizar uma estrutura relacional explícita?**

   Essa é uma hipótese plausível, não um resultado demonstrado. Para testá-la seria necessário comparar DNN, GNN e representações compactas em amostras geradas sob níveis controlados de pile-up e analisar a evolução das métricas com μ.

   Onde na tese: Capítulo 9, Seções 9.9.2 e 9.11.1.

B.15 Custo computacional, latência e implantação

1. **O tempo T reportado na tese é a latência do HLT?**

   Não. T é o tempo de predição amortizado do modelo treinado depois que a representação de entrada está disponível. Ele não inclui, de forma ponta a ponta, leitura do detector, construção dos anéis, extração de características, construção dos grafos, movimentação de memória, concorrência ou latência de pior caso.

   Onde na tese: Capítulo 5, Seção 5.12; Capítulo 9, Seções 9.9.4 e 9.11.3.

2. **Quantos eventos entram nas partições e como interpretar `max_train_samples=300000`?**

   O conjunto de 302.619 eventos é dividido em 211.833 eventos de desenvolvimento e 90.786 de teste independente. `max_train_samples=300000` é apenas um limite superior da implementação da GNN; como ele excede a cardinalidade de $\mathcal{D}_{70}$, não provoca subamostragem do conjunto de desenvolvimento. Os tempos amortizados de teste usam como denominador os 90.786 candidatos efetivamente processados.

   Onde na tese: Capítulo 5, Seções 5.7.1 e 5.12; Apêndice A, Seções A.3 e A.5.3.2.

3. **O valor $T = 0$ do Standard FastCalo significa custo computacional nulo?**

   Não. Significa apenas que nenhum custo adicional de inferência de ML é atribuído à referência dentro daquele ranking. A reconstrução Standard FastCalo obviamente possui custo próprio.

   Onde na tese: Capítulo 5, Seção 5.12; Capítulo 8, Seção 8.3.

4. **O número de entradas F é uma medida da complexidade total do modelo?**

   Não. F mede somente a dimensionalidade externa. Número de parâmetros treináveis, FLOPs, memória, profundidade e custo de construção da representação são grandezas distintas. A tese, portanto, não utiliza F nem o tempo de predição isoladamente para afirmar compatibilidade operacional com um orçamento específico de latência.

   Onde na tese: Capítulo 4, Seção 4.6; Capítulo 5, Seções 5.12 e 5.12.1; Capítulo 9, Seção 9.9.4.

5. **A tese mediu tempo de treinamento e latência de pior caso?**

   Não de forma completa entre todas as famílias. O foco computacional dos estudos foi o tempo de predição do modelo treinado. Tempo de treinamento, construção completa das características e latência de pior caso devem ser medidos em uma validação de implantação.

   Onde na tese: Capítulo 9, Subseções 9.9.4 e 9.11.3.

6. **Foi realizada uma análise controlada do efeito de *multithreading* ou paralelismo sobre os tempos reportados?**

   Não como fator experimental independente. Os tempos de predição devem ser interpretados no contexto da plataforma e da implementação utilizadas, e não como uma curva de escalabilidade em função do número de *threads*. Uma validação de implantação deve controlar explicitamente paralelismo, afinidade de CPU, *batching*, concorrência e pior caso antes de extrapolar os resultados para um ambiente de trigger.

Onde na tese: Capítulo 5, Seção 5.12; Apêndice A, Seção A.2; Capítulo 9, Seções 9.9.4 e 9.11.3.

B.16 Reprodutibilidade

1. **Quais elementos permitem reproduzir os resultados da tese?**

   A reprodução exige preservar dados e partição 70/30, transformação da representação, ambiente, grades, sementes, seleção de hiperparâmetros, configurações finais, ordem dos modelos compostos e convenções de avaliação. O roteiro executável está concentrado no Apêndice A.

   Onde na tese: Capítulo 5, Seção 5.14; Apêndice A, Seções A.1, A.3, A.4 e A.5.

2. **Quais bibliotecas e implementações foram usadas?**

   A tese mapeia MLR/PReg/DTree/RF/DNN para scikit-learn, BDTs para LightGBM, GNN para PyTorch/PyTorch Geometric e registra as bibliotecas auxiliares necessárias ao protocolo.

   Onde na tese: Apêndice A, Seções A.2 e A.2.

3. **Onde estão os espaços de busca e os melhores hiperparâmetros?**

   Estão documentados por etapa no Apêndice de Reprodutibilidade. Measurement e Information Fusion possuem configurações finais arquivadas de modelos representativos; para a Etapa I, o artigo não arquivou tabela equivalente e o apêndice preserva o espaço consolidado de reprodução sem inventar um "melhor conjunto" retrospectivo.

   Onde na tese: Apêndice A, Seção A.5.

4. **Por que o Apêndice de Reprodutibilidade não apresenta pseudocódigos?**

   Porque as operações dos modelos, das composições híbridas, da GNN, da nested CV e das métricas já são formalizadas por equações e descrição metodológica no corpo da tese. O Apêndice A registra apenas informações que não podem ser deduzidas dessas formulações, como implementações, contagens, sementes, espaços de busca e hiperparâmetros finais arquivados.

   Onde na tese: Capítulos 4 e 5; Apêndice A, Seções A.1–A.5.

5. **O ambiente de software está completamente congelado por versões?**

   O ambiente final documentado registra Python 3.13.5, mas não foi preservado um *lock-file* completo de todas as dependências. Por isso, o apêndice não infere versões ausentes. Para reprodução arquivística de longo prazo, recomenda-se preservar também um `requirements.txt` ou `environment.yml` do ambiente efetivamente utilizado.

   Onde na tese: Apêndice A, Seção A.2.

6. **Como devem ser tratados casos numéricos degenerados nos descritores da GNN?**

Uma reprodução fiel deve preservar a convenção efetivamente usada no código original; a tese não inventa retrospectivamente regras de regularização numérica ausentes dos artefatos. Os pontos que precisam ser registrados estão na Seção 4.4.3 e na Subseção A.3.

Onde na tese: Capítulo 4, Seção 4.4.3; Apêndice A, Subseção A.3.

B.17 Validade externa, dados reais e observáveis físicos

1. **A tese demonstra melhoria em dados experimentais reais?**

   Não. As conclusões são benchmark-level e condicionadas ao domínio de simulação. Dados reais exigem estratégia própria de referência, estudo de diferenças Monte Carlo–dados e validação experimental.

   Onde na tese: Capítulo 5, Seção 5.15; Capítulo 9, Seções 9.9.1 e 9.10.

2. **A melhora da resolução de energia implica necessariamente melhora da massa reconstruída de $Z \to e^+e^-$?**

   Ela reduz a contribuição energética esperada para a resolução de massa sob hipóteses simplificadas, mas isso é uma propagação analítica, não uma validação ressonante. Uma demonstração completa deve reconstruir o processo, incluindo correlações angulares, seleção, FSR, fundo e ajuste do pico.

   Onde na tese: Capítulo 8, Seção 8.10; Capítulo 9, Seção 9.7.3.

3. **Como deveria ser uma validação futura com $Z \to e^+e^-$?**

   Os eventos deveriam ser particionados no nível do evento físico para impedir que os dois elétrons correlacionados de um mesmo decaimento sejam separados entre treino e teste. Depois, devem ser avaliados escala, largura, caudas da massa, eficiência e, em dados, diferenças simulação–experimento e estratégias de *tag-and-probe*.

   Onde na tese: Capítulo 5, Seção 5.2.2; Capítulo 9, Seção 9.11.2.

4. **Os aproximadamente 300 mil eventos são suficientes para provar que modelos grandes não estão subtreinados?**

   O teste independente demonstra desempenho fora da amostra dentro da distribuição considerada, mas a tese não determina o número mínimo de eventos necessário para estabilizar cada arquitetura. Essa pergunta requer curvas de aprendizagem para BDTs, DNNs e GNNs.

   Onde na tese: Capítulo 9, Subseção 9.11.4.

5. **Por que não incluir trajetória, E/p, μ evento a evento ou outras variáveis do detector?**

   Porque a tese isola deliberadamente a contribuição da informação calorimétrica baseada em anéis. Incluir tracks ou outras fontes transformaria o problema em uma fusão multimodal mais ampla. Essa extensão é promissora, mas deve ser estudada por ablações incrementais para medir quanto cada nova fonte acrescenta.

   Onde na tese: Capítulo 9, Seções 9.4.5 e 9.11.4.

B.18 Questões de síntese da pesquisa

1. **Qual é o melhor modelo da tese?**

   Não há um vencedor universal porque o critério depende da aplicação. A GNN completa apresentou as menores estimativas pontuais de RMSE, d_0 e resolução na Etapa III, enquanto a DNN completa ficou próxima com menor custo e modelos compactos ocupam outro ponto da fronteira desempenho–complexidade.

   Onde na tese: Capítulo 8, Seções 8.3–8.4; Capítulo 9, Seções 9.2–9.3.

2. **Qual é a principal conclusão científica que permanece válida mesmo se a GNN deixar de ser o melhor modelo?**

   Que a representação Ringer contém informação útil para correção evento a evento de E_{fast} e que essa informação pode ser explorada por famílias distintas de regressores. A conclusão não depende da GNN: ela já aparece na Etapa I e é reproduzida por ensembles e DNNs.

   Onde na tese: Capítulo 6, Seção 6.11; Capítulo 9, Seções 9.4.1 e 9.5.

3. **Qual é a principal conclusão de engenharia?**

   Não existe uma configuração dominante em erro, dispersão, resolução, dimensionalidade e custo. A solução apropriada depende da função de custo operacional: representação completa e modelos expressivos favorecem máxima precisão; representações compactas favorecem menor dimensionalidade e menor custo.

   Onde na tese: Capítulo 9, Seções 9.3 e 9.4.6.

4. **Qual resultado a tese explicitamente não reivindica?**

   Ela não reivindica desempenho em dados reais do ATLAS, robustez a uma varredura de pile-up, generalização para endcap ou outros detectores, redução da taxa de jatos no trigger, melhoria experimental do pico do Z, causalidade da topologia da GNN nem latência de produção do HLT.

   Onde na tese: Capítulo 5, Seção 5.15; Capítulo 9, Seções 9.9–9.10.

5. **Qual experimento futuro aumentaria mais o nível de evidência da tese?**

   O avanço mais informativo não é acrescentar mais uma arquitetura, mas validar a metodologia sob mudanças de domínio: uma varredura controlada de pile-up; uma amostra ressonante $Z \to e^+e^-$; dados experimentais; fundo de jatos; e medição ponta a ponta em hardware/software representativos do sistema de destino.

   Onde na tese: Capítulo 9, Seção 9.11.

6. **Quais afirmações extrapolariam a evidência produzida nesta tese?**

   Extrapolam a evidência afirmações que atribuam o ganho isoladamente ao grafo, tratem a GNN como superior por princípio, confundam OOF/OOB com teste independente, atribuam ao Ridge uma decisão dinâmica por evento ou afirmem que a topologia representa a geometria tridimensional completa. Os limites formais estão nas seções indicadas abaixo.

   Onde na tese: Capítulo 4, Seções 4.2.2, 4.4 e 4.5; Capítulo 9, Seções 9.4.5 e 9.10.

C Declaração de Uso de Inteligência Artificial Generativa

Em consonância com as orientações apresentadas no *Guia para Uso Ético e Responsável da Inteligência Artificial Generativa na Universidade Federal da Bahia* (UFBA, 2025) e tomando como referência adicional as boas práticas de integridade científica estabelecidas pelo Art. 9º, inciso I, alíneas c, d e f, da Portaria CNPq nº 2.664, de 6 de março de 2026 (CNPq, 2026), este apêndice registra de forma transparente a utilização de ferramenta de inteligência artificial generativa como recurso auxiliar durante a elaboração desta tese de doutorado.

C.1 ChatGPT (OpenAI)

O ChatGPT, desenvolvido pela OpenAI (OPENAI, 2026), foi utilizado como ferramenta auxiliar nas seguintes atividades:

- **Revisão gramatical e textual**: apoio à revisão de trechos previamente redigidos pelo autor, incluindo correções gramaticais e ortográficas e sugestões de aprimoramento da clareza, concisão e fluidez textual; e
- **Elaboração de figuras**: apoio à composição gráfica das Figuras 14, 15 e 18, a partir de conteúdo científico, estrutura conceitual e especificações fornecidas pelo autor.

Os trechos submetidos à revisão com auxílio da ferramenta foram posteriormente avaliados e, quando necessário, editados pelo autor antes de sua incorporação à versão final da tese.

No caso das figuras, os recursos de geração de imagens disponibilizados por meio do ChatGPT foram utilizados como ferramenta de representação gráfica. A concepção científica, a estrutura, os elementos representados, suas relações e o conteúdo técnico das figuras foram definidos e posteriormente verificados pelo autor.

O uso da ferramenta não implica atribuição de autoria ou coautoria à inteligência artificial. A responsabilidade pela correção, integridade e conteúdo final do texto e das figuras apresentados nesta tese permanece integralmente com o autor.